Raport 4

Analiza avansată a procesării semnalelor ECG pentru detectarea și interpretarea caracteristicilor relevante în monitorizarea conducătorilor auto

Student: Știrbu Oana-Isabela

CUPRINS

1. Introducere 4

2. Tehnici și Algoritmi pentru Procesarea Semnalelor ECG 6

2.1. Sursa semnale 6

2.2. Derivațiile Electrocardiogramei 8

2.3. Posibilități de eliminare/minimizare zgomote și surse de interferență care afectează semnalele ECG 12

2.3.1. Variația liniei izoelectrice 12

2.3.2. Interferența de la rețeaua electrică de alimentare 12

2.3.3. Interferența semnalelor Electromiografice 13

2.3.4. Zgomot impulsiv 14

2.3.5. Zgomot respirator 14

2.4. Variabilitatea ritmului cardiac 17

2.4.1. Domeniul timp și statisticile de distribuție 18

2.4.2. Analiza în Domeniul frecvență a Variabilității ritmului cardiac 19

2.4.3. Componente pe termen lung 20

2.4.4. Periodograma Lomb-Scargle 22

2.4.5. Limite informaționale și zgomote de fundal 24

2.5. Abordarea nestaționarității 26

2.5.1. Măsurători ale HRV nestaționare și scalare fractală 26

2.5.2. Modificări corelate cu activitatea fizică 28

2.5.3. Analiza perturbațiilor 31

2.6. Realizarea unor metode de prelucrare a semnalelor ECG 35

2.6.1. Aducerea semnalului la linia de bază și eliminarea zgomotului 39

2.6.2. Extragerea caracteristicilor 50

3. Concluzii 54

4. Bibliografie 55

1. Introducere

Capacitatea de a conduce autovehicule reprezintă o abilitate complexă, care integrează o multitudine de factori fiziologici, psihologici și tehnici. În mediul dinamic al traficului rutier, siguranța și performanța conducătorilor auto sunt influențate direct de starea lor generală, incluzând nivelul de vigilență, sănătatea fizică și capacitatea de a reacționa rapid și adecvat la provocările neașteptate din trafic. În acest context, monitorizarea continuă și precisă a stării conducătorilor auto devine esențială pentru reducerea riscurilor și îmbunătățirea siguranței rutiere. Această direcție de cercetare a fost abordată în cadrul tezei de doctorat *„Contribuții privind sistemele de evaluare automată a capacității de conducere a vehiculelor”*, printr-o serie de trei rapoarte anterioare care au fundamentat analiza diferitelor aspecte legate de evaluarea șoferilor. **Raportul 1** a realizat o analiză amplă a stadiului actual al metodelor și tehnologiilor utilizate pentru monitorizarea capacității de conducere, cu accent pe markerii fiziologici și sistemele de monitorizare existente. În această etapă, s-a pus accent pe identificarea deficiențelor și a oportunităților din literatura de specialitate, oferind astfel o bază solidă pentru cercetările ulterioare. **Raportul 2** a aprofundat relația dintre aspectele fiziologice și psihologice specifice conducătorilor auto, ilustrând interacțiunile complexe dintre acești factori și modul în care influențează performanța la volan. Studiul a evidențiat conexiuni esențiale între parametrii fiziologici și stările cognitive și emoționale ale șoferilor, oferind o înțelegere clară asupra impactului acestora asupra capacității de a reacționa eficient la condițiile de trafic. În continuare, **Raportul 3** a abordat integrarea și analiza unor parametri fiziologici avansați, precum electrocardiograma (ECG), conductanța galvanică a pielii (GSR) și ritmul respirator. Acest raport a explorat metodele de procesare a acestor semnale fiziologice și relevanța lor pentru monitorizarea stării conducătorilor auto. De asemenea, s-au prezentat tehnici pentru eliminarea artefactelor, filtrarea zgomotului și extragerea caracteristicilor semnificative, toate acestea fiind fundamentale pentru dezvoltarea unor sisteme de monitorizare eficiente. În plus, a fost subliniată importanța acestor parametri în identificarea stărilor critice, precum stresul sau oboseala, care pot afecta semnificativ siguranța la volan.

Pe baza acestor direcții, **Raportul 4** își propune să aprofundeze analiza procesării semnalelor ECG, concentrându-se pe tehnicile avansate de eliminare a zgomotului, detectarea

caracteristicilor morfologice și interpretarea acestora. Electrocardiograma este un instrument esențial pentru înțelegerea stării fiziologice și emoționale a conducătorului auto, oferind date valoroase despre activitatea cardiacă și nivelurile de stres sau oboseală. În acest context, raportul explorează metodele de extragere a caracteristicilor semnalului ECG, cum ar fi detecția undelor R, analiza variabilității ritmului cardiac (HRV) și utilizarea algoritmilor avansați pentru procesare și clasificare. Structura raportului include o analiză detaliată a etapelor de preprocesare a semnalului ECG, cum ar fi eliminarea artefactelor și utilizarea filtrelor specializate pentru zgomot. Ulterior, se abordează metodele de detecție a punctelor caracteristice ale semnalului, extragerea caracteristicilor relevante și interpretarea acestora în contextul monitorizării conducătorilor auto. Raportul explorează, de asemenea, utilizarea inteligenței artificiale și a algoritmilor de învățare automată pentru procesarea automată a semnalelor ECG și generarea unor alerte personalizate în timp real.

Prin abordarea detaliată a procesării semnalelor ECG, acest raport completează demersul științific al tezei, consolidând bazele pentru dezvoltarea unor sisteme avansate de monitorizare a conducătorilor auto. Această lucrare contribuie semnificativ la înțelegerea interacțiunii dintre parametrii fiziologici și stările conducătorului auto, oferind soluții practice pentru implementarea unor tehnologii inteligente dedicate îmbunătățirii siguranței rutiere.

2. Tehnici și Algoritmi pentru Procesarea Semnalelor ECG

Monitorizarea electrocardiogramei (ECG) la conducătorii auto este esențială datorită influenței directe pe care starea fiziologică a acestora o are asupra siguranței și performanței la volan. ECG-ul reflectă activitatea electrică a inimii, furnizând informații valoroase despre stres, oboseală, ritmul cardiac neregulat sau alte stări critice care pot compromite capacitatea de a reacționa eficient în condiții de trafic complex. În special, parametrii precum variabilitatea ritmului cardiac (HRV) permit evaluarea interacțiunii dintre sistemul nervos autonom și activitatea cardiacă, oferind indicii clare despre nivelul de stres emoțional sau cognitiv al șoferului. În situații de trafic intens sau în momente de oboseală accentuată, modificările subtile ale ECG-ului pot semnala o reducere a vigilenței sau a capacității de decizie, prevenind astfel posibile accidente. Prin integrarea monitorizării ECG în vehicule moderne, se pot dezvolta sisteme inteligente care să detecteze în timp real aceste stări critice și să emită alerte personalizate. Această tehnologie avansată contribuie nu doar la protecția conducătorului auto, ci și la creșterea siguranței generale în trafic, prin identificarea timpurie a riscurilor fiziologice și emoționale ce pot afecta performanța la volan.

2.1. Sursa semnale

Mușchiul cardiac este compus din două tipuri principale de celule: cardiomiocite, care generează potențiale electrice în timpul contracției și celule excito-conducătoare specializate în generarea periodică a impulsurilor de depolarizare și în propagarea acestora în întreg volumul miocardului. În repaus, cardiomiocitele sunt polarizate cu un potențial de membrană de aproximativ 90 mV. Apariția unui stimul poate declanșa o inversare rapidă a potențialului electric al celulelor miocardice de lucru (depolarizare) [1]. Figura 2.1 prezintă principalele componente ale sistemului excito-conducător ale inimii. Impulsurile electrice sunt generate în nodul sino-atrial (SA). Pe măsură ce nodul SA transmite impulsul, care nu poate fi văzut în semnalul ECG, acesta se propagă către atriul drept și stâng.

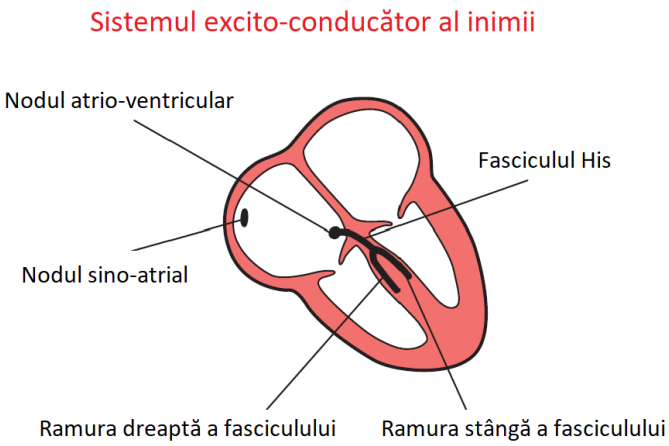


Figura 2.1 Sistemul excito-conducător al inimii [2]

În consecință, cele două camere superioare ale inimii se contractă. În semnalul ECG, acest proces corespunde undei prezentată în Figura 2.2. Impulsul se deplasează către nodul atrio-ventricular (AV), care este plasat deasupra ventriculelor. Nodul AV este singura conexiune electrică între atrium și ventricul și aici propagarea semnalului electric este întârziată. Acest lucru este reflectat în intervalul PR din Figura 2.2. Ulterior, impulsul electric se deplasează prin ambii ventriculi, ducând la contracție, reprezentată de complexul QRS în Figura 2.2. Deoarece ventriculii sunt mai mari în comparație cu atriile, amplitudinea complexului QRS este mai mare decât cea a undei P. În timpul relaxării mușchiului, ECG prezintă segmentul ST și unda T în Figura 2.2 [2].

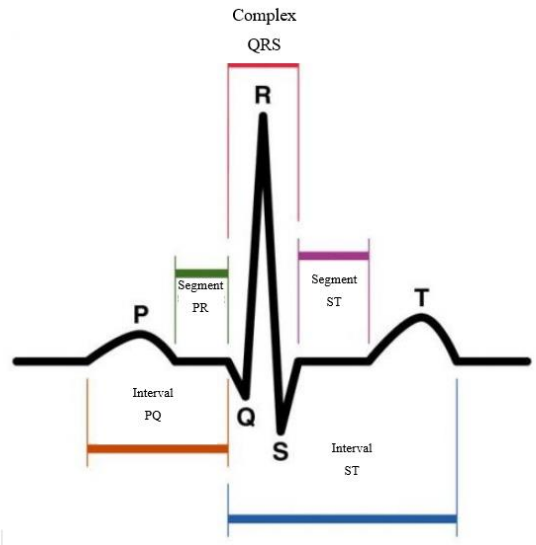


Figura 2.2 Forma de undă a unui semnal ECG [3]

2.2. Derivațiile Electrocardiogramei

Semnalul electric generat de inimă este detectat prin intermediul unor electrozi plasați pe suprafața corpului. Electrocardiograful compară diferitele activități electrice înregistrate între electrozi și creează așa-numita derivație [4]. În prezent, un ECG standard este format din 12 derivații, fiecare dintre acestea fiind reprezentată de un plasament și o orientare a electrozilor pe corp specifice. Acest lucru este necesar deoarece inima este un organ tridimensional și, prin urmare, trebuie privită din unghiuri diferite pentru a recrea semnalul complet [4]. În Figura 2.3 este prezentată maniera în care sunt utilizați electrozii pentru achiziția semnalelor ECG, toate cele 12 derivații. Figura 2.4 conține o reprezentare a modului în care se realizează ansamblul experimental pentru achiziția derivațiilor ECG. Se pot observa electrozii plasați la nivelul membrelor inferioare și superioare și cei de la nivelul cutiei toracice, prin care se achiziționează derivațiile precordiale.

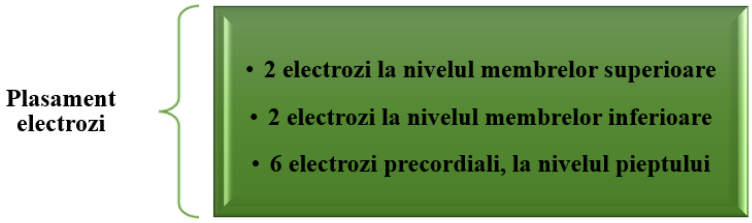


Figura 2.3 Electrozi utilizați în înregistrarea ECG

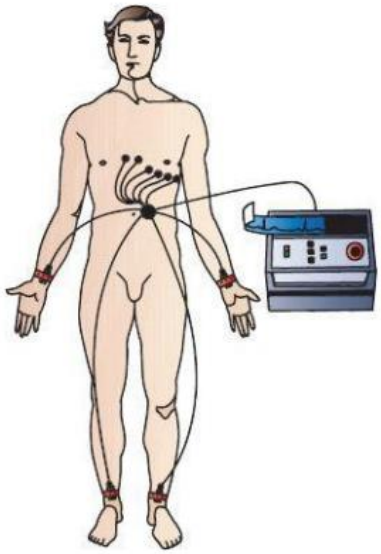


Figura 2.4 Plasament electrozi în cazul unui ECG[5]

Un semnal ECG se poate vizualiza fie pe hârtie, așa cum este redat și în figura de mai jos, fie poate fi digitalizat si vizualizat direct pe calculator, unde poate fi supus și unor procese de prelucrare pentru o evidențiere mai clară a anumitor particularități. Cele șase derivații ale membrelor înregistrează inima într-un plan vertical frontal. Acest lucru poate fi reprezentat ca un cerc pe corp, așa cum este arătat în Figurile 2.5 și 2.6. Pentru a produce aceste șase derivații, electrozii de pe brațe și picioare pot fi marcați pozitiv și negativ, în funcție de derivația care se dorește să fie evidențiată. Unghiul derivației poate fi ilustrat prin trasarea unor linii de la electrodul (electrozii) negativ la cel pozitiv, așa cum se arată în Figurile 2.5, respectiv, 2.6 [4].

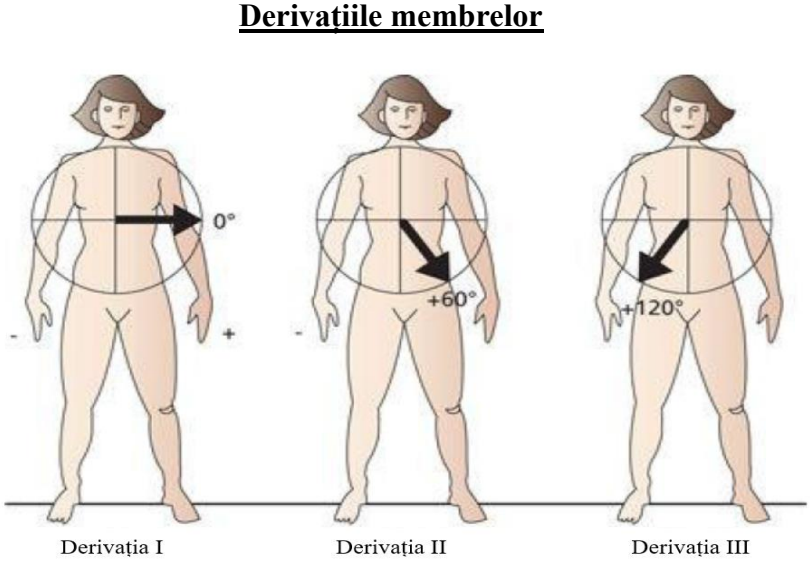


Figura 2.5 Derivațiile standard ale membrelor (bipolare) [5]

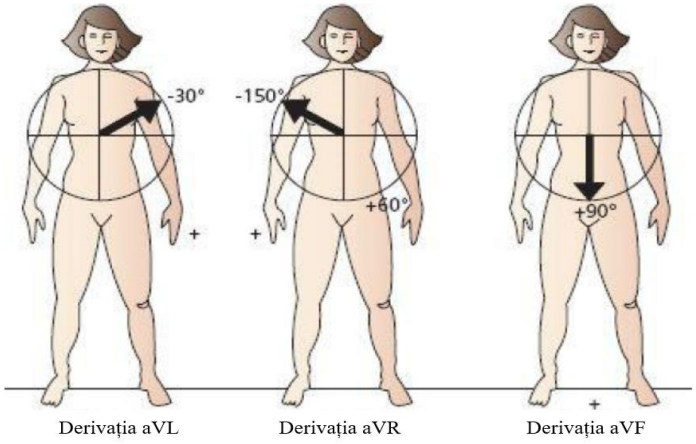


Figura 2.6 Derivațiile augmentate ale membrelor (unipolare) [5]

În Figurile 2.7 și 2.8 sunt precizate locurile în care se amplasează electrozii pentru achiziția derivațiilor corespunzătoare membrelor.

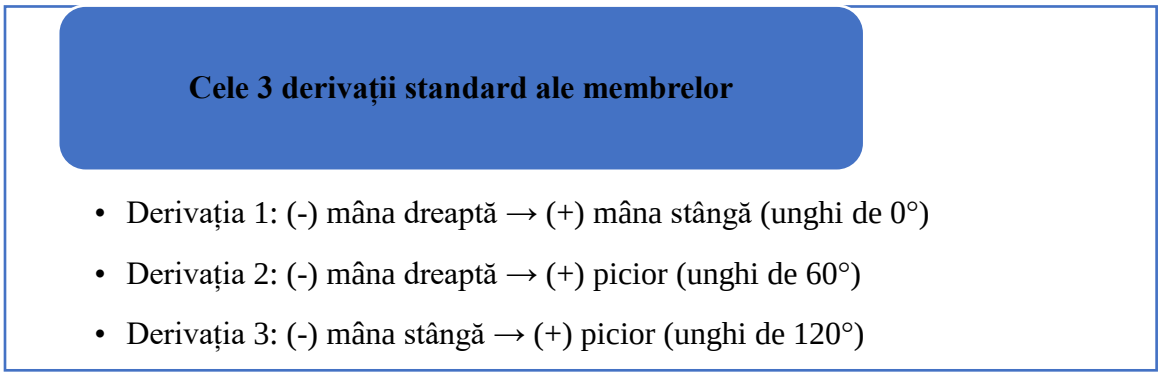


Figura 2.7 Amplasament electrozi pentru derivațiile standard ale membrelor [4]

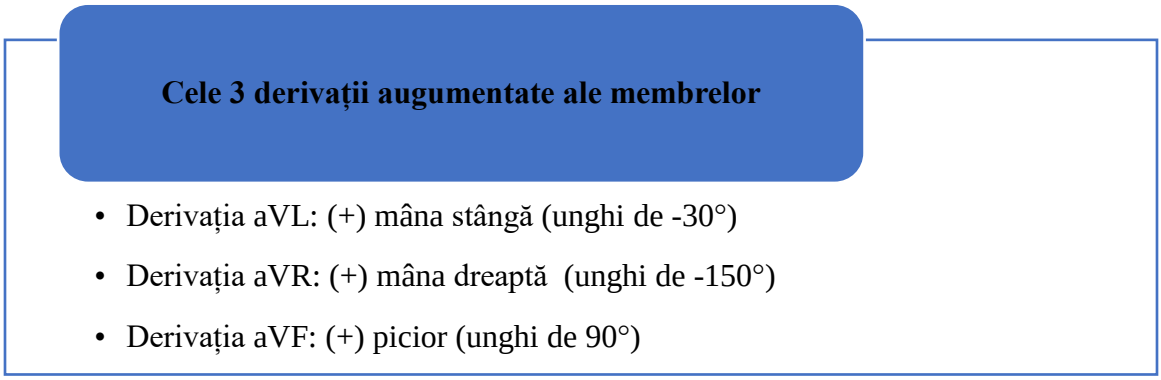


Figura 2.8 Amplasament electrozi pentru derivațiile augmentate ale membrelor [4]

În cazul derivațiilor augmentate, un electrod este ales să fie pozitiv, toți ceilalți sunt negativi. Unghiul este acum specificat între mediana electrozilor negativi și cel pozitiv. Fiecare derivație vede inima din orientări diferite. Derivațiile I, II și aVL oferă informații despre suprafața laterală stângă a inimii, III și aVF despre suprafața inferioară și aVR despre atriul drept [5].

Derivațiile precordiale

Acestea sunt achiziționate cu șase electrozi care sunt aranjați peste piept pentru a construi cele șase derivații precordiale, așa cum se vede în Figura 2.10. Pentru a obține aceste șase derivații,

un electrod este pozitiv și corpul acționează ca un punct comun. În Figura 2.9 este explicat modul în care se face amplasamentul electrozilor pentru achiziția acestor derivații.

Cele 6 derivații precordiale

- V1 este plasat pe stern, în al patrulea șanț intercostal;
- V2 este plasat în stânga sternului în al patrulea șant intercostal;
- V3 este plasat între V2 și V4;
- V4 este plasat în al 5-lea șanț intercostal pe o linie imaginară care se întinde în josul trunchiului, la mijlocul claviculei.

Figura 2.9 Amplasament electrozi pentru derivațiile precordiale [4]

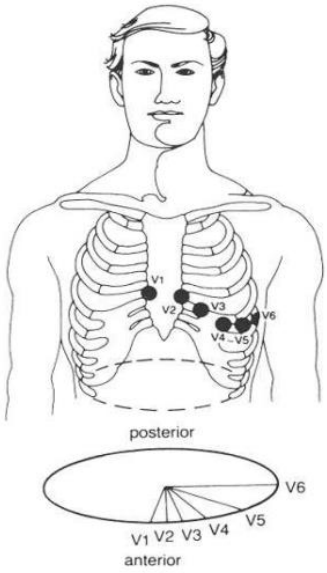


Figura 2.10 Vizualizare amplasament electrozi pentru derivațiile precordiale [5]

Derivațiile precordiale văd câmpurile electrice care se deplasează în plan anterior și posterior [5]. Aceste șase derivații privesc inima într-un plan orizontal, unde V1 și V2 oferă informații despre ventriculul drept, V3 și V4 despre septul dintre ventricule și V5 și V6 despre pereții anterior și lateral ai ventriculului stâng [5].

2.3. Posibilități de eliminare/minimizare zgomote și surse de interferență care afectează semnalele ECG

Deoarece zgomotul poate fi generat de mai multe surse, diferitele tipuri de zgomot trebuie delimitate unele de celelalte. Pentru a crea metode de filtrare pentru surse individuale de interferență, trebuie cunoscute caracteristicile zgomotului pentru care se implementează un filtru. Prin urmare, este o sarcină importantă implementarea de modele cu un singur zgomot în care să se poată îmbunătăți metodele de eliminare a zgomotului.

2.3.1. Variația liniei izoelectrice

Variația liniei izoelectrice este un tip de zgomot de frecvență joasă aditiv la semnalul ECG, rezultând o linie izoelectrica variabilă. Acest zgomot este cauzat de modificări ale impedanței dintre electrod și pielea pacientului. Aceste modificări pot fi cauzate de mișcare, respirație sau transpirație, ceea ce duce la o schimbare a distanței dintre sursa semnalului, inimă și electrozi. Segmentul ST, care este deosebit de relevant în testele de efort, este afectat în special de acest tip de zgomot. Componentele de frecvență ale variației liniei izoelectrice se află de obicei sub 0,5 Hz, dar, în cazul testelor de stres, această limită poate fi mai mare. Astfel, aceste componente pot fi în același interval cu componentele ECG de joasă frecvență, cum ar fi segmentul ST sau unda T [6]. Acest tip de interferență poate fi modelat prin adăugarea unei singure semi-unde în formă de sinus la semnalul ECG:

$$x(t) = A \cdot \sin(2 \cdot \pi \cdot f \cdot t) \quad (2.1)$$

Frecvența f a acestei funcții este determinată de punctul de pornire și punctul final introdus de utilizator. De asemenea, este posibil să se varieze raportul semnal-zgomot (SNR) al semnalului prin creșterea sau scăderea amplitudinii A a zgomotului. Un exemplu de semnal ECG este prezentat în Figura 2.11 [4].

2.3.2. Interferența de la rețeaua electrică de alimentare

O importantă sursă de zgomot este interferența de la rețea care are o frecvență de 50 Hz. Este o sursă semnificativă de zgomot în timpul măsurătorilor de biopotențial. Degradează calitatea semnalului și estompează caracteristicile fine care pot fi critice pentru monitorizarea și diagnosticarea clinică [7]. Liniile electrice și alte echipamente din jur produc câmpuri electromagnetice. În timpul înregistrării unui semnal ECG, calea semnalului dintre pacient și electrocardiograf nu poate fi complet ecranată. Prin urmare, aceste câmpuri produc interferențe semnificative, care pot fi modelate ca o sinusoidă. Spectrul de frecvență al interferențelor liniei de alimentare este destul de îngust și centrat în jurul frecvenței sursei de alimentare [4]

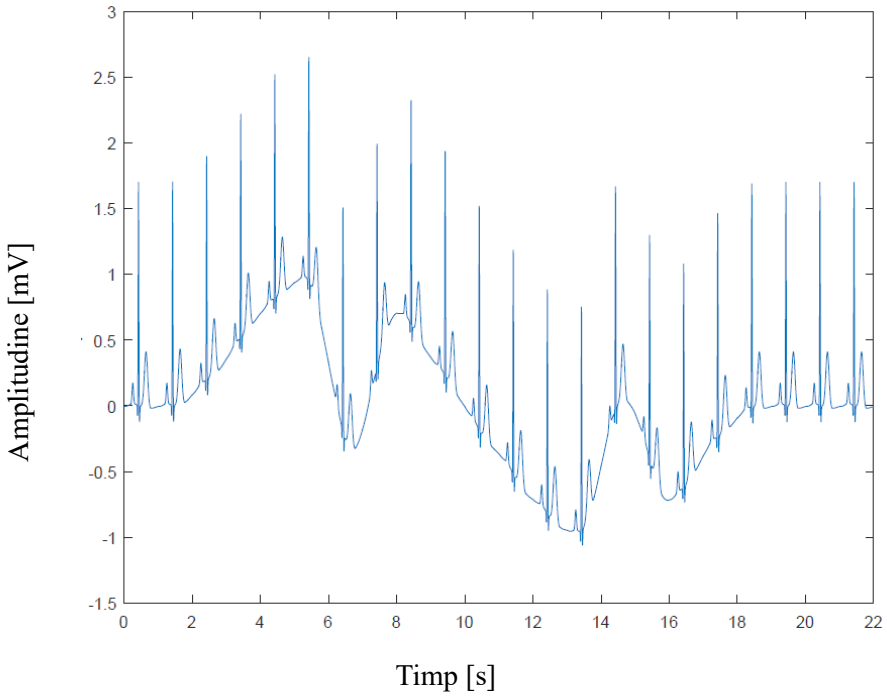


Figura 2.11 Semnal ECG care prezintă variația liniei izoelectrice, adăugată manual [4]

2.3.3. Interferența semnalelor Electromiografice

Interferențele musculare apar atunci când mușchii scheletici se contractă, pacientul se mișcă sau din cauza frisonului datorat temperaturii necorespunzătoare a mediului. Principala problemă cu aceste interferențe este suprapunerea spectrală dintre ECG și zgomotul muscular[4]. Figura 2.12 prezintă un semnal ECG, care prezintă zgomot muscular. Modelarea zgomotului muscular este destul de dificilă, deoarece apare la întâmplare și, prin urmare, nu are o descriere

deterministă exactă și poate fi caracterizată doar prin termeni stocastici. În practică, fie zgomotul gaussian alb, fie bazele de date pentru modele de zgomot sunt folosite pentru a adăuga tulburări musculare la semnalul ECG [4].

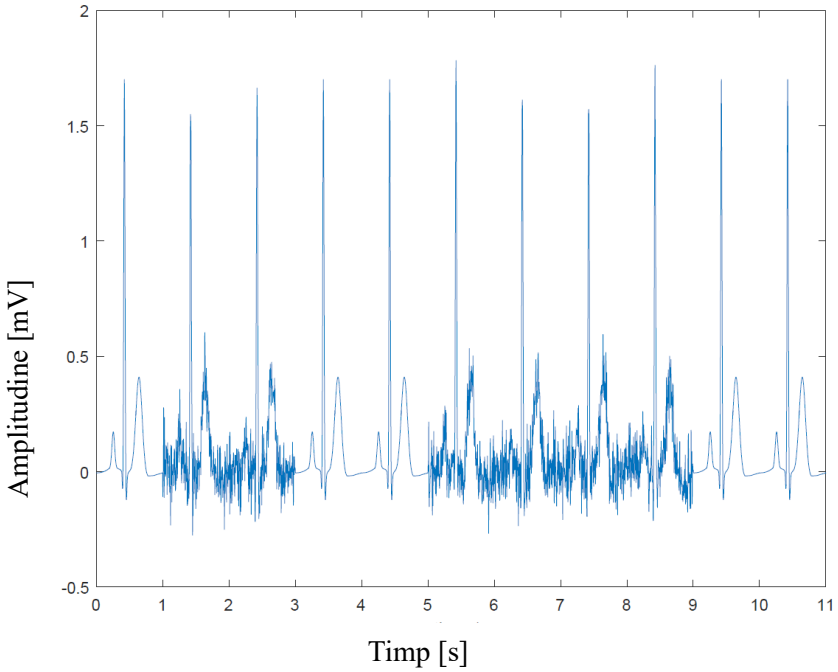


Figura 2.12 ECG cu zgomot muscular adăugat [4]

2.3.4. Zgomot impulsiv

Zgomotul muscular nu poate fi descris doar cu zgomotul gaussian alb, deoarece uneori are și un caracter de impuls. În plus, zgomotul impulsiv poate fi produs de diatermie, care este o formă de încălzire a țesutului, atunci când se utilizează dispozitive chirurgicale sau în terapia ocupațională. Aceste impulsuri au o durată scurtă și un vârf înalt și, prin urmare, pot fi formate ca o funcție triunghiulară cu înălțime și lățime reglabile, care se adaugă semnalului[8]. În Figura 2.13 este un semnal ECG afectat de 5 impulsuri de zgomot impulsiv de amplitudine 1.

2.3.5. Zgomot respirator

În timpul respirației, electrozii toracici își modifică plasamentul, schimbându-și poziția relativă dintre inimă și electrozi.

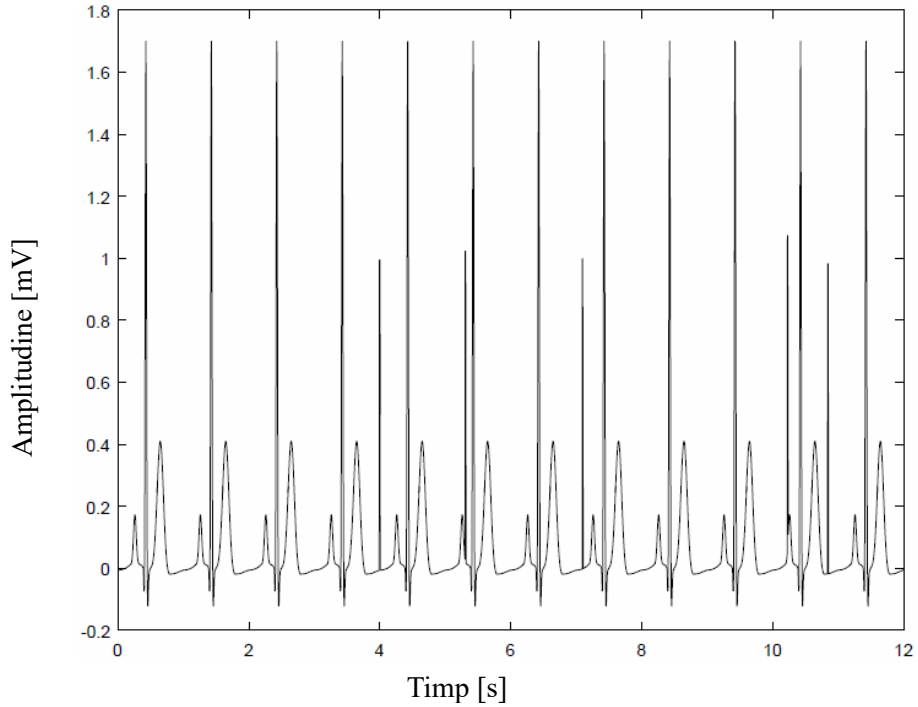


Figura 2.13 Semnal ECG afectat de zgomot impulsiv [4]

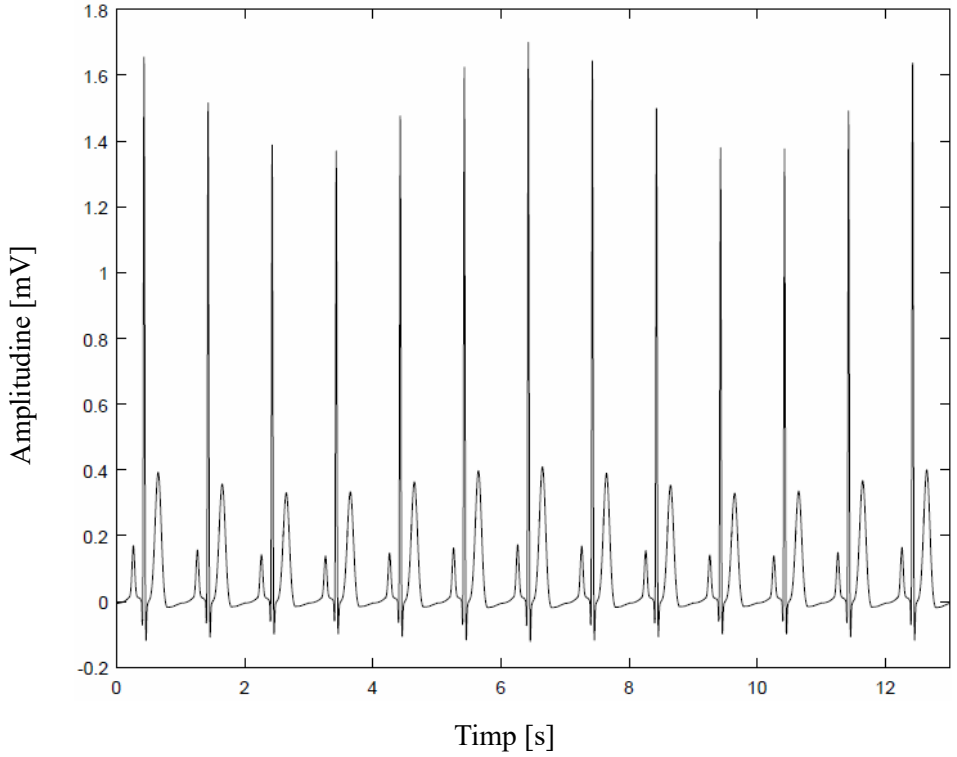


Figura 2.14 Semnal ECG alterat de zgomot respirator[4]

Acest lucru are ca rezultat amplitudini variate ale complexelor QRS. Un semnal afectat de zgomot respirator poate fi vizualizat în Figura 2.14 [4]. Semnalele biomedicale au o natură foarte imprevizibilă iar sursele de zgomot pot apărea din nenumărate locuri, depinzând de fiecare pacient sau de condițiile de achiziție. În Figura 2.15 sunt indicate si alte surse de interferență care pot afecta procesul de interpretare clinică a semnalului ECG.

Alte surse de zgomot

- zgomot de contact al electrodului - pierderea contactului dintre electrod și piele, manifestându-se sub formă de schimbări bruște în amplitudine pentru perioade de aproximativ 1 secundă pe ECG;

- artefacte de mișcare pacient-electrod - mișcarea electrodului departe de zona de contact pe piele, ducând la variații ale impedanței dintre electrod și piele, provocând variații ale ECG și manifestându-se de obicei ca modificări rapide (dar continue) ale liniei izoelectrice cu durate de până la 0,5 secunde;

- zgomotul dispozitivului de colectare a datelor - artefacte generate de hardware-ul de procesare a semnalului;

- zgomot electrochirurgical - zgomot generat de alte echipamente medicale prezente în mediul de îngrijire a pacientului la frecvențe cuprinse între 100 kHz și 1 MHz, cu o durată de aproximativ 1 și 10 secunde;

- Zgomot de cuantizare și aliasing;

- Artefacte de procesare a semnalului (de exemplu, oscilații Gibbs).

Figura 2.15 Alte surse de zgomot pentru semnalul ECG

2.4. Variabilitatea ritmului cardiac

Variabilitatea în timp a frecvenței cardiace este influențată de mulți factori, inclusiv vârsta, sexul, activitatea fizică, medicație și sănătatea [9]. Cu toate acestea, nu numai valoarea medie a ritmului cardiac de la o bătaie la alta se modifică, ci și varianța. Pe cea mai scurtă scală, timpul dintre fiecare bătăi ale inimii este neregulat (cu excepția cazului în care inima este stimulată de o sursă electrică artificială, cum ar fi un stimulator cardiac, sau un pacient este în comă). Aceste oscilații pe termen scurt reflectă modificări ale echilibrului relativ dintre ramurile simpatice și parasimpatice ale sistemului nervos autonom, echilibrul simpaticovagal. Această neregularitate a ritmului cardiac este o consecință bine studiată, cunoscută sub numele de variabilitatea ritmului cardiac (HRV) [10]. Valorile metrice HRV sunt adesea considerate a reflecta acțiunile aflate în opoziție ale acestor diferite ramuri ale sistemului nervos autonom pe nodul sinoatrial (SA). Prin urmare, intervalele RR asociate cu bătăi anormale (care nu provin din nodul SA) nu ar trebui incluse într-un calcul metric HRV și ar trebui analizată seria de intervale consecutive de bătăi normal-normal (NN) [11]. Este important de reținut că markerul de referință al fiecărei bătăi ar trebui să fie debutul undei P, deoarece acesta este un marker mai precis decât vârful R al stimulării nodului SA (debutul depolarizării atriale) pentru fiecare bătaie. Din păcate, unda P este de obicei o undă de amplitudine mică și, prin urmare, este adesea dificil de detectat. În schimb, unda R este ușor de detectat și de etichetat ca punct de referință. Locația exactă a acestui marker este de obicei definită ca fiind fie punctul cel mai înalt (sau cel mai jos), debutul QRS, fie centrul de masă al complexului QRS. În plus, efectele concurente ale ramurilor sistemului nervos autonom conduc la modificări subtile ale caracteristicilor ciclului cardiac. De exemplu, o inervație simpatică a nodului SA (din exercițiu, de exemplu) va duce la o creștere a frecvenței cardiace locale și la o scurtare asociată a intervalului PR [12], intervalului QT [13], lățimii QRS [14] și unda T [15]. Deoarece amplitudinea modulației de la un ciclu cardiac la altul a intervalului PR este corelată cu și mult mai puțin semnificativă decât cea a intervalului RR [12], [16], iar vârful R este bine definit și ușor de localizat, mulți cercetători aleg să analizeze doar tahograma RR (a intervalelor normale). Nu este clar în ce măsură diferențele de localizare a punctelor de referință afectează măsurătorile HRV, dar sensibilitatea măsurătorilor spectrale HRV la frecvențele de eșantionare sub 1 kHz indică faptul că până și diferențele mici pot avea un efect semnificativ pentru astfel de metrici în anumite circumstanțe [17]. La înregistrarea unei tahograme RR tipice timp de cel puțin 5 minute și calculul

densității spectrale de putere, sunt uneori observabile două vârfuri dominante: unul în domeniul de frecvență joasă (LF) ($0{,}015 < f < 0{,}15$ Hz) și unul în regiunea de frecvență înaltă (HF) ($0{,}15 \leq f \leq 0{,}4$ Hz). În general, activitatea în banda HF se consideră că se datorează în principal activității parasimpatice la nodul sinoatrial. Deoarece respirația este o activitate mediată parasimpatic (prin nervul vagal), un vârf corespunzător ratei respirației poate fi observat adesea în această bandă de frecvență (i.e. RSA). Cu toate acestea, nu toată activitatea parasimpatică se datorează respirației. În plus, frecvența respiratorie poate scădea sub limita inferioară (în general acceptată) a regiunii HF și, prin urmare, poate confunda măsurile în regiunea LF. Se crede, în general, că regiunea LF reflectă activitatea mediată simpatic, cum ar fi fenomenele legate de tensiunea arterială. Activitatea în benzi mai mici decât regiunea LF este mai puțin înțeleasă, dar pare să fie legată de activitatea miogenă, activitatea fizică și variațiile circadiene. De asemenea, aceste benzi de frecvență sunt la un anumit nivel destul de ad-hoc și nu ar trebui luate drept limite exacte ale diferitelor mecanisme din cadrul sistemul nervos autonom; sunt numeroase studii care au folosit variante ale acestor limite cu rezultate practice [11]. În literatura de specialitate au fost descrise mulți indicatori pentru evaluarea HRV, fiecare având un potențial diferit în evaluarea unor probleme clinice particulare. În general, valorile HRV pot fi împărțite fie în metrici statistice bazate pe timp (de exemplu, varianță), fie în metrici bazate pe frecvență care evaluează puterea, sau rapoartele de putere, în anumite benzi spectrale. În plus, majoritatea valorilor sunt calculate fie pe o durată scurtă de timp (de multe ori aproximativ 5 minute) sau pe perioade de timp extrem de lungi (de obicei 24 de ore). În special, s-a demonstrat că sensibilitatea (și lipsa de specificitate) măsurătorilor HRV în multe experimente se datorează parțial modificărilor legate de activitate [18] și utilizării pe scară largă a reeșantionării [19].

2.4.1. Domeniul timp și statisticile de distribuție

Statisticile domeniului timp sunt, în general, calculate pe intervale RR fără reeșantionare și, prin urmare, sunt flexibile în ceea ce privește îndepărtarea unor date (de artefacte și bătăi ectopice). O metrică din domeniul timpului recent revizuită este pNN50; procentul de intervale Normal adiacente care diferă cu mai mult de 50 ms pe o întreagă înregistrare ECG de 24 de ore. În [20] s-a studiat generalizarea acestei tehnici; pNNx — procentul de intervale NN dintr-o serie de timp de 24 de ore care diferă cu mai mult de x ms ($4 \leq x \leq 100$). S-a descoperit că o diferențiere

îmbunătățită între o varietate de condiții normale și patologice este posibilă prin utilizarea unei valori de x de la 20 ms sau mai puțin, mai degrabă decât pragul standard de 50 ms. Acest instrument și multe dintre instrumentele standard HRV sunt disponibile gratuit pe PhysioNet [21]. Această lucrare este similară cu lucrările recente din [22], care a analizat puterea predictivă a diferitelor vârfuri dintr-o histogramă netezită a intervalului RR și a definit volatilitatea cardiacă metrică. În publicațiile despre HRV [23], măsurătorile care implică o cuantificare a funcției de distribuție a probabilității a intervalelor NN (intervalul dintre două bătăi normale) pe o perioadă lungă de timp au fost denumite ca indici geometrici. În esență, aceste valori sunt doar o încercare de a calcula aproximări robuste ale statisticilor de ordin superior. Cu toate acestea, cu cât este mai mare momentul, cu atât este mai sensibil la valori eronate și artefacte și, prin urmare, astfel de tehnici „geometrice" au dispărut din literatură [11]. Al patrulea moment, kurtosis, măsoară cât de abruptă sau plată este o distribuție, în raport cu o distribuție gaussiană. Aproximațiile de kurtosis (curtoză) implică adesea entropia, o măsură mult mai robustă a non-gaussianității. (Un rezultat cheie al teoriei informației este că, pentru un set de surse independente, cu aceeași varianță, o distribuție Gaussiană are cea mai mare entropie, dintre toate semnalele) [11]. Al treilea moment al unei distribuții, asimetria, cuantifică asimetria unei distribuții și, prin urmare, a fost aplicat la pacienții la care accelerările bruște ale ritmului cardiac, urmate de decelerații mai lungi, indică o problemă clinică. În general, secvența intervalului RR accelerează mult mai repede decât încetinește.

2.4.2. Analiza în Domeniul frecvență a Variabilității ritmului cardiac

Modificările ritmului cardiac apar pe o gamă largă de scale de timp. Modificările simpatice, într-un timp de ordinul milisecundelor, stimulate de efort determină o creștere imediată a ritmului cardiac, rezultând un ritm cardiac inițial mai scăzut pe termen lung și o creștere a HRV pe o perioadă de săptămâni și luni. În mod similar, o creștere bruscă a tensiunii arteriale (din cauza unei embolii, de exemplu) va duce la o creștere bruscă semipermanentă a ritmului cardiac. Cu toate acestea, peste mai multe luni, baroreceptorii își vor reseta intervalul de operare pentru a provoca o scădere a ritmului cardiac și a tensiunii arteriale. Pentru a înțelege mai bine factorii care contribuie la HRV și scalele la care aceștia afectează inima, este util să se ia în considerare tahograma RR în domeniul frecvenței.

2.4.3. Componente pe termen lung

În Figura 2.16 sunt enumerate cele 4 benzi în care este împărțită tahograma RR, iar în Figura 2.17 se regăsește o reprezentare grafică a acesteia. Se mai pot folosi și alte benzi de frecvențe mai înalte sau mai joace, în funcție de aplicație. Măsurătorile HRV din domeniul frecvenței sunt apoi stabilite prin însumarea puterii în aceste benzi, luând rapoarte sau calculând panta, β, a spectrului de putere log-log (scară logaritmică). Motivația împărțirii spectrului în aceste benzi de frecvență constă în presupunerea că mecanismele de reglare biologică distincte care contribuie la HRV acționează la frecvențe care sunt limitate (aproximativ) în aceste benzi. Se presupune că fluctuațiile sub 0,04 Hz în benzile VLF și ULF se datorează unor mecanisme de reglare pe termen lung, cum ar fi sistemul de termoreglare, sistemul reniangiotensină (legat de tensiunea arterială și alți factori de reglare chimică) și alți factori umorali [25]. În 1998 s-a arătat că fluctuațiile VLF par să depindă în primul rând de fluxul parasimpatic [26]. În 1999 în [27] s-a demonstrat că banda ULF pare să fie dominată de contribuțiile activității fizice și că HRV în această bandă tinde să crească în timpul exercițiului. Prin urmare, se susține că orice studiu care evaluează HRV folosind date (chiar parțiale) din această bandă de frecvență ar trebui să includă întotdeauna o indicație a tiparelor de activitate fizică. Cu toate acestea, efectul activității fizice (și mai mult decât atât, mental) asupra HRV este atât de semnificativ încât s-a sugerat că evaluarea activității pentru toate parametrii este extrem de important [28].

În general, puterea spectrală din tahograma RR este împărțită în patru benzi :

- Frecvență ultra-joasă (ULF): 0.0001 Hz ≥ ULF < 0.003 Hz;
- Frecvență foarte joasă (VLF): 0.003 Hz ≥ VLF < 0.04 Hz;
- Frecvență joasă (LF) : 0.04 Hz ≥ LF < 0.15 Hz;
- Frecvență înaltă (HF) : 0.15 Hz ≥ HF < 0..4 Hz;

Figura 2.16 Enumerarea celor 4 benzi de putere spectrală [9]

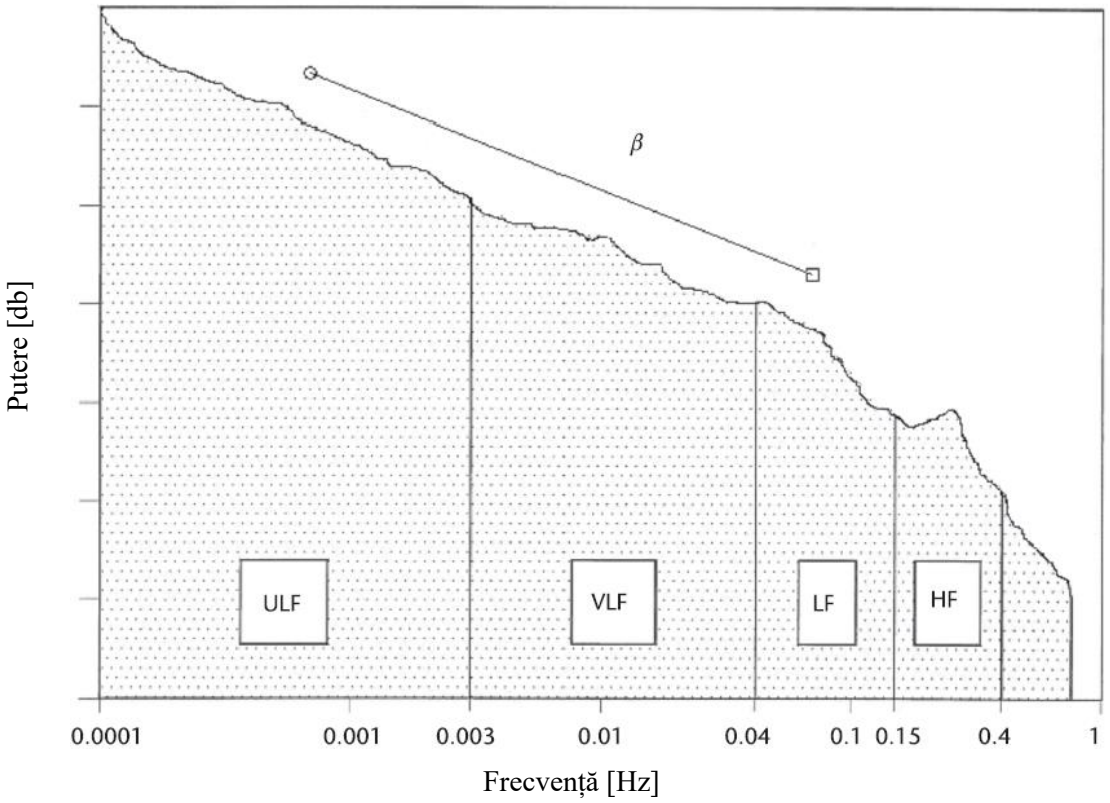


Figura 2.17 Periodogramă tipică a unei tahograme RR de 24 de ore în care puterea este reprezentată vertical și frecvența este reprezentată orizontal pe o scară logaritmică [9]

Aproape toate analizele spectrale ale tahogramei RR au fost efectuate folosind o variantă de estimare spectrală autoregresivă (AR) sau FFT (Transformata Fourier Rapidă) [9], care necesită implicit staționaritate și eșantioane distanțate în mod regulat. De asemenea, trebuie remarcat faptul că majoritatea tehnicilor de estimare spectrală, cum ar fi FFT, necesită o tehnică de windowing (de exemplu, fereastra hamming), care duce la o distorsiune neliniară implicită a tahogramei RR, deoarece valoarea tahogramei RR este asociată explicit cu referința temporală. Pentru a atenua nestaționaritățile, eliminarea liniară și polinomială a tendințelor este adesea folosită, în ciuda lipsei oricărei justificări reale pentru această procedură. În plus, deoarece marcajele de timp ale fiecărui interval RR sunt legate de intervalul RR anterior, tahograma RR este eșantionată în mod inerent inegal (sau neregulat). Prin urmare, atunci când se utilizează FFT, tahograma RR trebuie fie reprezentată în termeni de putere per ciclu per bătaie (care variază în funcție de ritmul cardiac local și, prin urmare, este extrem de dificil, dacă nu imposibil, să compare un calcul cu altul) sau este necesară o metodă de reeșantionare pentru ca seria temporală să fie eșantionată uniform. Schemele

obișnuite de reeșantionare implică reeșantionare interpolativă fie liniară, fie spline cubică. Au fost utilizate frecvențe de reeșantionare între 2 și 10 Hz, dar atâta timp cât criteriul Nyquist este satisfăcut, rata de reeșantionare nu pare să aibă un efect serios asupra metricilor bazate pe FFT [19]. Cu toate acestea, experimentele atât pe date artificiale, cât și pe date reale dezvăluie că astfel de procese supraestimează puterea totală în benzile LF și HF [19] (deși creșterea este la limită pentru reeșantionarea spline cubice dacă tahograma RR variază ușor și nu există lipsuri sau pauze: eșantioane de date eliminate din cauza ectopiei sau artefactului). FFT supraestimează raportul LF/HF cu aproximativ 50% cu reeșantionarea liniară și cu aproximativ 10% cu reeșantionarea spline cubică [19]. Această eroare poate fi mai mare decât diferența în raportul LF/HF între diferitele categorii de pacienți și, prin urmare, este extrem de semnificativă. O metodă pentru a reduce (și aproape în totalitate) această distorsiune este utilizarea periodogramei Lomb-Scargle (LSP) [29], [30], o metodă de estimare spectrală care nu necesită înlocuirea explicită a datelor (și nici nu presupune vreun model de bază) și care calculează densitatea spectrală de putere numai din valorile cunoscute (observate) dintr-o serie temporală [11].

2.4.4. Periodograma Lomb-Scargle

Se consideră o variabilă fizică X măsurată la momentele de timp t_j unde perioada de eșantionare este identică de la un eșantion la altul ($\Delta t = t_{j+1} - t_j = \text{constant}$) dintr-un proces stocastic. Vectorul rezultat, în funcție de timp, $\{X(t_j)\}$ $(j = 1, 2, \dots, N)$, se presupune că este o sumă dintre un semnal X_s și o serie de surse de eroare R:

$$X_j = X(t_j) = X_s(t_j) + R(t_j) \tag{2.2}$$

În plus, se consideră că semnalul este periodic și că sursele de eroare sunt independente de la un eșantion la altul ($R(t_j) \neq f(R(t_k))$ pentru $j \neq k$) și că $R(t_j)$ are o distribuție normală, de medie 0 și varianță constantă, σ^2. Transformata Fourier Discretă (TFD) în N puncte pentru această secvență este:

$$FT_X(\omega) = \sum_{j=0}^{N-1} X(t_j) e^{-i\omega t_j} \quad (2.3)$$

unde $\omega = 2\pi f_n,\ n = 1, 2, \dots, N$. Densitatea de putere spectrală estimată este obținută cu metoda standard de calcul a periodogramei:

$$P_X(\omega) = \frac{1}{N} \sum_{j=0}^{N-1} \left| X(t_j) e^{-i\omega t_j} \right|^2 \quad (2.4)$$

Se consideră că t_j nu mai este eșantionat uniform ($\Delta t = t_{j+1} - t_j \neq constant$) și generalizarea TFD în N puncte [31]:

$$F: T_X(\omega) = \left(\frac{N}{2}\right)^{\frac{1}{2}} \sum_{j=0}^{N-1} X(t_j) \left[A cos(\omega t_j) - iB sin(\omega t_j) \right] \quad (2.5)$$

unde $i = \sqrt{-1}$, j este indicele de ordine, iar A și B sunt funcțiile, încă necunoscute ale frecvenței unghiulare ω. Frecvența unghiulara poate să depindă de vectorul de timp t_j, dar nu de setul de date $\{X(t_j)\}$ sau de indicele de ordine j.

Periodograma normalizată rezultă:

$$P_X(\omega) = \frac{1}{N} |FT_X(\omega)|^2 = \frac{A^2}{2} \left[\sum_j X(t_j) \cos(\omega t_j) \right]^2 + \frac{B^2}{2} \left[\sum_j X(t_j) \sin(\omega t_j) \right]^2 \quad (2.6)$$

Dacă $A = B = (\frac{2}{N})^{\frac{1}{2}}$, ecuațiile 2 .5 și 2.6 se rezumă doar la definiția clasică. Pentru o eșantionare uniformă, $FT_X(\omega)$ se reduce doar la o TFD și și în limitele $\Delta t \to 0, N \to \infty$, aceasta

este proporțională cu Transformata Fourier. Scargle [31] arată cum soluția pentru (2.6) nu este unică și trebuie impuse condiții suplimentare pentru a deriva expresia corectată pentru periodograma Lomb-Scargle (LSP):

$$P_N(\omega) \equiv \frac{1}{2\sigma^2}\left\{\frac{\left[\sum_j (x_j - \bar{x})\cos\left(\omega(t_j - \tau)\right)^2\right]}{\sum_j \cos^2(\omega(t_j - \tau))} + \frac{\left[\sum_j (x_j - \bar{x})\sin\left(\omega(t_j - \tau)\right)^2\right]}{\sum_j \sin^2(\omega(t_j - \tau))}\right\} \quad (2.7)$$

unde $\tau \equiv tg^{-1}(\frac{\sum_j \sin(2\omega t_j)}{2\omega \sum_j \cos(2\omega t_j)})$. Deci τ este un decalaj care asigură ca $P_N(\omega)$ să fie complet independent de o deplasare a tuturor instanțelor de timp t_j, cu o oarecare constantă. Alegerea decalajului face ca din (X.7) să rezulte exact soluția care s-ar fi obținut dacă conținutul armonic al unui set de date, la o frecvență dată ω, ar fi fost estimat printr-un model de estimare liniară a celor mai mici pătrate $x(t) = A\cos(\omega t) + B\sin(\omega t)$. Astfel, LSP ponderează datele pe o bază de punct în loc să pondereze datele pe o bază de interval de timp. A se ține cont de faptul că, pentru semnale eșantionate uniform ($\Delta t = t_{j+1} - t_j = \text{constant}$), ecuația 2.7 se reduce la definiția clasica a periodogramei [29]. Există și alte metode pentru efectuarea estimării spectrale din date eșantionate neregulat și includ metoda de interpolare min-max [32] și tehnica geostatistică bine-cunoscută de krigging [33]. Domeniile strâns legate de imputarea datelor lipsă [34] și descoperirea variabilelor latente [35] sunt, de asemenea, metode adecvate pentru abordarea datelor lipsă. Cu toate acestea, LSP pare a fi suficient pentru analiza HRV, chiar și cu un SNR scăzut [19].

2.4.5. Limite informaționale și zgomote de fundal

Pentru a alege o dimensiune optimă a ferestrei, condiția de staționaritate trebuie corelată cu timpul necesar extragerii informațiilor prezente. Se sugerează [9] că cea mai scurtă perioadă de timp în care ar trebui evaluate valorile HRV este de 5 minute. Ca rezultat, cea mai joasă frecvență care poate fi abordată este 1/300 ≈ 0,003 Hz (chiar deasupra limitei inferioare a regiunii VLF). Prin urmare, astfel de segmente scurte pot fi folosite doar pentru a evalua valorile din benzile LF și HF. Limita superioară a frecvenței celei mai înalte benzi pentru analiza HRV este de 0,4 Hz [23].

Pentru că intervalul mediu pentru N eșantioane cuprinse în timpul T este$\Delta t_{av} = \frac{T}{N}$, atunci frecvența medie Nyquist [31] este $f'_c = \frac{1}{2\Delta t_{av}} = \frac{N}{2T}$. Atunci, o fereastră de 5 minute (T=300) având constrângerea Nyquist $f'_c = \frac{N}{2T} \geq 0.4$ pentru a evalua banda superioară de frecvență în zona HF, conduce la o limită inferioară pentru N la 240 de bătăi (un ritm cardiac mediu de 48 bpm dacă se iau în considerare toate ciclurile cardiace dintr-un segment de 5 minute). Utilizarea Periodogramei Lomb-Scargle, prin urmare, reliefează un prag de informație teoretică inferioară pentru considerarea segmentelor unei tahograme RR pentru analiza spectrală în regiunea superioară HF. Dacă intervale RR de cel puțin 1,25 secunde (corespunzând unei frecvențe cardiace instantanee de HRi = 60/RRi = 48 bpm) se regăsesc într-o tahogramă RR, atunci există frecvențe de până la 0,4 Hz. Cu toate acestea, acuratețea estimărilor frecvențelor superioare depinde de numărul de intervale RR care se încadrează ca valoare în jurul acestei regiuni spectrale. Tahogramele fără intervale RR mai mici de 1,25 s (HRi < 48 bpm) pot fi analizate, dar nu există nicio contribuție de putere la 0,4 Hz. Acest raționament conduce la un punct de vedere interesant asupra analizei spectrale HRV tradiționale pe termen scurt; interpolarea adaugă informații suplimentare (eronate) în seria temporală și completează FFT (în domeniul timpului), lăsând impresia pentru utilizator că există un semnal acolo, când într-adevăr, pur și simplu nu există suficiente eșantionarea într-un interval dat pentru a permite detectarea unui semnal (în sens semnificativ statistic). Scargle [31] arată că la orice frecvență particulară, f , și în cazul ipotezei nule, PX(ω), are o distribuție de probabilitate exponențială cu medie unitară. Prin urmare, probabilitatea ca PX(ω) să fie între o valoare pozitivă z și dz este e−zdz și, prin urmare, pentru o mulțime de M frecvențe independente, probabilitatea ca niciuna să nu dea valori mai mari decât z este (1 − e−z)M. Probabilitatea de alarmă falsă a ipotezei nule este deci:

$$P(>z) \equiv 1 - (1 - e^{-z})^M \tag{2.8}$$

Ecuația 1.8 se poate aplica pentru orice vârf din LSP, PX(ω) (o valoare mică, de exemplu, P < 0,05 indică un semnal cu un grad ridicat de periodicitate la o frecvență dată). M poate fi determinat de numărul de frecvențe eșantionate și de numărul de puncte de date, N [36]. Prin urmare, este important să se efectueze acest test pe fiecare periodograma înainte de a calcula o

metrică HRV bazată pe frecvență, pentru a verifica dacă există într-adevăr frecvențe măsurabile care nu sunt mascate de zgomot sau nestaționaritate.

2.5. Abordarea nestaționarității

Trebuie luat în considerare faptul că toți indicii HRV tradiționali folosesc tehnici care presupun un grad de staționaritate (slabă) în date. Dacă o parte din datele din porțiunea analizată de semnal prezintă modificări semnificative ale valorii medii sau ale variației, tehnica de estimare a HRV nu mai poate fi de încredere. O analiză rapidă a oricărei tahograme RR reale dezvăluie că schimbările în medie sau variație sunt o apariție frecventă [37]. Din acest motiv, se practică eliminarea variației liniei izoelectrice liniare sau parabolice din fereastră înainte de a calcula o metrică. Totuși, această eliminare a variației liniei izoelectrice nu are niciun efect asupra variației în raport cu schimbările în gradul de staționaritate și nu induce nicio modificare a distribuției spectrale a frecvențelor componente.

2.5.1. Măsurători ale HRV nestaționare și scalare fractală

Analizele empirice care folosesc tehnici de eliminare a anumitor tendințe pot duce la valori care la prima vedere facă distincția între anumite grupuri de pacienți. Astfel de tehnici includ analiza puterii pe mai multe scări, cum ar fi analiza fluctuațiilor de tendințe (DFA) [38], [39]. DFA este o metodă alternativă bazată pe variație pentru măsurarea scalei fractale a unei serii exprimate în funcție de timp. Se consideră o serie temporală de N eșantioane xk, care este exprimată în funcție de timp și rezultă seria y_k care este împărțită în porțiuni de lungime egală, m. În fiecare porțiune se efectuează o interpolare cu tehnica celor mai mici pătrate (pentru a estima tendința în secvența respectivă). Coordonata y a segmentelor se notează cu $y_k^{(m)}$. În continuare, seriei temporale integrate, yk, îi este redusă tendința locală, $y_k^{(m)}$, din fiecare porțiune. Deviația pătratică medie a acestei serii de timp integrate și declinate este calculată prin:

$$F(m) = \sqrt{\frac{1}{N}\left(\sum_{k=1}^{N}\left[y_k - y_k^{(m)}\right]^2\right)} \tag{2.9}$$

Acest calcul se repetă pe toate scalele de timp (dimensiunile secvenței) pentru a caracteriza relația dintre F(m), fluctuația medie, în funcție de dimensiunea casetei. De obicei, F(m) va crește cu dimensiunea secvenței m. O relație liniară pe o figură reprezentată la scară log-log indică prezența scalării legii puterii (fractale). În astfel de condiții, fluctuațiile pot fi caracterizate printr-un exponent de scalare α, panta dreptei care raportează log F(m) la log m, adică F (m) ~ mα. Există o legătură directă între DFA și tehnicile convenționale de analiză spectrală și alte tehnici de estimare a dimensiunii fractale. Aceste tehnici includ semivariograme (pentru a estima dimensiunea Hausdorf, Ha, [40]), intervalul redimensionat (pentru a estima exponentul Hurst, Hu [40], [41]), transformări wavelet (pentru a estima varianța wavelet Hw [42], [43]), factorul Fano αF și factorul Allan, αA [44], [45]. Cu toate acestea, este interesant de observat că fiecare dintre aceste măsuri fractale vine cu limitările de aplicabilitate și suferă de probleme diferite [46]. În special, factorul Fano este nepotrivit pentru estimarea $\beta > 1$, iar factorul Allan (un raport dintre varianță și medie) este limitat la $0 < \beta < 3$ [46]. Recent, McSharry et al. [43] a efectuat o analiză pentru a determina sensibilitatea fiecăreia dintre aceste metode pentru determinarea scalării fractale în seria temporală a intervalului RR. Ei au demonstrat că pentru o gamă de procese gaussiene și non-Gauss ($-2 < \beta < 4$), Hw a oferit cel mai bun interval de scalare fractală ($-2 < \beta < 4$ pentru proces Gaussian și $-0{,}8 < \beta < 4$ pentru proces non-Gauss) [11].

2.5.1.1. Entropia Multi-scalară

Entropia multi-scalară (MSE) este o versiune neliniară a metricilor multi-scalare care este bazată pe un tip de entropie cunoscută sub numele de entropie pe eșantion. O serie temporală de N puncte, $\{u(j) : 1 \leq j \leq N\}$, alcătuiește $N - m + 1$ vectori $x_m(i)$ pentru $\{i \mid 1 \leq i \leq N - m + 1\}$, unde $x_m(i) = u(i + k) : 0 \leq k \leq m - 1$ este vectorul de m eșantioane de la u(i) la u(i + m − 1). Dacă Ai este numărul de vectori $x_{m+1}(j)$ cu o rată de toleranță dată r a lui $x_{m+1}(i)$, Bi este numărul de vectori $x_m(j)$ care îndeplinesc condiția data de r al lui $x_m(i)$ și B(0) = N este lungimea seriei de intrare, entropia pe eșantion este dată de:

$$\mathrm{SampEn}(k, r, N) = -\ln \frac{A(k)}{B(k-1)} \qquad (k = 0, 1, \ldots, m-1) \tag{2.10}$$

Entropia pe eșantion este logaritmul natural negativ al unei estimări de probabilitate condiționate exprimate ca subserie (epocă) de lungime m care ține cont de gradul de toleranță r și de eșantionul curent și de cel care urmează în serie. Algoritmul de calculare a entropiei pe eșantion pe mai multe scale generează serii de puncte care se potrivesc în cadrul toleranței r până când nu există o concordanță și ține evidența compatibilității șablonului în statisticile de ordine A(k) și B(k) pentru toate lungimile de la k până la m. Odată ce toate concordanțele sunt numărate, valorile entropiei pe eșantion sunt calculate prin $SampEn(k, r, N) = -ln\frac{A(k)}{B(k-1)}$ pentru $(k = 0, 1, \dots, m - 1)$ cu B(0) = N, lungimea inițială a seriei. MSE nu se modifică liniar cu scala utilizată și, prin urmare, nu poate fi cuantificată de un singur exponent. În general, MSE crește (neliniar) cu creșterea N (sau scăderea factorului scalar), reflectând reducerea coerenței pe termen lung pentru scale din ce în ce mai lungi (factori scalari cu valori reduse). Această măsurătoare s-a dovedit a fi un descriptor al HRV independent față de exponentul de scalare fractal β [47]. O implementare cu acces deschis pentru publicul larg a acestui algoritm poate fi găsită pe site-ul web PhysioNet [48].

2.5.2. Modificări corelate cu activitatea fizică

2.5.2.1. Segmentarea seriilor temporale cardiace

O altă posibilitate atunci când intervin non-staționarități este de a segmenta semnalul pornind de la un punct identificabil în care acesta își schimbă morfologia și de a analiza secvențele în mod izolat. O abordare propusă de Moody [49] se bazează pe tratarea non-staționarităților ținând cont de frecvența cardiacă medie și HRV. Mai târziu, Fukada și colab. [50] a folosit un t-test modificat pentru a identifica decalajul în intervalul RR mediu. Dacă se presupune că tahograma RR este o serie de stadii aproximativ staționare și măsuram distribuția frecvenței lungimii și mărimii comutării între diferitele stadii, se observă că distribuțiile se încadrează aproximativ cu legile de putere specifice care variază în funcție de starea subiectului. Fukada şi colab. [50] au realizat segmentarea seriei de timp prin efectuarea unui t-test pentru a determina cea mai semnificativă modificare a intervalului RR mediu. Acest proces se repetă în mod recursiv pe fiecare secțiune până când statisticile numerelor mici stopează orice altă diviziune. Un rezultat interesant al aplicării acestei metode pe tahograma RR este constatarea că legile de scalare diferă semnificativ dacă subiectul doarme sau nu. Nu este clar dacă aceasta este o reflectare a faptului că

diferite părți ale creierului uman controlează aceste două stări majore, dar conexiunile dintre sistemul cardiovascular și mecanismele care controlează interacțiunea dintre somn și conștiență reprezintă domeniu de cercetare de mare nivel mondial [51]–[54]. Din păcate, metodele empirice de segmentare a seriilor de timp cardiace bazate exclusiv pe tahograma RR prezintă anumite limitări și deseori sunt necesare informații mai detaliate. S-a demonstrat recent [28] că prin cuantificarea HRV numai în timpul somnului și comparând HRV între pacienți doar pentru o anumită etapă a somnului, sensibilitatea unei anumite metode de evaluare HRV este semnificativ crescută. În plus, cu cât starea de somn este mai profundă, cu atât semnalul este mai staționar, iar zgomotul este mai scăzut și tehnica de estimare a HRV este mai sensibilă.

2.5.2.2. Etapele de somn vizualizate pe ECG

Frecvența respiratorie poate fi extrasă din ECG măsurat la nivelul toracelui prin măsurarea fluctuaților liniei izoelectrice [55] sau a amplitudinilor complexelor QRS care variază odată cu respirația. Acest fenomen este cunoscut sub numele de respirație derivată din ECG (EDR). Modificările în succesiunea intervalelor RR în timpul aritmiei sinusale respiratorii sunt, de asemenea, puternic corelate cu respirația prin modularea neurologică a nodului SA. Cu toate acestea, deoarece schimbările morfologiei complexelor QRS din cauza respirației sunt în mare parte mediate mecanic, diferența de fază dintre cele două semnale nu este întotdeauna constantă. Recent, Mietus et al. [56] au demonstrat că, urmărind schimbările din această cuplare prin analiza spectrală încrucișată a seriile de timp EDR și aritmia sinusală respiratorii (RSA), au reușit să cuantifice tipul și profunzimea somnului pe care oamenii îl experimentează în modelul alternant ciclic (CAP) și somnul non-CAP. Cuplarea frecvenței respiratorii poate fi cuantificată folosind densitatea spectrală încrucișată între RSA și EDR. Există două măsuri ușor diferite: frecvența de cuplare în funcție de magnitudinea oscilațiilor sinusoidale A(f) și consistența în fază a oscilațiilor Θ(f). Acestea sunt calculate separat astfel încât [56]:

$$A(f) = \varepsilon\left[\left|P_{xy}^{i}(f)\right|^{2}\right] \tag{2.11}$$

$$\Theta(f) = \left|\varepsilon\left[P_{xy}^{i}(f)\right]\right|^{2} \tag{2.12}$$

unde ε[.] Reprezintă medierea dintre toate $i = 1, 2, \dots, N$ segmente și $P_{xy}^{i}(f)$ este periodograma încrucișată a celui de-al i-lea segment. În general, Pxy(f) este un număr complex chiar dacă X(t) și Y(t) sunt reale. Deoarece A(f) se calculează luând în considerare pătratului lui Pxy(f) în fiecare bloc, urmat de mediere, acesta corespunde cuplajului de frecvență a celor două semnale datorită oscilațiilor numai în amplitudine. În mod similar, deoarece (f) este calculat prin medierea mai întâi a părților reale și imaginare ale lui Pxy (f) în toate blocurile, urmată de pătratul modulului, măsoară consistența în fază a oscilațiilor din toate blocurile. A(f) și (f) sunt normalizate și înmulțite împreună pentru a obține cuplarea cardiorespiratorie (CRC), o măsură a puterii cuplării dintre RSA și EDR, după cum urmează:

$$\mathrm{CRC(f)} = \frac{\mathrm{A(f)}}{\max[\mathrm{A(f)}]} * \frac{\Theta(\mathrm{f})}{\max[\Theta(\mathrm{f})]} \quad \textbf{(2.13)}$$

CRC variază între 0 și 1, un CRC scăzut indicând o cuplare slabă și, prin urmare, o activitate crescută. Un CRC ridicat (>0,4) indică o activitate scăzută care poate fi interpretată ca somn sau, uneori, sedare [57]. O valoare mai apropiată de 1 înseamnă o cuplare puternică a RSA și EDR la o frecvență dată. Figura 2.18 ilustrează aplicarea acestei tehnici la un pacient sedat și ventilat într-o unitate de terapie intensivă. Graficul inferior este o spectrogramă; o serie în funcție de timp a densității spectrale transversale dintre EDR și RSA. Graficul superior reprezintă o stabilitate a somnului de la WR (veghere sau somn REM) la somn CAP (C) la somn stabil non-CAP (NC). Această serie de timp este derivată prin prăguind raportul dintre regiunile de frecvență joasă (Lo) și înaltă (Hi) ale coerenței spectrale transversale. În ciuda faptului că acest pacient este ventilat (și, prin urmare, frecvența respiratorie este fixată la 0,3 Hz), somnul stabil (NC) este încă observabil. Cuplarea dintre RSA și EDR este mai evidentă sau mai ușor de obținut atunci când subiectul este în repaus (sau în somn stabil, sau poate, în somn profund) unde există mai puțini factori care pot influența semnificativ modificările ritmului respirator sau ale ritmului cardiac. Prin urmare, această tehnică a fost folosită și pentru a detecta modificări ale activității sau staționarității la pacienți . În plus, cea mai puternică frecvență de cuplare este direct corelată cu respirația, care este, de asemenea, un bun indice de activitate, precum și o estimare a frecvenței respiratorii predominante. O analiză a sensibilității a acestei tehnici arată, de asemenea, că metrica CPC este

extrem de robustă la zgomot, deoarece prezența zgomotului pe ECG este corelată cu modificările activității fizice [57].

2.5.3. Analiza perturbațiilor

O alternativă la eliminarea tendinței sau segmentarea seriilor de timp cardiace când apar modificări nestaționare și analizarea segmentelor în mod izolat, este efectuarea unei analize a modificărilor temporare ale semnalului în punctul de schimbare. Cu toate acestea, testele intervenționale pot să nu fie întotdeauna posibile sau adecvate și uneori este necesară o analiză mai pasivă a punctelor de schimbare. Acestea includ analiza periodicității acestor modificări și a modificărilor tranzitorii datorate schimbărilor intrinseci pasive ale activității cardiace, cum ar fi tranzițiile între stările de somn, modificările datorate excitațiilor în timpul somnului sau modificările datorate ectopiei [11].

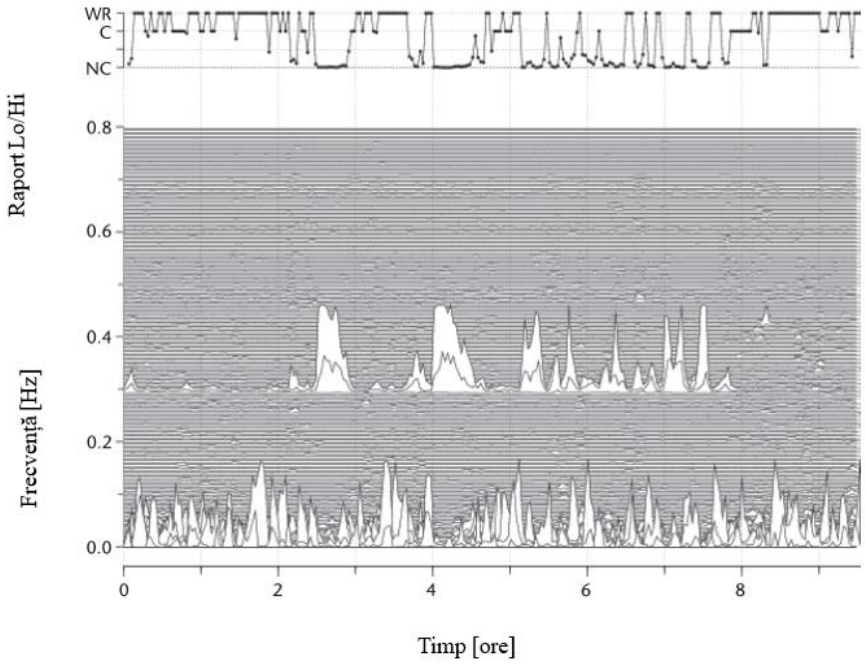


Figura 2.18 Spectrograma (inferioară) a relației EDR-RSA, asociată cu stabilitatea somnului (superioară) derivată din pragul raportului dintre puterea de frecvență joasă și frecvență înaltă (Lo/Hi) pentru fiecare segment. Acest pacient este pe un ventilator, astfel încât frecvența respiratorie este ascuțită și fixată la 0,3 Hz. Somnul stabil non-CAP (NC) este încă observabil în ciuda ventilației

2.5.3.1. Tulburări de ritm cardiac

Modificările de cvasi-staționaritate ale ritmului sinusal datorate modificărilor fiziologice bifazice care intervin asupra activității nodului SA sunt cunoscute sub denumirea de turbulență a ritmului cardiac (HRT). În analiza HRV, această perturbare este eliminată din tahograma RR și se presupune că faza tahogramei RR este neschimbată după ce semnalul revine la „ritmul netulburat". În HRT, modificările din secțiunea de „tulburare" sunt analizate pentru a extrage valori pentru a cuantifica modificările. În general, HRT se manifestă ca o scurtă accelerare inițială a ritmului cardiac pentru câteva bătăi, urmată de o decelerare înapoi la valoarea de referință de dinaintea contracției ventriculare premature (PVC). HRT este de obicei cuantificată prin doi parametri numerici: debutul turbulenței (TO) și panta turbulenței (TS). TO este definită ca diferența procentuală dintre valoarea medie a primelor două intervale normale RR după PVC (RRn, n = 2, 3) și a ultimelor două intervale normale precedând PVC (RR−n, n = 2, 1) și este dat de:

$$\mathrm{TO} = \frac{(\mathrm{RR}^{+2} + \mathrm{RR}^{+3}) - (\mathrm{RR}^{-2} + \mathrm{RR}^{-1})}{\mathrm{RR}^{-2} + \mathrm{RR}^{-1}} \times 100 \tag{2.14}$$

unde RR−2 și RR−1 sunt primele două intervale normale care apar înaintea PVC și RR+2 și RR+3 primele două intervale normale care urmează PVC. Prin urmare, valorile TO pozitive indică decelerare, iar valorile TO negative indică accelerarea ritmului sinusal postectopic. Deși TO poate fi determinată pentru fiecare PVC individual, TO s-a dovedit a fi mai predictivă (din punct de vedere clinic) dacă se calculează valoarea medie a tuturor măsurătorilor individuale. Pentru calcularea TO medie în versiunea curentă a algoritmului HRT disponibil gratuit [58], sunt necesare cel puțin 15 intervale normale după fiecare PVC individual. TS se calculează prin construirea unei serii de timp medii centrate în mod ectopic și determinând cea mai abruptă pantă (regresată liniar) pentru fiecare secvență posibilă de cinci intervale normale consecutive în tahograma „tulburată" post-PVC (de obicei considerată ca fiind de până la RR+16; primele 15 intervale RR normale). Adică toate pantele posibile din mulțimea {RR+2,+3,...,+6, . . . , RR+17,+18,...,+16} sunt calculate, iar maximul dintre cele 13 pante posibile este considerat TS. Figura 2.19 ilustrează calculul TS după apariția unei perturbații în tahograma RR din cauza unui PVC.

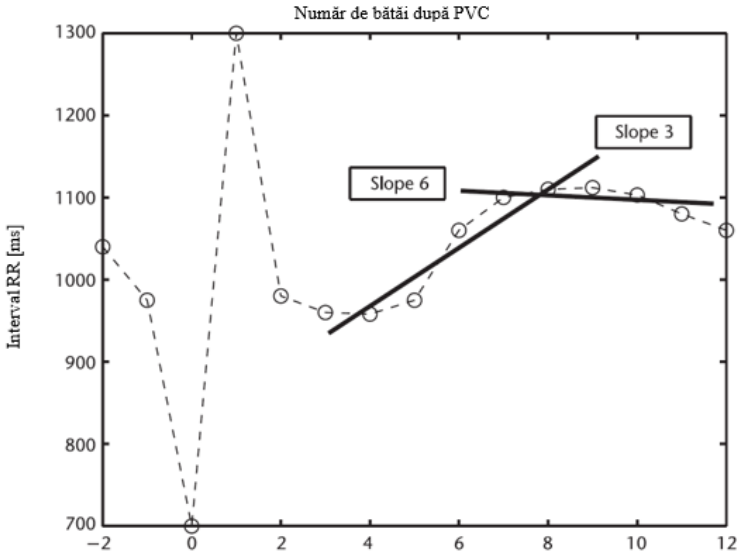


Figura 2.19 Exemplu de tulburare a HRT după PVC. Indicele bătăilor denotă intervalul RR asociat cu bătăile din jurul PVC-ului (indice zero). Următoarea bătaie după PVC (RR^{+1}) are asociat un interval RR alungit; pauza compensatorie după bătaia precoce (prematură). Pantele sunt calculate pentru fiecare set ulterior de cinci bătăi consecutive (doar pantele 3 și 6 sunt ilustrate pentru claritate) [59]

Următorul ritm după PVC (RR+1) are asociat un interval RR alungit, adică, pauza compensatorie după ritmul precoce (prematur) precedent. Deși pantele sunt calculate pentru fiecare set următor de cinci bătăi consecutive, doar a treia și a șasea pantă sunt ilustrate pentru claritate [11]. Criteriile de excludere a PVC-urilor trebuie să fie stricte, deoarece cuantificarea HRT poate oferi rezultate utilizabile numai dacă evenimentul declanșator a fost un PVC adevărat (și nu un artefact, undă T sau un eveniment similar non-PVC). În plus, ritmul sinusal imediat înainte și după PVC trebuie verificat pentru că acesta trebuie să fie lipsit de aritmie, artefacte și clasificări false ale bătăilor datorate artefactului. Un set util de criterii de excludere sunt:

- Eliminarea tuturor intervalelor RR < 300 ms sau > 2.000 ms;
- Eliminarea tuturor RRn unde RRn−1 − RRn > 200 ms;
- Eliminarea tuturor intervalelor RR care se modifică cu mai mult de > 20% față de media ultimelor cinci intervale sinusale (intervalul de referință);
- Folosirea numai a PVC-urilor cu o prematuritate minimă de 20%;
- Excluderea PVC-urilor cu un interval postextrasistolic care este cu cel puțin 20% mai lung decât intervalul normal [11].

Valorile TO sub 0 și valorile TS peste 2,5 sunt considerate normale și anormale în caz contrar (adică, un răspuns sănătos la PVC este o accelerare puternică a sinusurilor urmată de o

decelerare rapidă). Deși mecanismul exact care duce la HRT este necunoscut [59], se crede că este un baroreflex autonom prin care PVC-ul provoacă o scurtă perturbare a tensiunii arteriale [60]. Prin urmare, HRT poate fi măsurat în jurul punctului de ectopie atrială, precum și ectopie ventriculară. Când sistemul nervos autonom este sănătos, această schimbare rapidă determină un răspuns instantaneu în următoarele intervale RR. Dacă sistemul nervos autonom este afectat, amploarea acestui răspuns este fie diminuată, fie posibil complet absentă. Din punct de vedere clinic, valorile HRT s-au dovedit a fi predictive pentru mortalitate și posibil stop cardiac. În plus, valorile HRT s-au dovedit a fi deosebit de utile atunci când pacienții iau beta-blocante. Într-un studiu [61], [62], TO și TS combinate s-a dovedit a fi singurul predictor independent al mortalității în comparație cu markerii altfel predictivi, cum ar fi ritmul cardiac mediu, infarct miocardic anterior și o fracție de ejecție scăzută.

2.5.3.2. Tulburări ale segmentului QT și alte măsuri

Aplicarea analizei HRT pentru studiul variației intervalului QT după PVC-uri a arătat că tulburarea intervalului QT apare în asociere cu tulburarea HR [63]. QT TO a fost definită ca diferența relativă dintre intervalul QT al primului ciclu sinusal după un PVC indus și media intervalelor QT ale celor două cicluri sinusale anterioare bătăii premature. Savelieva și colab. [64] au descoperit că pacienții cu tahicardie ventriculară ischemică și disfuncție ventriculară stângă au prezentat valori QT TO semnificativ mai mici decât cei cu tahicardie ventriculară nonischemică și funcție ventriculară normală. Nici contracțiile atriale premature induse, nici PVC-urile nu au produs o dinamică QT târzie echivalentă cu TS a turbulenței HR (ritm cardiac), iar mecanismul de bază al tulburării QT rămâne neclar. Cu toate acestea, au fost efectuate puține studii privind tulburările intervalului QT și dificultățile în măsurarea și interpretarea intervalului QT pot îngreuna acest tip de analiză. Prin urmare, este incert dacă QT TS se va dovedi a fi o măsură utilă. În plus, multe valori legate de HRT au fost propuse cu diferite grade de succes, inclusiv:

- Dinamica tulburării [64]: Cea mai mare panta descrescătoare între TS și ritmul cardiac la un anumit individ pe o secvență de 10 bpm;
- Timpul tulburării [65]: numărul bătăii pentru o secvență de lungime de 5-RR utilizată în calculul TS la care apare cea mai mare pantă;
- Coeficientul de corelație al TS [66]: Coeficientul de corelație al dreptei descrescătoare ajustată la intervalele 5-RR care dă panta maximă (adică, unde este definită TS);
- Salt de tulburare [67]: Diferența maximă dintre intervalele RR adiacente;

- Scăderea frecvenței de tulburare [68]: O metrică în domeniul frecvenței obținută prin ajustarea unei funcții sinusoidale la pauza postcompensatorie.

Deși multe dintre aceste metrici s-au dovedit promițătoare ca indicatori independenți pentru o serie de afecțiuni, sunt necesare studii suplimentare pentru a determina dacă oricare dintre aceste metrici oferă o stratificare a riscului semnificativ superioară TO și TS. În plus, TO și TS sunt mai simplu de măsurat și au fost validate în studii prospective mari [11].

2.6. Realizarea unor metode de prelucrare a semnalelor ECG

În cadrul tezei de doctorat „Contribuții privind sistemele de evaluare automată a capacității de conducere a vehiculelor”, analiza, procesarea și extragerea de caracteristici din semnalele ECG reprezintă etape esențiale în dezvoltarea unor sisteme eficiente de monitorizare a stării conducătorilor auto. Pentru exemplificarea operațiilor, a fost selectat un semnal ECG cu 12 derivații standard: I, II, III, aVR, aVL, aVF, V1, V2, V3, V4, V5, V6. Un prim pas în procesare l-a reprezentat citirea semnalului și introducerea informațiilor privind formatul acestuia și numărul de derivații, după cum este ilustrat în Figura 2.21. Semnalul utilizat este în format „.mat”, cu o frecvență de eșantionare de 500 Hz, caracteristici evidențiate și în codul prezentat în Figura 2.22. Acest tip de prelucrare inițială este fundamental pentru asigurarea unei interpretări precise a datelor ECG, utilizate ulterior pentru monitorizarea stării fiziologice și emoționale a conducătorului auto.

```
%% Introducere tip de date si derivatiile studiate
tip_date = '.mat'
derivatii_semnal = ['I','II','III','aVR','aVL','aVF','V1','V2','V3','V4','V5','V6' ]
```

Figura 2.22 Introducerea formatului și a derivațiilor semnalului

```
%% Frecventa de esantionare
frecventa_esantionare = 500 #Hz

%% Incarcare semnal ca sir numeric
semnale=loadmat('JS00001.mat')['val'].astype(np.float64)
```

Figura 2.23 Setarea frecvenței de eșantionare și citirea semnalului

În continuare au fost separate derivațiile și ulterior afișate, după cum se poate observa în Figura 2.23. Pentru această etapă este folosit codul din Figura 2.24.

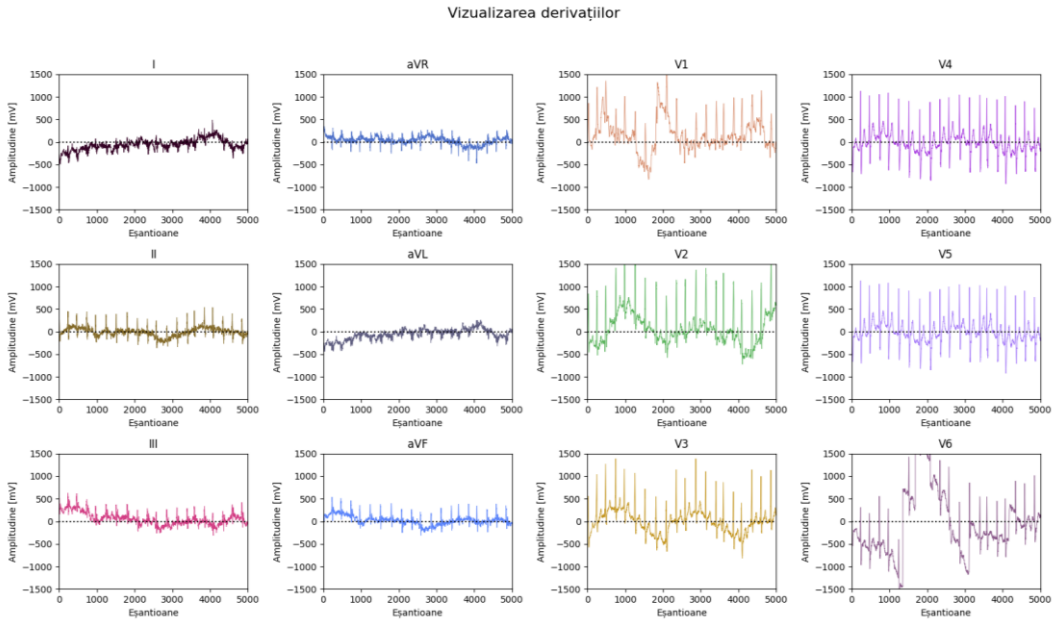


Figura 2.24 Vizualizarea celor 12 derivații ECG

```
#%% Atasare derivatii
semnal = {}

for i in range(0,len(derivatii_semnal)):
    semnal[derivatii_semnal[i]] = semnale[i,:]

_lr,_lc = 3,4
_derivatii = [
    [['I'],['aVR'],['V1'],['V4']],
    [['II'],['aVL'],['V2'],['V5']],
    [['III'],['aVF'],['V3'],['V6']]
]

# Vizualizare derivatii
fig,ax = plt.subplots(_lr,_lc, figsize=(_lr*7,_lc*4))
plt.subplots_adjust(wspace=0.4,hspace=0.4)
fig.suptitle('Vizualizarea derivațiilor', fontsize=16)
#fig.set_dpi(150)
for i in range(0,3):
    for j in range(0,4):
        _key = _derivatii[i][j][0]
        ax[i,j].set_title(_key)
        col = (np.random.random(), np.random.random(), np.random.random())
        ax[i,j].plot(semnal[_key], color=col, linewidth=0.6)
        ax[i,j].set_ylim((-1500,1500))
        ax[i,j].set_xlim((0,5000))
        ax[i,j].hlines(0,0,5000,color='black',linestyle='dotted')
        ax[i,j].set_xlabel('Eșantioane')
        ax[i,j].set_ylabel('Amplitudine [mV]')

plt.show()
```

Figura 2.25 Codul corespunzător vizualizării derivațiilor ECG

_lr și _lc reprezintă numărul de linii (_lr) și numărul de coloane (_lc) pe care se alege vizualizarea derivațiilor în Figura 2.23. Se constată că vizibilitatea este relativ mică, de aceea se alege și o vizualizare pe verticală a derivațiilor, utilizând codul din Figura 2.25. Rezultatul obținut este prezentat în Figura 2.26. De asemenea, prima reprezentare este în funcție de numărul de eșantioane (5000), iar cea de-a doua este în funcție de timp, fiecare derivație fiind înregistrată timp de 10 secunde.

```
#%%

# Vizualizare derivatii pe verticală
fig,ax = plt.subplots(12,1, figsize=(20,12*40),sharex=True, sharey=True)

# Ascunderea marginilor
fig.add_subplot(111, frameon=False)
plt.tick_params(labelcolor='none', which='both', top=False, bottom=False, left=False, right=False)
plt.xlabel('Timp [s]',fontsize=13)
plt.ylabel('Amplitudine [mV]',fontsize=13,labelpad=18)
plt.subplots_adjust(wspace=0.5,hspace=0.5)
fig.suptitle('Vizualizarea derivațiilor pe verticală', fontsize=16)
for i in range(0,12):
    _key = derivatii_semnal[i]
    #ax[i].set_title(_key)
    col = (np.random.random(), np.random.random(), np.random.random())
    ax[i].plot(semnal[_key], color=col, linewidth=0.6)
    ax[i].set_ylim((-1500,1500))
    ax[i].set_xticks(np.arange(0,5001,500))
    ax[i].set_xticklabels(np.arange(0,5001,500)/frecventa_esantionare)
    ax[i].grid(axis='x')
    ax[i].annotate(_key,(-200,0))
    ax[i].hlines(0,0,5000,color='black', linewidth=0.3)

plt.show()
```

Figura 2.26 Codul corespunzător vizualizării derivațiilor ECG pe verticală

Pentru o vizualizare mai ușoară a derivațiilor se alegerea folosirea unor axe comune (axa Ox și axa Oy) și încadrarea fiecărei derivații într-un chenar. Amplitudinile maxime atinse de semnal sunt de 1000 mV, iar cele minime de -1000 mV. În continuare s-a ales derivația V5 pentru a studia semnalul. Alegerea acestuia și reprezentarea grafică s-au facut conform codului din Figura 2.27, iar rezultatul obținut este prezentat în Figura 2.28.

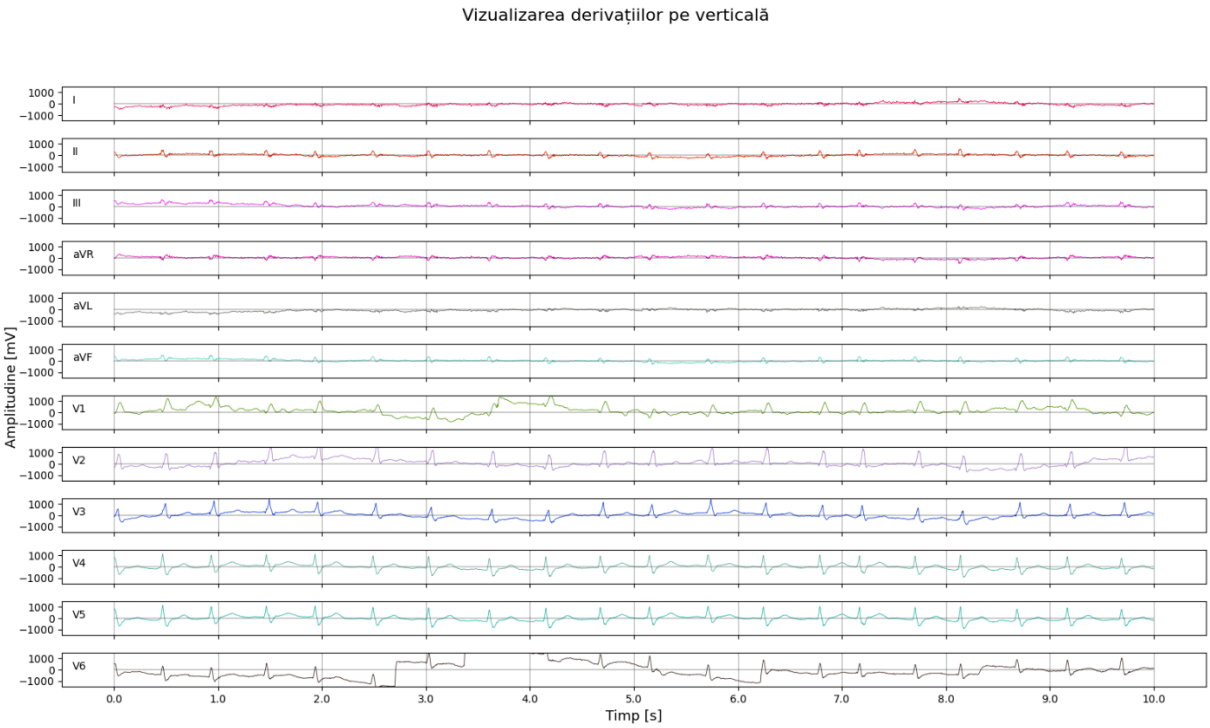


Figura 2.27 Vizualizarea celor 12 derivații ECG pe vertical

```
#%% Se alege o derivatie si se ploteaza
signal = semnal['V5']

plt.figure(figsize=(40,6))
plt.plot(signal, color='black', linewidth=0.6)
plt.hlines(0,0,5000,color='black', linewidth=0.3)
plt.xlabel('Eșantioane')
plt.ylabel('Amplitudine [mV]')
plt.title('Reprezentarea derivației I',fontsize=16)
```

Figura 2.28 Alegerea primei derivații și vizualizarea acesteia

Linia izoelectrică este o linie imaginară de pe înregistrarea ECG unde este înregistrat intervalul PR și unde se află în mod normal segmentul ST. Linia izoelectrică este importantă deoarece este utilizată ca punct de referință normal pentru evaluarea anomaliilor undei ST – T. După cum se observă în Figura 2.28 prezentată ulterior, linia izoelectrică, a electrocardiogramei, înregistrată în intervalul TP în timpul ritmurilor cu unde P, prezintă variații, ceea ce duce la o citire dificilă a semnalului.

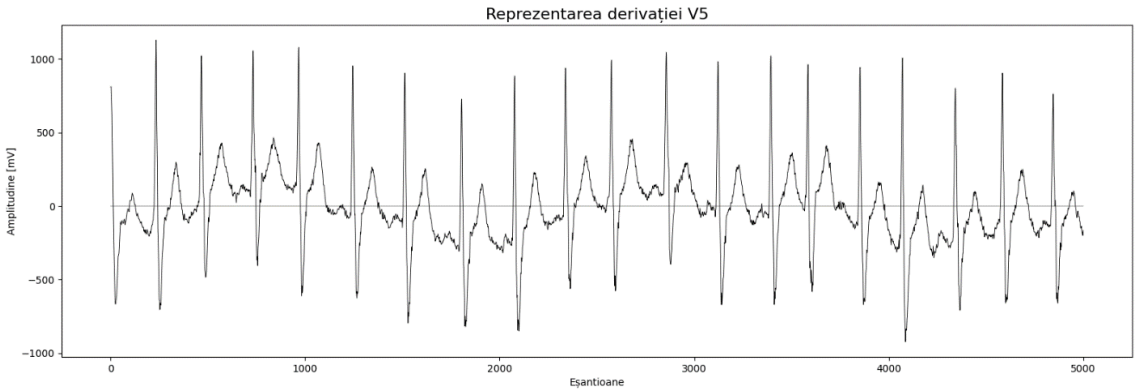


Figura 2.29 Reprezentarea derivației V5

2.6.1. Aducerea semnalului la linia de bază și eliminarea zgomotului

ECG-ul conține diferite unde și intervale care se corelează direct cu activitatea inimii. Pentru a diagnostica bolile cardiace, astfel de unde și intervale trebuie să fie detectate și măsurate corect. Tipurile de zgomote care sunt prezente în semnalul ECG sunt: deviația liniei de bază, interferența liniei de alimentare, artefactele de mișcare, contactul electrodului și zgomotul instrumentului [69]. Pentru a elimina aceste tipuri de zgomote din semnalul ECG cu ajutorul unor filtre noi în momentul procesării, se folosește metoda de pre-procesare. Zgomotele de tip "base line wander" – modificări apărute la nivelul liniei izoelectrice sunt produse de variațiile de amplitudine și frecvență din semnalul ECG [69]. Se observă, din Figura 2.29, că 50% din zgomotele liniei izoelectrice sunt prezente în amplitudinea semnalului ECG. Un alt tip de zgomot foarte important, care apare mai ales în semnalul ECG, este interferența liniei electrice și este cauzată de frecvența de 60 Hz în sinusoidală și de armonicele acesteia. În timpul măsurării semnalului sunt detectate unele tipuri de zgomote, cum ar fi mișcarea electrozilor și contracția musculară [70]. Filtrele trece-jos și trece-sus sunt filtrele obișnuite pentru a elimina zgomotul din semnalul ECG. Dar aceste tipuri de filtre produc artefacte pe complexul QRS și unele tipuri de filtre produc, de asemenea, aceste artefacte [71], [72]. Tehnicile moderne, cum ar fi analiza componentelor principale, rețele neuronale și transformata Wavelet, sunt utilizate pentru a elimina zgomotul din semnalul ECG, în special pentru a elimina frecvența înaltă, dar au dezavantajul că lățimea de bandă nu este constantă [73]–[75]. O altă metodă de eliminare a zgomotului este prin utilizarea unui filtru adaptiv în cascadă bazat pe transformata Wavelet. Cum semnalele ECG sunt adesea contaminate cu diferite tipuri de zgomot în timpul procesului de achiziție a datelor, filtrarea este una dintre cele mai utilizate

tehnici în prelucrarea semnalelor. Un filtru poate fi descris ca fiind un dispozitiv sau o componentă care primește un semnal la intrare și elimină anumite componente nedorite din acesta înainte de a-l emite. Deoarece fluctuația liniei izoelectrice este componenta nedorită din semnalul ECG, eliminarea fluctuației poate fi analizată ca o problemă de filtrare. Prelucrarea prealabilă a analizei ECG constă în corecția de frecvențe joase a liniei izoelectrice și în reducerea zgomotului de înaltă frecvență al artefactelor din ECG-ul brut. Variația liniei izoelectrice este un zgomot de frecvență joasă (0-0,5 Hz) care este cauzat de mișcările corpului și de respirație în timpul colectării datelor. Diferite filtre de răspuns la impulsuri finite (FIR) și de răspuns la impulsuri infinite (IIR) sunt utilizate pentru denaturarea semnalului ECG [76]. Filtrul trece sus poate fi aplicat pentru a elimina interferențele de frecvență joasă din semnalul. Dar filtrul trece sus elimină porțiunea inferioară a semnalului ECG împreună cu zgomotul [77]. În plus, filtrul tradițional IIR notch cu un coeficient fix poate fi, de asemenea, utilizat pentru a reduce orice anumită frecvență de zgomot din semnalul ECG. Dar, este dificil de aplicat acest tip de filtru crestător, deoarece are coeficienți ficși, iar semnalul ECG are o natură nestaționară. Prin urmare, atunci când acest tip de filtru crestător elimină zgomotul de bază sub 1 Hz, acesta elimină și o frecvență îngustă a semnalului ECG în jurul acestui zgomot [77]. Din acest motiv, deși zgomotul este eliminat, un anumit conținut semnificativ de frecvență al semnalului original este, de asemenea, eliminat odată cu zgomotul. Uneori, efectul de inelare este introdus în semnalul de ieșire filtrat în crestătură. Alături de transformata Hilbert-Huang, WT reprezintă cea mai populară tehnică matematică și cel mai eficient instrument pentru analiza semnalelor, precum și pentru reprezentarea semnalelor în domeniul timp-frecvență. Ea este utilizată în diferite domenii științifice ca instrument adecvat pentru analiza proceselor complexe [78]. Un complex QRS reprezintă starea de depolarizare a activității cardiace. Pentru a detecta complexul QRS, procedurile algoritmului propus utilizează transformările Wavelet. De fapt, metoda propusă se bazează pe descompunerea prin transformată Wavelet a semnalului ECG folosind unda mamă Biorthogonal inversă. Coeficienții rezultați sunt filtrați cu ajutorul unor filtre neliniare. Coeficienții filtrați rezultați sunt apoi trecuți prin pragul dinamic pentru a detecta toate complexele QRS [79]. Astfel, următorul pas este reprezentat de eliminarea zgomotului și aducerea semnalului la linia izoelectrică cu ajutorul transformatei Wavelet (WT) și a unui filtru median. Transformarea Wavelet a unui semnal temporal la orice scară este convoluția semnalului și a unei unde fiice la scară temporală. Scalarea și translația wavelet-ului mamă reprezintă mecanismul care adaptează transformarea la modificările spectrale și temporale ale semnalului. Transformatele Wavelet sunt, în general, funcții de bază ortogonale. Alegerea wavelet-ului mamă este strâns legată de natura semnalului [79]. Pentru abordarea

propusă, se utilizează undele biortogonale. Deși undele biortogonale adaugă complexitate pentru reconstrucția semnalului, care se datorează timpului suplimentar de calcul necesar pentru transformarea funcției duale. Cu toate acestea, ele oferă simetrie temporală, această simetrie temporală împreună cu oscilațiile pot fi convenabile în detectarea complexului QRS [80]. În Figura 2.29 este reprezentată derivația V5 înainte și după aplicarea filtrării. Cu galben este reprezentat semnalul inițial, iar cu negru este semnalul obținut în urma aplicării transformatei Wavelet.

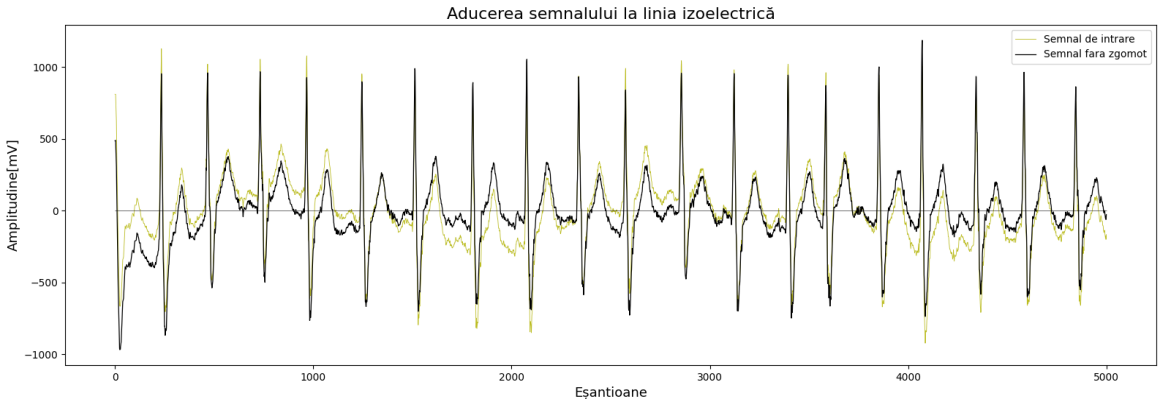


Figura 2.210 Filtrarea semnalului cu transformata Wavelet

Pentru a observa efectul transformatei, se alege reprezentarea din Figura 2.30, în care s-a colorat cu galben diferența între semnalul inițial și semnalul obținut după filtrare. Se constată că apare și o modificare a liniei izoelectrice în urma aplicării transformatei Wavelet. Analiza componentelor principale (PCA) se bazează pe ideea că părțile utile sunt necorelate cu zgomotul, iar denaturarea se realizează prin eliminarea componentelor mai puțin corelate din semnal. Cu toate acestea, ea poate procesa doar semnale aliniate sau semnale multicanal, în caz contrar, efectul de denoising va fi slăbit. Transformarea wavelet (WT) are proprietăți bune de localizare timp-frecvență și poate oferi o analiză a semnalului în timp și la scară. În același timp, proprietatea sa de multi-rezoluție poate descrie caracteristicile nestaționare ale semnalelor. Prin urmare, aceasta a devenit una dintre metodele de filtrare utilizate în mod obișnuit pentru semnalele ECG. Codul corespunzător Figurilor 1.29 și 1.30 este prezentat în Figura 2.31. Transformata folosită este potrivită pentru analiza semnalelor staționare care variază în timp, cum ar fi ECG-ul, deoarece oferă diferite benzi de rezoluție de frecvență după procesul de descompunere, în loc de Transformarea Fourier și Transformarea Fourier în timp scurt (STFT). Transformarea Fourier oferă un răspuns constant în frecvență, astfel încât sunt dificil de analizat semnale nestaționare, iar STFT oferă transformata Fourier a funcției la un

anumit moment din timp, examinată ca un centru de fereastră limitat în timp. Lățimea ferestrei STFT este constantă, astfel încât nu oferă o analiză cu rezoluție multiplă a semnalului. Spre deosebire de celelalte două, transformata Wavelet oferă atât rezoluția în frecvență, cât și în timp [81].

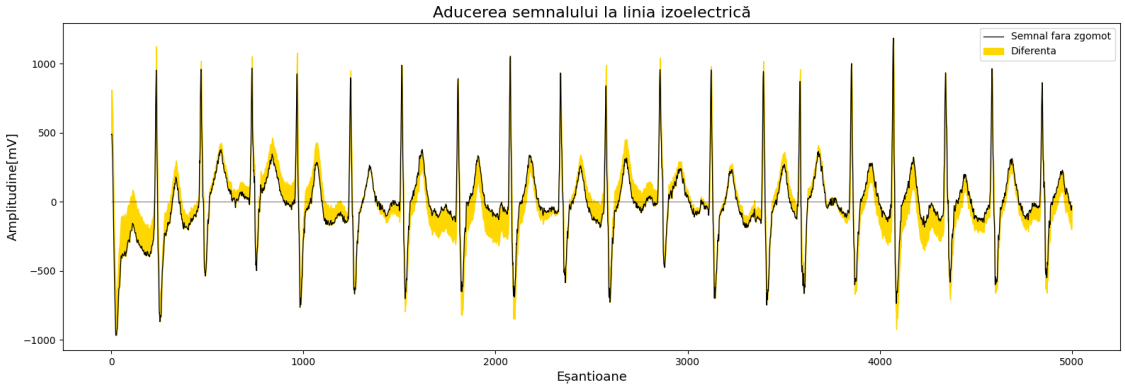


Figura 2.11 Diferența între semnalul inițial și semnalul filtrat

```
#%% Eliminare zgomot cu transformata Wavelet

def denoise_signal(X, dwt_transform, dlevels, cutoff_low, cutoff_high):
    coeffs = wavedec(X, dwt_transform, level=dlevels)   # Transformata Wavelet 'bior4.4'
    # Interval de la 0 la cutoff_low
    for ca in range(0,cutoff_low):
        coeffs[ca]=np.multiply(coeffs[ca],[0.0])
    # Interval de la cutoff_high pana la final
    for ca in range(cutoff_high, len(coeffs)):
        coeffs[ca]=np.multiply(coeffs[ca],[0.0])
    Y = pywt.waverec(coeffs, dwt_transform) # Transformata Wavelet inversa
    return Y


signal_den = denoise_signal(signal,'bior4.4', 9 , 1 , 10) # compromis - cu atât mai mica valoarea de cutoff_low -
# cu atât mai multe varfuri R sunt pierdute
plt.figure(figsize=(40,6))

plt.plot(signal, color='tab:olive', linewidth=0.6,label = 'Semnal de intrare')
plt.plot(signal_den, color='black', linewidth=0.9,label = 'Semnal fara zgomot')
plt.hlines(0,0,5000,color='black', linewidth=0.4)
plt.legend()
plt.xlabel('Eșantioane',fontsize=13)
plt.ylabel('Amplitudine[mV]',fontsize=13)
plt.title('Aducerea semnalului la linia izoelectrică',fontsize=16)
plt.show()

plt.figure(figsize=(40,6))
plt.plot(signal_den, color='black', linewidth=0.9,label = 'Semnal fara zgomot')
plt.fill_between(np.arange(0,5000,1),signal,signal_den,color='gold',label = 'Diferenta')
plt.hlines(0,0,5000,color='black', linewidth=0.4)
plt.legend()
plt.xlabel('Eșantioane',fontsize=13)
plt.ylabel('Amplitudine[mV]',fontsize=13)
plt.title('Aducerea semnalului la linia izoelectrică',fontsize=16)
plt.show()
```

Figura 2.12 Secvența de cod corespunzătoare aducerii semnalului la linia de bază

Aceste wavelet-uri sunt concepute pentru a satisface ortogonalitatea și simetria. Cu toate acestea, undele P și T, care sunt semnale importante utilizate în clinică, exprimând caracteristicile funcției cardiace, nu sunt evidente în unele derivații. Wavelet-urile cu ortogonalitate și simetrie prezintă totuși riscul ca caracteristicile undelor P și T să fie estompate

și slăbite după eliminarea zgomotului. În continuare a fost folosit un filtru median pentru eliminarea zgomotului din semnalul ECG. După cum s-a menționat mai devreme, deviația liniei izoelectrice se situează între 0-0,5 Hz. Prin urmare, dacă se elimină această bandă de frecvență specifică, se poate scăpa de zgomot. Filtrul median este un filtru care face posibilă eliminarea unei valori divergente prin schimbarea valorii divergente dintr-o serie finită cu valoarea mediană din aceeași serie. Adică este o tehnică de filtrare digitală neliniară, utilizată adesea pentru a elimina zgomotul. Această reducere a zgomotului este o etapă tipică de preprocesare pentru a îmbunătăți rezultatele procesării ulterioare. Ideea principală a filtrului median este de a parcurge semnalul intrare cu intrare, înlocuind fiecare intrare cu mediana intrărilor vecine. Modelul de vecinătate se numește "fereastră", care alunecă, intrare cu intrare, peste întregul semnal. Funcția consideră că semnalul este 0 dincolo de punctele de capăt, iar ieșirea are aceeași lungime cu semnalul original [82]. În Figura 2.32 este reprezentată derivația V5 înainte și după aplicarea filtrării mediene în scopul eliminării variației liniei izoelectrice. Cu roz este reprezentat semnalul inițial, iar cu negru este semnalul obținut în urma aplicării filtrului.

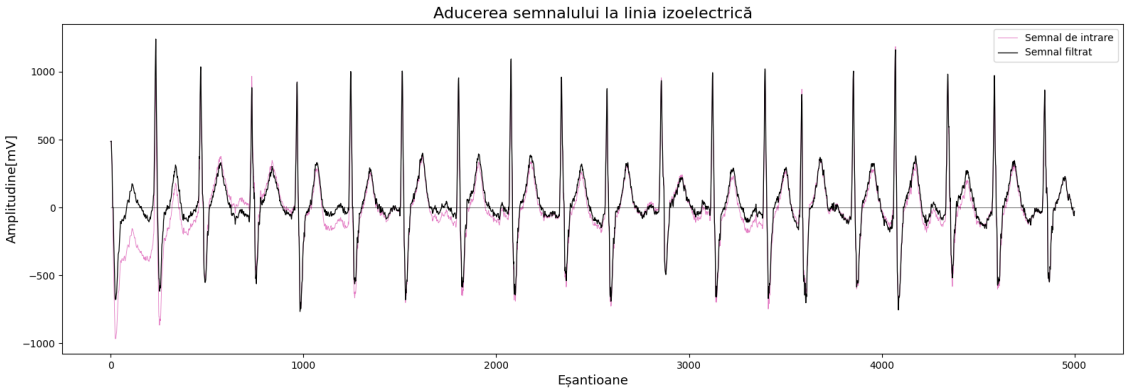


Figura 2.13 Reprezentarea semnalului înainte și după filtrare

De asemenea, în Figura 2.33, este evidențiată diferența dintre semnalul inițial și semnalul obținut în urma filtrării. Se constată că prima parte a semnalului prezintă artefacte de mișcare mai pronunțate, de aceea apare o modificare mai mare la nivelul liniei izoelectrice. Prin aplicarea acestui filtru se dorește menținerea amplitudinilor la valori cât mai apropiate de valoarea inițială și translatarea semnalului pentru aducerea acestuia la linia izoelectrică. Cele două figuri de mai jos reprezintă codul corespunzător definirii filtrului median. Figura 2.34 reprezintă funcția care definește filtrul, iar Figura 2.35 implică aplicarea acestuia și reprezentarea grafică. Filtrul median este un filtru extrem de neliniar; ieșirea acestuia la o poziție n este mediana valorilor care se află în domeniul de aplicare al ferestrei; de exemplu,

este valoarea care se află la mijloc atunci când eșantioanele sunt ordonate în ordine. Prin urmare, filtrarea mediană necesită sortare pentru fiecare calcul, iar acest lucru o face și destul de lentă.

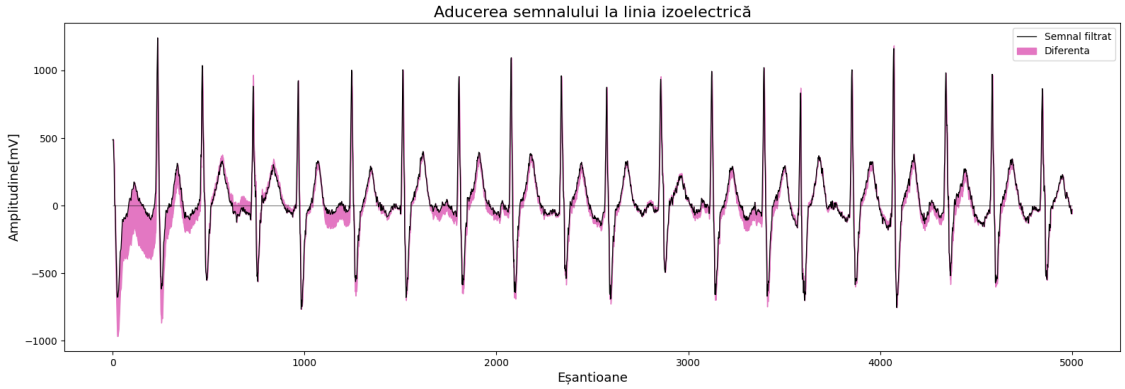


Figura 2.14 Diferența dintre semnalul semnalul original și semnalul filtrat

```
#%%
# Filtrarea semnalului
# Se utilizeaza filtrarea mediana -  filtrul de 200ms urmat de filtrul de 600 ms

def get_median_filter_width(sampling_rate, duration):
    res = int( sampling_rate*duration )
    res += ((res%2) - 1)
    return res

# Definirea parametrilor de filtrare
ms_flt_array = [0.2,0.6]    # lungimea filtrelor  (în secunde)
mfa = np.zeros(len(ms_flt_array), dtype='int')
for i in range(0, len(ms_flt_array)):
    mfa[i] = get_median_filter_width(frecventa_esantionare,ms_flt_array[i])
```

Figura 2.15 Codul corespunzător definirii filtrului median

Filtrul median este utilizat în principal pentru îndepărtarea zgomotului de tip sare și piper; în esență, acestea sunt eșantioane de zgomot local a căror filtrare în domeniul frecvenței nu este posibilă fără a degrada întregul semnal. Astfel de vârfuri locale (în timp) vor avea spectre de frecvență cu bandă largă care inhibă modificările în domeniul frecvenței pentru a le elimina, lăsând astfel posibile doar abordările în domeniul timpului (sau în domeniul timp-frecvență) [83]. Acest filtru are tendința de a păstra marginile, fiind astfel preferat în anumite operațiuni. Cu toate acestea, are și efectul secundar de a obține rezultate de tip "estompare" (detaliile se pierd și rămân doar marginile puternice), ceea ce indică faptul că utilizarea lor trebuie făcută cu grijă [84].

```
#%%

def filter_signal(X):
    global mfa
    X0 = X  # citirea semnalului original
    for mi in range(0,len(mfa)):
        X0 = medfilt(X0,mfa[mi]) # aplicare filtrul median unul câte unul unul peste celălalt
    X0 = np.subtract(X,X0)  # eliminarea semnalului original
    return X0


signal_flt = filter_signal(signal_den)
plt.figure(figsize=(40,6))

plt.plot(signal_den, color='tab:pink', linewidth=0.6,label = 'Semnal de intrare')
plt.plot(signal_flt, color='black', linewidth=0.9,label = 'Semnal filtrat')
plt.hlines(0,0,5000,color='black', linewidth=0.4)
plt.legend()
plt.xlabel('Eșantioane',fontsize=13)
plt.ylabel('Amplitudine[mV]',fontsize=13)
plt.title('Aducerea semnalului la linia izoelectrică',fontsize=16)
plt.show()

plt.figure(figsize=(40,6))
plt.plot(signal_flt, color='black', linewidth=0.9,label = 'Semnal filtrat')
plt.fill_between(np.arange(0,5000,1),signal_den,signal_flt,color='tab:pink',label = 'Diferenta')
plt.hlines(0,0,5000,color='black', linewidth=0.4)
plt.legend()
plt.xlabel('Eșantioane',fontsize=13)
plt.ylabel('Amplitudine[mV]',fontsize=13)
plt.title('Aducerea semnalului la linia izoelectrică',fontsize=16)
plt.show()
```

Figura 2.16 Codul corespunzător aplicării filtrului și afișării rezultatului

În principiu, cu cât dimensiunea ferestrei este mai mare, cu atât mai puternic va fi efectul de estompare. Prin urmare, se obișnuiește să se utilizeze dimensiuni ale ferestrei cât mai reduse posibil (cu excepția cazului în care aplicația respectivă impune altceva [85]). Revenind la exemplul prezentat, dacă se utilizează o dimensiune a ferestrei mai mare, detaliile locale care ar putea fi importante ar putea fi pierdute, de asemenea se poate modifica amplitudinea semnalului, deci se alege o dimensiune a ferestrei mai mică. După cum se poate observa în Figura 2.34 și în Figura 2.35, se aplică filtrarea mediană de două ori, prima oară utilizând o dimensiune a ferestrei de 200ms (adică 100 de eșantioane), iar a doua oară se utilizează o dimensiune mai mare, de 600ms (adică 400 de eșantioane). În continuare s-a studiat ordinea în care trebuie aplicate cele două operații de preprocesare, pentru a avea rezultate optime. O primă încercare a fost realizarea operației de eliminare a zgomotului, prin intermediul transformatei Wavelet, precedată de operația de eliminare a variației liniei izoelectrice, prin utilizarea filtrării mediene. Acest rezultat este prezentat în Figura 2.36. Cea de-a doua încercare implică ordinea inversă a operațiilor, astfel se realizează prima oară eliminarea variației liniei izoelectrice, prin utilizarea filtrării mediene, ulterior se efectuează operația de eliminare a zgomotului, prin intermediul transformatei Wavelet. Acest rezultat este prezentat în Figura 2.37. Pentru compararea celor două proceduri se realizează graficul prezentat în Figura 2.38, unde cu mov

este reprezentat semnalul care a fost prima oară filtrat cu transformata Wavelet, ulterior a fost adus la linia izoelectrică cu ajutorul filtrului median, iar cu roșu semnalul care a suferit cele două operații în ordine inversă.

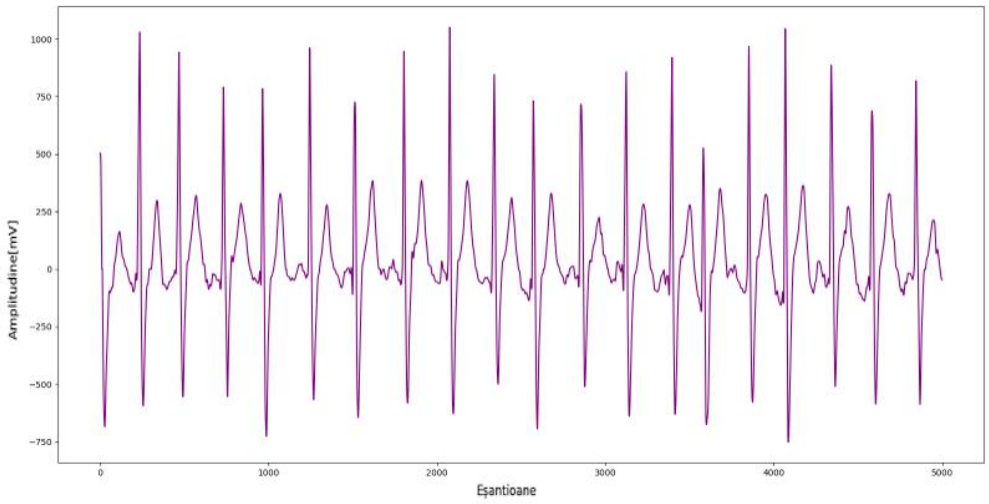


Figura 2.17 Semnalul obținut după eliminarea zgomotului, urmată de eliminarea variației liniei izoelectrice

Diferența dintre cele două rezultate este colorată cu cyan, pentru un contrast puternic. Se constată că semnalul reprezentat cu mov are o variație mai scăzută a liniei izoelectrice, ceea ce înseamnă că prezintă o eficiență mai ridicată. Prin urmare, conform Figurii 1.38, se constată că utilizarea unui filtru realizat prin transformata Wavelet, pentru eliminarea zgomotului, urmat de aplicarea unui filtru median, duce la rezultate mai bune decât inversarea operațiilor. Codul corespunzător celor 3 poze anterioare (1.36, 1.37, 1.38) este prezentat în Figura 2.39.

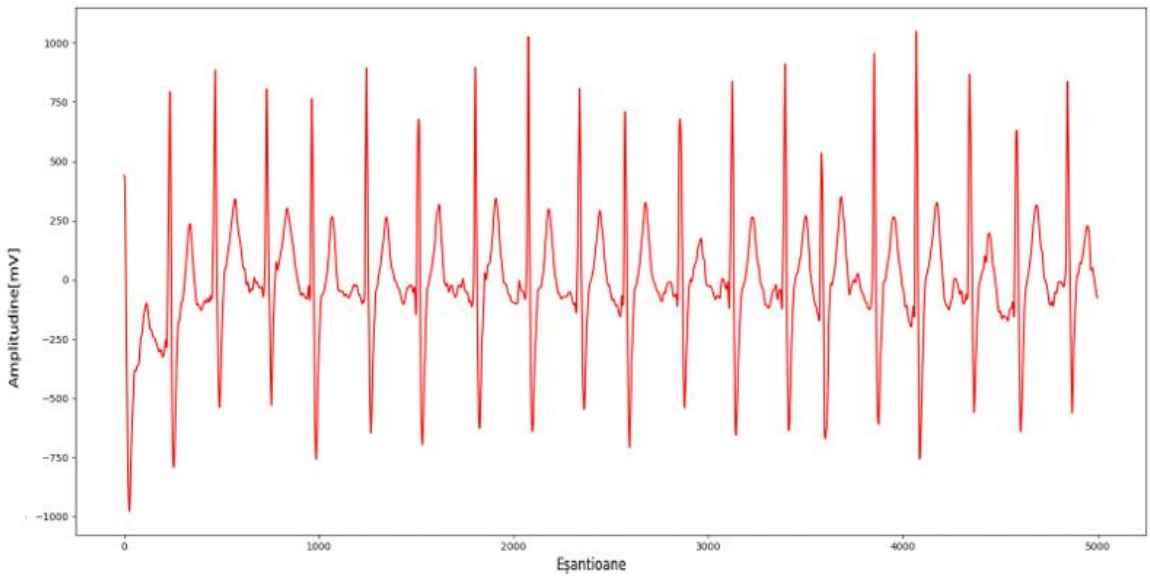


Figura 2.18 Semnalul obținut după eliminarea variației liniei izoelectrice, urmată de eliminarea zgomotului

Se aplică filtrul trece bandă de tip Butterworth cu frecvențe de tăiere de 1 și 40 Hz, care este domeniul de interes tipic în semnalele ECG. Cu toate acestea, aplicarea acestui filtru este perfectă pentru acest tip de aplicație, însă este posibil să nu fie potrivită pentru alte tehnici utilizate pe ECG. Filtrul Butterworth este un filtru de procesare a semnalului care are rolul de a oferi un răspuns în frecvență cât mai plat posibil la aplicarea filtrului trece-bandă, fiind numit și un filtru de magnitudine maxim aplatizată.

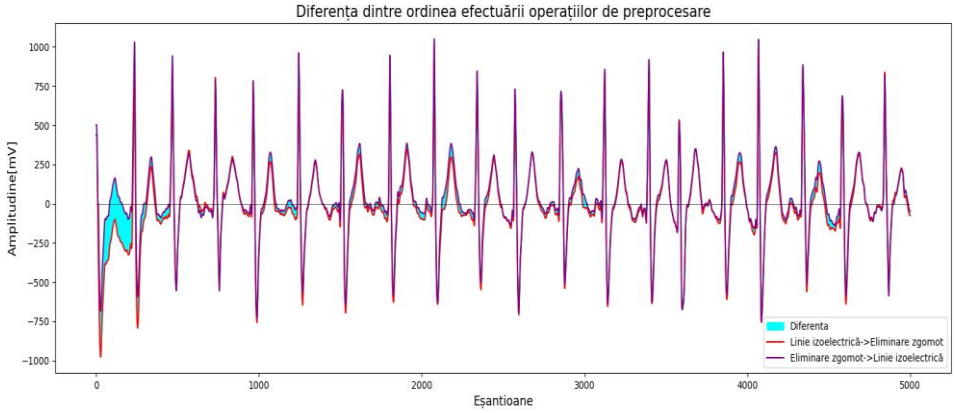


Figura 2.19 Diferența apărută în semnal în funcție de ordinea realizării operațiilor de preprocesare

```
#%%
# Studierea interschimbarii eliminare zgomot - aducere la linia izoelectrica
# Eliminarea zgomotului mai întâi și apoi montarea liniei de bază pare să funcționeze mai bine


s1 = denoise_signal(filter_signal(signal),'bior4.4', 9 , 1 , 7)
# prima oară aducere la linia de bază, apoi eliminare zgomot


s2 = filter_signal(denoise_signal(signal,'bior4.4', 9 , 1 , 7))
# prima oara eliminare zgomot, apoi aducere la linia de bază

plt.figure(figsize=(40,6))
#plt.plot(signal, color='black', linewidth=0.4,label = 'input')
plt.fill_between(np.arange(0,5000,1),s1,s2,color='cyan',label = 'Diferenta')
plt.plot(s1, color='red',label = 'Linie izoelectrică->Eliminare zgomot')
plt.show()
plt.plot(s2, color='purple',label = 'Eliminare zgomot->Linie izoelectrică')
plt.show()
plt.hlines(0,0,5000,color='black', linewidth=0.4)
plt.legend()
plt.xlabel('Eșantioane',fontsize=13)
plt.ylabel('Amplitudine[mV]',fontsize=13)
plt.title('Diferența dintre ordinea efectuării operațiilor de preprocesare',fontsize=16)
plt.show()
```

Figura 2.20 Codul corespunzător studierii ordinei efectuării operațiilor

În Figura 2.40 este ilustrat comportamentul unor filtre Butterworth de ordine diferite pe un semnal ECG zgomotos. Așadar, după eliminarea zgomotului și aducerea semnalului la linia izoelectrică , s-a aplicat un filtru trece bandă de tip Butterworth pentru eliminarea zgomotului

specific înregistrărilor de tipul ECG. Mai exact, s-a folosit o frecvență de taiere de 1 [Hz], respectiv 40 [Hz], aplicată pe un filtru de ordin 7. Rezultatul obținut este prezentat în Figura 2.41.

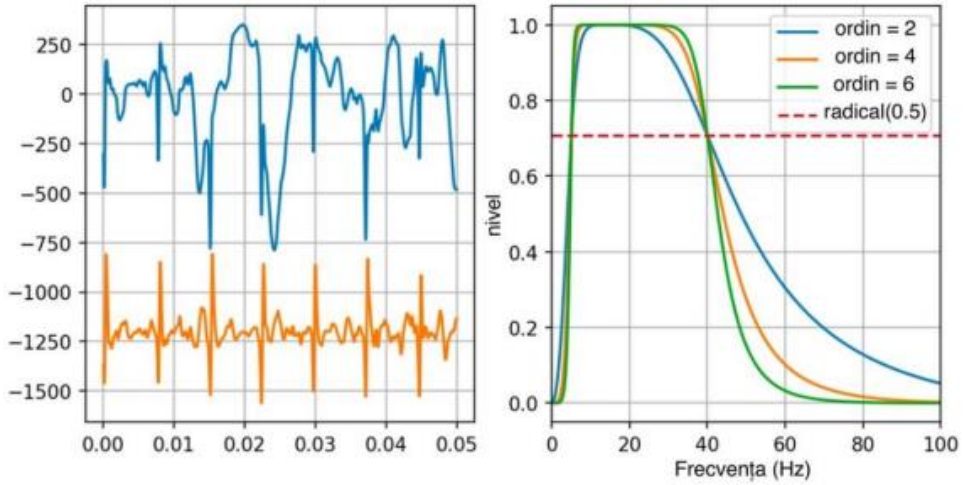


Figura 2.21 Comportamentul filtrului Butterworth

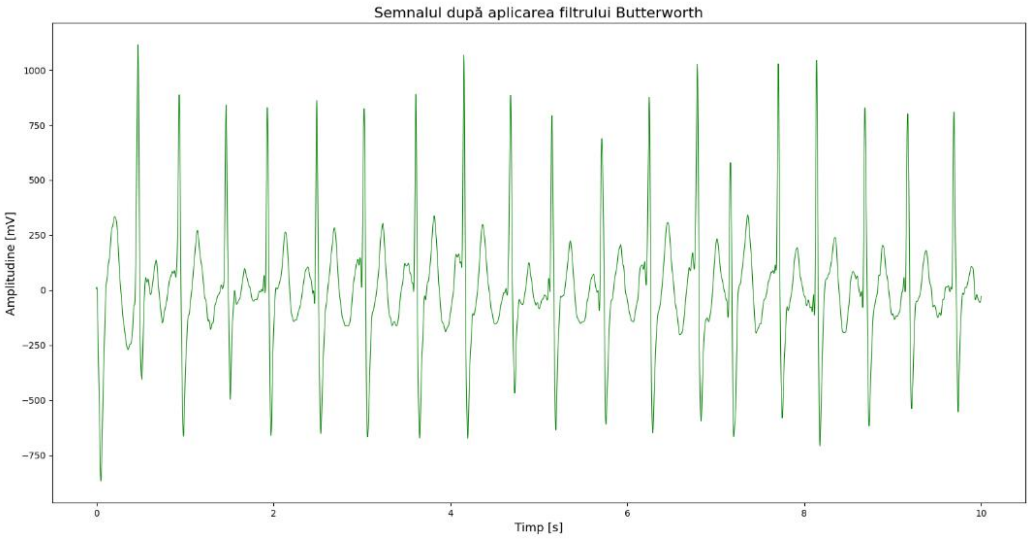


Figura 2.22 Semnalul rezultat în urma aplicării filtrului Butterworth

Codul corespunzător filtrării este prezentat în Figura 2.42. Pentru a observa modificarea în urma filtrării s-a ales o reprezentare în frecvență în urma căreia se observă o scădere în amplitudine, cât și eliminarea frecvențelor mai mici de 1 [Hz], respectiv mai mari de 40 [Hz]. Codul corespunzător aceste etape se regăsește în Figura 2.44, iar în Figura 2.43 este rezultatul în frecvență obținut în urma filtrării.

```
#%%

#Preluam lungimea semnalului (numarul de esantioane) pentru a crea vectorul de timp dupa care reprezentam grafic
lenght=len(s2)

#Cream vectorul pentru timp care pleaca de la 0, are lungimea numarului de esantioane/frecventa de esantionare
#si e compus din nr. esantioane/500 elemente

# Se cunoaste frecventa de esantionare de 500 esantioane/secunda
t=np.linspace(0, lenght, lenght)/500

from scipy import signal
#Aplicam filtrul Butterworth de ordin 7, de tip bandpass cu frecventele de taiere de 1 si 40 Hz,
#numerator/denominator ('ba') si frecventa de esantionare 500)

b,a=signal.butter(7, [1,40], btype='bandpass', output='ba', fs=500)
output=signal.filtfilt(b,a, s2)

#Vizualizam rezultatul
plt.plot(t, output, color='green',linewidth=0.8)
plt.title('Semnalul după aplicarea filtrului Butterworth', fontsize=16)
plt.ylabel('Amplitudine [mV]', fontsize=13)
plt.xlabel('Timp [s]', fontsize=13)
plt.show()
```

Figura 2.23 Codul corespunzător filtrării semnalului folosind un filtru Butterworth

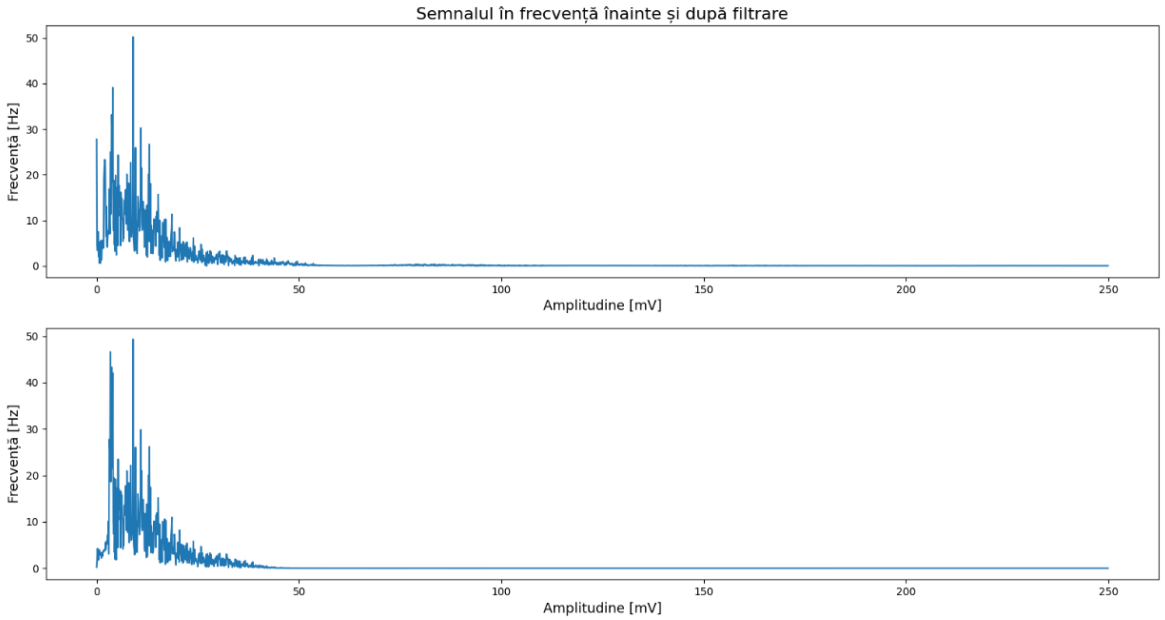


Figura 2.24 Reprezentarea în frecvență a semnalului înainte și după filtrare

```
#%%

# Reprezentarea in frecventa folosind transformata fourier
# inainte de filtrare
fourierTransform = np.fft.fft(s2)/len(s2)
fourierTransform = fourierTransform[range(int(len(s2)/2))]
tpCount     = len(s2)
values      = np.arange(int(tpCount/2))
timePeriod  = tpCount/500
frequencies = values/timePeriod


# dupa filtrare
fourierTransform1 = np.fft.fft(output)/len(output)
fourierTransform1 = fourierTransform1[range(int(len(output)/2))]
tpCount1     = len(output)
values1      = np.arange(int(tpCount1/2))
timePeriod1  = tpCount1/500
frequencies1 = values1/timePeriod1

# Vizualizarea semnalului in frecventa
figure, axis =plt.subplots(2)
axis[0].plot(frequencies, abs(fourierTransform))
axis[0].set_title('Semnalul în frecvență înainte și după filtrare', fontsize=16)


axis[1].plot(frequencies1, abs(fourierTransform1))
for ax in axis.flat:
    ax.set(xlabel='Amplitudine [mV]', ylabel='Frecvență [Hz]', fontsize=13)
plt.show()
```

Figura 2.25 Codul corespunzător reprezentării în frecvență a semnalului înainte și după filtrare

2.6.2. Extragerea caracteristicilor

Deoarece vârfurile R sunt cele mai importante componente ale semnalelor ECG și sunt cei mai importanți agenți care sunt utilizați pentru a diagnostica starea fiziologică. Așadar, detectarea vârfurilor R este o sarcină critică. În aceast proiect se utilizează mai multe tehnici pentru a detecta vârfurile R și apoi, printr-o procedură simplă, se calculează intervalul R-R dintre două vârfuri. Fiecare semnal are durata sa și fiecare conține un număr de bătăi ale inimii și intervale R-R diferite de celălalt, ceea ce duce la un set de date neuniform. Pentru comparație, se utilizează în continuare 6 tehnici de extragere a caracteristicilor, mai precis a poziției vârfurilor R: „ Engelse și Zeelenberg”, „ Medie dublă mobilă”, „ Transformata Wavelet Staționară”, „Pan Tompkins”, „ P.S. Hamilton”, „ Ivaylo I. Christov” și o bibliotecă specializată, denumită Biosppy.

```
#%%

#Scoatem informatii despre pozitia varfurilor R
#Libraria returneaza un tuplu format din mai multe liste cu informatii (ex bataile inimii),
#dintre care noi alegem al 3-lea element, cel cu pozitia varfuriilor R
semnal_bio=biosppy.signals.ecg.ecg(signal=output, sampling_rate=500, show=True)
plt.show()
# print(semnal_bio)
rpeaks=semnal_bio[2]
```

Figura 2.26 Extragerea vârfurilor R folosind biblioteca Biosppy

```
#% Detectare varfuri R cu algoritmi cunoscuti

#christov_detector pare să funcționeze cel mai bine pentru majoritatea cazurilor

from ecgdetectors import Detectors
detectors = Detectors(frecventa_esantionare)


signal_pad_samples = 10
signal_pad = np.zeros(signal_pad_samples) # padding de o secundă pentru a detecta vârfurile inițiale în mod corespunzător
signalf = signal_flt
detectors = Detectors(frecventa_esantionare)

detectors = {
            'Detector Pan_Tompkins':[detectors.pan_tompkins_detector, []],
            'Detector P.S. Hamilton':[detectors.hamilton_detector, []],
            'Detector Ivaylo I. Christov':[detectors.christov_detector, []],
            'Detector Engelse și Zeelenber':[detectors.engzee_detector, []],
            'Detector Transformata Wavelet Staționară':[detectors.swt_detector, []],
            'Detector Media dublă mobilă':[detectors.two_average_detector, []],
            }
```

a) Definirea celor 6 tehnici de detectare a vârfurilor R

```
#%%

for kd in detectors.keys():
    vd = detectors[kd]
    r_peaks = np.array(vd[0](np.hstack((signal_pad,signal_flt)))) - signal_pad_samples
    ritm=[]
    # for i in r_peaks:
    #     ritm=ritm.append(60*500/(r_peaks[i+1]-r_peaks[i]))
    #     print(ritm)
    vd[1] = r_peaks
    plt.figure(figsize=(40,6))
    plt.title(kd)
    plt.plot(signalf,color='green',linewidth=0.8)
    plt.hlines(0,0,5000,color='black', linewidth=0.4)
    plt.xticks(r_peaks)
    plt.xlabel('Eșantioane',fontsize=13)
    plt.ylabel('Amplitudine[mV]',fontsize=13)
    plt.grid(axis='x')
    plt.show()

data_signal = signalf
data_peaks = detectors['Detector Ivaylo I. Christov'][1]
```

b) Apelarea detectorilor și reprezentarea grafică

Figura 2.27 Codul pentru implementarea tehnicilor de detectare a vârfurilor R

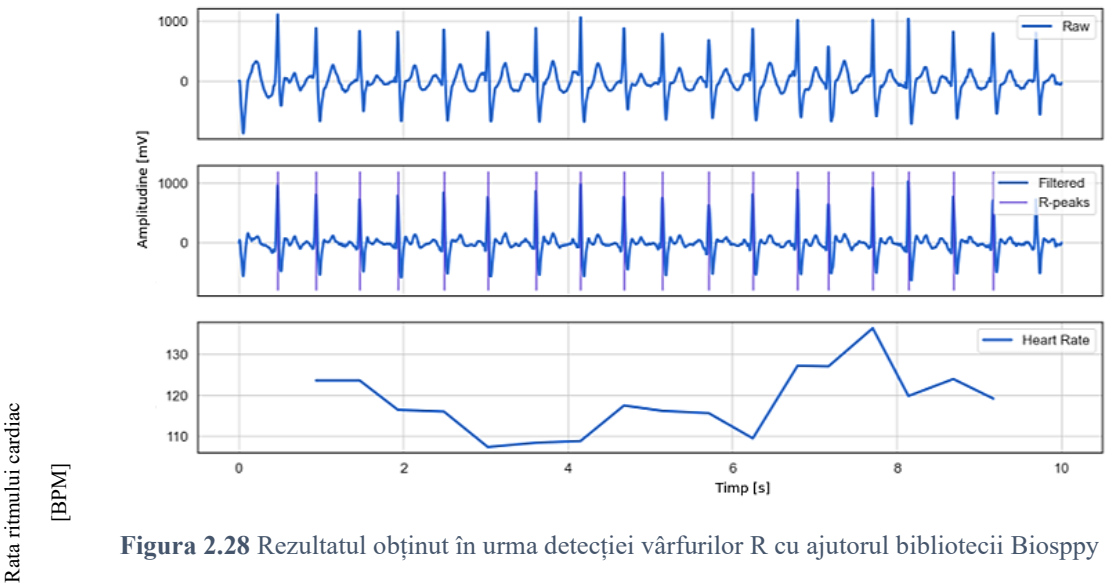


Figura 2.28 Rezultatul obținut în urma detecției vârfurilor R cu ajutorul bibliotecii Biosppy

În Figura 2.45 este prezentat codul pentru extragerea vârfurilor R cu ajutorul bibliotecii Biosppy, iar în Figura 2.46 este prezentat codul pentru implementarea celor 6 tehnici prezentate anterior. Rezultatul obținut în urma detecției vârfurilor R cu ajutorul bibliotecii Biosppy este prezentat în Figura 2.47, care returnează și un grafic al variației ritmului cardiac în timp. Acest grafic poate fi obținut și prin calcularea intervalelor R-R și calcularea ritmului cardiac corespunzător fiecărui ciclu. Codul corespunzător acestei etape este prezentat în Figura 2.49. Pentru extragerea caracteristicilor folosind librăria Biosppy, s-a obținut atât o reprezentare vizuală, cât și o listare. Listele conțin informații despre axa timpului, vectorul de valori din semnalul ECG, locațiile vârfurilor R și informațiile despre ritmul cardiac. Pentru determinarea intervalelor R-R s-a creat o listă la nivelul căreia s-a atașat rezultatul returnat de librăria Biosppy, care conține pozițiile vârfurilor R. După aceea, s-a folosit o buclă care trece prin elementele listei, făcând diferența între două vârfuri consecutive. S-au parcurs toate semnalele, iar pentru fiecare, lista intervalelor R-R obținute a fost atașată la o structura de tip DataFrame. Pentru obținerea variației ritmului cardiac fără utilizarea bibliotecii specializate se pleacă de la poziția vârfurilor R, determinată cu ajutorul detectorilor se obțin intervalele R-R prin diferența a două vârfuri R consecutive, iar apoi se împart 60 de secunde la fiecare interval în parte și se înmulțește cu frecvența de eșantionare pentru a determina ritmul cardiac. Rezultatul acestei secvențe de cod este prezentat în Figura 2.48. Presupunând că S este semnalul ECG cu $x = x_0$, $x_1, x_2, \ldots, x_n$, cu n+1 eșantioane din interiorul semnalului, n poate fi calculat prin n = durata semnalului * rata de eșantionare. După detectarea vârfurilor R se obține un alt vector p, acesta fiind de forma $p = p_0, p_1, p_2, \ldots, p_m$ unde m+1 este numărul de elemente din vector, însă m nu poate fi calculat deoarece depinde de ritmul cardiac al pacientului. Intervalele R-R sunt de

asemenea stocate într-un alt vector i, acesta fiind definit astfel i = i_0, i_1, i_2, . . . , i_k unde k = m−1 și i este definit ca o secvență $i_n = p_{(n+1)} - p_n$. Din variația ciclului cardiac se pot extrage informații despre starea fiziologică a subiectului. Aceste informații trebuie validate cu cel puțin o inspecție vizuală, dar pentru o acuratețe mai mare trebuie să fie corelate cu semnale EEG. În Figura 2.48 se observă o variație destul de puternică a ritmului cardiac între ciclul cardiac cu numărul 10 și ciclul cardiac cu numărul 14, având o trecere de la 110 bătăi pe minut, până la 160 de bătăi pe minut, într-o perioadă restrânsă de timp.

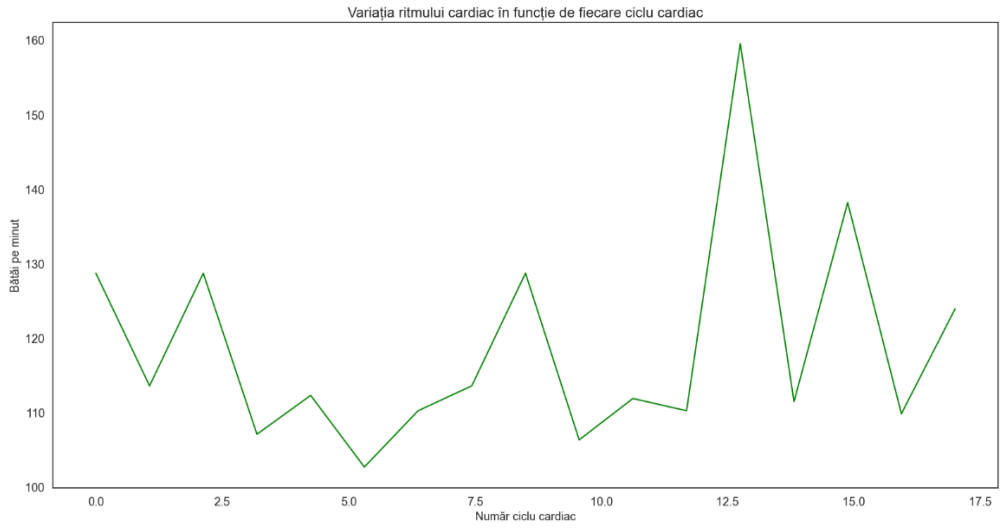


Figura 2.48 Variația ritmului cardiac în funcție de ciclurile cardiace

```
#%%

# Cream o lista goala in care vom atasa fiecare semanl RR
RR=[]
df_nou=pd.DataFrame()
# Vom trece prin atatea elemene cate are lista de vectori cu varfurile R
for x in range(len((rpeaks)+1)):

   # Pentru a gasi intervalul vom face diferenta intre pozitia unuia dintre
   # varfuri si cel anterior, apoi vom atasa rezultatul la lista.
     Rinterval=rpeaks[x]-rpeaks[x-1]
     RR.append(60*500/Rinterval)
     RR1=RR[1:]
# Lista obtinuta o atasam la cel de-al doilea DataFrame (declarat in interiorul buclei,
#care isi reseteaza valoare), pe care apoi il vom lipi de primul DataFrame
df_nou=df_nou.append(RR1)
print(df_nou)

lenght=len(df_nou)

#Cream vectorul pentru timp care pleaca de la 0, are lungimea numarului de esantioane/frecventa de esantionare
#si e compus din nr. esantioane/500 elemente

# Se cunoaste frecventa de esantionare de 500 esantioane/secunda
t=np.linspace(0, lenght, lenght)

plt.plot(t, df_nou, label= "Ritm cardiac", color= "green")
plt.title('Variația ritmului cardiac în funcție de fiecare ciclu cardiac', fontsize=16)
plt.ylabel('Bătăi pe minut', fontsize=13)
plt.xlabel('Număr ciclu cardiac', fontsize=13)
plt.show()
```

Figura 2.49 Codul corespunzător afișării variației ritmului cardiac în funcție de intervale R-R

3. Concluzii

Raportul 4 din cadrul tezei de doctorat *„Contribuții privind sistemele de evaluare automată a capacității de conducere a vehiculelor”* a avut ca obiectiv principal analiza avansată a procesării semnalelor ECG, cu accent pe tehnicile utilizate pentru eliminarea zgomotului, detectarea caracteristicilor morfologice și interpretarea acestora. A fost detaliată importanța electrocardiogramei (ECG) în monitorizarea stării fiziologice și emoționale a conducătorilor auto, explorându-se metodele de preprocesare a semnalelor și extragerea caracteristicilor relevante, precum undele R și parametrii variabilității ritmului cardiac (HRV). În cadrul acestui raport, s-au prezentat tehnici pentru eliminarea artefactelor, filtrarea zgomotului și optimizarea calității semnalului, contribuind la dezvoltarea unei baze solide pentru evaluarea stării conducătorului auto în timp real. Raportul a integrat aspecte teoretice și aplicative, evidențiind relevanța prelucrării semnalelor ECG pentru detectarea stărilor critice precum stresul sau oboseala, care pot afecta performanța la volan.

În continuarea cercetării, **Raportul 5** se va concentra pe tehnicile de detecție a vârfurilor R, esențiale pentru analiza ECG. Vor fi detaliate și comparate 6 metode consacrate de detecție a undelor R: Algoritmul Pan-Tompkins, Algoritmul Hamilton-Tompkins, Transformata Wavelet Staționară (SWT), Metoda de detecție Christov, Metoda de detecție Elgendi – media dublă mobile, Metoda de detecție Engzee. Pe lângă analiza acestor metode, raportul va explora utilizarea soluțiilor inovatoare bazate pe inteligența artificială (IA) pentru evaluarea capacității de conducere a vehiculelor. Se vor introduce noțiuni fundamentale despre IA, precum și detalii despre algoritmi de învățare supervizată și nesupervizată, incluzând tehnici avansate de deep learning. De asemenea, va fi realizată o analiză comparativă a bibliotecilor Python utilizate pentru recunoașterea modelelor, cu accent pe performanța acestora în aplicații legate de siguranța rutieră. Aceste demersuri vor extinde direcțiile de cercetare abordate în raportele anterioare, completând cunoștințele despre procesarea semnalelor ECG și integrarea inteligenței artificiale. Scopul este de a crea un cadru științific robust pentru dezvoltarea unor sisteme inteligente avansate, capabile să monitorizeze starea conducătorilor auto în timp real, să identifice situațiile critice și să implementeze măsuri proactive pentru creșterea siguranței rutiere. Aceste sisteme vor contribui, de asemenea, la transformarea vehiculelor viitorului în platforme adaptative, care să sprijine activ șoferii prin furnizarea de asistență personalizată și prevenirea incidentelor cauzate de factori umani.

4. Bibliografie

[1] A. C. (Adam C. Gacek and W. Pedrycz, “ECG signal processing, classification and interpretation : a comprehensive framework of computational intelligence,” p. 278, 2012, Accessed: Aug. 17, 2022. [Online]. Available: https://books.google.com/books/about/ECG_Signal_Processing_Classification_and.html?hl=ro&id=lPTiGqPKY94C

[2] J. R. Hampton and J. (Consultant physician) Hampton, “The ECG made easy,” p. 194.

[3] “Electrocardiography - Wikipedia.” https://en.wikipedia.org/wiki/Electrocardiography (accessed Aug. 17, 2022).

[4] J. Kepler, “ECG Preprocessing,” 2016. [Online]. Available: www.jku.atDVR0093696

[5] M. S. Thaler, “EKG book You ’ ll Ever Need,” p. 234, 2019, Accessed: Aug. 17, 2022. [Online]. Available: https://www.scribd.com/document/525618715/The-Only-EKG-Book-You-Ll-Ever-Need

[6] R. Jane, P. Laguna, N. v. Thakor, and P. Caminal, “Adaptive baseline wander removal in the ECG: Comparative analysis with cubic spline technique,” *Proceedings - Computers in Cardiology, CIC 1992*, pp. 143–146, 1992, doi: 10.1109/CIC.1992.269426.

[7] Y.-D. Lin and Y. H. Hu, “Power-Line Interference Detection and Suppression in ECG Signal Processing,” *IEEE Trans Biomed Eng*, vol. 55, no. 1, pp. 354–357, 2008, Accessed: Aug. 18, 2022. [Online]. Available: https://www.academia.edu/51396923/Power_Line_Interference_Detection_and_Suppression_in_ECG_Signal_Processing

[8] T. P. Pander, “A suppression of an impulsive noise in ECG signal processing,” *Conf Proc IEEE Eng Med Biol Soc*, vol. 2006, pp. 596–599, 2004, doi: 10.1109/IEMBS.2004.1403228.

[9] M. Malik *et al.*, “Heart rate variability: Standards of measurement, physiological interpretation, and clinical use,” *Circulation*, vol. 93, no. 5, pp. 1043–1065, Mar. 1996, doi: 10.1161/01.CIR.93.5.1043.

[10] Kitney and Rompelman, “The Study of heart-rate variability / edited by R. I. Kitney and O. Rompelman.,” 1980.

[11] G. D. Clifford, “ECG Statistics, Noise, Artifacts, and Missing Data,” 2006.

[12] \ R Shouldice, I. C. Heneghan, I. P. Nolan, P. G. Nolan, and W. Mcnicholas, “Modulating effect of respiration on atrioventricular conduction time assessed using PR interval variation”.

[13] A. A. Fossa, “The impact of varying autonomic states on the dynamic beat-to-beat QT-RR and QT-TQ interval relationships,” *Br J Pharmacol*, vol. 154, pp. 1508–1515, 2008, doi: 10.1038/bjp.2008.123.

[14] C. Yosefy, A. Cantor, L. Reisin, S. Efrati, and R. Ilia, “The diagnostic value of QRS changes for prediction of coronary artery disease during exercise testing in women: False-positive rates,” *Coron Artery Dis*, vol. 15, no. 3, pp. 147–154, May 2004, doi: 10.1097/00019501-200405000-00003.

[15] D. Attwell, I. Cohen, and D. A. Eisner, “THE EFFECTS OF HEART RATE ON THE ACTION POTENTIAL OF GUINEA-PIG AND HUMAN VENTRICULAR MUSCLE,” 1981.

[16] R. Shouldice, C. Heneghan, and P. Nolan, “Methods of quantifying respiratory modulation in human PR electrocardiographic intervals,” *Annual International Conference of the IEEE Engineering in Medicine and Biology - Proceedings*, vol. 2, pp. 1622–1623, 2002, doi: 10.1109/IEMBS.2002.1106569.

[17] S. Ward, R. B. Shouldice, M. Flanagan, and C. Heneghan, “Electrocardiogram sampling frequency errors in PR interval spectral analysis.” [Online]. Available: https://www.researchgate.net/publication/250102385

[18] G. D. Clifford and L. Tarassenko, “Segmenting cardiac-related data using sleep stages increases separation between normal subjects and apn ic patients,” *Physiol Meas*, vol. 25, no. 6, pp. N27–N35, 2004, Accessed: Aug. 19, 2022. [Online]. Available: https://www.academia.edu/55817715/NOTE_Segmenting_cardiac_related_data_using_sleep_stages_increases_separation_between_normal_subjects_and_apnoeic_patients

[19] G. D. Clifford and L. Tarassenko, “Quantifying Errors in Spectral Estimates of HRV Due to Beat Replacement and Resampling,” *IEEE Trans Biomed Eng*, vol. 52, no. 4, 2005, doi: 10.1109/TBME.2005.844028.

[20] J. E. Mietus, C.-K. Peng, I. Henry, and R. L. Goldsmith, “The pNNx files: re-examining a widely used heart rate variability measure”, doi: 10.1136/heart.88.4.378.

[21] G. B. Moody, “PhysioNet: Research Resource for Complex Physiologic Signals”, Accessed: Aug. 19, 2022. [Online]. Available: http://physionet.org/

[22] E. L. Grogan *et al.*, “Reduced heart rate volatility: an early predictor of death in trauma patients.,” *Ann Surg*, vol. 240, no. 3, pp. 547–54; discussion 554, Sep. 2004, doi: 10.1097/01.SLA.0000137143.65540.9C.

[23] Marek. Malik and A. John. Camm, *Heart rate variability*. Armonk NY: Futura Pub. Co, 1995.

[24] M. P. Griffin and J. R. Moorman, “Toward the early diagnosis of neonatal sepsis and sepsis-like illness using novel heart rate analysis,” *Pediatrics*, vol. 107, no. 1, pp. 97–104, 2001, doi: 10.1542/PEDS.107.1.97.

[25] A. Porta, M. Hasan, A. Voss, T. Ziemssen, K. Li, and H. Rüdiger, “Spectral Analysis of Heart Rate Variability: Time Window Matters,” *Frontiers in Neurology | www.frontiersin.org*, vol. 1, p. 545, 2019, doi: 10.3389/fneur.2019.00545.

[26] J. A. Taylor, D. L. Carr, C. W. Myers, and D. L. Eckberg, “Mechanisms Underlying Very-Low-Frequency RR-Interval Oscillations in Humans,” 1998. [Online]. Available: http://ahajournals.org

[27] J. M. Serrador, H. C. Finlayson, and R. L. Hughson, “Physical activity is a major contributor to the ultra low frequency components of heart rate variability”, doi: 10.1136/hrt.82.6.e9.

[28] G. D. Clifford and L. Tarassenko, “Segmenting cardiac-related data using sleep stages increases separation between normal subjects and apnœic patients,” *Physiol Meas*, vol. 25, no. 6, 2004, doi: 10.1088/0967-3334/25/6/N03.

[29] N. R. Lomb, “LEAST-SQUARES FREQUENCY ANALYSIS OF UNEQUALLY SPACED DATA,” 1976.

[30] “Spectral Analysis of Heart Rate Without Resampling.” http://archive.physionet.org/physiotools/lomb/ (accessed Aug. 19, 2022).

[31] J. D. Scargle, “Studies in astronomical time series analysis. II - Statistical aspects of spectral analysis of unevenly spaced data,” *undefined*, vol. 263, p. 835, Dec. 1982, doi: 10.1086/160554.

[32] J. A. Fessler and B. P. Sutton, “Nonuniform Fast Fourier Transforms Using Min-Max Interpolation,” vol. 51, no. 2, pp. 560–74, 2003.

[33] D. den Hertog, J. P. C. Kleijnen, and A. Y. D. Siem, “The Correct Kriging Variance Estimated by Bootstrapping,” *Other publications TiSEM*, 2004, Accessed: Aug. 19, 2022. [Online]. Available: https://ideas.repec.org/p/tiu/tiutis/00a66547-3e9a-4ccf-8c7b-8d62bd7b460e.html

[34] M. L. Brown and J. F. Kros, “The Impact of Missing Data on Data Mining,” *Data Mining*, pp. 174–198, 2003, doi: 10.4018/978-1-59140-051-6.CH007:

[35] J. K. Vermunt, “Causal log-linear modeling with latent variables and missing data,” *Uniwersytet śląski*, pp. 35–60, 1996, doi: 10.2/JQUERY.MIN.JS.

[36] W. H. Press, S. A. Teukolsky, W. T. Vetterling, and B. P. Flannery, “The Art of Scientific Computing Second Edition Cambridge New York Port Chester Melbourne Sydney,” 1988, Accessed: Aug. 22, 2022. [Online]. Available: http://www.nr.com

[37] G. D. Clifford and P. E. McSharry, “Generating 24-hour ECG, BP and respiratory signals with realistic linear and nonlinear clinical characteristics using a nonlinear model,” *Comput Cardiol*, vol. 31, pp. 709–712, 2004, doi: 10.1109/CIC.2004.1443037.

[38] A. L. Goldberger, L. A. N Amaral, J. M. Hausdorff, P. Ch Ivanov, C. Peng, and H. Eugene Stanley, “Self-Organized Complexity in the Physical,” *Biological, and Social Sciences*, vol. 99, Accessed: Aug. 22, 2022. [Online]. Available: www.pnas.orgcgidoi10.1073pnas.012579499

[39] C. K. Peng, S. Havlin, H. E. Stanley, and A. L. Goldberger, “Quantification of scaling exponents and crossover phenomena in nonstationary heartbeat time series,” *Chaos: An Interdisciplinary Journal of Nonlinear Science*, vol. 5, no. 1, p. 82, Aug. 1998, doi: 10.1063/1.166141.

[40] G. Consonni *et al.*, “Fractals, chaos, power laws: Minutes from an infinite paradise : Manfred Schroeder, (W.H. Freeman, New York, NY, 1991) $32.95, 429 pp,” *J Econ Dyn Control*, vol. 18, no. 5, pp. 1041–1043, 1994, doi: 10.1007/s00497-003-0165-9.

[41] M. C. Teich, S. B. Lowen, B. M. Jost, K. Vibe-Rheymer, and C. Heneghan, “Heart Rate Variability: Measures and Models,” 2000.

[42] “ivanov1996”.

[43] P. E. McSharry and B. D. Malamud, “Quantifying self-similarity in cardiac inter-beat interval time series,” in *Computers in Cardiology*, 2005, vol. 32, pp. 459–462. doi: 10.1109/CIC.2005.1588136.

[44] M. C. Teich, S. B. Lowen, B. M. Jost, K. Vibe-Rheymer, and C. Heneghan, “Heart Rate Variability: Measures and Models,” 2000.

[45] R. G. Turcott*’t *et al.*, “Fractal Character of the Electrocardiogram: Distinguishing Heart-Failure and Normal Patients,” 1996.

[46] S. B. Lowen, T. Ozaki, E. Kaplan, B. E. A. Saleh, and M. C. Teich, “Fractal Features of Dark, Maintained, and Driven Neural Discharges in the Cat Visual System,” *Methods*, vol. 24, no. 4, pp. 377–394, Aug. 2001, doi: 10.1006/METH.2001.1207.

[47] V. Tuzcu, S. Nas, T. Börklü, and A. Ugur, “Decrease in the heart rate complexity prior to the onset of atrial fibrillation,” *Europace*, vol. 8, no. 6, pp. 398–402, Jun. 2006, doi: 10.1093/EUROPACE/EUL031.

[48] “Multiscale Entropy Analysis v1.0.” https://www.physionet.org/content/mse/1.0/ (accessed Aug. 23, 2022).

[49] G. B. Moody, “ECG-based indices of physical activity,” *undefined*, pp. 403–406, 1992, doi: 10.1109/CIC.1992.269499.

[50] K. Fukuda, H. E. Stanley, and L. A. N. Amaral, “Heuristic Segmentation of a Nonstationary Time Series,” 2003.

[51] C.-C. Lo *et al.*, “Common scale-invariant patterns of sleep-wake transitions across mammalian species,” 2004. [Online]. Available: https://www.pnas.org

[52] P. C. Ivanov *et al.*, “Sleep-wake differences in scaling behavior of the human heartbeat: Analysis of terrestrial and long-term space flight data,” *Europhys Lett*, vol. 48, no. 5, p. 594, Dec. 1999, doi: 10.1209/EPL/I1999-00525-0.

[53] E. N. Brown, Y. Choe, H. Luithardt, and C. A. Czeisler, “A statistical model of the human core-temperature circadian rhythm,” *Am J Physiol Endocrinol Metab*, vol. 279, no. 3 42-3, 2000, doi: 10.1152/AJPENDO.2000.279.3.E669/ASSET/IMAGES/LARGE/H10900067007.JPEG.

[54] L. Ferini-Strambi, A. Bianchi, M. Zucconi, A. Oldani, V. Castronovo, and S. Smirne, “The impact of cyclic alternating pattern on heart rate variability during sleep in healthy young adults,” *Clinical Neurophysiology*, vol. 111, no. 1, pp. 99–101, Jan. 2000, doi: 10.1016/S1388-2457(99)00212-6.

[55] “Derivation of Respiratory Signals from Multi-lead ECGs.” http://physionet.cps.unizar.es/physiotools/edr/cic85/edr85.html (accessed Aug. 23, 2022).

[56] M. Mms. J. E. M. B. C.-K. P. P. A. L. G. M. Robert Joseph Thomas, “An Electrocardiogram-Based Technique to Assess Cardiopulmonary Coupling During Sleep.” [Online]. Available: https://academic.oup.com/sleep/article/28/9/1151/2708244

[57] G. Clifford, L. Zapanta, B. Janz, J. Mietus, C. Youn, and R. Mark, “Segmentation of 24-hour Cardiovascular Activity Using ECG-based Sleep/Sedation and Noise Metrics”.

[58] I. Cygankiewicz, “Heart Rate Turbulence,” *Prog Cardiovasc Dis*, vol. 56, no. 2, pp. 160–171, Sep. 2013, doi: 10.1016/J.PCAD.2013.08.002.

[59] M. A. Watanabe, “Heart Rate Turbulence: A Review,” *Indian Pacing Electrophysiol J*, vol. 3, no. 1, p. 10, Jan. 2003, Accessed: Aug. 23, 2022. [Online]. Available: /pmc/articles/PMC1555628/

[60] M. A. Watanabe and G. Schmidt, “Heart rate turbulence: A 5-year review,” *Heart Rhythm*, vol. 1, no. 6, pp. 732–738, Dec. 2004, doi: 10.1016/j.hrthm.2004.09.003.

[61] I. Cygankiewicz, “Heart rate turbulence,” *Prog Cardiovasc Dis*, vol. 56, no. 2, pp. 160–171, Sep. 2013, doi: 10.1016/j.pcad.2013.08.002.

[62] “Contributions of the heart rate turbulence method to risk stratification in patients after myocardial infarction: a review - PubMed.” https://pubmed.ncbi.nlm.nih.gov/35291511/ (accessed Aug. 23, 2022).

[63] I. Savelieva, D. Wichterle, and J. A. Camm, “QT-Interval Turbulence Induced by Atrial and Ventricular Extrastimuli in Patients with Ventricular Tachycardia,” *Pacing and Clinical Electrophysiology*, vol. 28, no. SUPPL. 1, pp. S187–S192, Jan. 2005, doi: 10.1111/J.1540-8159.2005.00017.X.

[64] A. Bauer *et al.*, “Turbulence dynamics: An independent predictor of late mortality after acute myocardial infarction,” *Int J Cardiol*, vol. 107, no. 1, pp. 42–47, Feb. 2006, doi: 10.1016/j.ijcard.2005.02.037.

[65] M. A. Watanabe, J. E. Marine, R. Sheldon, and M. E. Josephson, “Effects of ventricular premature stimulus coupling interval on blood pressure and heart rate turbulence,” *Circulation*, vol. 106, no. 3, pp. 325–330, Jul. 2002, doi: 10.1161/01.CIR.0000022163.24831.B5.

[66] M. Iwasaki *et al.*, “Correlation of Heart Rate Turbulence with Sympathovagal Balance in Patients with Acute Myocardial Infarction,” *http://dx.doi.org/10.1081/CEH-48872*, vol. 27, no. 2–3, pp. 251–257, Jan. 2009, doi: 10.1081/CEH-48872.

[67] J. D. Harris, C. J. L. Little, J. M. Dennis, and M. W. Patteson, “Heart rate turbulence after ventricular premature beats in healthy Doberman pinschers and those with dilated cardiomyopathy,” *Journal of Veterinary Cardiology*, vol. 19, no. 5, pp. 421–432, Oct. 2017, doi: 10.1016/J.JVC.2017.08.005.

[68] G. Schmidt *et al.*, “Heart-rate turbulence after ventricular premature beats as a predictor of mortality after acute myocardial infarction,” *Lancet*, vol. 353, no. 9162, pp. 1390–1396, Apr. 1999, doi: 10.1016/S0140-6736(98)08428-1.

[69] G. M. Friesen, T. C. Jannett, M. A. Jadallah, S. L. Yates, S. R. Quint, and H. T. Nagle, “A comparison of the noise sensitivity of nine QRS detection algorithms,” *IEEE Trans Biomed Eng*, vol. 37, no. 1, pp. 85–98, 1990, doi: 10.1109/10.43620.

[70] N. Kannathal, U. R. Acharya, K. P. Joseph, L. C. Min, and J. S. Suri, “Analysis of electrocardiograms,” *Advances in Cardiac Signal Processing*, pp. 55–82, 2007, doi: 10.1007/978-3-540-36675-1_2.

[71] T. Y. M. Slonim, M. A. Slonim, and E. A. Ovsyscher, “Use of simple FIR filters for filtering of ECG signals and a new method for post-filter signal reconstruction,” *Comput Cardiol*, pp. 871–873, 1993, doi: 10.1109/CIC.1993.378347.

[72] V. X. Afonso, W. J. Tompkins, T. Q. Nguyen, S. Trautmann, and S. Luo, “Filter bank-based processing of the stress ECG,” *Annual International Conference of the IEEE Engineering in Medicine and Biology - Proceedings*, vol. 17, no. 2, pp. 887–888, 1995, doi: 10.1109/IEMBS.1995.579254.

[73] H. Liang, Q. H. Lin, and J. D. Z. Chen, “Application of the empirical mode decomposition to the analysis of esophageal manometric data in gastroesophageal reflux disease,” *Annual International Conference of the IEEE Engineering in Medicine and Biology - Proceedings*, vol. 26 I, pp. 620–623, 2004, doi: 10.1109/IEMBS.2004.1403234.

[74] G. B. Moody and R. G. Mark, “QRS morphology representation and noise estimation using the Karhunen-Loeve transform,” *Comput Cardiol*, pp. 269–272, Sep. 1989, doi: 10.1109/CIC.1989.130540.

[75] G. Clifford, L. Tarassenko, and N. Townsend, “One-pass training of optimal architecture auto-associative neural network for detecting ectopic beats,” *Electron Lett*, vol. 37, no. 18, pp. 1126–1127, Aug. 2001, doi: 10.1049/EL:20010762.

[76] U. Biswas, A. Das, S. Debnath, and I. Oishee, “ECG signal denoising by using least-mean-square and normalised-least-mean- square algorithm based adaptive filter,” *2014 International Conference on Informatics, Electronics and Vision, ICIEV 2014*, 2014, doi: 10.1109/ICIEV.2014.6850857.

[77] U. Biswas and M. Maniruzzaman, “Removing power line interference from ECG signal using adaptive filter and notch filter,” *1st International Conference on Electrical Engineering and Information and Communication Technology, ICEEICT 2014*, Oct. 2014, doi: 10.1109/ICEEICT.2014.6919072.

[78] S. Avdaković and N. Čišija, “Wavelets as a tool for power system dynamic events analysis – State-of-the-art and future applications,” *Journal of Electrical Systems and Information Technology*, vol. 2, no. 1, pp. 47–57, May 2015, doi: 10.1016/J.JESIT.2015.03.005.

[79] K. Mourad, B. R. Fethi, ; Bereksi, and R. Fethi, “Accepted Manuscript Efficient Automatic Detection Of QRS Complexes In ECG Signal Based On Reverse Biorthogonal Wavelet Decomposition And Nonlinear Filtering Efficient Automatic Detection Of QRS Complexes In ECG Signal Based On Reverse Biorthogonal Wavelet Decomposition And Nonline-ar Filtering,” *Efficient Automatic Detection Of QRS Complexes In ECG Signal Based On Reverse Biorthogonal Wavelet Decomposition And Nonlinear Filtering*, 2016, doi: 10.1016/j.measurement.2016.09.014.

[80] H. A. N. Dinh, D. K. Kumar, N. D. Pah, and P. Burton, “Wavelets for QRS detection,” *Annual International Conference of the IEEE Engineering in Medicine and Biology-Proceedings*, vol. 2, pp. 1883–1887, 2001, doi: 10.1109/IEMBS.2001.1020593.

[81] R. Shankar Meena and A. Sharma, “COMPARISON AND ANALYSIS OF ORTHOGONAL AND BIORTHOGONAL WAVELETS FOR ECG COMPRSSION,” *IJRET: International Journal of Research in Engineering and Technology*, pp. 2321–7308, Accessed: Aug. 22, 2022. [Online]. Available: http://www.ijret.org

[82] J. S. Karnewar, “The Combined Effect of Median and FIR Filter in Pre-processing of ECG Signal using Matlab,” *Int J Comput Appl*, pp. 975–8887, Accessed: Aug. 23, 2022. [Online]. Available: http://www.lifehugger.com/doc/120/ecg-100-steps.