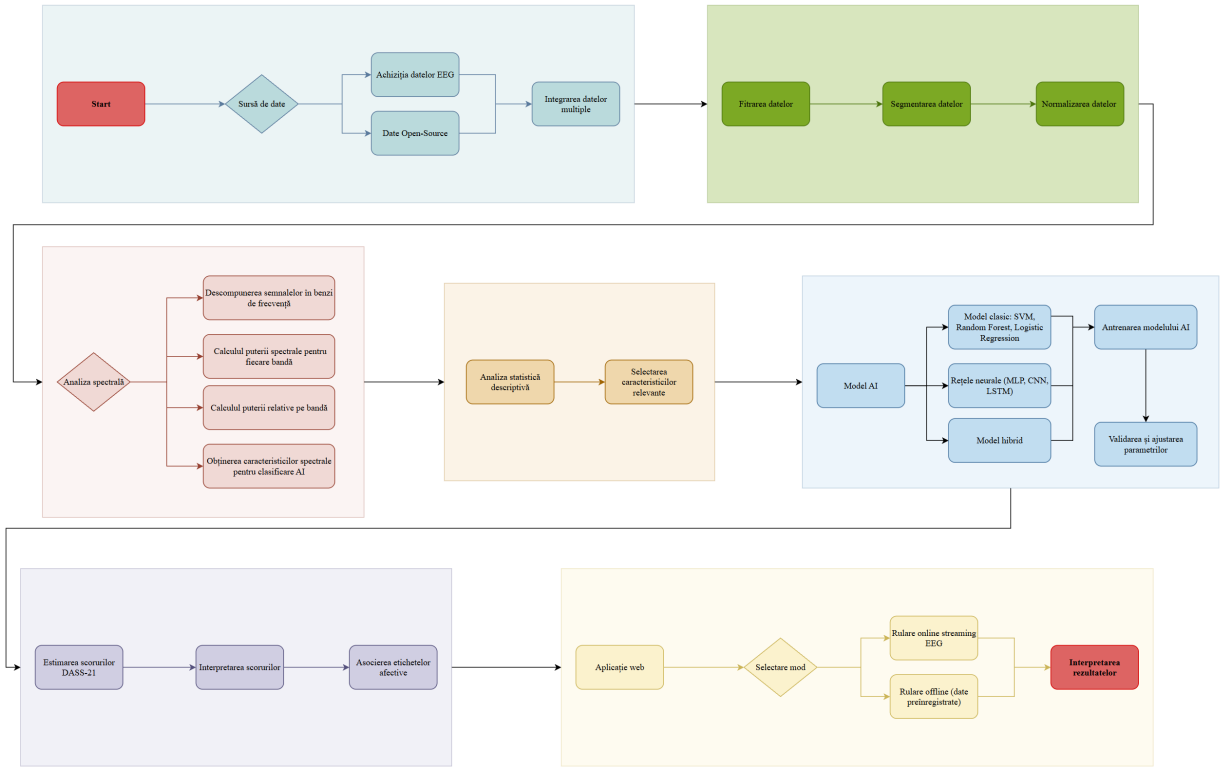
Raport 5

Titlu teză: „Contribuții privind estimarea stării afective pe baza semnalelor EEG și a inteligenței artificiale”

Student: Știrbu Oana-Isabela

ARHITECTURĂ TEZĂ



Această arhitectură descrie fluxul operațional complet al unui sistem automatizat de estimare a stărilor afective, precum depresie, anxietate și stres pe baza semnalelor EEG. Sistemul este calibrat în conformitate cu scala psihometrică standardizată DASS-21 (Depression, Anxiety, and Stress Scale – 21 items) și integrează cele mai recente tehnologii în domeniul achiziției EEG, prelucrării digitale a semnalului, analizei spectrale, modelării cu ajutorul inteligenței artificiale, precum și al vizualizării rezultatelor într-o aplicație web interactivă și scalabilă. Scopul principal al acestui sistem este de a oferi o alternativă non-invazivă, obiectivă și în timp real la chestionarele subiective utilizate în mod tradițional pentru evaluarea stărilor afective, contribuind astfel la avansul domeniului neurotehnologiei aplicate în sănătatea mintală.

Procesul începe cu etapa de achiziție a datelor EEG, care poate avea două surse principale. Prima sursă constă în înregistrările proprii realizate cu ajutorul dispozitivului portabil **Unicorn Hybrid Black**, un sistem EEG cu 8 canale, onfigurat conform standardului 10–20, cu o rată de eșantionare de 250 Hz, rezoluție de 24 biți și electrozi hibizi. Această platformă este aleasă datorită mobilității,

fiabilității și compatibilității cu sisteme de streaming EEG în timp real. A doua sursă este constituită din baze de date EEG open-source, utilizate în special pentru antrenarea și validarea inițială a modelelor de inteligență artificială, datorită diversității de subiecți, protocoale și condiții experimentale. Prin combinarea datelor proprii cu cele din surse publice, sistemul beneficiază atât de generalizare, cât și de adaptare la semnale în timp real.

După colectarea semnalului EEG, urmează o etapă esențială de preprocesare, care are rolul de a curăța și pregăti datele brute pentru analiză computațională. Această etapă presupune, în primul rând, *filtrarea semnalului pentru eliminarea zgomotelor provenite din surse nedorite*, cum ar fi artefactele musculare, interferențele electromagnetice sau mișcările oculare. În al doilea rând, semnalul este *segmentat în ferestre temporale fixe*, pentru a permite analiza secvențială și extragerea coerentă de caracteristici. În al treilea rând, datele sunt *normalizate*, astfel încât variațiile de amplitudine între subiecți sau sesiuni să nu afecteze robustetea modelelor de învățare automată. Procesul de normalizare poate include centrare în jurul mediei, scalare în intervalul [0, 1] sau standardizare în funcție de deviația standard, asigurând astfel compatibilitatea datelor cu cerințele algoritmilor de învățare automată.

După preprocesare, semnalul EEG este supus unei *analize spectrale*, care presupune descompunerea acestuia în benzi de frecvență specifice: delta (0.5–4 Hz), theta (4–8 Hz), alfa (8–12 Hz), beta (13–30 Hz) și gamma (>30 Hz). Fiecare bandă de frecvență este asociată, conform literaturii de specialitate, cu anumite stări cognitive și afective. De exemplu, activitatea în banda alfa este frecvent corelată cu stările de relaxare, în timp ce o intensificare a activității în banda beta poate indica niveluri ridicate de stres, agitație sau hiperactivitate mentală. Analiza spectrală se realizează prin metode consacrate, precum Transformata Fourier rapidă (FFT), metoda Welch sau tehnici bazate pe Transformate Wavelet, care permit estimarea puterii spectrale medii pentru fiecare bandă, constituind baza pentru extragerea caracteristicilor relevante.

În etapa următoare, sistemul realizează *extragerea caracteristicilor relevante* din semnalele EEG, atât din domeniul spectral, cât și din cel temporal. Aceste caracteristici pot include statistici de ordinul întâi (media, mediana, deviația standard), măsuri de entropie, corelații între canale, asimetrii inter-emisferice sau indici de coerență. Caracteristicile extrase sunt apoi utilizate în etapa de analiză statistică descriptivă, unde sunt agregate și analizate pentru a înțelege distribuția și variațiile în funcție de etichetele afective disponibile (ex. niveluri de depresie, stres sau anxietate).

Această etapă este esențială atât pentru explorarea inițială a datelor, cât și pentru selecția caracteristicilor relevante ce vor fi utilizate în procesul de antrenare a modelelor de inteligență artificială.

Modelele de inteligență artificială sunt antrenate pe baza acestor caracteristici, cu scopul de a învăța relațiile dintre activitatea EEG și scorurile obținute la scala psihometrică DASS-21, corespunzătoare dimensiunilor depresie, anxietate și stres. În funcție de natura etichetelor disponibile, pot fi utilizate atât modele de clasificare (pentru predicția unor clase discrete: normal, moderat, sever etc.), cât și modele de regresie (pentru estimarea valorilor continue ale scorurilor DASS-21). Se vor implementa, atât algoritmi clasici de învățare automată, cât și rețele neuronale artificiale, respectiv arhitecturi hibride care integrează informația temporală și spectrală. Etapa de antrenare presupune aplicarea unor proceduri riguroase de validare încrucișată și optimizare a hiperparametrilor, în vederea maximizării performanței de generalizare a modelelor.

După etapa de antrenare, modelul de inteligență artificială devine capabil să estimeze, pe baza semnalului EEG, scoruri afective corespunzătoare celor trei dimensiuni evaluate: depresie, anxietate și stres. Valorile obținute sunt ulterior interpretate conform pragurilor standardizate definite de scala DASS-21, corespunzând categoriilor: normal, ușor, moderat, sever și extrem de sever. Fiecare scor estimat este asociat cu o etichetă interpretabilă clinic, ceea ce facilitează integrarea rezultatelor în contexte de screening psihologic sau intervenție terapeutică. Este important de subliniat că sistemul propus nu are rol de diagnostic clinic, ci funcționează ca un instrument complementar, obiectiv și continuu, menit să sprijine evaluarea afectivă în mod non-invaziv.

Toate rezultatele generate de sistem sunt integrate într-o aplicație web interactivă, care suportă atât rularea în timp real (mod online), cât și testarea pe date preînregistrate (mod offline). În modul online, semnalul EEG este preluat în timp real prin intermediul driverului Unicorn și transmis prin LabStreamingLayer (LSL) către backend-ul aplicației. În modul offline, utilizatorul poate încărca înregistrări existente pentru a evalua performanța modelului. Interfața aplicației este dezvoltată în React și permite vizualizarea simultană a semnalului EEG filtrat, a distribuției în benzi de frecvență, a scorurilor DASS-21 estimate și a interpretării acestora. Backend-ul sistemului este implementat în Python, utilizând framework-ul FastAPI pentru gestionarea logicii aplicației și WebSocket pentru comunicarea bidirecțională în timp real cu interfața utilizator. Vizualizarea

interactivă este realizată cu biblioteca Plotly.js, care permite generarea de grafice dinamice și personalizabile.

Dincolo de funcționalitatea sa tehnică, arhitectura propusă se distinge printr-un design modular, scalabil și flexibil, cu aplicații directe în monitorizarea sănătății mintale, cercetarea în psihologie cognitivă și dezvoltarea tehnologiilor emergente de tip *digital phenotyping*. Sistemul permite adaptarea rapidă la noi seturi de date, extinderea numărului de stări afective investigate și integrarea într-un ecosistem mai larg de soluții e-health. Prin combinarea neuroștiinței, psihometriei și inteligenței artificiale, această platformă deschide perspective promițătoare pentru evaluarea obiectivă, continuă și personalizată a stării emoționale în contexte variate – de la cabinete psihologice și centre clinice, până la aplicații mobile de auto-monitorizare și intervenție precoce.

Capitolul 2 – SETURI DE DATE EEG

2.1. Analiza bazelor de date EEG open-source utilizate în în studiul proceselor cerebrale și în modelarea computațională 8

2.1.1. Baze de date EEG cu relevanță clinică generală 9

2.1.1.1. NMT Scalp EEG 9

2.1.1.2. TUH EEG CorpuS 11

2.1.1.3. CHB-MIT Scalp EEG 11

2.1.1.4. Predict-UNM 12

2.1.1.5. MODMA 13

2.1.1.6. SAM40 14

2.1.1.7. DASPS 14

2.1.2. Baze de date EEG relevante pentru analiza activității motorii 15

2.1.2.1. GIGADB 16

2.1.2.2. EEG Motor Movement/Imagery 16

2.1.2.3. Grasp-and-Lift EEG 17

2.1.2.4. SCP Data of Motor-Imagery 18
2.1.2.5. BCI Competition IV 18
2.1.2.6. High-Gamma 19
2.1.2.7. Planning Relax 20
2.1.2.8. Mental-Imagery 21
2.1.3. Baze de date EEG relevante pentru recunoașterea emoțiilor 21
2.1.3.1. DEAP 21
2.1.3.2. SEED 22
2.1.3.3. Regulation of Arousal 31
2.1.4. Baze de date EEG relevante pentru detectarea potențialelor legate de erori ... 32
2.1.4.1. BCI-NER 32
2.1.4.2. Monitoring ErrP in a target selection task 33
2.1.5. Baze de date EEG relevante pentru detectarea potențialelor vizual evocate ... 33
2.1.5.1. Synchronized Brainwave 34
2.1.6. Baze de date EEG relevante pentru detectarea potențialelor evocate legate de evenimente 34
2.1.6.1. Face-House Discrimination 35
2.1.6.2. Brain Invaders 35
2.1.6.3. Sustained-Attention Driving 36
2.1.6.4. Dryad-Speech 36
2.1.6.5. ERP Core 37
2.1.7. Baze de date EEG relevante pentru detectarea în condiții de repaus 38
2.1.7.1. Resting State EEG Data 38
2.1.7.2. MindID 38
2.1.7.3. SPIS Resting State Dataset 39
2.1.7.4. Alpha Waves 39
2.1.7.5. BIDS 40
2.1.8. Baze de date EEG pentru explorarea imaginației motorii și a reprezentărilor cognitive interne 41
2.1.8.1. Music Imagery Information Retrieval 41

2.1.9. Baze de date EEG relevante pentru analiza mișcărilor oculare și a clipitului .. 42
2.1.9.1. EEG Eye State 42
2.1.9.2. EEG-IO și EEG-VV/VR 43
2.1.9.3. Kara-One 43
2.1.9.4. EEGEyeNet 44
2.1.9.5. Multimodal Eye-Blink and Attention Level 44
2.1.10. Baze de date EEG pentru analiza diverselor sarcini cognitive și explorări atipice 45
2.1.10.1. NIST Brain Digits 46
2.1.10.2. ImageNet Brain 46
2.1.10.3. EEGLearn 47
2.1.10.4. Deep Sleep Slow Oscillation 47
2.1.10.5. Genetic Predisposition to Alcoholism 48
2.1.10.6. Confusion during MOOC 48
2.1.10.7. Nencki-Symfonia 49
2.1.10.8. Zurich Cognitive Language Processing Corpus 50
2.1.10.9. EEG During Mental Arithmetic Tasks 50
2.1.10.10. EEG Data 51
2.1.10.11. Raw EEG Data 52
2.1.11. Concluzii privind selecția și relevanța bazelor de date EEG open-source 53
2.1.12. Bibliografie 56

2.1. Analiza bazelor de date EEG open-source utilizate în în studiul proceselor cerebrale și în modelarea computațională

În contextul cercetării moderne asupra inteligenței artificiale aplicate semnalelor EEG, bazele de date open-source reprezintă o resursă fundamentală. Ele oferă un cadru standardizat pentru antrenarea, testarea și compararea algoritmilor în condiții reproductibile, contribuind semnificativ la dezvoltarea unor modele AI generalizabile. Accesul liber la aceste seturi a democratizat cercetarea neuroștiințifică și psihologică, permițând explorarea relației dintre activitatea cerebrală și diverse stări mentale, fără constrângeri legate de echipamente costisitoare sau protocoale proprii. În cadrul acestei teze, axată pe estimarea automată a stărilor afective negative (anxietate, depresie, stres), analiza bazelor de date EEG open-source constituie o etapă metodologică esențială. Este necesară nu doar identificarea resurselor care conțin etichete afective validate psihologic (ex. DASS-21[1], HAM-A[2], SAM[3]), ci și o cartografiere completă a paradigmelor experimentale existente, utile pentru pre-antrenare, validare comparativă sau transfer de învățare între sarcini. Prin urmare, acest capitol urmărește:

- realizarea unei analize tehnice extinse a celor mai frecvent utilizate baze de date EEG open-source,
- clasificarea sistematică a acestora în funcție de paradigma experimentală (clinic, afectiv, cognitiv, motor etc.) și de tipul de adnotări disponibile,
- o evaluare critică a compatibilității fiecărui set de date cu obiectivul lucrării – recunoașterea automată a stărilor afective vizate.

Pe lângă seturile relevante pentru tema cercetării, sunt incluse și resurse complementare, utilizate pentru pre-antrenarea modelelor, testarea robustă a arhitecturilor sau comparații între paradigme. În finalul capitolului, sunt prezentate explicit criteriile de selecție aplicate, precum și delimitarea clară între seturile utilizate experimental și cele analizate în scop exploratoriu.

[1] Este un instrument de autoevaluare format din 21 de itemi, conceput pentru a măsura stările emoționale de depresie, anxietate și stres [1].
[2] Este un instrument format din 14 itemi, coceput pentru a măsura anxietatea din punct de vedere psihologic și somatic [2].
[3] Este o tehnică de evaluarea non-verbală care masoară direct stările afective asociate cu reacția unei persoane la o gamă largă de stimuli [3].

2.1.1. Baze de date EEG cu relevanță clinică generală

Bazele de date EEG cu relevanță clinică generală includ înregistrări realizate în contexte medicale, în principal de la pacienți diagnosticați cu diverse afecțiuni neurologice sau psihiatrice (epilepsie, tulburări de dispoziție, traumatisme, schizofrenie etc.). Scopul principal al acestor seturi este susținerea cercetării medicale și dezvoltarea unor instrumente automatizate de screening, diagnostic sau monitorizare a patologiilor cerebrale. Deși majoritatea acestor baze nu conțin etichete explicite privind stările afective sau cognitive (ex. stres, anxietate, atenție), ele prezintă o valoare considerabilă în contextul inteligenței artificiale aplicate datelor EEG. Volumele mari de date, varietatea configurațiilor tehnice și etichetarea binară (normal/patologic) permit utilizarea lor pentru pre-antrenarea modelelor, testarea robustă a arhitecturilor AI, sau evaluarea generalizabilității algoritmilor în contexte clinice diverse.

În cadrul acestei teze, unele dintre aceste baze de date sunt analizate ca resurse complementare, în timp ce altele (precum MODMA, SAM40 și DASPS) au fost incluse în setul final de date utilizate, datorită relevanței directe pentru estimarea stărilor afective. Următoarele secțiuni oferă o descriere detaliată a acestor seturi, evidențiind caracteristicile tehnice, protocoalele de achiziție, tipurile de etichete disponibile și gradul de compatibilitate cu obiectivele prezentei lucrări.

2.1.1.1. NMT Scalp EEG

Baza de date **NMT (NUST-MH-TUKL) Scalp EEG** reprezintă una dintre cele mai ample colecții open-source de înregistrări EEG etichetate binar (normal sau patologic), fiind dezvoltată cu scopul de a sprijini dezvoltarea unor algoritmi de învățare automată pentru identificarea preliminară a activității cerebrale anormale. Colectarea datelor a fost realizată la Pak-Emirates Military Hospital (MH), Rawalpindi, Pakistan, oferind pentru prima dată o bază EEG publică provenită dintr-un context sud-asiatic. În total, baza include **2.417 înregistrări EEG**, însumând aproximativ **625 de ore de activitate cerebrală**. Înregistrările au fost realizate cu ajutorul unui **sistem KT88-2400** (Contec Medical Systems), utilizând montajul standard 10–20 cu 19 canale EEG, la o frecvență de eșantionare de 200 Hz, iar datele au fost salvate în format .edf (European Data Format). Protocolul de achiziție a presupus condiții de control riguros: pacienții adulți au fost instruiți să evite medicamentația sedativă și să se prezinte odihniți, iar copiii sub 2 ani au fost înregistrați în timpul somnului natural. Înregistrările au fost supravegheate de un tehnician EEG cu peste 5 ani de experiență. Etichetarea fiecărui EEG ca *normal* sau *patalogic* a fost efectuată de personal medical cu formare neurologică, apoi validată de doi neurologi independenți. În baza de date finală, au fost incluse doar acele înregistrări pentru care a existat consens între experți. Distribuția demografică a acoperit o gamă

largă de vârste (sub 1 an – 90 ani), cu un raport de 66,56% subiecți de sex masculin și restul de 33,44% de sex feminin. În medie, durata unei înregistrări a fost de aproximativ 15 minute. Proporția de înregistrări etichetate ca patologice a fost de 16,17% la bărbați și 19,18% la femei, după cum se poate observa în Figura 2.1.

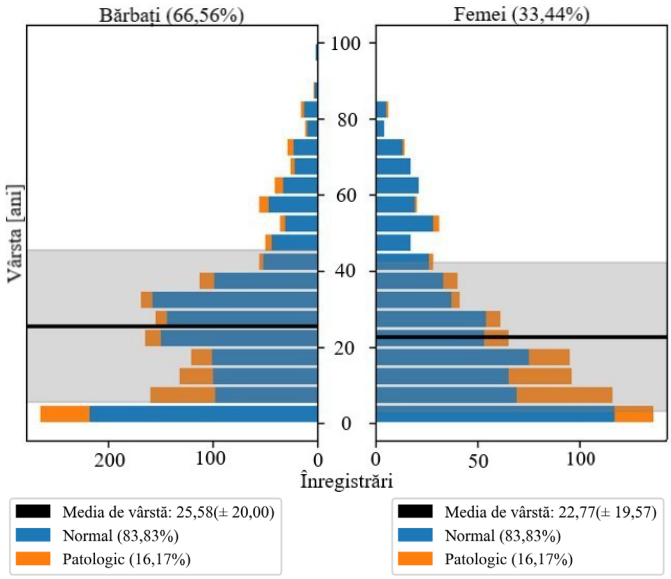


Figura 2.1 Histograma distribuției vârstei și a proporției de semnale EEG normale și patologice, separat pentru subiecți de sex masculin (stânga) și feminin (dreapta), în cadrul bazei de date NMT Scalp EEG [4]

Aproximativ 17% dintre semnalele EEG sunt etichetate ca patologice, fără a se specifica însă natura afecțiunii neurologice (de exemplu: epilepsie, encefalopatie, AVC (Accidentul vascular cerebral) etc.). Întrucât eticheta *patalogic* nu este însoțită de un diagnostic clinic concret, utilizarea acestui set este limitată la clasificări binare generice, fără aplicabilitate directă în recunoașterea stărilor cognitive sau a tulburărilor specifice. Pentru asigurarea compatibilității cu alte baze EEG (ex. **TUH EEG Corpus**), datele au fost ulterior procesate offline, utilizând o referință de tip medie globală, rezultând astfel 21 de canale EEG pentru fiecare înregistrare. Scopul declarat de autori a fost de a facilita dezvoltarea de instrumente de clasificare automată, ce pot fi utilizate în centre medicale rurale pentru identificarea preliminară a cazurilor suspecte care necesită consult neurologic [4]. Deși **NMT Scalp EEG** nu conține etichete referitoare la stări afective, aceasta rămâne o bază de date valoroasă pentru dezvoltarea și testarea arhitecturilor AI în sarcini de screening. Poate fi utilizat pentru:

- pre-antrenarea rețelelor neuronale pe date EEG reale,
- evaluarea robusteții modelelor în clasificare binară,
- studii de generalizare între seturi de date colectate în contexte demografice sau tehnice diferite,
- simularea unor sarcini clinice de detecție automată a anomaliilor EEG, fără diagnosticare specifică.

Totuși, în contextul acestei teze, care vizează estimarea stărilor afective pe baza semnalelor EEG, baza NMT nu a fost inclusă în setul principal de date utilizate deoarece nu furnizează etichete legate de starea mentală a subiecților, ci doar o clasificare binară generală (normal/patologic), fără detalii clinice suplimentare.

2.1.1.2. TUH EEG CorpuS

Într-o manieră similară, dar la o scară mult mai mare, **TUH (Temple University Hospital) EEG CorpuS**, dezvoltat de *Neural Engineering Data Consortium* din cadrul Temple University, SUA, oferă cea mai extinsă colecție clinică open-source. Este considerată cea mai extinsă bază disponibilă public, cu peste **60.000 de înregistrări EEG** provenind de la aproximativ **14.000 de pacienți**, colectate începând cu anul 2002 până în prezent. Înregistrările includ între 20 și 128 de canale EEG, sunt eșantionate la 250 Hz și salvate în format .edf, alături de un canal de adnotări ce conține marcaje ale evenimentelor relevante (spike-uri epileptice, artefacte, perioade de somn etc.) [5]. TUH este împărțit în subseturi tematice (ex. *Abnormal EEG Corpus*, *Seizure Corpus*, *Artifact Corpus*) [6] și este utilizat pe scară largă în literatura de specialitate pentru antrenarea și validarea algoritmilor de clasificare automată a EEG-urilor patologice. Cu toate acestea, scopul său este exclusiv clinic, iar datele nu conțin etichete explicite privind stări afective. Prin urmare, deși TUH EEG Corpus este o resursă pentru dezvoltarea și validarea sistemelor AI clinice, acesta nu a fost inclusă în setul principal de date utilizate în prezenta teză, întrucât nu corespunde obiectivelor de estimare a stării afective, ci este destinat în principal clasificării automate a anomaliilor EEG în context medical.

2.1.1.3. CHB-MIT Scalp EEG

CHB-MIT Scalp EEG este o bază de date EEG de referință în studiul epilepsiei pediatrice, fiind colectată la *Children's Hospital Boston* și publicată prin platforma PhysioNet [7]. Aceasta conține **664 de fișiere** .edf grupate în 23 de cazuri clinice, corespunzătoare unui număr de **22 subiecți** (5 băieți și 17 fete, cu vârste între 1,5 și 22 de ani), diagnosticați cu forme severe de epilepsie. Înregistrările EEG au fost realizate pe parcursul mai multor zile de monitorizare continuă, în contextul întreruperii tratamentului medicamentos, pentru a caracteriza tiparul convulsiv și a evalua eligibilitatea pentru intervenție chirurgicală. În total, sunt documentate 198 de crize epileptice, fiecare având adnotări temporale precise privind momentul de debut și final. Semnalele EEG au fost înregistrate la o frecvență de eșantionare de 256

Hz, cu rezoluție pe 16 biți, utilizând în general 23 de canale EEG, conform sistemului internațional 10–20 de plasare a electrozilor (în unele cazuri fiind utilizate până la 26 de canale) – Figura 2.2 [8].

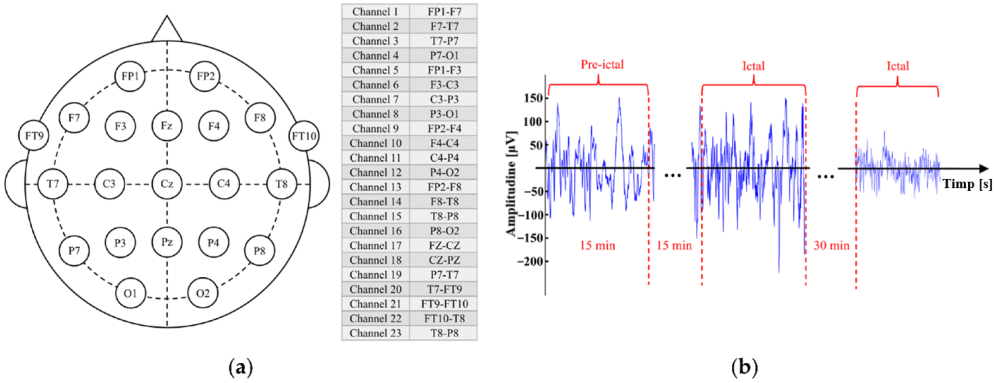


Figura 2.2 Configurația electrozilor și structura temporală a înregistrărilor EEG în baza de date CHB-MIT. (a) Poziționarea electrozilor conform sistemului internațional 10–20 și conexiunile bipolare. (b) Ilustrarea secvenței temporale a episoadelor epileptice: perioadele pre-ictale (15–30 min înainte de criză), ictale (în timpul crizei) și inter-ictale (între crize) [8]

Înregistrările sunt etichetate la nivel de fișier (cu sau fără criză), iar în unele cazuri sunt disponibile și semnale suplimentare (ex. ECG sau stimularea nervului vag) [4][6]. Deși CHB-MIT este un set de date valoros pentru antrenarea algoritmilor de detecție automată a crizelor epileptice, acesta nu oferă etichete privind stări afective, iar din acest motiv, baza nu a fost utilizată în cadrul experimentelor din prezenta teză, dar rămâne relevantă pentru dezvoltarea arhitecturilor AI aplicate pe semnale EEG reale în contexte clinice.

2.1.1.4. Predict-UNM

Baza de date **Predict-UNM** reprezintă o colecție complexă de seturi de date EEG clinice, pusă la dispoziție de University of New Mexico, cu scopul de a sprijini cercetarea în identificarea biomarkerilor neuronali asociați tulburărilor psihiatrice și neurologice. Această resursă valorifică potențialul EEG pentru a diferenția grupuri clinice pe baza activității cerebrale înregistrate în condiții controlate, acoperind o gamă largă de patologii precum: boala Parkinson, traumatisme cranio-cerebrale ușoare (mTBI), tulburări obsesiv-compulsive (TOC) cu simptomatologie severă, schizofrenie și depresie cu scoruri ridicate pe Scala de Depresie Beck **(Inventarul Depresiei Beck - BDI)**. Datele sunt organizate pe grupuri clinice și includ, pentru fiecare participant, semnale EEG înregistrate în stare de repaus și/sau în timpul unor sarcini cognitive standardizate. Înregistrările sunt completate de informații demografice (vârstă, sex) și de evaluări psihologice cantitative, oferind un cadru coerent pentru analiza relației dintre activitatea neuronală și manifestările clinice. Deși detaliile tehnice privind numărul de electrozi și protocoalele exacte pot varia

între sub-seturi, Predict-UNM este considerată o resursă valoroasă pentru dezvoltarea de algoritmi AI care vizează detectarea automată a semnalelor patologice în EEG [10].

În contextul acestei teze, baza Predict-UNM a fost inclusă în selecția finală de seturi utilizate pentru validarea arhitecturilor propuse, datorită relevanței sale clinice și a prezenței unor etichete afective standardizate, precum scorurile BDI. Diversitatea tulburărilor psihice incluse, alături de înregistrările EEG realizate în condiții controlate și completate cu date demografice și evaluări psihologice, oferă un cadru adecvat pentru testarea modelelor de învățare automată în scenarii reale de clasificare a stărilor afective. Deși accesul la unele subseturi a fost limitat, porțiunea disponibilă a fost valorificată pentru testarea generalizabilității și robusteții arhitecturilor dezvoltate.

2.1.1.5. MODMA

Baza de date **MODMA (Multimodal Open Dataset for Mental-disorder Analysis)** este o colecție EEG clinică ce vizează investigarea diferențelor neurofiziologice dintre pacienții cu tulburare depresivă majoră (MDD) și subiecții sănătoși [11]. Baza MODMA este alcătuită din mai multe subseturi:

- EEG_128channels_ERP_lanzhou_2015: conține înregistrări EEG cu 128 de canale, obținute în condiții de potențiale evocate (ERP) de la 24 de pacienți diagnosticați cu MDD și 29 de subiecți de control, cu vârste cuprinse între 16 și 52 de ani. Protocolul a inclus atât achiziția în stare de repaus, cât și în timpul unor sarcini cu stimulare cognitivă, urmărind extragerea markerilor diferențiatori între grupuri;
- EEG_128channels_resting_lanzhou_2015: același eșantion clinic, dar cu înregistrări EEG efectuate exclusiv în stare de repaus (fără stimulare), folosind aceleași 128 de canale;
- EEG_3channels_resting_lanzhou_2015: înregistrări în stare de repaus cu un dispozitiv EEG portabil, prevăzut cu doar 3 electrozi, de la 26 pacienți cu MDD și 29 de tip control, cu vârste între 16 și 56 de ani.

Toate subseturile includ, pe lângă datele EEG brute, și informații demografice și rezultate ale evaluărilor psihologice standardizate, ceea ce permite corelarea directă a activității cerebrale cu simptomele clinice [12].

În contextul prezentei teze, baza MODMA a fost inclusă în selecția finală de seturi utilizate efectiv pentru testarea algoritmilor de învățare automată, datorită relevanței sale clinice, calității semnalului EEG și disponibilității unor etichete diagnostice clare (MDD/control). Datorită prezenței protocoalelor EEG realizate atât în stare de repaus, cât și în regim de ERP, această bază a fost utilizată pentru a evalua robustețea

arhitecturilor propuse în detecția diferențelor cognitive asociate depresiei, reprezentând un caz aplicativ în direcția estimării automate a stărilor afective patologice.

2.1.1.6. SAM40

Baza de date **SAM40** a fost concepută pentru a investiga răspunsurile cerebrale asociate stresului cronic, indus prin sarcini standardizate de dificultate moderată. Setul de date include înregistrări EEG de la **40 de participanți** (14 femei și 26 bărbați), cu o vârstă medie de 21,5 ani, obținute în timpul desfășurării unor sarcini cognitive variate care au potențialul de a induce stres pe termen scurt. Protocolul experimental a inclus patru condiții distincte: (1) testul Stroop, (2) rezolvarea de sarcini aritmetice, (3) identificarea imaginilor simetrice, (4) stare de relaxare. Fiecare sarcină a fost desfășurată timp de 25 de secunde, repetată în trei sesiuni, rezultând o cantitate semnificativă de date EEG etichetate în funcție de natura activității cognitive și nivelul de solicitare psihică. Achiziția semnalelor EEG s-a realizat folosind un sistem **Emotiv Epoc Flex** cu 32 de canale, oferind o rezoluție spațială adecvată pentru captarea modificărilor induse de stres în zonele frontale și parietale ale cortexului. Semnalele brute au fost segmentate în epoci de 25 de secunde și procesate ulterior pentru reducerea variațiilor lente de bază (drift) și eliminarea artefactelor, folosind filtrarea Savitzky-Golay și metode bazate pe Wavelet [13].

Relevanța acestei baze de date constă în posibilitatea de a analiza răspunsurile EEG asociate stresului cronic, într-un cadru experimental controlat, cu sarcini clare și durate bine definite. Informațiile pot fi valorificate în dezvoltarea interfețelor creier–calculator (BCI), dar și în algoritmi de detecție automată a stării de stres, bazată pe semnale cerebrale. Având în vedere obiectivele prezentei tezei și accentul pus pe identificarea stărilor cognitive precum stresul, baza de date SAM40 a fost inclusă în selecția finală a seturilor utilizate în testarea arhitecturilor propuse. Structura clară a protocolului, varietatea sarcinilor induse și calitatea semnalelor EEG oferă un cadru adecvat pentru explorarea automată a markerilor cerebrali asociați stresului.

2.1.1.7. DASPS

Baza de **date DASPS (Detection of Anxiety through Psychological Stimulation)** a fost concepută pentru a sprijini cercetările privind detecția stărilor anxioase pe baza semnalelor EEG, în contexte controlate de inducere emoțională. Setul de date cuprinde înregistrări EEG de la 23 de participanți, obținute în timpul unui protocol experimental care vizează stimularea imaginară ghidată, sub supravegherea unui psihoterapeut. Protocolul experimental presupune inducerea stării de anxietate prin intermediul unor

scenarii recitate verbal de către psihoterapeut, urmate de o perioadă în care participantul își imaginează situația respectivă. Fiecare secvență este compusă din două etape: (1) recitarea scenariului timp de 15 secunde și (2) rememorarea imaginară a situației timp de alte 15 secunde, în condiții de relaxare (ochi închiși, minimizarea mișcărilor și vorbirii). La finalul fiecărui scenariu, participantul își autoevaluează starea afectivă utilizând **scala SAM** (Self-Assessment Manikin), care include două dimensiuni relevante: valența emoțională și excitația. Protocolul este repetat pentru șase situații distincte, iar scorurile de anxietate sunt reevaluate și prin scale clinice, precum **HAM-A** (Hamilton Anxiety Rating Scale). Înregistrările EEG au fost realizate folosind sistemul **Emotiv EPOC+**, care are 14 canale active și 2 pentru referințe, plasate conform standardului 10–20. Semnalul a fost eșantionat la 128 Hz (cu rată internă de 2048 Hz) și cu o rezoluție de 14 biți. Baza de date conține fișiere .edf cu semnalul EEG brut, precum și variante preprocesate în format .mat, alături de scripturi MATLAB pentru segmentarea automată a datelor în cele 6 episoade experimentale [14].

Datorită designului său care combină inducerea afectivă dirijată, etichetarea afectivă dimensională și înregistrarea EEG în timp real, baza DASPS constituie un punct de plecare solid pentru dezvoltarea și validarea algoritmilor de recunoaștere automată a stărilor de anxietate. În contextul acestei teze, DASPS a fost inclusă în setul de baze de date selectate pentru analiza stărilor cognitive afective, având potențialul de a sprijini clasificarea automată a emoțiilor negative și explorarea relației dintre răspunsul cortical și activarea afectivă indusă.

2.1.2. Baze de date EEG relevante pentru analiza activității motorii

Sarcinile motorii, fie ele efectuate în mod real sau doar imaginate, generează tipare distincte de activitate electrică cerebrală care pot fi captate prin EEG și analizate cu ajutorul tehnicilor de învățare automată. Bazele de date EEG axate pe controlul motor voluntar sau imaginație joacă un rol central în dezvoltarea BCI și oferă un cadru valoros pentru antrenarea și testarea algoritmilor de clasificare a intenției motorii. Deși nu vizează direct stările afective sau cognitive, aceste baze de date sunt incluse în prezenta analiză datorită volumului mare de date disponibile, a protocoalelor bine controlate și a posibilității de a fi utilizate pentru pre-antrenare, transfer de învățare sau testarea robusteții arhitecturilor propuse. În continuare, sunt prezentate cele mai relevante seturi de date EEG cu aplicații în analiza sarcinilor motorii reale sau imaginare, evidențiind caracteristicile tehnice, structura experimentală și utilitatea potențială pentru cercetarea EEG asistată de AI.

2.1.2.1. GIGADB

Setul de date **GigaDB** reprezintă o colecție extinsă de semnale EEG înregistrate în timpul unor sarcini de imaginație a mișcării mâinii stângi sau drepte, fiind utilizat frecvent pentru antrenarea și validarea algoritmilor de clasificare EEG în aplicații BCI. Datele provin de la **52 de subiecți**, dintre care 38 au fost validați pe baza caracteristicilor discriminative extrase din date. Înregistrările sunt completate cu informații din chestionare fiziologice și psihologice, precum și cu semnale EMG (Electromiogramă) auxiliare. În plus, sunt disponibile date referitoare la poziționarea 3D a electrozilor EEG, precum și înregistrări EEG în afara sarcinilor (cum ar fi stări de repaus). Protocolul experimental a presupus solicitarea participanților să își imagineze mișcarea mâinii stângi sau drepte într-un mod controlat, pe baza unor stimuli vizuali sau auditivi. Nu sunt disponibile detalii standardizate privind montajul EEG, numărul de canale sau frecvența de eșantionare, deoarece acestea pot varia în funcție de subgrupul de participanți și de echipamentele folosite în diferite sesiuni [15], [16]. Această bază este utilă în special pentru:

- studii comparative asupra imaginației,
- dezvoltarea și testarea algoritmilor de clasificare,
- corelarea caracteristicilor EEG cu profiluri psihologice.

Totuși, lipsa unei descrieri tehnice riguroase a parametrilor de achiziție (număr fix de canale, frecvență etc.) limitează reproducibilitatea completă în unele cazuri și impune o atenție sporită în preprocesarea și normalizarea datelor.

2.1.2.2. EEG Motor Movement/Imagery

Setul de date **EEG Motor Movement/Imagery**, publicat pe platforma PhysioNet, este una dintre cele mai frecvent utilizate resurse open-source pentru analiza EEG în contexte de mișcare și imaginație. Acesta conține peste **1.500 de înregistrări EEG**, colectate de la **109 voluntari sănătoși** [17], cu vârste între 20 și 40 de ani. Semnalele au fost înregistrate utilizând un sistem **EEG cu 64 de canale**, în conformitate cu sistemul internațional 10–10, la o frecvență de eșantionare de 160 Hz. Fiecare participant a fost implicat într-un protocol experimental standardizat, alcătuit din 14 sesiuni succesive. Primele două sesiuni au reprezentat condiții de bază, în care subiecții au fost înregistrați timp de un minut cu ochii deschiși, respectiv un minut cu ochii închiși, pentru a oferi o referință de activitate cerebrală în stare de repaus. Acestea au fost urmate de 12 sesiuni a câte două minute fiecare, corespunzătoare celor patru sarcini motorii definite în cadrul experimentului: (1) mișcarea reală a pumnului stâng sau drept, în funcție de poziția unei ținte vizuale afișate pe ecran; (2) imaginația aceleiași mișcări, fără efectuarea efectivă a acțiunii; (3) mișcarea efectivă a ambilor pumni sau a ambelor picioare, în funcție de localizarea țintei în partea

superioară sau inferioară a ecranului; și (4) imaginația acestor mișcări bilaterale, fără efectuarea efectivă a acțiunii. Fiecare dintre cele patru sarcini a fost repetată de trei ori, rezultând un total de 12 sesiuni active, intercalate cu perioade de relaxare. După fiecare sarcină, participanții intrau într-o perioadă scurtă de relaxare. În total, fiecare subiect a fost expus la un set standardizat de sarcini motorii reale și imaginare [18], făcând acest set ideal pentru dezvoltarea de algoritmi de clasificare multiclasă și pentru analiza diferențelor între execuție și imaginație motorie.

2.1.2.3. Grasp-and-Lift EEG

Grasp-and-Lift EEG este o bază de date dezvoltată în contextul competiției internaționale *BNCI Horizon 2020*, cu scopul de a facilita dezvoltarea de algoritmi pentru detecția și interpretarea evenimentelor motorii subtile, pe baza semnalelor EEG. Aceasta constă în înregistrări EEG realizate în timpul unei sarcini de apucare și ridicare a unui obiect cu senzor de greutate, într-un cadru controlat de laborator. Spre deosebire de alte baze de date de imaginație, această colecție include mișcări reale, executate natural, fiind astfel relevantă pentru studii de decodificare a intenției motorii în contexte BCI aplicate. Protocolul experimental a presupus desfășurarea unui set de 6 evenimente distincte care compun acțiunea de apucare și ridicare: (a) HandStart (inițierea mișcării mâinii), (b) FirstDigitTouch (primul contact cu obiectul), (c) BothStartLoadPhase (începerea aplicării forței de prindere), (d) LiftOff (ridicarea obiectului), (e) Replace (repoziționarea pe suprafață), și (f) BothReleased (eliberarea completă). Aceste etape sunt adnotate temporal și permit alinierea exactă a semnalelor EEG cu evenimentele biomecanice corespunzătoare. Înregistrările EEG au fost obținute de la **12 participanți sănătoși**, fiecare realizând multiple sesiuni de ridicare a unui obiect. S-au utilizat 32 de canale EEG cu o frecvență de eșantionare de 500 Hz, alături de date auxiliare precum EMG, EOG (electrooculogramă), accelerometru și forța de apucare, oferind astfel o perspectivă multimodală asupra evenimentelor motorii [19]. Semnalele EEG au fost înregistrate în format .mat, iar etichetele evenimentelor sunt furnizate ca fișiere separate sincronizate cu semnalul neurofiziologic [20].

Această bază este valoroasă pentru evaluarea modelelor de învățare automată în sarcini de segmentare temporală și clasificare a fazelor mișcării, fiind una dintre puținele colecții care oferă EEG de înaltă calitate pentru sarcini motorii reale, fine, desfășurate în contexte experimentale cu feedback senzorial realist. De asemenea, oferă oportunități de integrare a semnalelor EEG cu informații biomecanice și electromiografice pentru aplicații în robotică asistivă, proteze controlate neuronal și predicția intenției motorii.

2.1.2.4. SCP Data of Motor-Imagery

Baza **SCP Data of Motor-Imagery** reprezintă una dintre cele mai extinse colecții EEG axate pe potențiale corticale lente (SCP) generate în timpul imaginației. A fost dezvoltată în cadrul studiilor BCI, cu scopul de a antrena utilizatorii să modifice voluntar activitatea lor corticală pentru controlul unor dispozitive externe. Setul de date conține **peste 60 de ore de înregistrări EEG**, obținute în cadrul a 75 de sesiuni experimentale desfășurate cu **13 participanți sănătoși**. Fiecare participant a fost implicat în mai multe sesiuni, fiecare conținând diverse paradigme de interacțiune BCI, bazate pe șase tipuri diferite de imaginație, inclusiv sarcini precum: mișcarea mâinilor, picioarelor sau alte activități mentale (ex. rotații, calcule mentale). Protocolul experimental este remarcabil prin diversitatea paradigmelor și prin abordarea pe termen lung, cu sesiuni multiple înregistrate pentru același individ, ceea ce permite analiza învățării și adaptării corticale pe parcursul mai multor zile. În plus, faptul că aceleași sarcini au fost efectuate repetat de aceiași participanți permite studii robuste de evaluare intra-subiect și inter-sesiune. Înregistrările EEG au fost realizate cu un sistem medical de înaltă calitate, utilizând **38 de canale EEG** și protocoale standardizate [21]. Sarcinile au fost însoțite de feedback în timp real, aspect esențial în cercetarea BCI, în special pentru controlul prin SCP, unde semnalele se dezvoltă lent și necesită antrenament cognitiv susținut pentru a fi modulate voluntar. Această bază este extrem de valoroasă pentru:

- analiza SCP în imaginație,
- studii de adaptare neuroplastică în paradigme BCI,
- dezvoltarea de algoritmi de detecție a semnalelor SCP utilizând rețele neuronale profunde,
- evaluarea stabilității semnalelor EEG în contexte longitudinale.

De asemenea, poate fi folosită pentru a testa robustețea clasificatorilor în condiții variabile (zile sau paradigme diferite) și este potrivită pentru dezvoltarea de aplicații pentru persoane cu dizabilități motorii, datorită accentului pus pe controlul non-invaziv al unor stări mentale subtile.

2.1.2.5. BCI Competition IV

O contribuție majoră în domeniul bazelor de date EEG destinate cercetării în BCI este reprezentată de seria de competiții **BCI Competition IV**, care a furnizat multiple seturi de date standardizate, utilizate pe scară largă pentru antrenarea și evaluarea algoritmilor de clasificare a activității motorii de imaginație. Trei dintre aceste seturi – Dataset 1, Dataset 2a și Dataset 2b – sunt deosebit de relevante în contextul analizelor EEG centrate pe activarea motorie imaginară, fiind adesea utilizate în studii comparative. **BCI Competition IV – Dataset 1** a fost dezvoltat de grupul *Berlin BCI* din cadrul Technische Universität Berlin,

în colaborare cu *Fraunhofer FIRST – Intelligent Data Analysis Group*. Acest set conține date EEG colectate de la **7 subiecți**, înregistrați cu **64 de canale EEG** la o frecvență de 1000 Hz. Sarcina principală a presupus imaginația mișcărilor mâinii stângi, mâinii drepte și a piciorului, în timp ce datele de evaluare includ și perioade de stare de repaus, ceea ce permite testarea algoritmilor în condiții de EEG continuu. Această abordare reflectă mai fidel condițiile reale de aplicare a unui BCI [22]. **BCI Competition IV – Dataset 2a** a fost dezvoltat de *Institute for Knowledge Discovery* din cadrul Graz University of Technology, Austria. Setul include înregistrări EEG de la **9 subiecți**, fiecare având două sesiuni a câte 288 de trialuri de 4 secunde. Înregistrările au fost realizate cu **22 de electrozi** și o frecvență de eșantionare de 250 Hz. Sarcinile propuse acoperă patru clase de imaginație: mișcarea imaginară a mâinii stângi, mâinii drepte, picioarelor și limbii [23]. **BCI Competition IV – Dataset 2b**, provenit de la aceeași echipă de la Graz University of Technology, se concentrează pe o variantă mai restrânsă a paradigmei de imaginație motorie. Setul conține date EEG de la **9 subiecți**, înregistrate doar pe **3 canale EEG bipolare** (C3, Cz și C4), eșantionate la 250 Hz. Fiecare subiect a participat la 5 sesiuni, dintre care ultimele 3 au inclus și feedback online. Sarcinile constau în imaginația mișcărilor mâinii stângi sau drepte. Acest set este adesea utilizat pentru teste de clasificare simplificată și evaluarea eficienței algoritmilor în condiții de feedback [24], [25].

Deși aceste seturi de date sunt recunoscute la nivel internațional pentru valoarea lor științifică și sunt frecvent utilizate în cercetarea BCI bazată pe imaginație motorie, ele nu conțin etichete explicite privind stări afective. Din acest motiv, nu au fost utilizate în cadrul experimentelor din prezenta teză, însă sunt prezentate aici pentru a evidenția tipologia bazelor EEG existente și a contextualiza alegerea bazelor de date axate pe etichetarea stărilor vizate. În plus, aceste seturi oferă un reper valoros pentru validarea arhitecturilor AI în sarcini EEG bine definite, cum ar fi discriminarea între tipuri de imaginație motorie.

2.1.2.6. High-Gamma

High-Gamma reprezintă un set de înregistrări EEG de înaltă rezoluție colectate de la **14 subiecți sănătoși** în cadrul unor sarcini motorii efectuate efectiv (executate real, nu imaginate). Fiecare subiect a participat la aproximativ 13 sesiuni, fiecare conținând câte aproximativ 1.000 de epoci EEG (de câte 4 secunde), rezultând în total aproximativ 14.000 de segmente EEG. Setul de date se remarcă prin utilizarea unei configurații de 128 de canale EEG (conform sistemului internațional 10–5), înregistrate la o frecvență de eșantionare ridicată (512 Hz), oferind astfel o rezoluție spațială și temporală optimă pentru analiza activității motorii. Subiecții au fost instruiți să efectueze mișcări efective ale membrelor superioare și inferioare. Cele patru clase motorii incluse în experiment sunt: mișcarea mâinii stângi, mâinii drepte, ambelor picioare și o stare de repaus. Fiecare sesiune a fost împărțită în 13 runde de înregistrare, fiecare rundă conținând o succesiune aleatorie de sarcini motorii, ceea ce asigură o bună variabilitate intra-subiect.

Mișcările au fost efectuate în mod repetat pe durata fiecărui segment de patru secunde, cu pauze între sarcini pentru a evita oboseala musculară [26], [27]. Datorită dimensiunii mari a setului de date și a rezoluției sale ridicate, High-Gamma este extrem de potrivită pentru:

- analiza activității corticale în benzile gamma asociate mișcărilor efective,
- detectarea timpurie a intenției de mișcare,
- antrenarea rețelelor neurale profunde în clasificarea multiclasă,
- evaluarea transferabilității între subiecți și între clase motorii,
- studii comparative între rețele dense de electrozi,
- proiectarea sistemelor BCI cu viteză și precizie ridicată în controlul dispozitivelor externe.

Este important de menționat că acest set nu conține sarcini de imaginație motorie, fiind axat exclusiv pe mișcări reale. De asemenea, nu sunt disponibile informații comportamentale sau semnale EMG, ceea ce limitează evaluarea directă a performanței execuției motorii. Cu toate acestea, calitatea ridicată a datelor EEG și numărul mare de înregistrări oferă un suport valoros pentru cercetările în domeniul BCI.

2.1.2.7. Planning Relax

Planning Relax este o bază de date EEG care a fost creată pentru a investiga activarea corticală asociată cu o sarcină mentală de imaginație — mișcarea degetului mare al mâinii drepte. Deși simplă ca structură, această bază de date are avantajul unui protocol experimental bine controlat, cu alternanță clară între repaus și activare mentală specifică. Pentru fiecare sesiune, subiectul a fost instruit să se relaxeze timp de 5 minute, timp în care s-a înregistrat activitate EEG în stare de repaus (cu ochii închiși). Ulterior, s-au colectat epoci de 5 secunde în care participantul a fost rugat să își imagineze exclusiv mișcarea degetului mare de la mâna dreaptă. Fiecare segment de imaginație a fost urmat de o nouă perioadă de repaus, creând astfel o alternanță regulată repaus–activare. Înregistrările au fost realizate cu **8 canale EEG**, conform sistemului internațional 10–20, la o frecvență de eșantionare de 256 Hz. Deși setul de date este limitat la un singur subiect, etichetele sunt clar definite pentru clasele *„repaus”* și *„imagine mișcare deget mare”* [28]. Baza este utilă în special pentru:

- testarea sensibilității algoritmilor AI la sarcini de imaginație motorie de finețe;
- validarea modelelor simple în clasificarea binară repaus–activare mentală;
- studii exploratorii asupra activării motorii focalizate în lipsa mișcării reale;
- pre-antrenare pentru rețele de tip CNN (Rețele neurale Convoluționale) cu date EEG reale.

2.1.2.8. Mental-Imagery

Mental-Imagery este una dintre cele mai complexe și bine structurate baze de date EEG pentru analiza stărilor de imaginație. A fost creată cu scopul de a susține cercetările în BCI, fiind caracterizată printr-o varietate de paradigme și un număr mare de exemple înregistrate. Studiul a implicat **13 participanți** și a fost organizat în patru paradigme de interacțiune BCI, fiecare vizând între patru și șase clase de imaginație motorie (ex: mișcarea mâinii stângi, mâinii drepte, ambelor picioare, rotația internă a limbii). Fiecare participant a parcurs mai multe sesiuni experimentale, înregistrările fiind etichetate corespunzător fiecărei stări mentale. În total, s-au obținut peste 60.000 de epoci EEG etichetate, distribuția între clase fiind echilibrată. Datele au fost colectate cu un sistem EEG medical de înaltă precizie, cu **38 de canale**, conform sistemului 10–20. Înregistrările au fost realizate într-un cadru standardizat, iar structura fișierelor și adnotările sunt conforme cu bunele practici din domeniul EEG [21].

2.1.3. Baze de date EEG relevante pentru recunoașterea emoțiilor

Recunoașterea automată a emoțiilor pe baza semnalelor EEG reprezintă un domeniu activ de cercetare, cu aplicații în interacțiunea om–calculator, sănătate mintală, educație și realitate virtuală. Bazele de date EEG construite pentru clasificarea emoțiilor oferă protocoale experimentale bine controlate, stimuli de tip emoțional și etichete afective clare (discrete sau dimensionale). Aceste seturi de date contribuie esențial la dezvoltarea și validarea algoritmilor de învățare automată care urmăresc identificarea stărilor afective precum frica, bucuria, tristețea sau starea neutră, pe baza activității cerebrale înregistrate. În această secțiune sunt prezentate cele mai utilizate baze de date EEG pentru recunoașterea emoțiilor, cu accent pe structura lor experimentală, tipurile de etichete oferite și relevanța lor potențială pentru estimarea stărilor cognitive.

2.1.3.1. DEAP

Baza de date **DEAP** reprezintă una dintre cele mai utilizate colecții open-source pentru recunoașterea emoțiilor din semnale EEG și fiziologice [29]. A fost dezvoltată cu scopul de a permite evaluarea algoritmilor de învățare automată în sarcini de clasificare afectivă bazate pe răspunsuri multimodale (EEG, EOG, EMG, GSR – răspunsul galvanic la pielii, temperatură etc.). DEAP este deosebit de relevantă pentru cercetarea stărilor cognitive, întrucât oferă etichete asociate dimensiunilor afective

precum valență, excitație, dominanță, familiaritate, dar și evaluări binare (îmi place/nu îmi place). Protocolul experimental a implicat **32 de subiecți** (16 femei și 16 bărbați) cu vârste între 19 și 37 de ani. Fiecare participant a fost expus la 40 de fragmente muzicale de câte 60 de secunde, selecționate pe baza etichetelor afective și a unei selecții manuale, astfel încât să acopere o gamă largă de stări emoționale. După fiecare fragment, participanții au completat un chestionar subiectiv în care și-au evaluat starea emoțională pe o scală de la 1 la 9 pentru dimensiunile valență, excitație, dominanță și pe o scală de la 1 la 5 pentru familiaritate. Evaluarea de tip *„îmi place"*a fost exprimată în mod binar. În plus, pentru 22 dintre participanți au fost înregistrate și expresiile faciale (prin semnal de tip video), ceea ce permite fuzionarea EEG cu analiza facială [30]. Semnalele EEG au fost înregistrate conform sistemului 10–20 de la 32 de electrozi, cu o frecvență de eșantionare inițială de 512 Hz (ulterior decimată la 128 Hz pentru eficiența procesării). Datele sunt disponibile în formate .mat și .csv, în versiuni preprocesate (filtrare 4–45 Hz, referință comună aplicată, segmente temporale standardizate) [22][23]. Această bază este extrem de valoroasă pentru:

- antrenarea și testarea modelelor AI pentru clasificarea emoțiilor;
- studii de corelație între EEG și evaluări subiective ale stării afective;
- cercetări multimodale ce integrează semnale EEG, fiziologice și expresii faciale;
- explorarea dimensiunilor afective într-un spațiu multidimensional;
- recunoașterea automată a stărilor afective în interfețele om-computer.

În contextul acestei teze, baza DEAP este considerată o resursă complementară importantă pentru analiza stărilor afective și dezvoltarea sistemelor multimodale EEG. Totuși, aceasta nu oferă etichete relevante pentru stări afective specifice, motiv pentru care nu a fost inclusă în selecția de date utilizate pentru antrenarea și evaluarea arhitecturilor AI din cadrul acestei lucrări. O concluzie similară a fost formulată și în cazul bazei SEED, care, deși valoroasă în cercetarea emoțiilor, nu acoperă în mod direct dimensiunile cognitive de interes pentru obiectivele prezentei teze.

2.1.3.2. SEED

Familia de baze de date **SEED (SJTU Emotion EEG Datasets)**, dezvoltată de Brain and Cognitive Modeling Laboratory din cadrul Shanghai Jiao Tong University (SJTU), constituie una dintre cele mai extinse și utilizate resurse open-source pentru recunoașterea emoțiilor pe baza semnalelor EEG. Inițial destinată exclusiv clasificării emoțiilor de bază, această familie de seturi de date a evoluat într-o suită complexă de experimente EEG ce acoperă nu doar procesarea afectivă, ci și vigilența, oboseala, percepția vizuală dinamică sau influența somnului asupra răspunsului cerebral. Până în septembrie 2024, SEED a fost

inclusă în peste 6340 de aplicații de cercetare și utilizată de 2320 de instituții din 93 de țări, ceea ce o face una dintre cele mai influente resurse în domeniul neuroștiințelor computaționale. Seturile SEED includ, pe lângă EEG, și date multimodale precum mișcări oculare (utilizând dispozitive de tip eye-tracking), înregistrări video faciale sau indicatori fiziologici, fiind ideale pentru cercetări interdisciplinare. În ceea ce privește estimarea stărilor cognitive, familia SEED este relevantă în special pentru recunoașterea afectivă (emoții pozitive, negative, neutre, frică, furie etc.), evaluarea vigilenței (în sarcini de condus simulat sau real), precum și pentru studii privind efectul somnului, oboselii sau al percepției vizuale complexe asupra activității cerebrale [32].

Tabel 2.1 Comparație generală între subseturile din familia SEED

Set de date	Emoții	Nr. subiecți	EEG (canale)
SEED	pozitivă, negativă, neutră	15	62
SEED-GER	pozitivă, negativă, neutră	8	62
SEED-FRA	pozitivă, negativă, neutră	8	62
SEED-IV	fericire, tristețe, frică, neutru	15	62
SEED-V	fericire, tristețe, frică, dezgust, neutru	15	62
SEED-VII	fericire, tristețe, frică, dezgust, neutru, furie, surprindere	15	62
SEED-VIG	vigilență, semi-vigilență, non-vigilență (PERCLOS[4])	23	18
SEED-VLA/VRW	stare de oboseală (condus real sau simulare)	20 / 14	62
SEED-DV	40 de concepte vizuale (animal, vehicul etc.)	20	62
SEED-SD	privare de somn, recuperare somn și somn normal	40	62

Tabelul 2.1 prezintă o comparație generală între subseturile SEED [32]. Baza SEED descrisă mai sus a stat la baza dezvoltării unei întregi familii de subseturi complementare, extinse cu mai multe clase emoționale, înregistrări multimodale, sarcini cognitive suplimentare (vigilență, oboseală), sau adaptate cultural (ex. SEED-FRA, SEED-GER). În cele ce urmează, sunt prezentate subseturile relevante din această familie extinsă.

Baza de date **SEED**, dezvoltată de Shanghai Jiao Tong University, este una dintre cele mai cunoscute resurse open-source pentru recunoașterea emoțiilor pe baza semnalelor EEG [29]. Este deosebit de valoroasă în contextul estimării stării cognitive, întrucât propune o abordare experimentală riguroasă, cu stimuli controlați și etichete afective clare, acoperind cele trei stări emoționale fundamentale: pozitivă,

[4] Procentul de închidere a ochilor [33].

negativă și neutră – Figura 2.3. Studiul a inclus **15 participanți** (cu vârsta medie de 23,27 ani), fiecare fiind expus la o serie de 15 clipuri video de aproximativ 4 minute, selectate anterior pentru a induce în mod consistent emoții specifice (5 clipuri/emoție). Fiecare participant a participat la 3 sesiuni experimentale separate, desfășurate în zile diferite, pentru a evalua stabilitatea răspunsurilor EEG în timp. După vizionarea fiecărui videoclip, subiecții au completat un chestionar subiectiv pentru a confirma starea afectivă resimțită, permițând validarea etichetelor emoționale. EEG-ul a fost înregistrat folosind un **sistem Neuroscan cu 62 de canale EEG** plasate conform standardului internațional 10-20. Frecvența de eșantionare a fost de 1000 Hz, cu aplicarea unui filtru trece-jos la 200 Hz și ulterior decimare la 200 Hz [25][26].

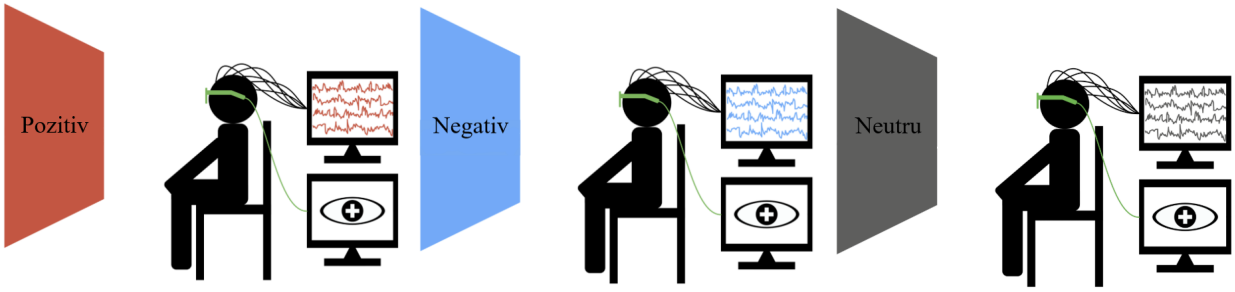


Figura 2.3 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED

Înregistrările includ și marcaje de început/sfârșit pentru fiecare segment de stimul video. Datele sunt disponibile în format .mat, împărțite pe sesiuni, participanți și clase emoționale. Fiecare înregistrare conține un segment EEG complet pentru fiecare clip video, însoțit de eticheta emoțională corespunzătoare. Pentru a facilita antrenarea rețelelor neuronale, baza este însoțită de o versiune preprocesată, în care semnalele au fost filtrate și normalizate (folosind un filtru trece-bandă 0.5–70 Hz) [23][25]. Baza de date SEED este larg utilizată în cercetarea din domeniul învățării automate aplicate pe semnale EEG, în special pentru:

- clasificarea multiclasă a stărilor emoționale pozitive, negative și neutre;
- antrenarea și evaluarea rețelelor CNN, LSTM și ale modelelor hibride;
- studii longitudinale privind consistența emoțiilor în timp;
- analiza corelației între caracteristicile EEG și autoevaluările emoționale;
- cercetări privind robustețea algoritmilor la variații inter-sesiune și inter-subiect.

Bazele de date **SEED-FRA** și **SEED-GER** reprezintă extensii trans-culturale ale seriei SEED, concepute cu scopul de a evalua generalizarea modelelor EEG de recunoaștere a emoțiilor în contexte interculturale, prin includerea unor participanți din spațiul european (Franța și Germania), în condiții

experimentale comparabile cu SEED. Ambele baze conțin semnale EEG și date preluate de la *dispozitive de eye-tracking* înregistrate în timpul vizualizării unor filmulețe afective, atent selecționate pentru a induce cele trei stări emoționale fundamentale: *emoție pozitivă*, *negativă* și *stare neutră*. Protocolul experimental a fost adaptat după modelul SEED original, cu menținerea duratei stimulilor (aproximativ 4 minute/video), chestionarelor subiective post-stimuli și etichetării afective clare. **SEED-FRA** cuprinde date colectate de la 8 subiecți francezi [36], în timp ce **SEED-GER** include înregistrările EEG de la 8 subiecți germani, ambele subseturi fiind structurate pentru a permite comparații directe între subiecți asiatici (din SEED) și europeni [37]. EEG-ul a fost înregistrat folosind sisteme compatibile cu Neuroscan, cu 62 de canale plasate conform standardului 10–20 și o frecvență de eșantionare de 1000 Hz, decimată ulterior. Seturile de date sunt disponibile în format preprocesat (.mat), cu marcaje de început/sfârșit pentru fiecare secvență video și etichete emoționale asociate [34]. Valoarea științifică majoră a acestor baze constă în:

- analiza diferențelor culturale în percepția emoțiilor și răspunsul EEG aferent;
- testarea robusteții și transferabilității algoritmilor antrenați pe SEED, în contexte etnice și lingvistice diferite;
- dezvoltarea de modele AI capabile de recunoaștere afectivă interculturală, relevante pentru aplicații globale (e.g., interfețe BCI adaptive la cultura utilizatorului).

SEED-IV reprezintă o extensie semnificativă a bazei de date originale SEED, propusă de aceeași echipă de cercetare din cadrul Shanghai Jiao Tong University (BCMI Lab). Obiectivul principal al acestui subset este de a rafina clasificarea afectivă prin extinderea numărului de emoții investigate și integrarea unor semnale biometrice suplimentare, în special mișcările oculare. În contrast cu SEED, care includea doar trei clase emoționale (pozitiv, negativ, neutru), SEED-IV introduce patru categorii afective distincte: *fericire*, *tristețe*, *frică* și *stare neutră*, oferind astfel un cadru experimental mai nuanțat pentru recunoașterea emoțiilor discrete – Figura 2.4.

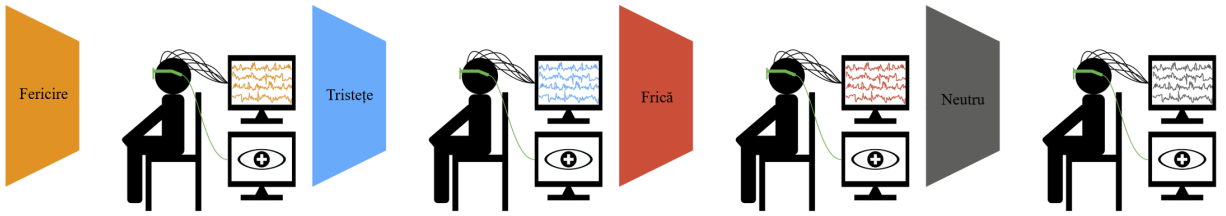


Figura 2.4 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-IV

Studiul a inclus **15 participanți** (cu vârsta medie de aproximativ 23 de ani), fiecare supus la trei sesiuni experimentale desfășurate în zile diferite [35]. În cadrul fiecărei sesiuni, subiecții au vizionat 24 de videoclipuri scurte (de ~1 minut), selectate riguros pentru a induce în mod specific una dintre cele patru

emoții țintă. După fiecare stimul afectiv, participanții au completat un chestionar subiectiv, prin care și-au evaluat starea emoțională. Pentru validarea suplimentară a reacțiilor afective, au fost înregistrate și date oculare cu ajutorul ochelarilor SMI, oferind posibilitatea analizei sincronizate EEG–mișcare oculară. EEG-ul a fost înregistrat cu un **sistem Neuroscan cu 62 de canale**, conform sistemului 10–20, la o frecvență de eșantionare de 1000 Hz, ulterior decimată la 200 Hz [25][29]. Datele sunt furnizate în format .mat, structurate pe sesiuni și emoții, și includ marcaje temporale precise. Pentru eficiență computațională, este disponibilă și o versiune preprocesată [39]. Baza de date SEED-IV este extrem de valoroasă pentru:

- antrenarea și validarea algoritmilor AI pentru recunoașterea emoțiilor discrete,
- cercetări multimodale care explorează integrarea semnalelor EEG și a mișcărilor oculare,
- studii asupra dinamicii emoționale în contexte realiste, cu stimuli vizuali de tip video,
- analiza diferențelor inter-sesiune și inter-subiect în procesarea afectivă cerebrală.

Baza de date SEED-V reprezintă o extindere semnificativă a setului original SEED, fiind concepută pentru recunoașterea emoțiilor din semnale EEG cu o granularitate mai fină și un spectru emoțional mai divers. Această versiune introduce cinci stări afective distincte — *fericire*, *tristețe*, *frică*, *dezgust* și *stare neutră* — oferind astfel o bază solidă pentru dezvoltarea și validarea algoritmilor de clasificare multiclasă în contexte afective – Figura 2.5. Creșterea numărului de clase emoționale față de versiunile anterioare permite explorarea mai detaliată a răspunsurilor cerebrale asociate cu emoțiile discrete [40].



Figura 2.5 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-V

Protocolul experimental este inspirat din versiunile SEED și SEED-IV, însă a fost extins pentru a acoperi o gamă mai largă de emoții. Participanții au vizionat o serie de videoclipuri atent selecționate, menite să inducă una dintre cele cinci emoții țintă. După fiecare secvență video, aceștia au completat un chestionar subiectiv de autoevaluare, ceea ce a permis validarea etichetelor emoționale asociate fiecărui segment EEG. Această metodologie riguroasă asigură corelarea clară între semnalul neurofiziologic și starea afectivă percepută de participant. În plus față de semnalele EEG, SEED-V include și caracteristici oculomotorii, obținute prin înregistrarea simultană cu ajutorul ochelarilor SMI. Așadar, SEED-V este un

set de date multimodal, potrivit pentru cercetări ce vizează fuziunea dintre semnalele EEG și mișcările oculare în scopul îmbunătățirii preciziei recunoașterii emoțiilor. Semnalele EEG au fost înregistrate utilizând un sistem cu 62 de canale plasate conform standardului internațional 10–20, la o frecvență de eșantionare de 1000 Hz [34], ulterior decimată pentru a facilita procesarea.

Baza de date este disponibilă în format .mat, organizată pe participanți, sesiuni și clase emoționale. Fiecare înregistrare include marcaje temporale precise și metadate referitoare la eticheta afectivă și răspunsul ocular [40]. Din acest motiv, SEED-V este o resursă extrem de valoroasă pentru antrenarea și testarea arhitecturilor bazate pe rețele neuronale convoluționale, modele LSTM sau abordări hibride, în special în sarcini de clasificare a emoțiilor discrete. De asemenea, baza permite studii longitudinale privind variațiile inter-sesiune și inter-subiect ale activării corticale în context emoțional.

Baza de date SEED-VII reprezintă cea mai extinsă și complexă versiune a seriei SEED, dezvoltată de BCMI Laboratory din cadrul Shanghai Jiao Tong University. Această versiune marchează un punct culminant în evoluția seturilor de date orientate spre recunoașterea emoțiilor, prin extinderea numărului de clase afective la șapte: *fericire*, *tristețe*, *frică*, *dezgust*, *neutru*, *furie* și *surpriză* – Figura 2.6 [41].

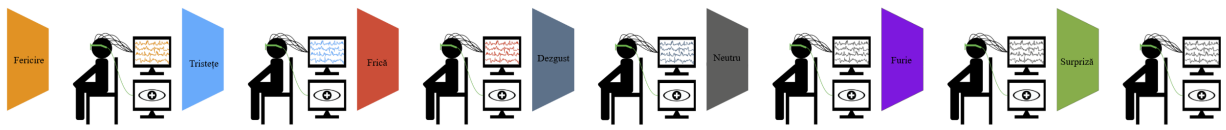


Figura 2.6 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-VII

Prin această diversificare, SEED-VII permite evaluarea algoritmilor de clasificare emoțională în contexte mult mai apropiate de complexitatea emoțiilor umane reale. Protocolul experimental a presupus expunerea participanților la stimuli video selectați cu grijă pentru a induce emoțiile menționate. După fiecare videoclip, subiecții au completat chestionare de autoevaluare, ceea ce a permis confirmarea subiectivă a stării afective resimțite și corelarea acesteia cu semnalul EEG înregistrat. Această metodologie bazată pe validare dublă – stimul standardizat și autoevaluare – asigură o etichetare riguroasă și fidelă a emoțiilor. Un aspect definitoriu al SEED-VII este caracterul său multimodal avansat [42].

Înregistrările EEG sunt completate cu date precise de *eye-tracking* obținute cu dispozitive de înaltă fidelitate (Tobii Pro Fusion), ceea ce permite integrarea răspunsurilor neurofiziologice și comportamentale în analiza stării emoționale. EEG-ul a fost înregistrat folosind un sistem cu 62 de canale plasate conform standardului 10–20, cu o frecvență de eșantionare de 1000 Hz și ulterior decimată pentru procesare eficientă. Sunt disponibile și marcaje temporale precise pentru segmentele video și răspunsurile subiective. Datele sunt distribuite în format compatibil .mat, organizate pe sesiuni, subiecți și etichete emoționale, fiind

însoțite de metadate detaliate privind caracteristicile oculare, structura clipurilor video și scorurile subiective [42]. Această organizare complexă face ca SEED-VII să fie o resursă ideală pentru dezvoltarea de modele de învățare profundă, fuziune multimodală, recunoaștere emoțională în timp real sau pentru validarea sistemelor de interacțiune om-computer bazate pe starea afectivă.

SEED-VIG este o extensie a seriei SEED, concepută special pentru studiul nivelului de vigilență în contexte simulatoare de conducere. Această bază de date documentează o abordare realistă și validă a monitorizării atenției și stării de alertă în timpul unei sarcini de conducere simulată. Subiecții au fost plasați într-un vehicul real amplasat în fața unui ecran panoramic de mari dimensiuni, simulând un mediu de condus realist [43] – Figura 2.7.



Figura 2.7 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-VIG

În timpul sesiunilor de condus, a fost înregistrat semnalul EEG împreună cu date de urmărire oculară obținute prin ochelarii SMI. SEED-VIG cuprinde date EEG colectate de la **23 de participanți** (12 femei și 11 bărbați, cu vârsta medie 23,3 ± 1,4 ani), înregistrate de la 17 canale EEG la 1000 Hz, în cadrul unor sesiuni de aproximativ două ore, însumând 885 de fragmente EEG. Etichetele de vigilență au fost obținute automat prin indicatorul PERCLOS, o metrică standard utilizată în studii privind somnolența și scăderea atenției [25][34]. Această bază este extrem de relevantă pentru dezvoltarea și testarea algoritmilor de clasificare a vigilenței sau pentru detecția timpurie a stării de somnolență în aplicații auto.

Baza **SEED-VLA** (Virtual Lab) și **SEED-VRW** (Virtual Real World) a fost creată pentru a investiga detecția oboselii în medii controlate (laborator) și naturale (condus real) – Figura 2.8.

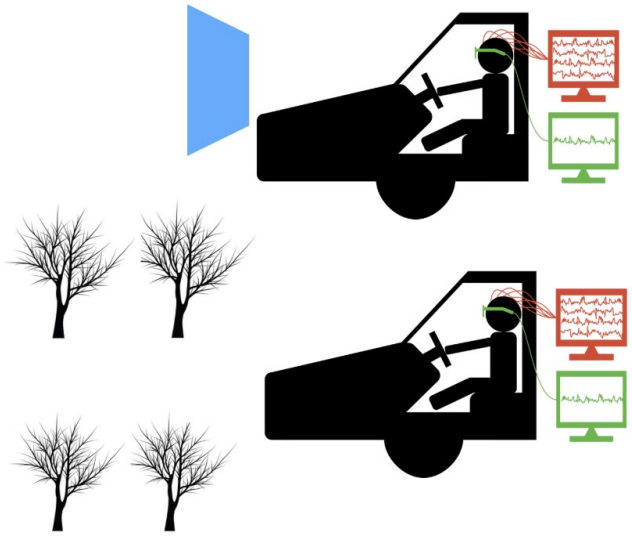


Figura 2.8 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-VLA / SEED-VRW

Protocolul a fost conceput pentru a induce oboseala treptat, în timp ce participanții efectuau sarcini de conducere monotonă. Semnalele EEG permit analiza tranzițiilor cognitive asociate cu scăderea vigilenței, iar datele oferă o bază valoroasă pentru antrenarea algoritmilor de detecție a stării de somnolență și pentru construirea de modele predictive în contexte de condus asistat.

SEED-DV reprezintă un set de date EEG unice, conceput pentru studiul percepției vizuale dinamice și pentru explorarea decodificării semnalelor cerebrale în timpul procesării vizuale complexe. Baza conține înregistrări EEG de la **20 de participanți** care au urmărit 1400 de videoclipuri scurte, fiecare asociat cu una dintre cele 40 de concepte vizuale (ex. animale, plante, peisaje naturale, sport, alimente, instrumente muzicale etc.) – Figura 2.9. Semnalele EEG au fost colectate în timp ce participanții vizualizau aceste videoclipuri naturale, cu scopul de a înțelege modul în care creierul răspunde la categorii conceptuale dinamice. Înregistrările sunt utile în cercetări privind codificarea vizuală, învățarea profundă aplicată pe semnale EEG și pentru dezvoltarea interfețelor neurale care decodează percepția vizuală [45]. SEED-DV nu conține etichete afective directe și nu este orientat către evaluarea stării cognitive în sens strict (vigilență, stres etc.), motiv pentru care nu a fost selectat în cadrul studiului experimental al acestei teze. Cu toate acestea, oferă perspective importante asupra reprezentărilor neuronale ale conceptelor vizuale.

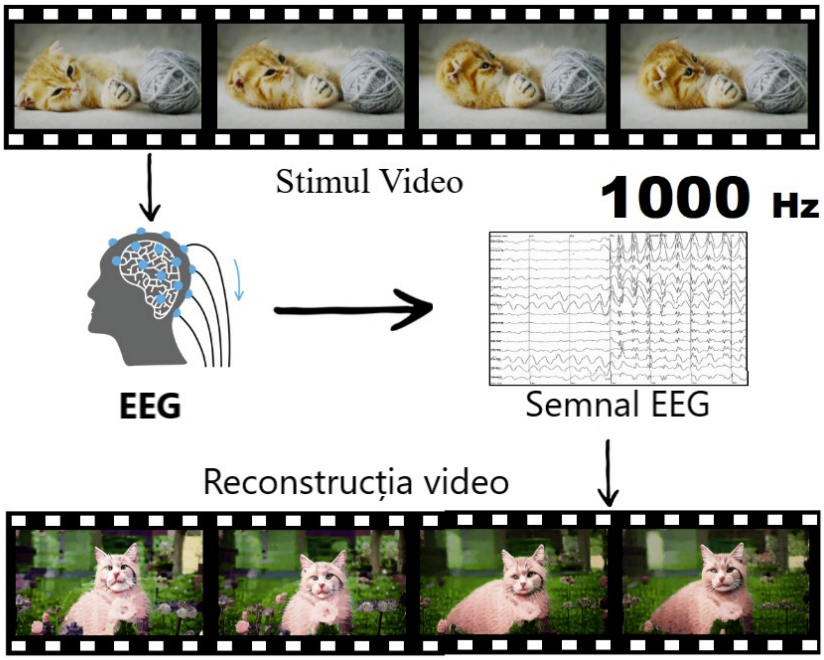


Figura 2.9 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-DV

SEED-SD este o bază multimodală recentă, care vizează explorarea efectelor privării de somn asupra răspunsurilor emoționale și cognitive. Setul conține înregistrări EEG și de mișcare oculară de la **40 de participanți**, colectate în trei condiții distincte: somn normal (NS), privare de somn (SD) și recuperare somn (SR) – Figura 2.10. Fiecare participant a fost expus la stimuli emoționali (fericire, tristețe, frică, neutru), iar răspunsurile EEG au fost înregistrate pentru a observa variațiile în funcție de starea fiziologică [46].

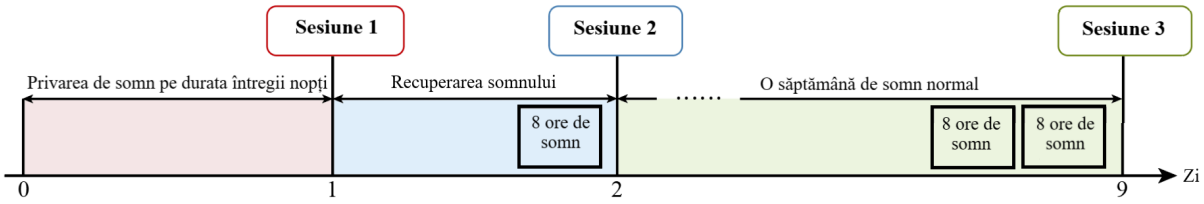


Figura 2.10 Protocolul de achiziție a semnalelor EEG în cazul bazei de date SEED-SD

Prin designul său factorial (emoție × stare de somn), SEED-SD permite evaluarea modului în care oboseala și lipsa de somn afectează percepția emoțională și procesele cognitive asociate [47]. Baza este valoroasă pentru dezvoltarea unor modele robuste de clasificare afectivă și pentru studii privind impactul stărilor fiziologice asupra activității cerebrale.

Deși familia SEED cuprinde unele dintre cele mai extinse, riguroase și influente baze de date EEG destinate recunoașterii emoțiilor, nicio variantă dintre acestea nu oferă etichete explicite pentru stări

cognitive precum stresul, oboseala cognitivă, atenția susținută sau starea de vigilență într-un cadru controlat adecvat obiectivelor prezentei teze. În ciuda complexității multimodale, a designului experimental elaborat și a popularității acestor seturi în literatura de specialitate, lipsa etichetelor direct relevante pentru evaluarea cognitiv efectivă a subiecților limitează aplicabilitatea lor în studiul propus. Prin urmare, niciuna dintre bazele de date din familia SEED nu a fost inclusă în selecția finală de date utilizate efectiv în experimentele dezvoltate în cadrul acestei lucrări de doctorat. Totuși, ele rămân resurse valoroase pentru validare externă și analiză comparativă în domeniul inteligenței artificiale aplicate pe semnale EEG.

2.1.3.3. Regulation of Arousal

Baza de date **Regulation of Arousal**, disponibilă prin intermediul **IEEE DataPort** reprezintă o resursă valoroasă pentru studierea relației dintre reglarea stării de excitare și performanța umană în sarcini motorii complexe. Aceasta a fost colectată în cadrul unui experiment desfășurat într-un simulator de zbor online, și a inclus un număr de **18 participanți sănătoși** (femei și bărbați, cu vârsta medie de aproximativ 25 de ani). Subiecții au fost implicați într-o sarcină cognitiv-motorie de tip **Boundary Avoidance Task (BAT)**, care simula pilotarea unui avion în condiții dificile, necesitând menținerea atenției și controlului motor subtil pe parcursul mai multor minute de zbor simulat. Protocolul experimental a presupus utilizarea feedback-ului auditiv generat în timp real, pe baza activității electroencefalografice, pentru a modula nivelul de excitare al participantului. Au fost investigate trei condiții experimentale distincte: feedback autentic (derivat din EEG), feedback fals și fără feedback. Această structură a permis evaluarea impactului neurofeedback-ului autentic asupra performanței și stării psihofiziologice. EEG-ul a fost înregistrat prin intermediul unei configurații cu 64 de canale, la o frecvență de eșantionare de 1024 Hz, utilizând un **sistem BioSemi ActiveTwo**. Pe lângă EEG, au fost colectate date multimodale adiționale precum: dilatarea pupilară (printr-un dispozitiv de eye-tracking binocular), rata variabilității ritmului cardiac (HRV) și parametri de performanță (precizia traiectoriei zborului și rata coliziunilor). Studiul a arătat că doar în condiția unui feedback autentic, participanții au reușit să-și mențină performanța semnificativ mai bine în fazele dificile ale sarcinii BAT, ceea ce indică potențialul reglării conștiente a stării de excitare. n plus, semnalele EEG au evidențiat modificări semnificative în benzile de frecvență alfa și beta, asociate cu procesul de reglare a stării de excitare. Aceste modificări au fost corelate atât cu performanța percepută subiectiv de participanți, cât și cu indicatorii obiectivi de performanță [48].

În contextul acestei teze, baza Regulation of Arousal este relevantă datorită aplicabilității sale în estimarea și reglarea stărilor cognitive precum vigilența și excitația neuronală în timp real. Cu toate acestea, din cauza lipsei de etichete explicite legate de emoții discrete sau de stări cognitive precum stresul sau oboseala, această bază de date nu a fost inclusă în setul principal de date utilizate în faza de antrenare a

modelelor AI din cadrul prezentei teze, ci este menționată ca exemplu de aplicație a semnalelor EEG în reglarea afectivă asistată de feedback în buclă închisă.

În concluzie, bazele de date EEG dedicate recunoașterii emoțiilor, reprezintă resurse valoroase pentru cercetarea multidimensională a stărilor afective, oferind protocoale experimentale riguroase, etichete emoționale bine definite și adesea o componentă multimodală. Aceste baze susțin dezvoltarea de algoritmi avansați pentru clasificarea emoțiilor, explorarea corelațiilor dintre răspunsurile subiective și activitatea cerebrală, precum și conceperea de interfețe om–computer. Cu toate acestea, în contextul specific al acestei teze, care vizează estimarea stărilor afective precum: depresia, anxietatea și stresul, aceste baze nu oferă etichete direct relevante pentru scopurile propuse. Majoritatea au fost construite pentru discriminarea între emoții discrete (ex. fericire, tristețe, frică) sau pentru măsurarea dimensiunilor afective (valență, excitație), fără a integra componente explicit legate de sarcini cognitive, vigilență susținută sau efort mental. Din acest motiv, deși recunoscute și valoroase în literatura de specialitate, bazele de date descrise anterior nu au fost incluse în selecția finală de date utilizate pentru antrenarea și validarea modelelor dezvoltate în cadrul acestei cercetări.

2.1.4. Baze de date EEG relevante pentru detectarea potențialelor legate de erori

Potențialele legate de erori (ErrP) sunt semnale EEG evocate automat în creierul uman atunci când o persoană percepe că a făcut sau a observat o greșeală, fie în mod conștient, fie inconștient. Ele sunt extrem de utile în sistemele BCI pasive sau hibride, deoarece permit detectarea automată a momentelor în care utilizatorul nu este mulțumit de rezultatul unui sistem (ex: o literă care a fost selectată în mod eronat) [49]. Bazele de date EEG dedicate ErrP includ, în general, sarcini cu feedback greșit/corect și sunt utile pentru dezvoltarea de interfețe om-computer sensibile la erori.

2.1.4.1. BCI-NER

Baza de date **BCI-NER** reprezintă un set complex conceput pentru detectarea potențialelor de eroare generate în timpul utilizării unui ***sistem BCI de tip speller*** bazat pe paradigma P300. În acest context, potențialele ErrP apar atunci când utilizatorul percepe o discrepanță între intenția sa și litera selectată de sistem – Figura 2.11. Baza conține date EEG de la **26 de participanți**, înregistrați folosind un sistem cu **56 de canale EEG (sistem EGI GES300)** la o frecvență de eșantionare de 250 Hz [50]. Fiecare participant a realizat sarcini de selectare de caractere pe o interfață vizuală (P300 Speller), în care algoritmul putea

interpreta corect sau greșit intenția utilizatorului [50]. Etichetele au inclus distincția între răspunsuri corecte și greșite, permițând analiza precisă a potențialelor de eroare evocate. Acest set este extrem de valoros pentru antrenarea modelelor de clasificare ErrP în contexte realiste, cu feedback implicit.



Figura 2.11 Ilustrarea conceptuală a detecției potențialelor de eroare (ErrP) în interfețele creier-calculator (BCI)

2.1.4.2. Monitoring ErrP in a target selection task

Monitoring ErrP in a target selection task este o bază de date care a fost creată pentru investigarea potențialelor de eroare (ErrP) în contextul unei sarcini pasive de selecție vizuală a unei ținte. Șase subiecți au fost înregistrați cu 64 de canale EEG în timp ce urmăreau mișcarea unui cursor controlat automat către o țintă prestabilită. În momentul în care traiectoria cursorului devia de la direcția corectă, creierul utilizatorului genera un potențial de eroare, detectabil în semnalul EEG. Etichetele disponibile indică în mod precis momentele când acțiunea a fost percepută ca fiind corectă sau incorectă, fiind sincronizate atât cu poziția cursorului, cât și cu activitatea neuronală. Acest protocol, care nu necesită interacțiune activă din partea subiectului, este valoros pentru studiul răspunsurilor eronate implicite și pentru dezvoltarea interfețelor creier-calculator pasive [51]. Baza permite analiza detaliată a dinamicii spațio-temporale a ErrP și reprezintă o resursă importantă pentru cercetările care urmăresc integrarea răspunsurilor cerebrale automate în sisteme BCI adaptive.

2.1.5. Baze de date EEG relevante pentru detectarea potențialelor vizual evocate

Potențialele vizual-evocate (VEPs) sunt răspunsuri cerebrale generate de stimuli vizuali specifici, precum luminile intermitente, modelele grafice repetitive sau modificările ritmice ale unor stimuli vizuali. Acestea sunt utilizate frecvent în sistemele BCI de tip SSVEP (steady-state visually evoked potentials), în care utilizatorul își focalizează atenția asupra unui stimul vizual ce se modulează la o frecvență constantă. Răspunsul EEG rezultat este sincronizat cu frecvența stimulului, permițând un control precis al interfeței [52]. Bazele de date VEP sunt esențiale pentru studiul atenției vizuale, al percepției și pentru dezvoltarea BCI bazate pe focalizare vizuală.

2.1.5.1. Synchronized Brainwave

Baza de date **Synchronized Brainwave (SBW)** a fost concepută pentru a studia sincronizarea activității cerebrale în raport cu o varietate de stimuli vizuali și sarcini cognitive. În cadrul experimentului, **15 participanți** au fost expuși la două seturi de videoclipuri concepute pentru a declanșa diferite procese mentale, precum relaxarea, calculul mintal, clipitul voluntar sau involuntar, identificarea de obiecte colorate și urmărirea de reclame. Fiecare set de videoclipuri a fost înregistrat sincronizat cu semnalele EEG pentru a permite analiza răspunsurilor vizuale evocate în timp real [53]. Deși nu este o bază de date VEP în sens strict (bazată exclusiv pe stimulare cu frecvență fixă, ca în SSVEP), SBW oferă un cadru ecologic interesant pentru investigarea activității corticale ca răspuns la stimuli vizuali complecși și este adecvată pentru aplicații exploratorii în interacțiunea om-computer și analiza atenției vizuale. În contextul acestei teze, baza poate servi drept referință pentru testarea algoritmilor de clasificare a răspunsurilor EEG la stimuli vizuali. Totuși, absența unui protocol de stimulare vizuală standardizat (de exemplu, utilizarea unor stimuli luminoși intermitenți sau a unor secvențe vizuale repetitive controlate) limitează aplicabilitatea sa în scenarii riguroase de estimare a stării afective.

2.1.6. Baze de date EEG relevante pentru detectarea potențialelor evocate legate de evenimente

Potențialele evocate legate de evenimente (ERP) sunt modificări tranzitorii ale activității EEG legate de un stimul cognitiv, senzorial sau motor. Acestea sunt folosite pentru a studia procese cognitive precum atenția, percepția, luarea deciziilor sau înțelegerea limbajului. Cele mai cunoscute tipuri de ERP includ P300 (pentru decodificarea atenției), N400 (pentru înțelegerea semantică), N70 **(**pentru de procesarea automată a fețelor) și LRP (pentru pregătirea motorie) [54]. Bazele ERP sunt larg utilizate în cercetarea

neuroștiințifică, mai ales în paradigme de tip oddball, discriminare vizuală, sarcini de învățare sau recunoașterea obiectelor.

2.1.6.1. Face-House Discrimination

Baza de date **Face-House Discrimination** a fost concepută pentru a analiza diferențele în răspunsul cortical asociat procesării categoriilor vizuale – în acest caz, fețe umane comparativ cu imagini de locuințe. Experimentul a implicat **7 pacienți epileptici**, cărora li s-au prezentat câte 50 de imagini în nuanțe de gri pentru fiecare categorie (față/locuință), în cadrul a 3 sesiuni experimentale, însumând astfel 300 de prezentări per participant. Această paradigmă a fost selectată în vederea investigării potențialelor evocate de tip ERP, în special componenta N170, asociată proceselor timpurii de recunoaștere vizuală, cum ar fi percepția fețelor și a obiectelor [55]. Deși această bază include un număr redus de participanți și are un caracter preponderent clinic, ea ilustrează un protocol ERP relevant pentru investigarea proceselor de procesare vizuală complexă.

2.1.6.2. Brain Invaders

Un grup extins de baze de date a fost derivat din aplicația **Brain Invaders** – un joc BCI vizual bazat pe paradigma de tip oddball (stimuli rari și frecvenți), utilizată frecvent pentru a evoca răspunsul ERP de tip P300. Această paradigmă implică identificarea unor ținte rare printre stimuli frecvenți și generează un vârf pozitiv al semnalului EEG (P300) la aproximativ 300 ms după prezentarea țintei [56]. Inițial, au fost înregistrați **24–25 de participanți**, iar semnalele EEG au fost achiziționate utilizând un sistem cu 16 electrozi, poziționați conform standardului internațional 10–20. Aceasta înseamnă că activitatea electrică cerebrală a fost înregistrată simultan de la 16 locații diferite de pe scalp, ceea ce permite detectarea cu precizie a răspunsurilor P300 generate de apariția stimulilor țintă (vizuali) [47][48].

Ulterior, această colecție de date a fost extinsă semnificativ, incluzând noi protocoale experimentale și mai mulți participanți. Un subset a inclus **71 de subiecți**, ale căror semnale EEG au fost colectate cu aceiași 16 electrozi menționați anterior [59]. Alte experimente au explorat interacțiuni sociale în medii colaborative sau competitive, în care câte doi subiecți participau simultan la sarcină – fiecare purtând un sistem EEG cu 32 de electrozi. În aceste studii, grupuri de 38, 44 sau 50 de participanți au fost expuși la diferite variații ale condițiilor de prezentare vizuală, precum ajustarea duratei stimulilor luminoși sau introducerea unor sesiuni suplimentare de antrenament și testare, desfășurate cu sau fără etapă de calibrare bazată pe geometria Riemanniană [60], [61], [62]. De asemenea, un subset distinct de 12 participanți a fost

utilizat pentru a investiga influența impedanței contactului scalp–electrod asupra calității semnalului EEG. În acest context, impedanța a fost modificată controlat, cu scopul de a evalua robustețea metodelor de preprocesare și clasificare în condiții de raport semnal-zgomot redus.[63]. Aceste variante multiple ale setului Brain Invaders îl transformă într-o resursă complexă și extrem de utilă pentru cercetarea sistemelor BCI bazate pe P300 în contexte realiste și variate. Toate aceste seturi permit cercetarea răspunsurilor P300 într-o varietate de condiții experimentale și tehnologice și sunt resurse cheie pentru dezvoltarea algoritmilor de detecție a intenției și clasificare a răspunsurilor în aplicații BCI.

2.1.6.3. Sustained-Attention Driving

Sustained-Attention Driving (SADT) este o bază de date care vizează monitorizarea atenției susținute într-un mediu de conducere simulată în realitate virtuală (VR) [64]. Experimentul a inclus **27 de participanți**, fiecare participând la două sesiuni de 90 de minute (una fără feedback și una cu feedback kinestezic). EEG-ul a fost înregistrat cu 32 de canale la o frecvență de eșantionare de 500 Hz [65]. Această bază este utilă pentru analiza ERP-urilor asociate menținerii atenției și recunoașterii reducerii vigilenței în sarcini de durată, într-un context aplicativ relevant pentru siguranța rutieră și evaluarea oboselii.

2.1.6.4. Dryad-Speech

Dryad-Speech este o colecție complexă de experimente EEG, concepută pentru a explora înțelegerea limbajului natural prin intermediul potențialelor evocate (ERP), în contexte variate de ascultare, citire și procesare multisenzorială. Această bază de date a fost construită pornind de la premisele neurocognitive conform cărora înțelegerea discursului se bazează pe mecanisme cerebrale rapide și relativ sincronizate cu semnificația cuvintelor, cu implicarea componentelor ERP de tip N400. Spre deosebire de paradigmele clasice, care se bazează pe procesarea unor propoziții scurte cu incongruențe semantice deliberate, Dryad-Speech adoptă o abordare mai ecologică, în care semnalul EEG este înregistrat în timp ce participanții ascultă discursuri naturale, continue, ce reflectă mai fidel contextul conversațional real.

Baza cuprinde cinci paradigme experimentale distincte. Primul experiment a presupus ascultarea unei versiuni audio a unui roman de ficțiune american din secolul al XX-lea de către un grup de 19 participanți. Al doilea experimentează redarea inversă a acelorași fragmente audio, pentru a analiza pierderea semnificației și impactul asupra procesării semantice. Al treilea experiment constă într-un test clasic de tip N400, în care 300 de propoziții sunt prezentate vizual, iar jumătate dintre acestea se încheie cu un cuvânt semantic incongruent. Această paradigmă permite investigarea clară a componentelor ERP

asociate procesării semantice neașteptate. Al patrulea experiment, de tip „cocktail party”, a implicat 33 de participanți împărțiți în două grupuri, fiecare fiind instruit să acorde atenție doar unuia dintre cele două fluxuri narative prezentate simultan în urechea stângă și în cea dreaptă. Acest protocol permite analiza atenției selective și a capacității de separare auditivă. În final, al cincilea experiment constă în prezentarea unor videoclipuri cu vorbitori naturali, în contexte conversaționale, pentru a evalua integrarea audio-vizuală a limbajului [66].

Un aspect metodologic esențial al bazei este utilizarea unui model computațional care cuantifică gradul de disimilitudine semantică a fiecărui cuvânt în raport cu contextul anterior. Această măsură este ulterior corelată cu activitatea EEG prin modele de regresie, evidențiind o componentă negativă pronunțată în intervalul 200–600 ms post-stimul, predominant în regiunile centro-parietale, cu trăsături similare componentei N400 [67]. Rezultatele arată că această activare ERP este profund dependentă de nivelul de înțelegere al discursului, fiind diminuată sau absentă atunci când sensul este distorsionat (ex. vorbire inversată) sau când atenția este deviată.

Prin combinarea de sarcini variate și realiste, **Dryad-Speech** oferă un cadru valoros pentru investigarea limbajului natural, a procesării semantice, a efectelor atenției selective și a integrării multisenzoriale. Deși setul de date este extrem de relevant pentru studiile din neuroștiință, el nu oferă etichete directe legate de stări afective. În consecință, Dryad-Speech nu a fost inclus în selecția de baze de date utilizate efectiv în cadrul experimentelor acestei teze, însă rămâne o resursă valoroasă pentru cercetări viitoare privind dinamica ERP în analiza discursului natural.

2.1.6.5. ERP Core

Baza de date **ERP Core** reprezintă o colecție standardizată, dezvoltată pentru a acoperi cele mai utilizate paradigme de potențiale evocate în cercetarea neuroștiințifică. Setul include date EEG de la **40 de participanți sănătoși** și este însoțit de adnotări, fișiere preprocesate și scripturi MATLAB pentru analiză, fiind astfel o resursă completă atât pentru studii experimentale, cât și pentru scopuri educaționale. Datele EEG au fost colectate în condiții controlate, în cadrul unor paradigme validate, care investighează procese cognitive fundamentale precum percepția vizuală, atenția, procesarea semantică, detecția stimulilor auditivi devianți, luarea deciziilor și monitorizarea erorilor. Printre acestea se numără paradigme specifice pentru detecția N170, MMN (discriminarea auditivă pasivă), N2pc (atenția vizuală direcționată), N400 (procesarea semantică), P3b (recunoașterea conștientă a unui stimul rar), LRP (inițierea răspunsului motor) și ERN (negativitatea asociată erorii), asociate cu inițierea răspunsului motor și detecția erorilor [68].

Prin calitatea și diversitatea protocoalelor incluse, ERP Core oferă un cadru de referință pentru cercetarea activității corticale în sarcini cognitive de bază. Deși această colecție nu a fost utilizată direct în

experimentele prezentei cercetări, aceasta oferă un punct de reper valoros pentru validarea metodologiilor de procesare EEG și a algoritmilor de detecție automată a componentelor ERP în contexte controlate.

2.1.7. Baze de date EEG relevante pentru detectarea în condiții de repaus

Înregistrările EEG în stare de repaus constituie o componentă fundamentală a cercetării neuroștiințifice, oferind informații esențiale despre activitatea cerebrală de fond, în absența unei sarcini cognitive sau senzoriale explicite. Aceste date sunt utilizate frecvent pentru estimarea stării funcționale a creierului, evaluarea rețelelor neuronale în repaus și dezvoltarea unor biomarkeri neinvazivi pentru diagnostic sau identificare personală. În cadrul acestui subcapitol sunt prezentate mai multe baze de date open-source care conțin semnale EEG în condiții de repaus cu ochii închiși și/sau deschiși, unele dintre ele fiind însoțite de etichete relevante pentru oboseală sau identificare biometrică.

2.1.7.1. Resting State EEG Data

Baza de date **Resting State EEG Data** conține înregistrări EEG de la un grup de **22 de subiecți**, fiecare participant fiind înregistrat în două condiții standard de repaus: cu ochii deschiși și cu ochii închiși. Fiecare sesiune a durat în total 8 minute, fiind împărțită în mod egal: 4 minute cu ochii închiși, urmate de alte 4 minute cu ochii deschiși. Semnalele EEG au fost achiziționate cu ajutorul unui **sistem cu 72 de canale**, ceea ce oferă o rezoluție spațială ridicată a activității corticale în stare de repaus. Structura experimentală a fost concepută pentru a permite analiza comparativă între cele două condiții vizuale de repaus, diferențiate prin prezența sau absența stimulării vizuale externe. Această diferență este esențială pentru studiul undelor alfa, a rețelelor neuronale implicate în procesarea internă și a nivelului general de activare corticală [69].

Baza este adesea utilizată pentru analizarea activității cerebrale spontane, estimarea conectivității funcționale și identificarea tiparelor EEG asociate cu stări precum relaxarea, somnolența sau vigilența scăzută. Prin urmare, Resting State EEG Data este o resursă valoroasă pentru studiile de referință care investighează activitatea cerebrală de fond, dar și pentru aplicații moderne precum biometria EEG sau sistemele adaptive de neurofeedback.

2.1.7.2. MindID

Bazele de date **MindID (EID-M și EID-S)** conțin înregistrări EEG în stare de repaus (ochi închiși), colectate de la **8 subiecți** utilizând **sistemul Emotiv EPOC+** cu 14 electrozi, la o frecvență de eșantionare de 128 Hz. Durata fiecărei înregistrări este de 54 de secunde. Setul **EID-M** include trei sesiuni per subiect, iar **EID-S** conține o singură sesiune. Scopul principal al acestor baze de date a fost dezvoltarea unui sistem de identificare biometrică, capabil să recunoască identitatea subiecților pe baza semnalelor EEG [70]. Deși durata înregistrărilor este relativ scurtă, structura experimentală simplă, repetabilitatea ridicată (în EID-M) și controlul riguros al condițiilor de achiziție fac ca aceste seturi de date să fie valoroase în cercetări privind clasificarea EEG în regim offline, precum și în studiile de identificare a trăsăturilor neurofiziologice distinctive între indivizi. Aceste baze de date nu includ etichete legate de stări afective, astfel că nu au fost incluse în selecția experimentală a acestei teze.

2.1.7.3. SPIS Resting State Dataset

Baza de date **SPIS Resting State Dataset** a fost concepută pentru a analiza activitatea cerebrală în stare de repaus, înregistrată înaintea unei sarcini cognitive susținute. Aceasta conține înregistrări EEG colectate de la **10 subiecți**, folosind 64 de canale (montaj internațional 10-10), în două condiții distincte: cu ochii închiși și cu ochii deschiși. Fiecare condiție a fost înregistrată timp de 2,5 minute, imediat înainte de începerea unei sesiuni de 105 minute de tip **Sustained Attention to Response Task (SART)**, caracterizată printr-o succesiune fixă de stimuli și intervale de timp variabile între aceștia [71]. Obiectivul principal al setului de date a fost de a furniza o bază EEG stabilă pentru comparația între starea de repaus și activitatea cognitivă prelungită, oferind un cadru relevant pentru studiul mecanismelor neurofiziologice implicate în menținerea atenției. Deși înregistrările sunt scurte ca durată, asocierea cu o sarcină cognitivă riguroasă le conferă un potențial deosebit în analiza dinamicii stării de vigilență și a modificărilor EEG înainte de sarcină. Cu toate acestea, lipsa etichetelor explicite privind starea mentală a subiecților limitează utilizarea directă a acestei baze de date în contextul prezentei teze, dar o recomandă pentru validarea metodelor de extragere a trăsăturilor EEG asociate atenției susținute.

2.1.7.4. Alpha Waves

Baza de date **Alpha Waves** a fost realizată în cadrul unui experiment pilot desfășurat în anul 2017 la laboratorul GIPSA (Université Grenoble Alpes, CNRS, Grenoble-INP). Scopul principal al acestei baze a fost de a furniza un set simplu, dar fiabil, de înregistrări EEG în stare de repaus, util pentru validarea algoritmilor de procesare a semnalului și a modelelor de învățare automată. Un aspect important al acestei

colecții de date constă în faptul că explorează activitatea cerebrală alfa asociată cu starea de repaus, în special diferențele între condițiile *„ochi închiși”* și *„ochi deschiși”*. Experimentul a inclus **20 de voluntari**, dintre care 7 femei, cu vârste cuprinse între 19 și 44 de ani (vârsta medie: 25,8 ani). Fiecare participant a fost înregistrat timp de 100 de secunde, împărțite în 10 blocuri experimentale de câte 10 secunde. Cele două condiții – ochi închiși și ochi deschiși – s-au alternat de la un bloc la altul, fiind marcate manual în semnalul EEG cu ajutorul unei aplicații personalizate. Înainte de fiecare bloc, subiecții au fost instruiți să închidă sau să deschidă ochii, iar datele rezultate au fost etichetate în timp real. Astfel, fiecare fișier conține marcaje temporale precise, etichete pentru fiecare condiție experimentală și date demografice despre participant, precum vârsta, sexul și un scor de oboseală autoevaluat pe o scală de la 0 (odihnit) la 10 (epuizat). Semnalele EEG au fost achiziționate folosind un **amplificator g.USBamp** și **o cască EC20** cu 16 electrozi, plasați conform sistemului internațional 10–20, cu o frecvență de eșantionare de 512 Hz. Referința a fost plasată pe lobul urechii drepte, iar impedanța de contact a fost menținută sub 5 kΩ pentru toți electrozii. Înregistrările nu au fost filtrate digital în timpul achiziției, oferind astfel acces la semnalul EEG brut, esențial pentru cercetări metodologice sau testarea diferitelor metode de preprocesare. Un element distinctiv al acestei baze de date este includerea scorurilor de oboseală raportate subiectiv de fiecare participant. Această etichetă, deși simplă, oferă un punct de plecare valoros pentru explorarea relației dintre ritmurile alfa (8–12 Hz), nivelul de relaxare și oboseala mentală [72]. Așadar, AlphaWaves se dovedește a fi o resursă utilă pentru studii de diferențiere între condiții de repaus și pentru validarea preliminară a modelelor AI, datorită structurii sale clare și protocolului bine definit, deși durata înregistrărilor a fost scurtă.

În contextul prezentei teze, axate pe estimarea stărilor afective precum anxietatea, depresia și stresul, baza AlphaWaves nu a fost inclusă în selecția principală de date utilizate experimental, deoarece nu conține etichete afective explicite. Cu toate acestea, datorită structurii protocolare clare și a disponibilității scorului subiectiv de oboseală, această bază poate reprezenta o resursă complementară valoroasă în etapa de testare exploratorie. Informațiile privind nivelul de oboseală perceput pot fi utile pentru investigarea relației dintre starea de relaxare mentală și reactivitatea afectivă, precum și pentru identificarea unor posibile efecte de interacțiune sau confuzii în clasificarea stărilor afective, întrucât oboseala poate influența percepția și raportarea anxietății, depresiei sau stresului.

2.1.7.5. BIDS

Baza de date **BIDS** documentează activitatea cerebrală a **24 de participanți** implicați într-o activitate de meditație. Subiecții au fost instruiți să mediteze într-un cadru controlat, iar la intervale regulate (aproximativ la fiecare 2 minute), au fost întrerupți pentru a-și autoevalua nivelul de concentrare și tendința de deviere a atenției de la meditație (mind-wandering). Aceste autoevaluări oferă un reper valoros pentru

etichetarea stărilor mentale interne, dificil de cuantificat în mod obiectiv. Datele EEG au fost achiziționate utilizând un **sistem BioSemi cu 64 de canale**, care respectă standardul internațional 10-20 de plasare a electrozilor. Frecvența de eșantionare utilizată a fost de 2048 Hz, ceea ce permite o rezoluție temporală foarte ridicată și o captare fidelă a semnalelor rapide din activitatea electrică cerebrală [73]. Setul de date este organizat conform formatului BIDS (Brain Imaging Data Structure), ceea ce facilitează prelucrarea automată, interoperabilitatea cu instrumente open-source și reproductibilitatea experimentelor [74].

Deși numărul participanților este relativ redus, acest set de date oferă un cadru valoros pentru investigarea relației dintre activitatea EEG și dinamica atenției conștiente în contextul meditației, un domeniu aflat în expansiune în cercetarea neuroștiințifică. În contextul tezei, baza este analizată ca exemplu de experiment EEG axat pe stări mentale introspective, dar nu este inclusă în setul principal de date utilizate în etapele experimentale.

2.1.8. Baze de date EEG pentru explorarea imaginației motorii și a reprezentărilor cognitive interne

Sarcinile de imaginație și reprezentare mentală implică procese cognitive complexe, precum simularea internă a acțiunilor, evocarea de stimuli senzoriali în absența stimulului extern sau manipularea mentală a obiectelor. Studiul EEG în astfel de contexte permite investigarea activității cerebrale asociate cu planificarea motorie, memoria senzorială și dinamica atenției orientate intern. Bazele de date descrise în continuare oferă un cadru experimental pentru analizarea acestor fenomene, prin sarcini controlate de imaginație muzicală, motorie sau vizual-spațială.

2.1.8.1. Music Imagery Information Retrieval

Baza de date **Music Imagery Information Retrieval (MIIR)** a fost concepută pentru a studia procesele cognitive implicate în reprezentarea mentală a muzicii și în reactivarea voluntară a conținutului auditiv în memorie, fără prezența stimulului sonor extern. Aceasta include date EEG înregistrate de la **10 participanți** în timpul unor sarcini de imaginație muzicală, în care subiecții au fost instruiți să își imagineze mental fragmente muzicale distincte, fără a le auzi efectiv în acel moment. Scopul experimentului a fost acela de a capta activarea neuronală asociată cu evocarea internă a sunetului și a ritmului, permițând explorarea mecanismelor cerebrale ale percepției auditive interne și ale memoriei muzicale. În total, au fost utilizate 12 fragmente muzicale diferite, care variază în ceea ce privește structura ritmică, tempo-ul și metrica. Această diversitate permite investigarea modului detaliat în care creierul procesează structuri

muzicale complexe în absența stimulului extern. Semnal EEG a fost înregistrat folosind un **sistem cu 64 de canale** conform standardului 10-20, ceea ce oferă o acoperire spațială extinsă a cortexului implicat în procesarea auditivă și imaginară. Protocolul a presupus perioade distincte de ascultare și de imaginație, iar datele au fost segmentate în funcție de aceste condiții [75].

Relevanța acestei baze de date pentru studiul stărilor cognitive constă în capacitatea sa de a capta activitatea neurală în absența stimulului senzorial direct, ceea ce o face valoroasă pentru înțelegerea fenomenelor de simulare mentală, memorie auditivă și procesare internă a informației muzicale. În contextul prezentei teze, baza MIIR este analizată ca exemplu de sarcină cognitivă complexă bazată pe reprezentare internă, fără a fi însă inclusă în setul principal de date utilizate în cadrul experimentelor.

2.1.9. Baze de date EEG relevante pentru analiza mișcărilor oculare și a clipitului

Mișcările oculare și clipitul reprezintă fenomene comportamentale cu relevanță crescută în analiza EEG, întrucât pot influența semnificativ semnalul cortical în regiunile frontale și perioculare. Pe de o parte, aceste activități pot genera artefacte înregistrate în canalele EEG, necesitând identificare și corectare în etapa de preprocesare. Pe de altă parte, mișcările oculare pot servi drept indicatori comportamentali indirecți ai stării cognitive, cum ar fi vigilența, atenția sau oboseala. Din acest motiv, bazele de date EEG care integrează informații temporale despre clipitul ocular sau expresiile faciale, obținute prin înregistrări video sau senzori specializați, oferă oportunități valoroase pentru dezvoltarea de sisteme multimodale și interfețe creier–computer care valorifică semnalele oculare ca indicatori ai stării cognitive.

În cele ce urmează, sunt prezentate o serie de baze de date EEG care includ informații despre clipit, poziția ochilor sau expresiile faciale, fie în mod direct (prin etichete sau înregistrări video), fie indirect (prin impactul asupra activității EEG). Aceste seturi sunt utile atât pentru cercetarea proceselor oculomotorii, cât și pentru integrarea EEG cu date vizuale în scopul estimării stării cognitive.

2.1.9.1. EEG Eye State

Baza de date **EEG Eye State** reprezintă un set simplu, dar eficient, pentru evaluarea metodelor de clasificare binară aplicate semnalelor EEG, în contextul detecției stării ochilor (deschiși sau închiși). Aceasta constă într-o singură sesiune continuă de înregistrare, cu o durată de aproximativ două minute (117 secunde), obținută de la un singur participant. Achiziția a fost realizată folosind o cască **EEG Emotiv EPOC**, care include 14 canale EEG, oferind astfel o configurație minimă, dar suficientă pentru evaluarea fezabilității unor sisteme de detecție automată. Etichetele asociate semnalului EEG indică în timp real starea

ochilor, permițând o abordare de învățare supervizată la nivel de eșantion temporal [76]. Deși dimensiunea bazei de date este limitată, aceasta oferă un exemplu concret de aplicație EEG în contexte non-clinice și în condiții de utilizare realistă, fiind frecvent folosită în lucrări introductive privind clasificarea clipitului, vigilența și prototiparea de interfețe om-computer cu cost redus. În contextul estimării stării cognitive, **EEG Eye State** nu include etichete explicite pentru atenție sau oboseală, dar oferă o sursă complementară de date pentru detecția tranzițiilor vizuale, utile în integrarea cu alte surse EEG orientate spre analiza vigilenței sau somnolenței.

2.1.9.2. EEG-IO și EEG-VV/VR

Următoarele trei baze, **EEG-IO** și **EEG-VV/VR**, oferă un cadru experimental mai bine controlat pentru analiza clipitului voluntar și involuntar. În cazul EEG-IO, au fost înregistrate clipiri voluntare induse prin stimuli externi, folosind electrozi frontali (Fp1, Fp2) și echipamente **OpenBCI** și **BIOPAC Cap100C**. 20 de participanții au fost instruiți să efectueze aproximativ 25 de clipiri controlate într-o sesiune, iar evenimentele au fost etichetate manual cu ajutorul unui flux video sincronizat [77]. În schimb, EEG-VV și EEG-VR se concentrează pe clipitul involuntar în două contexte cognitive diferite: vizionarea unui videoclip (condiție pasivă) și citirea unui articol (condiție activă) [78]. Aceeași configurație hardware a fost utilizată, iar adnotarea a fost realizată cu precizie prin corelare video [79], ceea ce face ca aceste date să fie deosebit de utile pentru recunoașterea automată a tiparelor naturale de clipit și evaluarea vigilenței bazate pe comportamentul ocular.

2.1.9.3. Kara-One

Kara-One este o bază de date complexă, în care EEG-ul este înregistrat în paralel cu semnalele audio și urmărirea facială în timpul pronunțării (imaginate sau reale) a unor foneme sau cuvinte întregi. Protocolul experimental a inclus **14 participanți**, fiecare fiind supus unei serii de comenzi vizuale și auditive constând în 7 foneme (ex. iy, uw, piy, tiy, diy) și 4 cuvinte reale (pat, pot, knew, gnaw), selectate strategic pentru a acoperi o varietate de sunete vocale, nazale, oclusive (sau explozive) și consonantice. Fiecare stimul a fost prezentat într-un cadru controlat, printr-o succesiune de 4 stări: repaus, prezentare vizuală și auditivă a stimulului, vorbire imaginată (fără mișcare), și pronunțare efectivă. Aceste etape au fost însoțite de înregistrări EEG de înaltă rezoluție (**sistem Neuroscan Quick-cap** cu 64 de canale și frecvența de eșantionare de 1.000 Hz), capturi audio și urmărire facială cu ajutorul unei camere Microsoft Kinect [80]. Kara-One este valoroasă și din perspectiva analizei mișcărilor oculare și faciale, întrucât

activitatea musculară frontală este capturată în paralel prin electrozi suplimentari poziționați în jurul ochilor, dar și prin urmărirea expresiilor faciale cu ajutorul Kinect. Integrarea sincronă a semnalelor EEG, a datelor audio și a înregistrărilor video faciale transformă această bază într-un instrument complex pentru cercetarea mecanismelor de decodificare a vorbirii interne (fără articulare vocală), dezvoltarea interfețelor creier–computer orientate spre imaginația verbală și investigarea activării corticale frontale în timpul sarcinilor lingvistice.

2.1.9.4. EEGEyeNet

EEGEyeNet reprezintă una dintre cele mai extinse colecții EEG open-source dedicate analizei corelate a activității cerebrale și a mișcărilor oculare. Setul de date conține înregistrări de la **356 de participanți sănătoși**, cu vârste cuprinse între 18 și 80 de ani (190 femei și 166 bărbați). Achiziția EEG a fost realizată cu un **sistem EEG Geodesic Hydrocel** cu 128 de canale, la o frecvență de eșantionare de 500 Hz, utilizând o referință centrală mediană și menținând impedanța sub 40 kΩ pentru fiecare electrod. Simultan, poziția ochilor a fost monitorizată cu ajutorul unui dispozitiv de eye-tracking **EyeLink 1000 Plus**, având aceeași frecvență de eșantionare (500 Hz) și o rezoluție spațială sub 0.01 RMS. Participanții au fost poziționați la 68 cm de un monitor de 24 inci (rezoluție 800×600 px), cu sprijin pentru bărbie pentru a elimina mișcările capului. Înregistrările s-au desfășurat în cadrul a trei paradigme experimentale: urmărire stânga–dreapta, variații de unghi și amplitudine, precum și poziționare absolută. Fiecare paradigmă a fost concepută pentru a genera date sincronizate EEG și eye-tracking care să permită dezvoltarea de modele robuste de fuziune multimodală [81]. EEGEyeNet oferă nu doar date brute, ci și versiuni preprocesate la două niveluri (minim și maxim), împreună cu codul complet de preprocesare, reducând astfel bariera tehnică pentru utilizatorii care doresc să testeze metode AI pe semnale EEG în contextul integrării informației vizuale și a mișcărilor oculare. Această resursă este ideală pentru cercetări privind integrarea semnalelor cerebrale și oculare, recunoașterea automată a atenției vizuale, precum și pentru validarea arhitecturilor neuronale în contexte realiste de urmărire a privirii.

2.1.9.5. Multimodal Eye-Blink and Attention Level

Baza de date **Multimodal Eye-Blink and Attention Level (mEBAL)** a fost concepută pentru a susține cercetarea în detectarea automată a clipitului și estimarea nivelului de atenție în contexte educaționale online. Această bază reprezintă o extensie a platformei eDBBdb, fiind centrată pe monitorizarea multimodală a activității cognitive și oculare a studenților în timpul unor sarcini variate, prin

integrarea semnalelor EEG, a imaginilor RGB/NIR și a detectării faciale. În cadrul experimentului au participat **38 de studenți**, dintre care 11 purtau ochelari, în condiții care simulau scenarii realiste de învățare la distanță. Fiecare participant a efectuat opt sarcini repartizate în trei categorii de atenție cognitivă: completarea unor formulare (atenție scăzută), rezolvarea de sarcini logice sau lingvistice (atenție medie) și întrebări de tip grilă (atenție ridicată). Clipitul a fost înregistrat prin camere RGB și NIR (Intel RealSense D435i), cu o frecvență de 30 cadre/secundă și o rezoluție de 1280x720, permițând captarea clipiturilor pe intervale de 3–13 cadre (100–400 ms). În paralel, au fost colectate și semnale EEG de la 5 canale folosind un dispozitiv NeuroSky, care a furnizat atât activitatea cognitivă, cât și nivelul de intensitate a clipitului [82].

Etichetarea clipiturilor s-a realizat într-o manieră semi-supervizată. Inițial, posibilele momente de clipire au fost identificate automat pe baza variațiilor semnalului EEG, iar apoi au fost validate manual prin inspecția înregistrărilor video. Fiecare eveniment validat conține un segment temporal de 21 cadre (10 înainte și 10 după momentul de clipit), furnizând astfel o informație temporală exploatabilă în antrenarea algoritmilor. În total, baza include 6000 de exemple echilibrate (clipit/neclipit), provenind din partea stângă și dreaptă a câmpului vizual, și însumând peste 750.000 de imagini. Pentru a garanta acuratețea localizării, a fost aplicat un sistem de detecție facială prin repere, care a extras automat regiuni de interes (ochi, față, cadru complet) [82]. Fiind o bază multimodală bine structurată și realistă, mEBAL este deosebit de valoroasă pentru dezvoltarea sistemelor de monitorizare a atenției, interfețelor BCI bazate pe clipit și algoritmilor de detecție a oboselii sau pierderii vigilenței în medii educaționale digitale.

Deși bazele de date EEG dedicate analizei mișcărilor oculare și a clipitului oferă informații valoroase despre interacțiunea dintre activitatea oculară și activitatea corticală, ele nu au fost incluse în selecția finală de seturi de date utilizate în cadrul acestei teze. Aceste resurse se remarcă prin diversitatea paradigmelor experimentale, caracterul multimodal și prin potențialul lor în domenii precum detecția atenției, monitorizarea clipitului voluntar/involuntar sau dezvoltarea de interfețe BCI bazate pe mișcări oculare. Cu toate acestea, lipsa unor etichete cognitive explicite și focalizarea pe componente motorii periferice sau senzoriale, mai degrabă decât pe procese cognitive centrale, au condus la excluderea lor din etapa de validare experimentală a arhitecturilor AI propuse în această cercetare. Ele rămân totuși resurse de referință utile pentru cercetările viitoare care își propun o fuziune între EEG și semnale oculare pentru evaluarea stării mentale.

2.1.10. Baze de date EEG pentru analiza diverselor sarcini cognitive și explorări atipice

În această secțiune sunt prezentate o serie de baze de date EEG open-source care nu se încadrează într-una dintre categoriile tematice clasice precum recunoașterea emoțiilor, mișcarea imaginară, potențialele

evocate sau starea de repaus. Aceste seturi de date explorează o varietate de paradigme experimentale – de la sarcini de recunoaștere vizuală și memorie de lucru, la monitorizarea stărilor de confuzie în contexte educaționale, influența predispoziției genetice asupra activității cerebrale sau oscilațiile lente din somnul profund. Caracterul lor experimental, multidisciplinar și uneori limitat din punct de vedere al dimensiunii grupurilor de participanți le face dificil de inclus într-un cadru strict de analiză cognitivă, dar acestea pot reprezenta surse valoroase pentru testarea algoritmilor de preprocesare, explorări metodologice sau studii de fezabilitate. În contextul prezentei teze, aceste baze nu au fost utilizate în mod direct, însă sunt prezentate pentru completarea perspectivei asupra diversității datelor EEG disponibile în mediul academic.

2.1.10.1. NIST Brain Digits

MNIST Brain Digits este o bază de date EEG care explorează răspunsurile cerebrale asociate percepției vizuale a cifrelor. Setul de date constă în înregistrări EEG realizate în momentul prezentării unor imagini reprezentând cifre între 0 și 9, fiecare imagine fiind afișată timp de 2 secunde. Înregistrările au fost realizate pentru un singur subiect, utilizând mai multe dispozitive comerciale precum **MindWave**, **Emotiv EPOC**, **Muse** și **NeuroSky Insight**. Această varietate de echipamente facilitează studiul comparativ al calității semnalului și robusteții algoritmilor în condiții de achiziție non-clinică. Setul de date include peste 1,2 milioane de fragmente EEG, organizate pe clasele de cifre, cu etichete corespunzătoare pentru fiecare prezentare. Deși înregistrările sunt limitate la un singur participant, volumul ridicat de date permite antrenarea unor modele de clasificare vizuală bazate exclusiv pe semnale cerebrale [83]. Astfel, **MNIST Brain Digits** oferă o resursă relevantă pentru dezvoltarea și testarea unor algoritmi de învățare automată în contexte de tip BCI, mai ales în scenarii cu date etichetate dar resurse umane limitate.

2.1.10.2. ImageNet Brain

ImageNet Brain este o bază de date EEG experimentală care investighează răspunsurile cerebrale la stimuli vizuali complecși, proveniți din setul de imagini ImageNet ILSVRC2013. Protocolul experimental presupune afișarea aleatorie a imaginilor — selectate dintr-un subset de aproximativ 14.000 de clase vizuale — și înregistrarea activității cerebrale timp de 3 secunde pentru fiecare stimul. Înregistrările au fost realizate pentru **un singur participant**, însă setul final cuprinde peste 70.000 de exemple EEG etichetate, organizate în funcție de categoria imaginii prezentate. Fiecare eșantion EEG este corelat cu o imagine unică, oferind astfel un cadru valoros pentru explorarea relației dintre percepția vizuală și reprezentarea neurală [83]. Volumul mare de date permite testarea ipotezelor privind decodificarea conținutului vizual din activitatea cerebrală, inclusiv dezvoltarea unor modele AI capabile să clasifice categoria imaginii doar pe baza semnalului EEG. Prin caracterul său unic, ImageNet Brain deschide direcții

de cercetare în neurovizualizare, interpretabilitatea semnalului EEG și învățarea automată aplicată în contexte cu stimulare vizuală de înaltă variabilitate.

2.1.10.3. EEGLearn

EEGLearn este o colecție EEG concepută pentru investigarea activității cerebrale asociate proceselor de memorie de lucru. Protocolul experimental se bazează pe o paradigmă de tip *„potrivire întârziată la model" (delayed match-to-sample)*, utilizând caractere alfabetice: participanților le este prezentat un set de litere (SET) timp de 500 ms, urmat de o perioadă de menținere activă în memorie de 3 secunde, după care este afișat un caracter de test (TEST). Sarcina participantului este de a indica dacă acest caracter a fost sau nu inclus în setul inițial. Acest design solicită atât codificarea vizuală, cât și menținerea și compararea activă a informației, oferind un cadru experimental riguros pentru analiza memoriei de lucru. Datele au fost colectate de la **15 studenți**, utilizând un **sistem EEG cu 64 de canale** și o frecvență de eșantionare de 500 Hz. Deși doar un subset al datelor brute este disponibil public, setul este suficient de bogat pentru testarea modelelor AI în clasificarea stărilor cognitive implicate în procese de retenție și luare a deciziei. Datorită structurii temporale bine definite și etichetării precise a evenimentelor, această bază de date oferă un punct de plecare valoros pentru investigarea nivelului de solicitare cognitivă și a dinamicii activității cerebrale în sarcini de memorie de lucru [84].

2.1.10.4. Deep Sleep Slow Oscillation

Baza de date **Deep Sleep Slow Oscillation** a fost creată în contextul cercetărilor privind îmbunătățirea somnului profund prin stimulare auditivă. Setul conține înregistrări EEG obținute în condiții de control, fără aplicarea niciunei intervenții sonore, utilizând **dispozitivul portabil Dreem Headband**, echipat cu electrozi EEG, accelerometru și pulsoximetru. Dispozitivul are capacitatea de a monitoriza activitatea cerebrală, postura corpului, frecvența cardiacă și mișcările în timpul somnului, iar în condiții experimentale standard poate livra stimuli acustici prin conducție osoasă. Totuși, în cadrul acestei baze de date, nu a fost utilizată nicio formă de stimulare, obiectivul fiind acela de a caracteriza și prezice evoluția naturală a oscilațiilor lente din timpul somnului profund, în lipsa intervenției. Fiecare eșantion din setul de date corespunde unei ferestre de 10 secunde de semnal EEG, înregistrată imediat înainte de finalul unei oscilații lente. Frecvența de eșantionare este de 125 Hz, ceea ce conduce la 1250 de puncte de semnal per înregistrare. În plus, setul de date include 10 variabile contextuale relevante, precum: numărul, amplitudinea medie și durata oscilațiilor lente anterioare, stadiul actual al somnului, timpul scurs de la adormire, precum și durata cumulată petrecută până în acel moment în stadiile de somn profund, somn ușor, REM și stări de

veghe. Aceste metacaracteristici oferă un cadru contextual bogat pentru interpretarea activității cerebrale, facilitând analiza relației dintre dinamica somnului și apariția oscilațiilor lente. Fiecărui segment temporal i-a fost asociată o etichetă de predicție care reflectă evenimentul anticipat în secunda imediat următoare: 0 – nu debutează nicio oscilație lentă; 1 – debutează o oscilație lentă de amplitudine redusă; 2 – debutează o oscilație lentă de amplitudine ridicată [85]. Scopul acestui set de date este de a sprijini dezvoltarea unor modele predictive ale activității cerebrale în timpul somnului profund, care pot estima momentul optim pentru aplicarea unei eventuale stimulări sonore în vederea consolidării somnului. O înțelegere mai profundă a evoluției spontane a oscilațiilor lente permite optimizarea algoritmilor de personalizare a stimulării și oferă un cadru de referință pentru evaluarea impactului intervențiilor exogene în raport cu dinamica naturală a somnului.

2.1.10.5. Genetic Predisposition to Alcoholism

Genetic Predisposition to Alcoholism este una dintre cele mai citate colecții open-source în studiile neurofiziologice privind diferențele între indivizi cu risc crescut de tulburări adictive și cei din grupuri de control. Această bază a fost creată în cadrul unui studiu amplu desfășurat în Statele Unite, destinat să investigheze corelațiile EEG cu predispoziția genetică la alcoolism, pe baza răspunsului cerebral la stimuli vizuali. Datele au fost înregistrate de la **122 de participanți**, fiecare fiind clasificat fie ca subiect de control, fie ca subiect cu antecedente familiale de alcoolism. Fiecare participant a parcurs 120 de probe, în cadrul cărora i-au fost prezentate unul sau două stimuluri vizuale succesive (S1 și S2), constând în imagini alb-negru standardizate care reprezentau obiecte uzuale. Protocolul a inclus atât condiții congruente (S1 = S2), cât și incongruente (S1 ≠ S2), iar participanții au avut sarcina de a evalua dacă cele două imagini corespund sau nu. Achiziția EEG s-a realizat folosind 64 de electrozi, poziționați conform sistemului standard 10–20, cu o frecvență de eșantionare de 256 Hz [86]. Această bază de date este valoroasă pentru cercetări privind:

- modul în care predispoziția genetică afectează procesarea cognitivă timpurie a stimulilor vizuali,
- analiza diferențelor între componente ERP (precum P300) la subiecți alcoolici și control,
- dezvoltarea algoritmilor de clasificare bazată pe EEG pentru detecția riscului neuropsihiatric,
- estimarea afectării funcțiilor executive în tulburările adictive.

2.1.10.6. Confusion during MOOC

Baza de date **Confusion during MOOC** investighează posibilitatea detecției nivelului de confuzie al studenților în timpul vizionării online a cursurilor, utilizând un dispozitiv EEG simplu, cu un singur canal.

Studiul pilot, realizat de cercetători de la Carnegie Mellon University, a inclus **10 studenți** care au urmărit câte 10 videoclipuri educaționale de câte două minute, din două categorii: materiale considerate *„neconfuze”* (ex. introducere în algebră sau geometrie) și materiale *„confuze”* (ex. mecanica cuantică sau celule stem), selectate pe baza presupunerii de dificultate cognitivă. După fiecare clip, participanții și-au evaluat nivelul de confuzie pe o scală de la 1 la 7, iar evaluatori externi au completat evaluări suplimentare pe baza limbajului non-verbal. Înregistrările EEG au fost realizate cu **dispozitivul NeuroSky MindSet**, care captează activitatea electrică în zona frontală (Fp1) și oferă, atât semnal EEG brut (512 Hz), cât și măsurători derivate privind *„atenția”* și *„meditația”*, împreună cu valorile medii ale benzilor de frecvență delta, theta, alfa, beta și gamma [87]. Deși dimensiunea eșantionului este redusă, studiul demonstrează potențialul dispozitivelor EEG low-cost în contextul educației online, ca mijloc de a obține feedback obiectiv privind starea cognitivă a cursanților. În pofida unor limitări metodologice — precum numărul redus de participanți și potențiala suprapunere între efort cognitiv crescut și starea reală de confuzie — această bază de date reprezintă un exemplu valoros al utilizării semnalelor EEG pentru estimarea în timp real a stării de confuzie în contexte de învățare online.

Setul de date Confusion during MOOC nu a fost inclus în selecția finală a bazelor de date utilizate în cadrul acestei teze, însă rămâne relevant ca exemplu aplicativ pentru detecția automată a stării de confuzie cognitivă, în special în contexte educaționale sau de interacțiune om–computer.

2.1.10.7. Nencki-Symfonia

Baza de date EEG **Nencki-Symfonia** este o colecție extinsă de înregistrări EEG cu densitate mare, obținute în cadrul Institutului de Biologie Experimentală Nencki din Varșovia, Polonia. Proiectul a fost conceput pentru a oferi o resursă complexă destinată cercetării neuroștiințifice, în special studiului proceselor cognitive asociate cu interferența, atenția, reacția la stimuli rari și starea de repaus. Eșantionul a fost alcătuit din **42 de adulți sănătoși**, toți dreptaci, cu vârste cuprinse între 20 și 35 de ani. Protocolul experimental a inclus patru paradigme distincte. Prima sarcină, MSIT+ (Sarcina de Interferență din Surse Multiple), integrează condiții de control alături de elemente din paradigmele clasice Simon și Flanker, oferind un cadru experimental complex pentru investigarea controlului cognitiv, a interferenței și a proceselor executive. Cea de-a doua sarcină utilizează o paradigmă de tip *oddball* cu trei categorii de stimuli vizuali – standard, țintă rară și distractor rar – frecvent aplicată în studiul potențialelor evocate și al mecanismelor neurale implicate în detecția devianței. A treia paradigmă este o sarcină simplă de reacție (SRT), concepută pentru a evalua procesele senzorio-motorii fundamentale. Suplimentar, pentru fiecare participant au fost înregistrate date EEG în stare de repaus (REST), atât cu ochii deschiși, cât și cu ochii

închiși, pe parcursul câtorva minute, în vederea obținerii unui profil de activitate cerebrală de bază. Înregistrările EEG au fost achiziționate cu un **sistem Biosemi ActiveTwo cu 128 de canale**, la o frecvență de eșantionare de 2048 Hz, fiind ulterior puse la dispoziție atât în format brut, cât și preprocesat. De asemenea, setul de date include metadate detaliate privind caracteristicile participanților, precum și jurnale experimentale precise pentru fiecare sarcină, facilitând corelarea riguroasă între parametrii individuali și răspunsurile EEG obținute [88].

Așadar, baza de date Nencki-Symfonia reprezintă o resursă valoroasă pentru studiul proceselor cognitive de tip atenție, control executiv și rezolvarea conflictelor, fiind construită pe paradigme clasice validate științific (MSIT+, oddball, reacție simplă). Totuși, având în vedere obiectivele specifice ale prezentei teze — centrate pe estimarea stărilor afective precum stresul, depresia și anxietatea, în contexte naturale și multimodale cu aplicabilitate practică directă — această bază de date nu a fost inclusă în selecția finală de seturi utilizate experimental. Ea este menționată în analiza comparativă ca exemplu de colecție EEG de înaltă densitate, cu design experimental riguros, relevantă pentru validarea modelelor cognitive în condiții controlate.

2.1.10.8. Zurich Cognitive Language Processing Corpus

Baza de date **Zurich Cognitive Language Processing Corpus (ZuCo)** combină înregistrări EEG de înaltă densitate cu privind mișcările oculare, obținute de la **12 subiecți sănătoși**, vorbitori nativi de limba engleză. Fiecare participant a fost înregistrat în timp ce citea texte naturale timp de 4–6 ore, ceea ce face ca această bază să reflecte un context realist pentru procesarea limbajului. Setul de date conține 21.629 de cuvinte distribuite în 1107 propoziții și un total de 154.173 de fixări oculare, acoperind atât sarcini de citire liberă, cât și de citire cu scop specific. Prin combinarea EEG-ului cu mișcările oculare, ZuCo oferă o perspectivă detaliată asupra mecanismelor neurocognitive implicate în înțelegerea limbajului scris [89].

Relevanța științifică a acestei baze de date este dublă: pe de o parte, oferă un cadru valoros pentru antrenarea și validarea modelelor de învățare automată în sarcini de procesare a limbajului natural, precum extragerea entităților sau analiza sentimentelor; pe de altă parte, facilitează o explorare detaliată a relației dintre activitatea cerebrală, mișcările oculare și caracteristicile lingvistice ale textului, contribuind la înțelegerea mecanismelor neurocognitive implicate în limbajului. În ciuda complexității și valorii sale științifice, baza ZuCo nu a fost selectată pentru experimentele din cadrul acestei teze, întrucât nu conține etichete explicite pentru stări cognitive precum stresul, oboseala sau vigilența. Totuși, ea constituie un reper important pentru studiile ce vizează înțelegerea limbajului și integrarea multimodală EEG– mișcări oculare.

2.1.10.9. EEG During Mental Arithmetic Tasks

Baza de date **EEG During Mental Arithmetic Tasks** a fost concepută pentru a analiza modificările activității cerebrale asociate execuției unei sarcini de aritmetică mentală, comparativ cu starea de repaus. Această colecție conține înregistrări EEG realizate atât anterior, cât și pe parcursul desfășurării unei sarcini mentale de numărare descrescătoare, efectuată silențios, fără răspuns verbal sau scris. Sarcina a presupus efectuarea unei scăderi mentale în serie, pornind de la un număr de patru cifre (ex. 3141), din care participantul trebuia să scadă repetitiv un număr de două cifre (ex. 42). Valoarea inițială și decrementul au fost comunicate oral la începutul fiecărei probe. Semnalele EEG au fost înregistrate cu un **sistem Neurocom cu 23 de canale**, folosind electrozi de tip Ag/AgCl plasați conform montajului internațional 10–20. Anterior analizei, datele EEG au fost preprocesate prin aplicarea unui filtru trece-sus cu prag la 30 Hz și a unui filtru de rețea la 50 Hz, pentru a elimina componentele de joasă frecvență și interferențele electrice. Ulterior, s-a utilizat **metoda ICA** (Analiza Componentelor Independente) pentru îndepărtarea artefactelor produse de mișcările oculare, activitatea musculară și semnalele cardiace.

Fiecare segment EEG este de 60 de secunde, fără artefacte, permițând o analiză comparabilă între condiții. Fiecare participant are asociate două fișiere .edf: (1) fișier corespunzător înregistrării semnalului EEG în stare de repaus (1) și (2) fișier desfășurării sarcinii cognitive (2). Participanții au fost împărțiți în două grupuri în funcție de performanța la sarcină: **grupul „G" (24 subiecți)** a realizat în medie 21 de operații în 4 minute, iar **grupul „B" (12 subiecți)** a realizat în medie doar 7 operații. Informațiile demografice (sex, vârstă, ocupație, data înregistrării) și apartenența la grup sunt disponibile în fișierul *subject-info.csv* [90].

Această bază de date este deosebit de relevantă pentru explorarea activității cognitive în sarcini ce implică memoria de lucru, atenția susținută și calculul mental. Prin comparația între starea de repaus și activitatea cognitivă, aceasta poate servi la identificarea tiparelor EEG asociate cu efortul mental și la evaluarea diferențelor inter-subiective în performanță. În contextul acestei teze, baza este considerată un exemplu valoros de sarcină cognitivă generală, fiind inclusă în selecția extinsă de date utilizate pentru analiza stărilor mentale înregistrate prin EEG.

2.1.10.10. EEG Data

Colecția **EEG Data** cuprinde aplicații experimentale pentru BCI, reunește mai multe sub-seturi de date EEG obținute în contexte experimentale variate, având ca scop sprijinirea dezvoltării de interfețe creier–calculator și testarea algoritmilor pentru sarcini cognitive, senzoriale și motorii. Baza include înregistrări EEG obținute în timpul sarcinilor motorii imaginare, precum și date P300, utile pentru paradigmele bazate pe detectarea potențialelor evocate. O altă componentă importantă o constituie înregistrările EEG în timpul somnului, colectate de la **8 participanți**, ceea ce oferă un punct de plecare

pentru analiza etapelor somnului sau a stării de repaus cerebral. Setul se remarcă și prin includerea unor date EEG de la pacienți cu epilepsie, provenite atât din surse intracraniene, cât și de la voluntari sănătoși, ceea ce extinde aplicabilitatea bazei în direcția studiilor clinice. Totodată, este disponibil un volum semnificativ de date pentru aproximativ **120 de participanți**, fiecare având înregistrări de tip VEP, în timp ce priveau imagini simple pentru perioade scurte (1 secundă) și încercau să le memoreze. Mai sunt incluse și alte seturi experimentale de interes: date EEG înregistrate de la **14 participanți** în timpul unor sarcini de recunoaștere sau categorizare a imaginilor, semnale EEG de la **5 subiecți** implicați în diferențierea perechilor de cuvinte sinonime/antonime, respectiv înregistrări de la **7 participanți** angajați în sarcini precum număratul, rezolvarea de probleme aritmetice, imaginație spațială (rotirea mentală a unor obiecte), scriere de litere sau repaus [91].

Datorită lipsei unei coerențe experimentale unitare, etichetării incomplete și protocoalelor neuniforme, această colecție de date nu a fost inclusă în setul de date utilizat efectiv în cadrul tezei. Totuși, este menționată pentru valoarea sa exploratorie și pentru posibilitatea de a oferi exemple de aplicabilitate în multiple domenii: recunoaștere vizuală, procesare semantică, analiză VEP investigarea activității cerebrale în timpul somnului.

2.1.10.11. Raw EEG Data

Baza de date **RAW EEG Data** oferă o colecție complexă de înregistrări EEG brute, preprocesate, obținute în cadrul unui studiu experimental desfășurat pe un eșantion de **61 de studenți** de anul III la o facultate de administrarea afacerilor. Participanții au fost împărțiți în trei grupuri pe baza performanței academice anterioare: studenți cu performanță ridicată, normală și scăzută, utilizând scorurile academice din cinci semestre consecutive. Toți subiecții au fost dreptaci, fără afecțiuni neurologice, consum de substanțe sau tulburări de somn, și au fost selectați conform unor criterii stricte de includere și excludere. Achiziția EEG a fost realizată utilizând **sistemul Enobio20 (NeuroElec)**, cu 20 de electrozi amplasați conform sistemului internațional 10–20. Frecvența de eșantionare a fost de 500 Hz, iar impedanța fiecărui electrod a fost menținută sub 10 kΩ. Experimentele au fost desfășurate într-un mediu controlat, iar participanții au interacționat cu sarcinile utilizând un controller Xbox, în timp ce erau monitorizați. Baza de date este structurată în trei seturi de experimente: (1) Stare de repaus: participanții au fost instruiți să rămână relaxați și să privească un simbol „+” afișat în centrul ecranului timp de 5 minute, fără a efectua vreo sarcină cognitivă; (2) Sarcina de memorie de lucru Sternberg (STB): subiecții au fost expuși la serii de litere colorate, fiind instruiți să memoreze doar literele negre, apoi să răspundă dacă anumite litere țintă au fost sau nu prezente anterior. Această sarcină implică codificare, retenție și decizie, fiind relevantă pentru studiul memoriei de scurtă durată;

(3) Testul Raven pentru evaluarea abilităților cognitive: subiecții au rezolvat serii de figuri geometrice incomplete, selectând varianta corectă care completa logica matricială. Testul este recunoscut pentru evaluarea raționamentului fluid, a atenției și a proceselor executive [92]. Înregistrările EEG acoperă o gamă variată de stări cognitive — de la odihnă și memorare, până la rezolvare de probleme abstracte — permițând analiza diferențelor între grupurile academice [93]. Deși doar primele 5 minute ale fiecărui experiment sunt incluse pentru fiecare subiect (din considerente de volum și procesare), datele rămân valoroase prin claritatea protocolului, acuratețea achiziției și diversitatea sarcinilor cognitive.

În contextul prezentei teze, această bază de date nu a fost inclusă în selecția finală de date utilizate experimental, însă este menționată pentru valoarea sa ilustrativă în analiza diferențelor EEG asociate cu performanța cognitivă, vigilența și memoria de lucru. Structura protocolului și diversitatea sarcinilor cognitive o recomandă ca posibil reper pentru validarea ulterioară a modelelor de clasificare a stărilor cognitive.

2.1.11. Concluzii privind selecția și relevanța bazelor de date EEG open-source

Analiza extinsă a bazelor de date EEG prezentate în acest subcapitol evidențiază o diversitate semnificativă în ceea ce privește scopurile experimentale, natura etichetelor asociate, protocoalele de achiziție și gradul de preprocesare aplicat. Aceste resurse acoperă domenii variate — de la clasificarea emoțiilor și sarcini motorii, până la diagnostic clinic, interacțiuni vizual-auditive sau procese cognitive complexe (atenție, memorie, oboseală, stres etc.).

Totuși, în contextul obiectivului principal al acestei teze — estimarea stărilor afective pe baza semnalelor EEG și a modelelor de inteligență artificială — doar o parte dintre aceste baze sunt cu adevărat compatibile metodologic. Selectarea seturilor de date utilizate efectiv a fost realizată pe baza unor criterii stricte, precum: prezența etichetelor relevante pentru stările vizate, calitatea înregistrărilor EEG, diversitatea participanților și caracterul repetabil al protocoalelor. Astfel, seturile de date utilizate efectiv în cadrul experimentelor prezentate în această teză sunt:

- **Predict-UNM** – pentru analiza stărilor afective în contexte vizuale și evaluarea răspunsurilor EEG la stimuli emoționali;
- **MODMA** – pentru recunoașterea oboselii, afectivității și evaluarea diferențelor între protocoale longitudinale;
- **SAM40** – axat pe inducerea stresului cognitiv în condiții controlate;
- **DASPS** – pentru testarea modelelor de detecție a stărilor afective din EEG brut și preprocesat;
- **Alpha Waves** – utilizat complementar în etapa de testare exploratorie pentru analiza stării de relaxare și nivelului perceput de oboseală.

În schimb, alte seturi de date, deși valoroase din punct de vedere tehnic, clinic sau multimodal, nu au fost incluse în selecția finală din motive precum: absența etichetelor cognitive explicite, orientarea exclusivă către control motor (ex. BCI Competition IV), lipsa validării emoționale (ex. EEG Eye State) sau caracterul prea general al protocoalelor clinice (ex. TUH EEG Corpus, CHB-MIT, NMT EEG).

Tabel 2.2 Clasificare comparativă a bazelor de date EEG analizate

Bază de date	Domeniu principal	Utilizată în cadrul tezei
NMT Scalp EEG	Clinic (normal/patologic)	✕
TUH EEG Corpus	Clinic (epilepsie, anomalii EEG)	✕
CHB-MIT Scalp EEG	Clinic (epilepsie pediatrică)	✕
Predict-UNM	Clinic (boala Parkinson, mTBI, TOC, schizofrenie, depresie)	✓
MODMA	Clinic (MDD)	✓
SAM40	Clinic (stres cognitiv)	✓
DASPS	Clinic (anxietate)	✓
GIGADB	Activitate motorie	✕
EEG Motor Movement/Imagery	Activitate motorie	✕
Grasp-and-Lift EEG	Activitate motorie	✕
SCP Data of Motor-Imagery	Activitate motorie (potențiale corticale lente)	✕
BCI Competition IV	Activitate motorie	✕
High-Gamma	Activitate motorie efectivă (mișcări reale)	✕
Planning Relax	Activitate motorie	✕
Mental-Imagery	Activitate motorie (cognitivă)	✕
DEAP	Recunoaștere emoții (dimensiuni afective: valență, excitație, dominanță, familiaritate)	✕
SEED	Recunoaștere emoții (pozitiv, negativ, neutru, fericire, tristețe, frică, dezgust, neutru, furie, surprindere, vigilență, semi-vigilență, non-vigilență, stare de oboseală, privare de somn, recuperare somn și somn normal)	✕
Regulation of Arousal	Recunoaștere emoții (relația dintre reglarea stării de excitare și performanța umană)	✕
BCI-NER	Potențialele legate de erori	✕
Monitoring ErrP in a target selection task	Potențialele legate de erori	✕
Synchronized Brainwave	Potențialele vizual-evocate	✕

Face-House Discrimination	Potențialele evocate legate de evenimente (N170)	✕
Brain Invaders	Potențialele evocate legate de evenimente	✕
Sustained-Attention Driving	Potențialele evocate legate de evenimente (P300)	✕
Dryad-Speech	Potențialele evocate legate de evenimente (N400)	✕
ERP Core	Potențialele evocate legate de evenimente (MMN, N170, N400, N2pc, P3b, LRP, ERN)	✕
Resting State EEG Data	Stare de repaus	✕
MindID	Stare de repaus	✕
SPIS Resting State Dataset	Stare de repaus anticipativă (înaintea unei sarcini cognitive)	✕
Alpha Waves	Stare de repaus (oboseală)	✓
BIDS	Concentrare, tendința de deviere a atenției de la meditație	✕
Music Imagery Information Retrieval	Reprezentarea mentală a muzicii	✕
EEG Eye State	Starea ochilor (deschiși/închiși)	✕
EEG-IO / EEG-VV/VR	Clipit voluntar/involuntar	✕
Kara-One	Pronunțarea fonemelor și cuvintelor (imaginate sau reale)	✕
EEGEyeNet	Corelația activității cerebrale și a mișcărilor oculare	✕
Multimodal Eye-Blink and Attention Level	Atenție cognitivă	✕
NIST Brain Digits	Aritmetică mentală	✕
ImageNet Brain	Recunoaștere vizuală	✕
EEGLearn	Recunoaștere semantică, atenție	✕
Deep Sleep Slow Oscillation	Somn profund	✕
Genetic Predisposition to Alcoholism	Clinic (tulburări adictive - predispoziția genetică la alcoolism)	✕
Confusion during MOOC	Stare de confuzie	✕
Nencki-Symfonia	Procese cognitive asociate cu interferența, atenția, reacția la stimuli rari și starea de repaus	✕
Zurich Cognitive Language Processing Corpus	Limbaj natural și mișcări oculare	✕
EEG During Mental Arithmetic	Memorie de lucru, atenție	✕
EEG Data	Sarcini cognitive diverse	✕
Raw EEG Data	Memorie, raționament, repaus	✕

Pentru a sprijini alegerea acestor seturi, în Tabelul 2.2 a fost realizată o sinteză comparativă a bazelor analizate, în funcție de domeniul principal și includerea sau nu în experimentele din teză. Această clasificare justifică selecția metodologică și oferă un cadru clar pentru integrarea datelor în capitolele experimentale ulterioare.

2.1.12. Bibliografie

[1] S. H. Lovibond and P. F. Lovibond, "Depression Anxiety Stress Scales." Sept. 12, 2011. doi: 10.1037/t01004-000.

[2] W. Maier, R. Buller, M. Philipp, and I. Heuser, "The Hamilton Anxiety Scale: reliability, validity and sensitivity to change in anxiety and depressive disorders," *J. Affect. Disord.*, vol. 14, no. 1, pp. 61–68, Jan. 1988, doi: 10.1016/0165-0327(88)90072-9.

[3] M. M. Bradley and P. J. Lang, "Measuring emotion: The self-assessment manikin and the semantic differential," *J. Behav. Ther. Exp. Psychiatry*, vol. 25, no. 1, pp. 49–59, Mar. 1994, doi: 10.1016/0005-7916(94)90063-9.

[4] H. A. Khan *et al.*, "The NMT Scalp EEG Dataset: An Open-Source Annotated Dataset of Healthy and Pathological EEG Recordings for Predictive Modeling," *Front. Neurosci.*, vol. 15, Jan. 2022, doi: 10.3389/fnins.2021.755817.

[5] A. Harati, S. Lopez, I. Obeid, J. Picone, M. P. Jacobson, and S. Tobochnik, "The TUH EEG CORPUS: A big data resource for automated EEG interpretation," in *2014 IEEE Signal Processing in Medicine and Biology Symposium (SPMB)*, Philadelphia, PA, USA: IEEE, Dec. 2014. doi: 10.1109/spmb.2014.7002953.

[6] "Electroencephalography (EEG) Resources." Accessed: July 23, 2025. [Online]. Available: https://isip.piconepress.com/projects/nedc/html/tuh_eeg/

[7] "CHB-MIT Scalp EEG Database." Accessed: July 22, 2025. [Online]. Available: https://physionet.org/content/chbmit/1.0.0/chb01/#files-panel

[8] Z. Tian, B. Hu, Y. Si, and Q. Wang, "Automatic Seizure Detection and Prediction Based on Brain Connectivity Features and a CNNs Meet Transformers Classifier," *Brain Sci.*, vol. 13, no. 5, p. 820, May 2023, doi: 10.3390/brainsci13050820.

[9] Y. G. Chung, A. Cho, H. Kim, and K. J. Kim, “Single-channel seizure detection with clinical confirmation of seizure locations using CHB-MIT dataset,” *Front. Neurol.*, vol. 15, May 2024, doi: 10.3389/fneur.2024.1389731.

[10] J. F. Cavanagh, A. Napolitano, C. Wu, and A. Mueen, “The Patient Repository for EEG Data + Computational Tools (PRED+CT),” *Front. Neuroinformatics*, vol. 11, p. 67, Nov. 2017, doi: 10.3389/fninf.2017.00067.

[11] S. Khan *et al.*, “A machine learning based depression screening framework using temporal domain features of the electroencephalography signals,” *PLOS ONE*, vol. 19, no. 3, p. e0299127, Mar. 2024, doi: 10.1371/journal.pone.0299127.

[12] H. Cai *et al.*, “A multi-modal open dataset for mental-disorder analysis,” *Sci. Data*, vol. 9, no. 1, p. 178, Apr. 2022, doi: 10.1038/s41597-022-01211-x.

[13] Swaymprabha Alias Megha Mane, “An EEG Recordings Dataset for Mental Stress Detection.” Mendeley, Apr. 03, 2023. doi: 10.17632/WNSHBVDXS2.1.

[14] A. Baghdadi, Y. Aribi, R. Fourati, N. Halouani, P. Siarry, and A. M. Alimi, “DASPS database.” IEEE DataPort, Jan. 06, 2021. doi: 10.21227/BARX-WE60.

[15] H. Cho, M. Ahn, S. Ahn, M. Kwon, and S. Jun Chan, “Supporting data for ‘EEG datasets for motor imagery brain computer interface.’” GigaScience Database, p. 9.97 GB, 2017. doi: 10.5524/100295.

[16] “GigaDB Dataset.” Accessed: July 23, 2025. [Online]. Available: https://gigadb.org/dataset/100295

[17] Z. Shuqfa, A. Lakas, and A. N. Belkacem, “Increasing accessibility to a large brain–computer interface dataset: Curation of physionet EEG motor movement/imagery dataset for decoding and classification,” *Data Brief*, vol. 54, p. 110181, June 2024, doi: 10.1016/j.dib.2024.110181.

[18] G. Schalk, D. J. McFarland, T. Hinterberger, N. Birbaumer, and J. R. Wolpaw, “EEG Motor Movement/Imagery Dataset.” physionet.org, 2009. doi: 10.13026/C28G6P.

[19] “Grasp-and-Lift EEG.” Accessed: July 24, 2025. [Online]. Available: https://www.kaggle.com/c/grasp-and-lift-eeg-detection/data

[20] M. D. Luciw, E. Jarocka, and B. B. Edin, “Multi-channel EEG recordings during 3,936 grasp and lift trials with varying weight and friction,” *Sci. Data*, vol. 1, no. 1, Nov. 2014, doi: 10.1038/sdata.2014.47.

[21] M. Kaya, M. K. Binli, E. Ozbay, H. Yanar, and Y. Mishchenko, “A large electroencephalographic motor imagery dataset for electroencephalographic brain computer interfaces,” *Sci. Data*, vol. 5, no. 1, Oct. 2018, doi: 10.1038/sdata.2018.211.

[22] B. Blankertz, G. Dornhege, M. Krauledat, K.-R. Müller, and G. Curio, “The non-invasive Berlin Brain–Computer Interface: Fast acquisition of effective performance in untrained subjects,” *NeuroImage*, vol. 37, no. 2, pp. 539–550, Aug. 2007, doi: 10.1016/j.neuroimage.2007.01.051.

[23] C. Brunner, R. Leeb, G. R. Muller-Putz, and A. Schlogl, “BCI Competition 2008 – Graz data set A”.

[24] R. Leeb, C. Brunner, G. R. Muller-Putz, and A. Schlogl, “BCI Competition 2008 – Graz data set B”.

[25] “BCI Competition IV.” Accessed: July 23, 2025. [Online]. Available: https://www.bbci.de/competition/iv/#datasets

[26] R. T. Schirrmeister *et al.*, “Deep learning with convolutional neural networks for EEG decoding and visualization,” *Hum. Brain Mapp.*, vol. 38, no. 11, pp. 5391–5420, Nov. 2017, doi: 10.1002/hbm.23730.

[27] “High Gamma Dataset.” Accessed: July 23, 2025. [Online]. Available: https://github.com/robintibor/high-gamma-dataset?tab=readme-ov-file

[28] Rajen Bhatt, “Planning Relax.” UCI Machine Learning Repository, 2004. doi: 10.24432/C5T023.

[29] S. K. Jha, S. Suvvari, and M. Kumar, “EEG-based Emotion Recognition: An In-depth Analysis using DEAP and SEED Datasets,” in *2024 11th International Conference on Computing for Sustainable Global Development (INDIACom)*, New Delhi, India: IEEE, Feb. 2024. doi: 10.23919/indiacom61295.2024.10498398.

[30] S. Koelstra *et al.*, “DEAP: A Database for Emotion Analysis ;Using Physiological Signals,” *IEEE Trans. Affect. Comput.*, vol. 3, no. 1, pp. 18–31, Jan. 2012, doi: 10.1109/t-affc.2011.15.

[31] M. Kumar and M. Molinas, “Human Emotion Recognition from EEG Signals: Model Evaluation in DEAP and SEED Datasets”.

[32] “SEED Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/home/seed/seed.html

[33] T. Abe, “PERCLOS-based technologies for detecting drowsiness: current evidence and future directions,” *SLEEP Adv.*, vol. 4, no. 1, p. zpad006, Jan. 2023, doi: 10.1093/sleepadvances/zpad006.

[34] H. A. Hamzah and K. K. Abdalla, “EEG-Based Emotion Recognition Datasets for Virtual Environments: A Survey,” *Appl. Comput. Intell. Soft Comput.*, vol. 2024, no. 1, Jan. 2024, doi: 10.1155/2024/6091523.

[35] J. Li, S. Li, J. Pan, and F. Wang, “Cross-Subject EEG Emotion Recognition With Self-Organized Graph Neural Network,” *Front. Neurosci.*, vol. 15, June 2021, doi: 10.3389/fnins.2021.611653.

[36] “SEED-FRA Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-FRA.html

[37] “SEED-GER Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-GER.html

[38] S. K, S. D, G. N M, L. S R, and S. K A K, “Emotion Recognition using EEG Signal Classification of seed Dataset,” in *2023 2nd International Conference on Advancements in Electrical, Electronics, Communication, Computing and Automation (ICAECA)*, Coimbatore, India: IEEE, June 2023, pp. 1–6. doi: 10.1109/icaeca56562.2023.10199350.

[39] “SEED-IV Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-iv.html

[40] “SEED-V Dataset.” [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-v.html

[41] W.-B. Jiang, X.-H. Liu, W.-L. Zheng, and B.-L. Lu, “SEED-VII: A Multimodal Dataset of Six Basic Emotions With Continuous Labels for Emotion Recognition,” *IEEE Trans. Affect. Comput.*, vol. 16, no. 2, pp. 969–985, Apr. 2025, doi: 10.1109/taffc.2024.3485057.

[42] “SEED-VII Dataset.” [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-vii.html

[43] “SEED-VIG Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-vig.html

[44] “SEED-VLA / SEED-VRW Dataset.” Accessed: July 25, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-VLA.html

[45] “SEED-DV Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/home/eeg2video/

[46] Z. Li, L.-Y. Tao, R.-X. Ma, W.-L. Zheng, and B.-L. Lu, “Investigating the Effects of Sleep Conditions on Emotion Responses With EEG Signals and Eye Movements,” *IEEE Trans. Affect. Comput.*, pp. 1–18, 2025, doi: 10.1109/taffc.2025.3572504.

[47] “SEED-SD Dataset.” Accessed: July 24, 2025. [Online]. Available: https://bcmi.sjtu.edu.cn/~seed/seed-SD.html

[48] J. Faller, J. Cummings, S. Saproo, and P. Sajda, “Regulation of arousal via online neurofeedback improves human performance in a demanding sensory-motor task,” *Proc. Natl. Acad. Sci.*, vol. 116, no. 13, pp. 6482–6490, Mar. 2019, doi: 10.1073/pnas.1817207116.

[49] G. Pires, M. Castelo-Branco, C. Guger, and G. Cisotto, “Editorial: Error-related potentials: Challenges and applications,” *Front. Hum. Neurosci.*, vol. 16, July 2022, doi: 10.3389/fnhum.2022.984254.

[50] “BCI Challenge @ NER 2015.” Accessed: July 25, 2024. [Online]. Available: https://www.kaggle.com/c/inria-bci-challenge/overview

[51] R. Chavarriaga and J. D. R. Millan, “Learning From EEG Error-Related Potentials in Noninvasive Brain-Computer Interfaces,” *IEEE Trans. Neural Syst. Rehabil. Eng.*, vol. 18, no. 4, pp. 381–388, Aug. 2010, doi: 10.1109/tnsre.2010.2053387.

[52] “Visually evoked potentials,” in *Handbook of Clinical Neurology*, Elsevier, 2019, pp. 501–522. doi: 10.1016/b978-0-444-64032-1.00034-5.

[53] K. S. Srujan, “Classification of Synchronized Brainwave Recordings using Machine Learning and Deep Learning Approaches,” in *2018 IEEE 9th Annual Information Technology, Electronics and Mobile Communication Conference (IEMCON)*, Vancouver, BC: IEEE, Nov. 2018, pp. 877–881. doi: 10.1109/iemcon.2018.8614866.

[54] W. D. Penny, S. J. Kiebel, J. M. Kilner, and M. D. Rugg, “Event-related brain dynamics,” *Trends Neurosci.*, vol. 25, no. 8, pp. 387–389, Aug. 2002, doi: 10.1016/s0166-2236(02)02202-6.

[55] K. J. Miller, G. Schalk, D. Hermes, J. G. Ojemann, and R. P. N. Rao, “Spontaneous Decoding of the Timing and Content of Human Object Perception from Cortical Surface Recordings Reveals Complementary Information in the Event-Related Potential and Broadband Spectral Change,” *PLOS Comput. Biol.*, vol. 12, no. 1, p. e1004660, Jan. 2016, doi: 10.1371/journal.pcbi.1004660.

[56] M. Congedo *et al.*, “‘“Brain Invaders”’: a prototype of an open-source P300- based video game working with the OpenViBE platform”.

[57] E. Vaineau, A. Barachant, A. Andreev, P. L. C. Rodrigues, G. Cattan, and M. Congedo, “Brain Invaders Adaptive versus Non-Adaptive P300 Brain-Computer Interface dataset.” Zenodo, Nov. 22, 2018. doi: 10.5281/ZENODO.2669187.

[58] G. F. P. Van Veen, A. Barachant, A. Andreev, G. Cattan, P. L. Coelho Rodrigues, and M. Congedo, “Building Brain Invaders: EEG data of an experimental validation.” Zenodo, Apr. 23, 2019. doi: 10.5281/ZENODO.2649069.

[59] L. Korczowski *et al.*, “Brain Invaders calibration-less P300-based BCI using dry EEG electrodes Dataset (bi2014a).” Zenodo, July 02, 2019. doi: 10.5281/ZENODO.3266223.

[60] L. Korczowski *et al.*, “Brain Invaders Solo versus Collaboration: Multi-User P300-based Brain-Computer Interface Dataset (bi2014b).” Zenodo, July 03, 2019. doi: 10.5281/ZENODO.3267302.

[61] L. Korczowski *et al.*, “Brain Invaders calibration-less P300-based BCI with modulation of flash duration Dataset (bi2015a).” Zenodo, July 03, 2019. doi: 10.5281/ZENODO.3266930.

[62] L. Korczowski *et al.*, “Brain Invaders Cooperative versus Competitive: Multi-User P300-based Brain-Computer Interface Dataset (bi2015b).” Zenodo, July 03, 2019. doi: 10.5281/ZENODO.3268762.

[63] E. S. Kappenman and S. J. Luck, “The effects of electrode impedance on data quality and statistical significance in ERP recordings,” *Psychophysiology*, Mar. 2010, doi: 10.1111/j.1469-8986.2010.01009.x.

[64] Z. Cao, C.-H. Chuang, J.-K. King, and C.-T. Lin, “Multi-channel EEG recordings during a sustained-attention driving task,” *Sci. Data*, vol. 6, no. 1, p. 19, Apr. 2019, doi: 10.1038/s41597-019-0027-4.

[65] Zehong Cao, M. Chuang, J.T. King, and Chin-Teng Lin, “Multi-channel EEG recordings during a sustained-attention driving task (raw dataset).” figshare, p. 19555039027 Bytes, 2019. doi: 10.6084/M9.FIGSHARE.6427334.V5.

[66] M. P. Broderick, A. J. Anderson, G. M. Di Liberto, M. J. Crosse, and E. C. Lalor, “Data from: Electrophysiological correlates of semantic dissimilarity reflect the comprehension of natural, narrative speech.” Dryad, p. 14842958274 bytes, Feb. 07, 2019. doi: 10.5061/DRYAD.070JC.

[67] M. P. Broderick, A. J. Anderson, G. M. Di Liberto, M. J. Crosse, and E. C. Lalor, "Electrophysiological Correlates of Semantic Dissimilarity Reflect the Comprehension of Natural, Narrative Speech," *Curr. Biol.*, vol. 28, no. 5, pp. 803-809.e3, Mar. 2018, doi: 10.1016/j.cub.2018.01.080.

[68] E. S. Kappenman, J. Farrens, W. Zhang, A. X. Stewart, and S. J. Luck, "ERP CORE: An Open Resource for Human Event-Related Potential Research," May 22, 2020, *PsyArXiv*. doi: 10.31234/osf.io/4azqm.

[69] L. T. Trujillo, C. T. Stanfield, and R. D. Vela, "The Effect of Electroencephalogram (EEG) Reference Choice on Information-Theoretic Measures of the Complexity and Integration of EEG Signals," *Front. Neurosci.*, vol. 11, p. 425, July 2017, doi: 10.3389/fnins.2017.00425.

[70] X. Zhang, L. Yao, S. S. Kanhere, Y. Liu, T. Gu, and K. Chen, "MindID: Person Identification from Brain Waves through Attention-based Recurrent Neural Network," *Proc. ACM Interact. Mob. Wearable Ubiquitous Technol.*, vol. 2, no. 3, pp. 1–23, Sept. 2018, doi: 10.1145/3264959.

[71] M. Torkamani-Azar, S. D. Kanik, S. Aydin, and M. Cetin, "Prediction of Reaction Time and Vigilance Variability From Spatio-Spectral Features of Resting-State EEG in a Long Sustained Attention Task," *IEEE J. Biomed. Health Inform.*, vol. 24, no. 9, pp. 2550–2558, Sept. 2020, doi: 10.1109/JBHI.2020.2980056.

[72] G. Cattan, P. L. C. Rodrigues, and M. Congedo, "EEG Alpha Waves dataset." Zenodo, Dec. 17, 2018. doi: 10.5281/ZENODO.2358753.

[73] T. Brandmeyer and A. Delorme, "Reduced mind wandering in experienced meditators and associated EEG correlates," *Exp. Brain Res.*, vol. 236, no. 9, pp. 2519–2528, Sept. 2018, doi: 10.1007/s00221-016-4811-5.

[74] A. Delorme, "BIDS formatted EEG meditation experiment data." Zenodo, Nov. 19, 2018. doi: 10.5281/ZENODO.2536267.

[75] S. Stober, A. Sternin, A. M. Owen, and J. A. Grahn, "Towards Music Imagery Information Retrieval: Introducing the OpenMIIR Dataset of EEG Recordings from Music Perception and Imagination".

[76] O. Roesler, "EEG Eye State." UCI Machine Learning Repository, 2013. doi: 10.24432/C57G7J.

[77] E. Gupta, M. Agarwal, and R. Sivakumar, “Blink to Get In: Biometric Authentication for Mobile Devices using EEG Signals,” in *ICC 2020 - 2020 IEEE International Conference on Communications (ICC)*, Dublin, Ireland: IEEE, June 2020, pp. 1–6. doi: 10.1109/ICC40277.2020.9148741.

[78] M. Agarwal and R. Sivakumar, “Charge for a whole day: Extending Battery Life for BCI Wearables using a Lightweight Wake-Up Command,” in *Proceedings of the 2020 CHI Conference on Human Factors in Computing Systems*, Honolulu HI USA: ACM, Apr. 2020, pp. 1–14. doi: 10.1145/3313831.3376738.

[79] M. Agarwal and R. Sivakumar, “Blink: A Fully Automated Unsupervised Algorithm for Eye-Blink Detection in EEG Signals,” in *2019 57th Annual Allerton Conference on Communication, Control, and Computing (Allerton)*, Monticello, IL, USA: IEEE, Sept. 2019, pp. 1113–1121. doi: 10.1109/ALLERTON.2019.8919795.

[80] S. Zhao and F. Rudzicz, “Classifying phonological categories in imagined and articulated speech,” in *2015 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, South Brisbane, Queensland, Australia: IEEE, Apr. 2015, pp. 992–996. doi: 10.1109/ICASSP.2015.7178118.

[81] A. Kastrati *et al.*, “EEGEyeNet: a Simultaneous Electroencephalography and Eye-tracking Dataset and Benchmark for Eye Movement Prediction,” 2021, *arXiv*. doi: 10.48550/ARXIV.2111.05100.

[82] R. Daza, A. Morales, J. Fierrez, and R. Tolosana, “mEBAL: A Multimodal Database for Eye Blink Detection and Attention Level Estimation,” 2020, *arXiv*. doi: 10.48550/ARXIV.2006.05327.

[83] D. Vivancos and F. Cuesta, “MindBigData 2022 A Large Dataset of Brain Signals,” 2022, *arXiv*. doi: 10.48550/ARXIV.2212.14746.

[84] P. Bashivan, I. Rish, M. Yeasin, and N. Codella, “Learning Representations from EEG with Deep Recurrent-Convolutional Neural Networks,” 2015, *arXiv*. doi: 10.48550/ARXIV.1511.06448.

[85] “Predict brain deep sleep slow oscillation.” Accessed: July 26, 2025. [Online]. Available: https://challengedata.ens.fr/challenges/10

[86] H. Begleiter, “EEG Database.” UCI Machine Learning Repository, 1995. doi: 10.24432/C5TS3D.

[87] H. Wang, Y. Li, X. Hu, Y. Yang, Z. Meng, and K. Chang, “Using EEG to Improve Massive Open Online Courses Feedback Interaction”.

[88] P. Dzianok, I. Antonova, J. Wojciechowski, J. Dreszer, and E. Kublik, “Supporting data for ‘The Nencki-Symfonia EEG/ERP dataset: Multiple cognitive tasks and resting-state data collected in a sample of healthy adults.’” GigaScience Database, p. 1 GB, 2022. doi: 10.5524/100990.

[89] N. Hollenstein, J. Rotsztejn, M. Troendle, A. Pedroni, C. Zhang, and N. Langer, “ZuCo, a simultaneous EEG and eye-tracking resource for natural sentence reading,” *Sci. Data*, vol. 5, no. 1, p. 180291, Dec. 2018, doi: 10.1038/sdata.2018.291.

[90] I. Zyma, S. Tukaev, and I. Seleznov, “EEG During Mental Arithmetic Tasks.” physionet.org, 2018. doi: 10.13026/C2JQ1P.

[91] “EEG data.” Accessed: July 26, 2025. [Online]. Available: https://engineuring.wordpress.com/2009/07/08/downloadable-eeg-data/

[92] Z. Xu, P. Zhang, M. Tu, M. Zhang, and Y. Lai, “Brain optimization with additional study time: potential brain differences between high- and low-performance college students,” *Front. Psychol.*, vol. 14, p. 1209881, Sept. 2023, doi: 10.3389/fpsyg.2023.1209881.

[93] Zhiwei Xu, “RAW EEG Data.” Science Data Bank, p. 940790688 bytes, 1 files, Nov. 28, 2022. doi: 10.57760/SCIENCEDB.06664.

Capitol 4. Prelucrarea și Modelarea Semnalelor EEG

4.1. Analiza EEG pe baza setului de date Alpha Waves

Un aspect esențial în analiza EEG pentru estimarea stărilor afective îl reprezintă controlul factorilor perturbatori care pot influența semnificativ măsurătorile. Printre acești factori, oboseala mentală joacă un rol important, fiind asociată cu modificări caracteristice ale activității cerebrale în benzile de frecvență [1]. Astfel, în cadrul acestei lucrări, s-a introdus un pas preliminar (pasul 0), dedicat estimării stării de oboseală a participanților, anterior evaluării afective propriu-zise (anxietate, depresie, stres). Decizia de a include această etapă a fost motivată de multiple studii care evidențiază faptul că oboseala influențează semnificativ ritmurile EEG [2], [3], în special prin

activitățile în banda alfa și theta [3]. În acest context, ignorarea stării de oboseală ca variabilă latentă poate conduce la clasificări eronate sau distorsionate ale stărilor afective, întrucât un participant obosit poate obține scoruri ridicate la itemii DASS-21 corespunzători stresului sau depresiei, fără a prezenta în mod real aceste stări.

Pentru a estima oboseala, s-au utilizat inițial datele EEG disponibile în baza de date Alpha Waves, care oferă o succesiune alternantă de condiții: *ochi închiși (EC)* și *ochi deschiși (EO)* într-o stare de repaus [4]. Pentru fiecare participant, semnalul EEG achiziționat la 512 Hz a fost segmentat în ferestre fixe de 10 secunde (5120 de eșantioane). Ferestrele au fost extrase astfel: pentru fiecare eșantion la care markerul binar al condiției avea valoarea 1 s-a decupat o fereastră de 10 s; ferestrele incomplete de la capătul înregistrării au fost omise. Fiecare fereastră a fost filtrată în banda alfa (8–12 Hz) folosind un **filtru Butterworth de ordinul 5** aplicat bidirecțional (fără întârziere de fază), iar apoi s-a estimat puterea medie a semnalului filtrat prin media pătratului amplitudinii. Pentru a obține un singur indicator per fereastră, s-a calculat **media valorilor pe cele 16 canale**, rezultând o singură valoare a puterii alfa pentru fiecare fereastră. La nivel de participant, valorile obținute au fost grupate pe condiții EC și EO și s-au calculat indicatori precum: numărul de ferestre pe fiecare condiție, media puterii alfa în EC, media în EO și diferența dintre ele, $\Delta\alpha = P\alpha(EC) - P\alpha(EO)$. Pentru vizualizare, seriile de putere au fost reprezentate pe o axă temporală idealizată (puncte la 0, 20, 40, … s pentru EC și la 10, 30, 50, … s pentru EO), iar fundalul a fost colorat în benzi de câte 10 s pentru a sugera alternanța dintre condiții.

Pentru estimarea stării de oboseală, s-a analizat diferența de activare în banda alfa între cele două condiții experimentale: EC (relaxare) și EO (vigilență). Acest contrast a fost considerat un **indicator funcțional indirect al vigilenței corticale**. Activitatea alfa este în mod normal pronunțată în condiții de repaus cu ochii închiși, fiind inhibată în prezența stimulilor vizuali (ochi deschiși), iar această inhibiție reflectă integritatea reactivității neuronale și nivelul de alertă al sistemului nervos. Astfel, o diferență semnificativă între cele două condiții (valori alfa mai mari în starea EC) sugerează un răspuns fiziologic adecvat, specific unui subiect odihnit și vigilent. În schimb, o diferență redusă poate indica o alterare a mecanismelor de inhibiție senzorială și o capacitate scăzută de reglare a activității corticale, aspecte asociate în literatura de specialitate cu prezența oboselii mentale [5]. Prin urmare, această diferență a fost utilizată ca **măsură cantitativă a oboselii**, capabilă să distingă între subiecți în stare optimă de vigilență și cei care prezintă semne

fiziologice de epuizare mentală. Acest indicator preliminar va fi integrat ulterior în modelele de învățare automată fie ca variabilă explicativă, fie ca filtru pentru selecția datelor valide în vederea clasificării stărilor afective.

Figurile 4.1–4.5 indică în mod consecvent un contrast clar între condițiile EC și EO: puterea medie în banda alfa este sistematic mai mare în intervalele cu ochii închiși decât în cele cu ochii deschiși. Acest tipar este congruent cu fenomenul de **reactivitate alfa**, prin care activitatea α se **sincronizează** în repaus cu ochii închiși și se **desincronizează** odată cu deschiderea ochilor, pe fondul stimulării vizuale. Observațiile vizuale sunt coerente cu valorile medii pe subiect ($\Delta\alpha = P\alpha(EC) - P\alpha(EO) > 0$ în setul analizat), ceea ce susține utilizarea acestui contrast ca indicator funcțional al vigilenței. În plus, se remarcă o variabilitate inter-subiecți în mărimea diferenței EC–EO (Δα), legată de scorul subiectiv de oboseală. De exemplu, la subiectul 05 (scor de oboseală 4 – Figura 4.5) contrastul dintre condiții este mult mai pronunțat decât la subiectul 04 (scor de oboseală 2 – Figura 4.4). În schimb, participanții cu scoruri 0 (Figura 4.2) prezintă valori alfa foarte ridicate în condiția EC, un tipar compatibil cu un nivel bun de vigilență și relaxare. Această tendință sugerează o asociere între reactivitatea alfa și oboseala auto-raportată; confirmarea ei necesită însă o evaluare statistică explicită (de exemplu, corelație Spearman între Δα și scorul de oboseală).

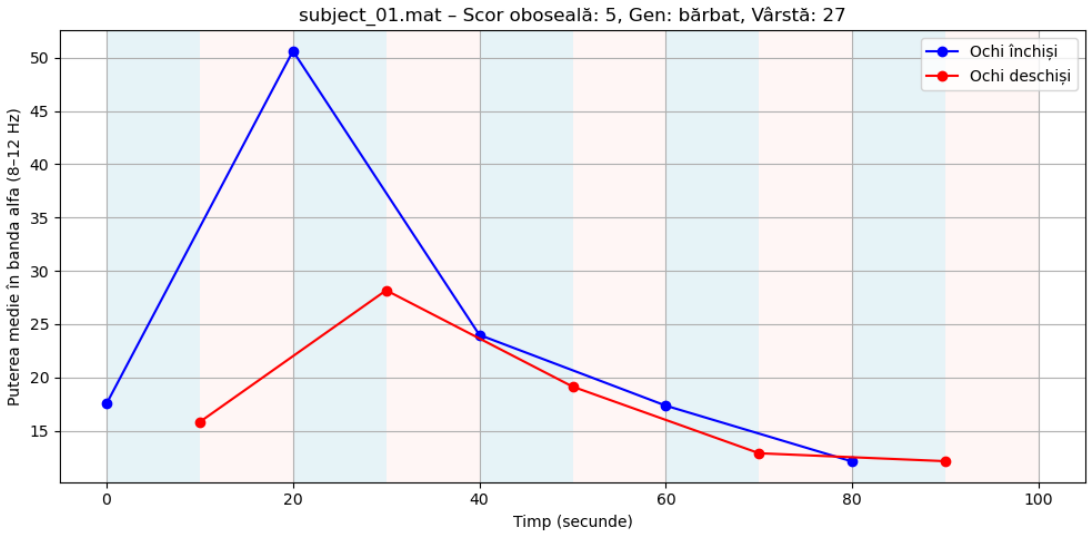


Figura 4.1 Reprezentarea EC–EO pentru subiectul S01

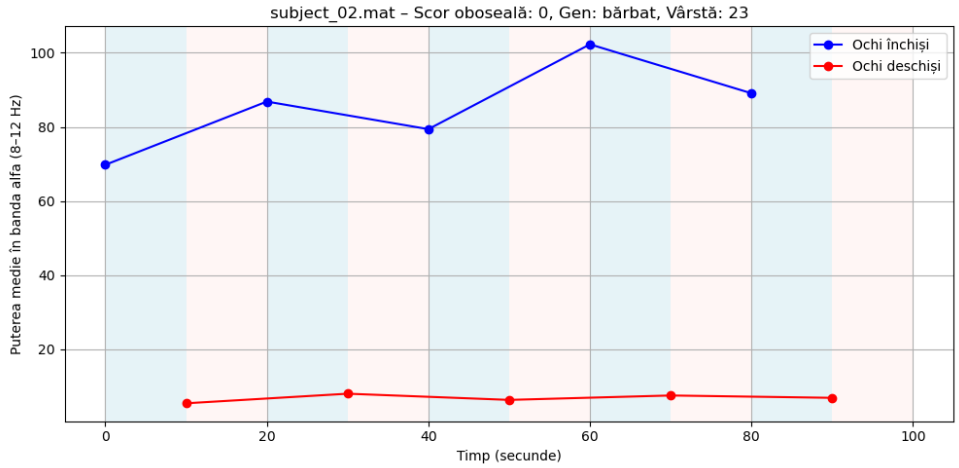


Figura 4.2 Reprezentarea EC–EO pentru subiectul S02

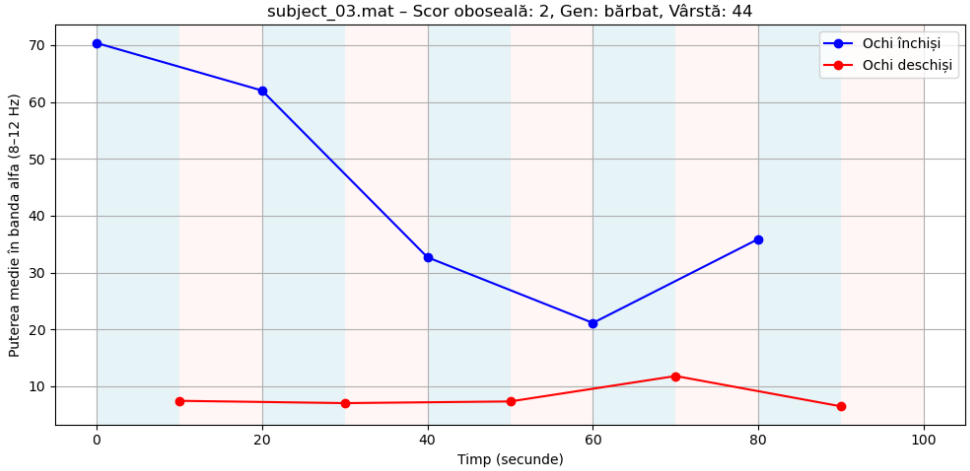


Figura 4.3 Reprezentarea EC–EO pentru subiectul S03

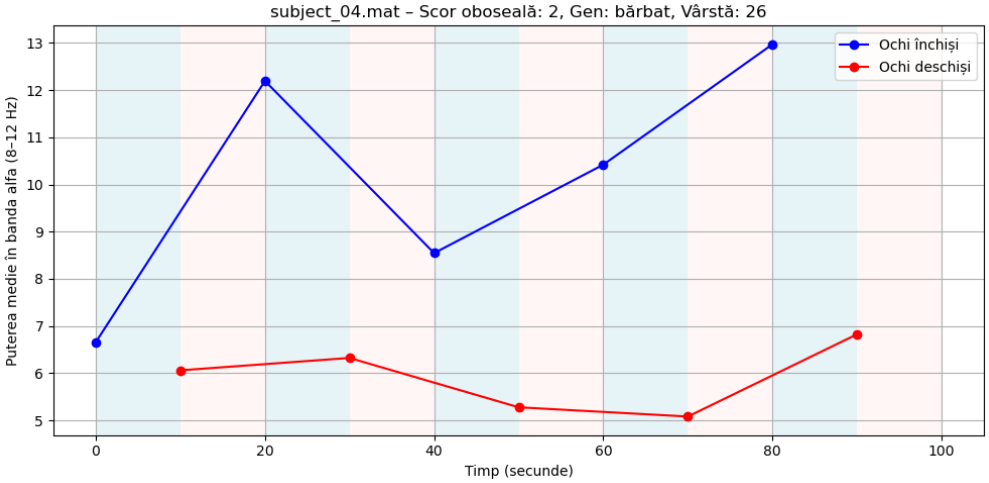


Figura 4.4 Reprezentarea EC–EO pentru subiectul S04

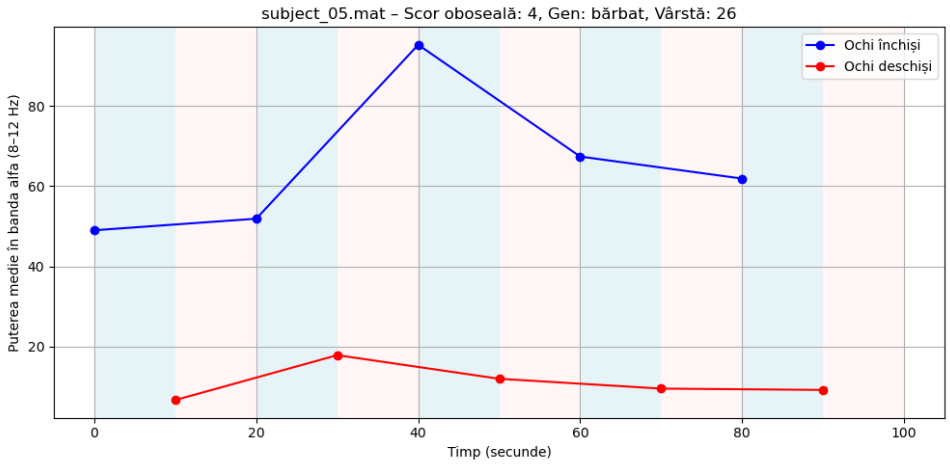


Figura 4.5 Reprezentarea EC–EO pentru subiectul S05

Această tendință generală susține ipoteza că **puterea în banda alfa (8–12 Hz)** poate servi drept **marker candidat, obiectiv** pentru estimarea stării de oboseală. În același timp, rezultatele confirmă utilitatea **prelucrării spectrale** și a **segmentării în ferestre de 10 s** pentru separarea robustă a stărilor neurofiziologice de bază (EC vs EO). Aceste observații vor sta la baza etapei următoare a studiului, în care scorul de oboseală va fi inclus **ca factor de control** sau **ca variabilă covariată** în modelele de învățare automată dezvoltate pentru clasificarea afectivă (anxietate, depresie, stres). Pentru validare, relația dintre reactivitatea alfa (Δα) și oboseala auto-raportată va fi testată statistic (corelație Spearman).

În continuare am realizat o sarcină binară de clasificare a oboselii, folosind indicatorii calculați la nivel de participant. Eticheta a fost definită ca **1 = obosit** (scor de oboseală ≥ 5) și **0 = odihnit**. Pentru fiecare subiect au fost folosite trei caracteristici: media puterii în banda alfa în condiția „ochi închiși”, media în „ochi deschiși” și diferența dintre ele (EC–EO). Setul a fost împărțit în antrenare și testare (70/30) cu stratificare după etichetă, iar trăsăturile au fost normalizate pentru modelul neuronal. Au fost antrenate două modele non-liniare: **Random Forest** (300 arbori) și **MLP cu două straturi ascunse (32 și 16 neuroni, ReLU, Adam, max_iter=1000)**. Performanța a fost evaluată pe setul de test prin **acuratețe**, **F1-score** și **AUC**. În rulara curentă, setul de test a conținut 6 cazuri (5 „odihniți” și 1 „obosit”), ceea ce face evaluarea sensibilă la prag și la dezechilibrul de clasă – Figura 4.6. **Random Forest** a obținut o acuratețe de 0,667, F1=0,000 și AUC=0,80; matricea de confuzie indică ratarea singurului caz „obosit” (TN=4, FP=1, FN=1, TP=0). **MLP** a obținut o acuratețe de 0,500, F1=0,400 și AUC=0,40; modelul a identificat corect

cazul „obosit” (TP=1), însă cu mai multe alarme false (TN=2, FP=3). Diferența dintre AUC și F1 reflectă efectul pragului implicit de 0,5 la probabilități, în contextul unui eșantion foarte mic și dezechilibrat. Anexa 1 prezintă întregul cod implementat pentru aceasta bază de date.

Model	Acuratețe	F1	AUC	TN	FP	FN	TP
Random Forest	0.667	0.000	0.800	4	1	1	0
MLP	0.500	0.400	0.400	2	3	0	1

Figura 4.6 Performanța modelelor Random Forest și MLP pentru clasificarea stării de oboseală

În Figura 4.7 sunt prezentate scorurile de probabilitate obținute atunci când modelele dezvoltate (MLP și Random Forest) au fost aplicate pe același fișier EEG de test. MLP a returnat 99,6%, iar Random Forest 80,7%; folosind pragul de decizie 0,5, ambele modele clasifică subiectul ca „obosit”. Lățimea barelor reflectă probabilitatea estimată, diferența dintre scoruri indicând calibrări/încrederi diferite ale celor două modele. Aceasta este o ilustrare punctuală a fluxului de testare; interpretarea clinică necesită evaluare pe mai multe înregistrări.



Figura 4.7 Aplicarea modelelor pe un fișier EEG de test

Concluzii preliminare:

Aceste rezultate sunt **exploratorii**. Estimarea oboselii pe baza activității EEG nu reprezintă obiectivul principal al lucrării, ci o **etapă intermediară** necesară în fluxul analitic. Scopul ei este să verifice starea funcțională generală a participanților înaintea clasificării afective, având în vedere că oboseala poate modifica activitatea de repaus și modularea în banda alfa. Prin identificarea unui nivel scăzut de vigilență, această etapă permite **filtrarea** subiecților care pot introduce variabilitate nedorită și, la nevoie, **ponderarea** contribuției lor în modelele ulterioare, astfel încât predicțiile privind stările afective să reflecte și contextul fiziologic al înregistrării. În plus, contrastul EC–EO în banda alfa poate fi analizat comparativ între grupuri (de pildă, stres crescut vs. oboseală crescută), oferind indicii despre interacția dintre afectivitate și funcționarea

cognitivă. Pe setul Alpha Waves, indicatorii extrași (media puterii alfa în EC, în EO și diferența EC–EO) furnizează un semnal util, dar evaluarea este limitată de **eșantionul mic** și de **dezechilibrul de clasă**. Diferențele dintre AUC și F1 arată că acuratețea poate fi înșelătoare în acest context și că pragul implicit de decizie influențează puternic rezultatele. Din acest motiv, interpretarea trebuie făcută cu prudență și susținută prin validări mai riguroase. Modelele **Random Forest** și **MLP** apar drept cele mai promițătoare pentru această sarcină binară. Performanța lor poate fi îmbunătățită prin **optimizare de hiperparametri**, **validare încrucișată stratificată**, **ponderarea claselor**, **optimizarea pragului**, precum și **calibrarea scorurilor**.

În continuare, voi constitui o **bază de date proprie** și voi transfera întregul pipeline pe aceste înregistrări, urmărind o rafinare sistematică a modelelor pe un set mai mare, mai omogen și mai bine documentat. Colectarea va fi realizată după un **protocol de achiziție standardizat** (aceleași condiții EC/EO), cu **metadate clinice** consecvente (vârstă, gen, medicație, somn/consum de cafeină, scoruri de oboseală obținute prin instrumente validate). Fluxul de preprocesare va include controlul artefactelor și segmente ne-suprapuse. **Estimările spectrale robuste** vor cuprinde PSD Welch în scară logaritmică, puteri relative pe benzi, rapoarte θ/α, frecvența de vârf alfa[5] și contrastul EC–EO. Rafinarea modelelor se va realiza prin optimizarea hiperparametrilor (căutare bayesiană), cu folduri grupate pe subiecți pentru a evita scurgerile între antrenare și validare. Dezechilibrele vor fi tratate prin ponderarea claselor și, unde este cazul, prin eșantionare informată a exemplelor. Scorurile de ieșire vor fi calibrate și evaluate prin diagrame de fiabilitate și Brier score, iar pragul de decizie va fi stabilit pe setul de validare în funcție de obiectiv (maximizarea F1, criteriul Youden sau o funcție de cost specifică aplicației). Estimarea performanței va fi realizată prin validare încrucișată pe subiecți în regim *nested* (selectare de hiperparametri în bucla internă, raportare în bucla externă), completată de curbe de învățare pentru a evalua dependența de mărimea eșantionului și de bootstrap stratificat pentru intervale de încredere ale metricilor. Generalizarea va fi verificată pe un set extern (hold-out), separat de la începutul studiului, cu raportarea mediei ± deviației standard și, când este util, a testelor de permutare pentru semnificație. Această schemă oferă estimări stabile, reproductibile și relevante pentru utilizarea ulterioară în clasificarea afectivă.

[5] Este frecvența (în Hz) din banda alfa la care spectrul de putere (PSD) atinge maximul în repaus, de regulă în condiția ochi închiși și pe canalele occipitale (O1/O2).

Așadar, informația privind starea de oboseală va fi integrată explicit ca factor de control în toate analizele. O voi include fie ca **covariată numerică** în modele (pentru a corecta direct efectul ei), fie prin **rezidualizarea** trăsăturilor afective față de oboseală (astfel încât modelele să învețe doar variabilitatea rămasă), fie prin **stratificarea** sau **ponderarea eșantioanelor** în funcție de nivelul de oboseală (pentru comparații corecte între grupuri). În paralel, voi evalua un cadru **multi-task**, în care modelul învață simultan să estimeze oboseala și etichetele afective, reducând efectele de confuzie și îmbunătățind generalizarea. Prin această integrare consecventă, voi obține estimări mai stabile și reproductibile, crescând robustețea clasificării afective și relevanța concluziilor finale ale tezei.

Bibliografie

[1] C. S. Nayak and A. C. Anilkumar, "EEG Normal Sleep," in *StatPearls*, Treasure Island (FL): StatPearls Publishing, 2025. Accessed: Aug. 22, 2025. [Online]. Available: http://www.ncbi.nlm.nih.gov/books/NBK537023/

[2] K.-C. Huang, C.-Y. Tseng, and C.-T. Lin, "EEG Information Transfer Changes in Different Daily Fatigue Levels During Drowsy Driving," *IEEE Open J. Eng. Med. Biol.*, vol. 5, pp. 180–190, 2024, doi: 10.1109/OJEMB.2024.3367496.

[3] J. Santamaria and K. H. Chiappa, "The EEG of Drowsiness in Normal Adults:," *J. Clin. Neurophysiol.*, vol. 4, no. 4, pp. 327–382, Oct. 1987, doi: 10.1097/00004691-198710000-00002.

[4] G. Cattan, P. L. C. Rodrigues, and M. Congedo, "EEG Alpha Waves dataset." Zenodo, Dec. 17, 2018. doi: 10.5281/ZENODO.2358753.

[5] S. P. J. Goodman *et al.*, "Approaches to inducing mental fatigue: A systematic review and meta-analysis of (neuro)physiologic indices," *Behav. Res. Methods*, vol. 57, no. 4, p. 102, Feb. 2025, doi: 10.3758/s13428-025-02620-7.

Capitol 6. Proiectarea și Implementarea Platformei Web EEG-AFFECT

Acest capitol descrie proiectarea și implementarea platformei web - EEG-Affect, dezvoltată în cadrul tezei ***„Contribuții privind estimarea stărilor afective pe baza semnalelor EEG și a inteligenței artificiale”***. Scopul platformei este să ofere un flux complet, reproductibil și extensibil: de la importul datelor EEG până la interpretarea rezultatelor, într-o interfață web ușor de utilizat.

6.1 Autentificare utilizatori și control de acces

Figurile 6.1 și 6.2 prezintă pagina de autentificare a **platformei EEG-Affect**, punctul de intrare în aplicație. Autentificarea se realizează pe baza adresei de e-mail și a parolei; parolele nu sunt stocate în clar, verificarea efectuându-se prin compararea hash-ului parolei introduse cu cel stocat. La validare, aplicația inițiază o sesiune de utilizator, care fundamentează autorizarea operațiilor ulterioare. După autentificare, interfața se adaptează rolului (administrator sau utilizator clinic), iar rutele serverului aplică politici de acces corespunzătoare. Autentificarea și controlul de acces din **platforma EEG-Affect** urmăresc să asigure faptul că funcțiile aplicației sunt disponibile doar utilizatorilor autorizați, iar operațiile de administrare sunt rezervate explicit rolului de administrator (admin).

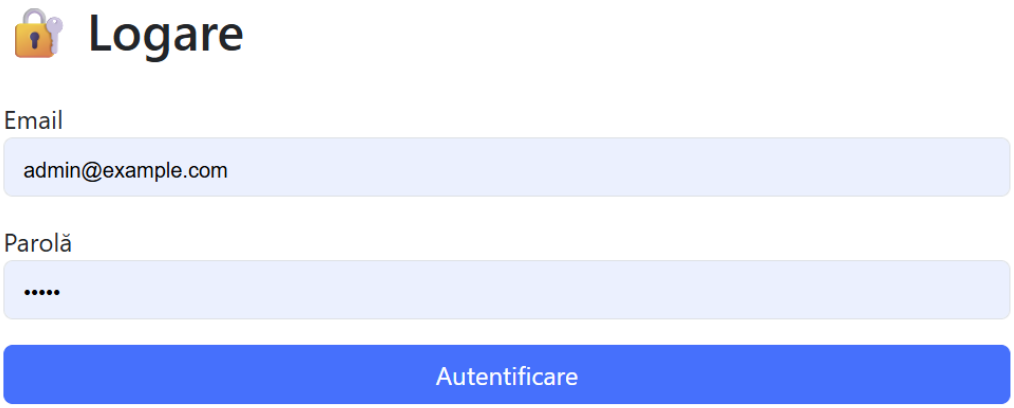


Figura 6.1 Fereastra de autentificare al platformei EEG-Affect (formular cu e-mail și parolă)

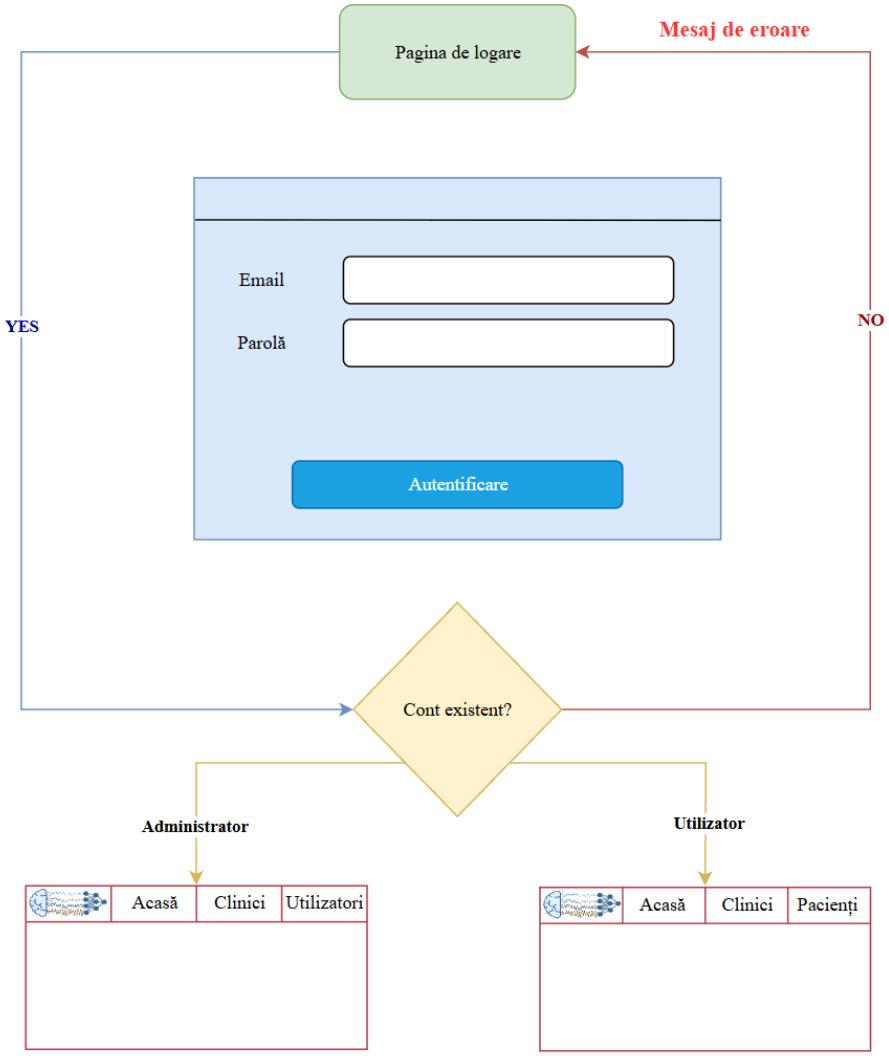


Figura 6.2 Fluxul de autentificare și rutare către panourile de Administrator/Utilizator

Figura 6.3 prezintă un model ierarhic pentru organizarea entităților și a drepturilor de acces în cadrul **platformei EEG-Affect**. Administratorul guvernează întregul ecosistem, clinicile reprezintă limite organizaționale, iar utilizatorii pot aparține mai multor clinici. Pacienții sunt entități operaționale gestionate de utilizatori și sunt ancorați într-o singură clinică; fiecare subiect aparține unui singur utilizator și, implicit, clinicii în care a fost creat. Așadar cardinalitățile relevante sunt următoarele:

- Clinică ↔ Utilizator = N:M,
- Clinică → Subiect = 1:N,
- Utilizator → Subiect = 1:N.

Deci poy exista N clinici; fiecare clinică poate avea N utilizatori, iar fiecare utilizator poate fi membru în N clinici și poate gestiona N subiecți în clinicile unde are acces. Rolul administratorului este exclusiv de guvernanță: înființează și configurează clinici, creează conturi de utilizator și le gestionează apartenențele la clinici, poate dezactiva/reactiva conturi și administrează parametrii platformei. Administratorul are vizibilitate administrativă asupra sistemului (configurație, starea serviciilor, număr de entități etc.), fără acces la conținutul clinic (înregistrări de pacienți, date fiziologice etc.). Administratorul nu introduce, nu modifică și nu șterge pacienți; operațiunile clinice sunt rezervate exclusiv utilizatorilor.

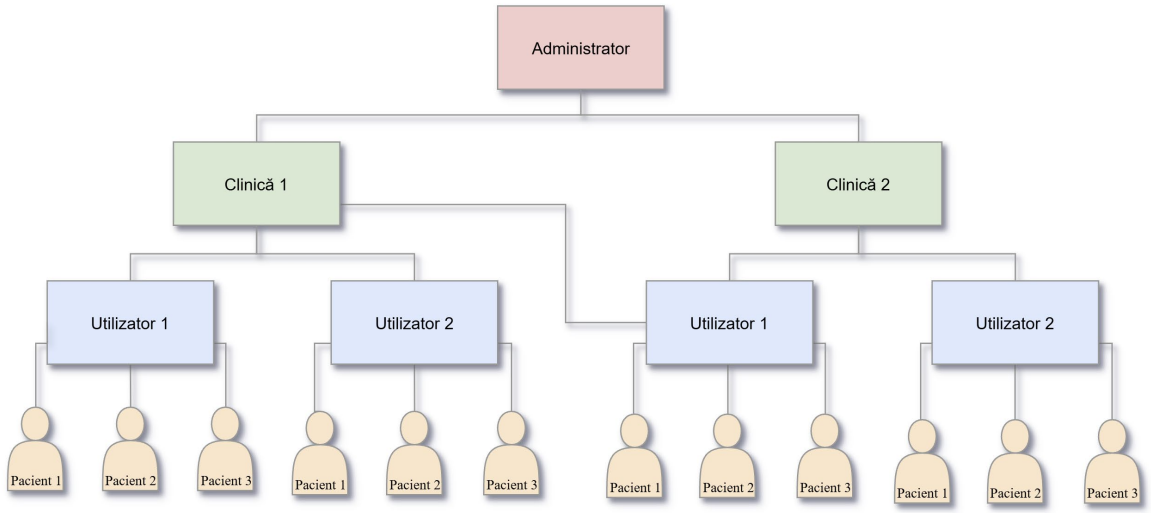


Figura 6.3 Organizarea entităților și a drepturilor de acces în cazul platformei EEG-Affect

În cazul în care un utilizator nu este membru în nicio clinică, **platforma EEG-Affect** afișează un mesaj de informare (Figura 6.4) și nu expune nici liste de pacienți, nici funcționalități de analiză. Accesul la aceste resurse devine disponibil exclusiv după asocierea utilizatorului la cel puțin o clinică, operațiune realizată de către administrator.

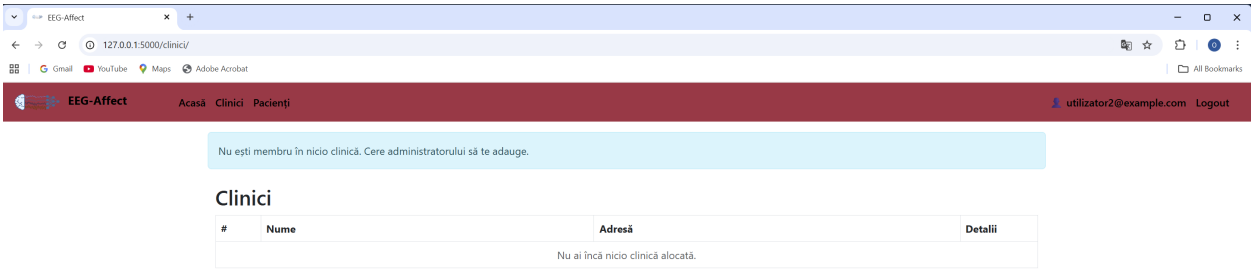


Figura 6.4 Fereastra „Clinici” pentru un utilizator fără apartenență; mesajul de informare și lista goală

Controlul de acces este realizat printr-un model RBAC[6] minimalist, construit în jurul a două roluri care separă clar guvernanța de operațiunile clinice. Administratorul are rol exclusiv de configurare, iar utilizatorul operează strict în perimetrul clinicilor din care face parte. Aplicarea politicilor de acces este realizată concomitent la nivelul interfeței și la nivelul serverului, pentru o apărare în profunzime. În interfață sunt ascunse acțiunile pentru care utilizatorul nu deține drepturi (butoanele de administrare apar exclusiv pentru rolul de **admin**), reducând astfel suprafața de atac. Pe server, fiecare rută care operează asupra datelor impune validări obligatorii: existența unei sesiuni autentificate (*session['user_id']*), deținerea privilegiilor administrative acolo unde este cazul (*is_admin*), apartenența utilizatorului la o clinică (verificată prin *_is_member(user_id, clinic_id)*), precum și proprietatea asupra resursei în cazul pacienților. Încălcarea oricăreia dintre aceste condiții conduce determinist la răspunsul **403 Forbidden** (Figura 6.5).

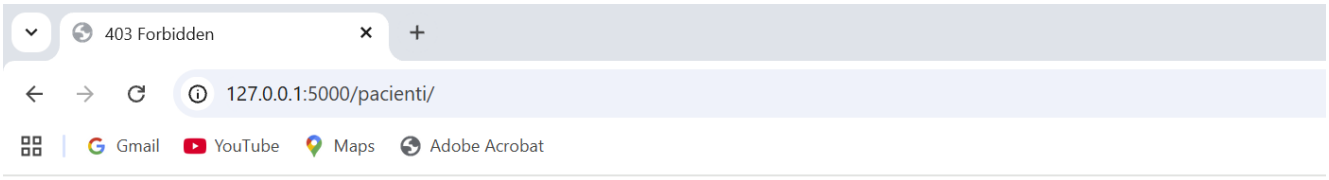


Figura 6.5 Răspunsul **403 Forbidden** la accesarea ferestrei „Pacienți” de către un utilizator neautorizat

Prin această dublă aplicare, platforma adoptă o strategie de *defense-in-depth*, blocând atât tentativele accidentale, cât și accesul neautorizat obținut prin manipularea directă a URL-urilor. Din perspectiva utilizatorilor **membri în mai multe clinici**, selectorul de context listează exclusiv clinicile proprii, iar fiecare acțiune **POST** revalidează pe server identificatorul clinicii (*clinic_id*), eliminând posibilitatea de **manipulare a URL-urilor**. Modificarea apartenențelor produce efecte imediate: dacă un utilizator este revocat dintr-o clinică, accesul la pacienții aferenți devine indisponibil; în fluxul administrativ recomandat, revocarea este precedată de ștergerea explicită a pacienților, pentru a evita persistența unor entități inaccesibile. În plus, o clinică se poate șterge doar dacă nu are pacienți (subiecți) înregistrați.Schema de date impune explicit invariabilele domeniului prin constrângeri la nivelul bazei de date, completând

[6] Controlul de acces bazat pe roluri (RBAC) este un model de securitate prin care permisiunile sunt asociate rolurilor, nu direct utilizatorilor. Utilizatorii primesc unul sau mai multe roluri, iar nivelul lor de acces la resurse și operații este determinat de permisiunile agregate ale acestor roluri [1].

validările din ORM (Object-Relational Mapping) și din formulare. Fiecare tabel este identificat printr-o cheie primară numerică (id), iar relațiile sunt fixate prin chei externe: un subiect aparține întotdeauna unei clinici și unui utilizator (atât *subject.clinic_id*, cât și *subject.user_id* sunt de tip NOT NULL și sunt constrânse să corespundă cheilor primare din tabelele *clinic* și *user*), iar apartenențele utilizator–clinică sunt modelate în tabelul de legătură *user_clinic*, care conține referințe către *user.id* și *clinic.id*. Pentru a evita stările redundante, se aplică unicitatea adresei de e-mail la nivel de cont (*user.email* este UNIQUE), iar *user_clinic* folosește o cheie primară compusă (*user_id*, *clinic_id*), împiedicând înregistrarea aceleiași apartenențe de două ori. Constrângerile de domeniu asigură consistența semantică: genul pacientului este limitat la o mulțime finită de valori (prin enumerare sau CHECK), data nașterii nu poate depăși data curentă (CHECK *date_of_birth* ≤ *current_date*), iar câmpurile esențiale—precum identificatorii de clinică și utilizator sau numele—sunt obligatorii (NOT NULL).

Politicile de referință reglementează ștergerile: pentru user_clinic se aplică ON DELETE CASCADE, astfel încât eliminarea unui utilizator ori a unei clinici să curețe automat apartenențele aferente; pentru *subject* se preferă o strategie conservatoare (RESTRICT/NO ACTION la nivel de aplicație) prevenind ștergerea accidentală a unei clinici sau a unui utilizator care încă deține pacienți. În ansamblu, aceste mecanisme previn apariția înregistrărilor neasociate (de tip *subject* cu chei externe nule sau nevalide), elimină dublurile de apartenență și ambiguitățile de identificare, reducând nevoia de verificări imperative în cod și lăsând motorul de baze de date să asigure corectitudinea structurală. Implementarea completă este documentată în următoarele anexe: **Anexa A – models.py** (definirea ORM, chei și constrângeri etc.); **Anexa B – rutele aplicației** (*routes/patients.py*, *users.py*, *clinics.py*, cu validările server-side (verificări realizate pe server) și politicile aplicate operațiilor CRUD - operațiile fundamentale asupra datelor: *Create* (creare), *Read* (citire/listare), *Update* (actualizare) și *Delete* (ștergere)); **Anexa C – forms.py** (validări la nivelul formularelor); **Anexa D – inițializare și migrare** (*app.py* pentru configurarea bazei de date și apelul *db.create_all()*, respectiv utilitare precum *create_admin.py*, *init_db.py*, *migrate_subjects.py*). Reflectarea acestor reguli în interfață poate fi consultată în *templates/layout.html*, *patients.html*, precum și în paginile dedicate *templates/Patients/*.html* și *templates/Clinics/*.html*.

6.2 Arhitectura aplicației EEG-Affect

Aplicația EEG-Affect urmează o arhitectură pe straturi, care separă responsabilitățile între prezentare, controlul fluxului HTTP, logica aplicației (inclusiv integrarea cu modelele de învățare automată) și persistență. Interfața cu utilizatorul este realizată cu **șabloane Jinja2** și **Bootstrap**, organizate în *templates/* și *static/*, unde layout-ul comun (navigație, mesaje de tip flash, paleta vizuală) este definit în *templates/layout.html*, iar paginile funcționale sunt compuse din șabloane specializate, precum

templates/Patients/.html* și *templates/Clinics/*.html*. Stratul de rutare este structurat cu **Blueprint-uri Flask**, ceea ce permite modularizarea clară a zonelor de funcționalitate: autentificare și sesiune (*routes/auth.py*), tabloul de bord și navigația generală (*routes/main.py*), administrarea utilizatorilor (*routes/users.py*), administrarea clinicilor și apartenențelor (*routes/clinics.py*) și fluxurile clinice legate de pacienți și clasificarea EEG (*routes/patients.py*). Această organizare reduce cuplajul între părți și permite extinderea incrementală a platformei prin adăugarea de noi module. Logica aplicativă este organizată în două straturi complementare: (1) stratul de rute, care implementează regulile de acces, validările de securitate și orientează fluxul execuției (verificarea sesiunii și a rolului, confirmarea apartenenței la clinică sau a proprietății asupra unui pacient), și (2) stratul de analiză EEG, care încapsulează algoritmii de prelucrare a semnalelor și extragerea caracteristicilor în module dedicate (de exemplu: *alpha_waves_analysis.py)* expuse prin interfețe stabile și reutilizabile. Această separare a responsabilităților crește coeziunea, testabilitatea și reutilizarea codului, asigurând totodată centralizarea consecventă a mecanismelor de autentificare și autorizare în stratul de rute, fără duplicarea logicii de securitate în componentele de analiză.

Modelele de ML și normalizatorul sunt încărcate o singură dată la inițializarea modulului (*scaler.joblib*, *mlp_model.joblib, rf_model.joblib*), reducând latența la inferență și evitând costuri repetitive de I/O. Persistența datelor este asigurată prin **SQLAlchemy ORM**; în *models.py* sunt definite explicit entitățile de bază (utilizator, clinică, subiect) și relația utilizator–clinică (user_clinic), împreună cu cheile, constrângerile și relațiile bidirecționale corespunzătoare. Formularele sunt descrise în *forms.py* folosind **Flask-WTF/WTForms**, ceea ce aduce validări coerente la nivel de câmp și **protecție CSRF** în fluxurile de creare/editare. Fluxul unei cereri HTTP urmează un traseu uniform. Utilizatorul interacționează cu UI-ul (formular, selector de clinică, încărcare fișier), iar browserul emite cererea către o rută din blueprintul asociat. La intrarea în rută, aplicația validează identitatea (existența unei sesiuni), rolul (privilegii administrative pentru operațiile de guvernanță), apartenența la clinică atunci când cererea poartă un *clinic_id*, respectiv dreptul de proprietate pentru resursele ce țin de pacienți. Odată validate aceste condiții, controlul este transferat către logica de domeniu: acces la stratul de persistență (ORM) pentru operații de citire/scriere, după caz declanșarea lanțului de prelucrare EEG și executarea inferenței modelelor. Răspunsul este apoi compus sub forma unui șablon Jinja2, la care se atașează datele necesare și mesajele de feedback. Această succesiune — interfață, validări, acces la date/ML, randare — garantează delimitarea riguroasă a straturilor de securitate, logică de domeniu, prezentare și blochează tentativele de acces neautorizat prin manipularea URL-urilor.

Stratul de persistență este realizat cu SQLAlchemy peste un motor relațional, pe un model de date minimal și riguros care reflectă regulile domeniului: **User**, **Clinic**, **Subject** și tabela de asociere N:M

user_clinic (Figura 6.6). Fiecare entitate are identitate stabilă (cheie primară numerică), iar legăturile sunt exprimate explicit prin chei externe, permițând SGBD-ului să impună integritatea referențială. Un subiect aparține întotdeauna unei singure clinici și are exact un proprietar (utilizatorul care l-a creat); relația utilizator–clinică este modelată de *user_clinic*, care exprimă explicit cardinalitatea N–M. Cheile externe *(subject.clinic_id → clinic.id, subject.user_id → user.id, respectiv user_clinic.user_id → user.id și user_clinic.clinic_id → clinic.id)* sunt declarate NOT NULL acolo unde logica interzice valori lipsă. Politicile de ștergere sunt restrictive și explicite: legăturile din *user_clinic* se curăță prin **ON DELETE CASCADE**, în timp ce Subject adoptă un comportament restrictiv (**RESTRICT/NO ACTION** aplicat la nivel de aplicație), prevenind eliminarea unei clinici care deține încă pacienți. Astfel, sistemul exclude stări imposibile (subiecți fără clinică, apartenențe duplicate) și mută consistența structurală în SGBD, unde poate fi aplicată uniform. Calitatea datelor este consolidată prin constrângeri de unicitate și validări de domeniu: *user.email* este unic (identificare neambiguă și fluxuri de autentificare simple), *user_clinic* are cheie primară compusă (*user_id*, *clinic_id*) (prevenind dublarea apartenențelor și făcând verificările de **membership** deterministe), iar **Subject** marchează câmpurile esențiale (*clinic_id*, *user_id*, *name*) ca NOT NULL. Atribute precum genul sau data nașterii sunt validate (enumerări/CHECK pentru gen; interdicția unei date de naștere din viitor). Schema este însoțită de o strategie de indexare aliniată cu traseele reale de interogare: index unic pe *user.email* (autentificare și administrare), index pe *clinic.name* (listare/sortare), exploatarea cheii compuse din *user_clinic* pentru interogări de apartenență și un index compus pe **Subject**(*user_id*, *clinic_id*, *last_name*, *first_name*) pentru fereastra **Pacienți**; opțional, indici pe **Subject**(*clinic_id* și *created_at*) pentru agregări și filtrări temporale, evitând supra-indexarea pentru a menține costurile de scriere sub control.

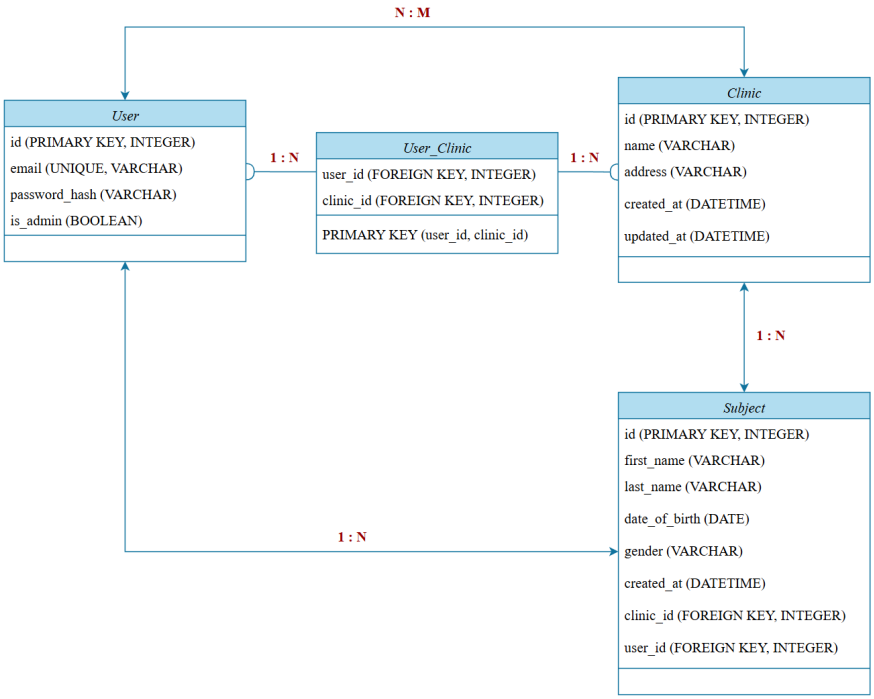


Figura 6.6 Diagrama ER a platformei EEG-Affect

Evoluția schemei este gestionată diferențiat pe medii. În dezvoltare, schema se regenerează integral cu *db.create_all()* pentru a susține iterații rapide; în producție, modificările sunt livrate prin migrații versionate (de exemplu: Alembic sau scripturi dedicate), aplicate incremental și cu posibilitate de *rollback*, acoperind operații precum adăugarea coloanelor *created_at/updated_at*, introducerea de indici sau ajustarea constrângerilor. Platforma include utilitare de inițializare/migrare (de tip *init_db.py*, *migrate_subjects.py*, scripturi pentru crearea administratorilor); pentru **SQLite** este recomandată activarea explicită a **PRAGMA foreign_keys** = ON, astfel încât politicile definite în cheile externe să fie efectiv impuse de motorul de baze de date. În modulele de rutare sunt folosite funcții utilitare precum *_is_member()* și *_current_user()* pentru a standardiza predicatele de apartenență și a concentra logica transversală, menținând rutele compacte și ușor de verificat. În ansamblu, arhitectura trasează o separare netă a responsabilităților, facilitează testarea izolată pe straturi și permite extinderea controlată a platformei (noi rute, entități sau clasificatori EEG) cu risc minim de regresii. Figura 6.7 prezintă fluxul de control al accesului: verificarea sesiunii, a rolului și a apartenenței la clinică.

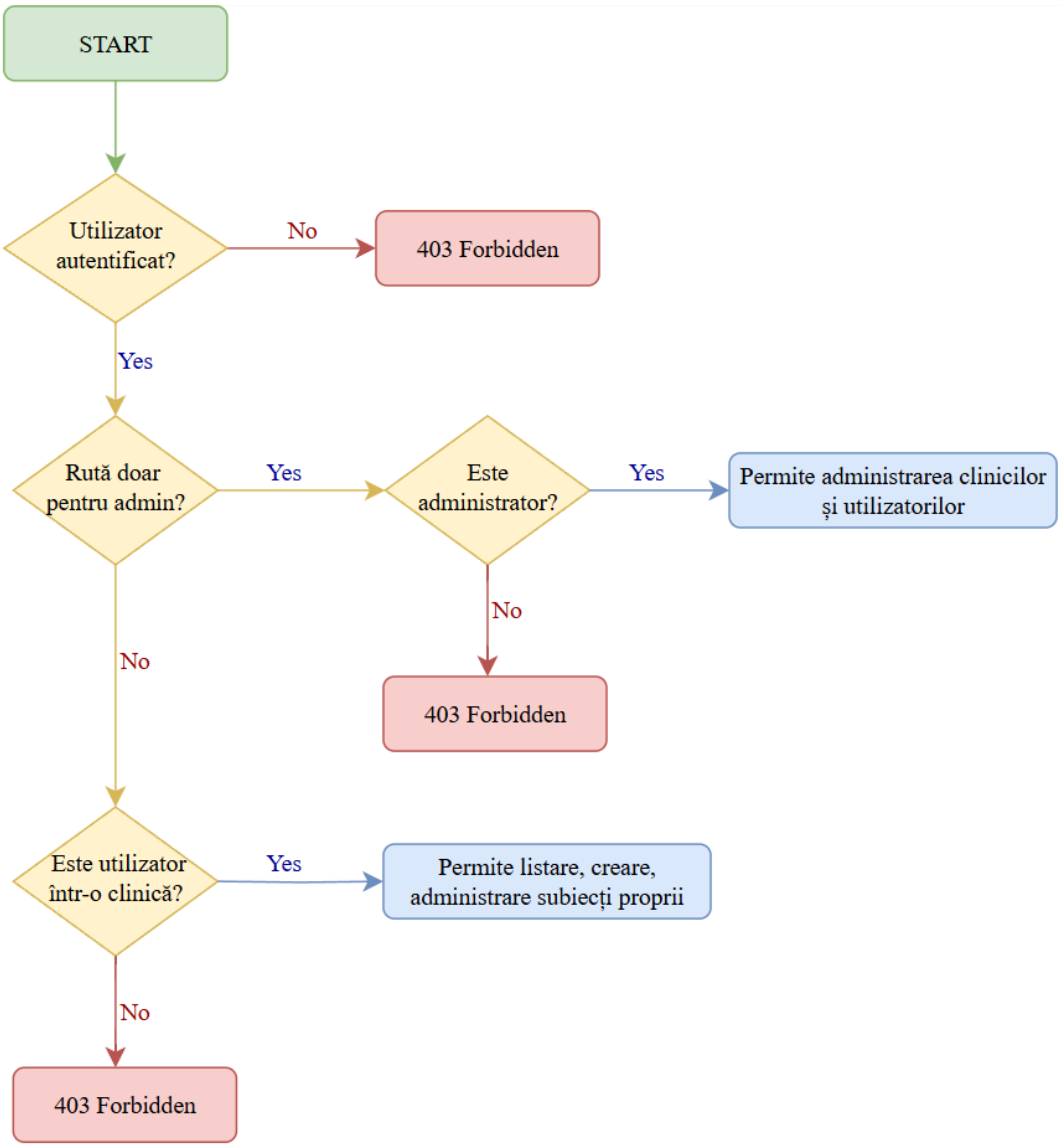


Figura 6.7 Fluxul de control al accesului în cadrul platformei EEG-Affect

6.3. Contul de administrator

Rolul de **administrator** are exclusiv responsabilități de guvernanță: configurarea clinicilor, gestionarea conturilor și apartenențelor, precum și întreținerea platformei. Administratorul **nu** are acces la date clinice (pacienți, fișiere cu date sau rezultate). În interfață, acest lucru se reflectă printr-o navigație redusă la secțiunile **Acasă**, **Clinici** și **Utilizatori**; itemul **Pacienți** nu este afișat – Figura 6.8. La nivel de server, toate rutele clinice (pacienți/clasificare) impun condiția de apartenență la clinică și proprietate, condiții pe care adminul nu le îndeplinește.

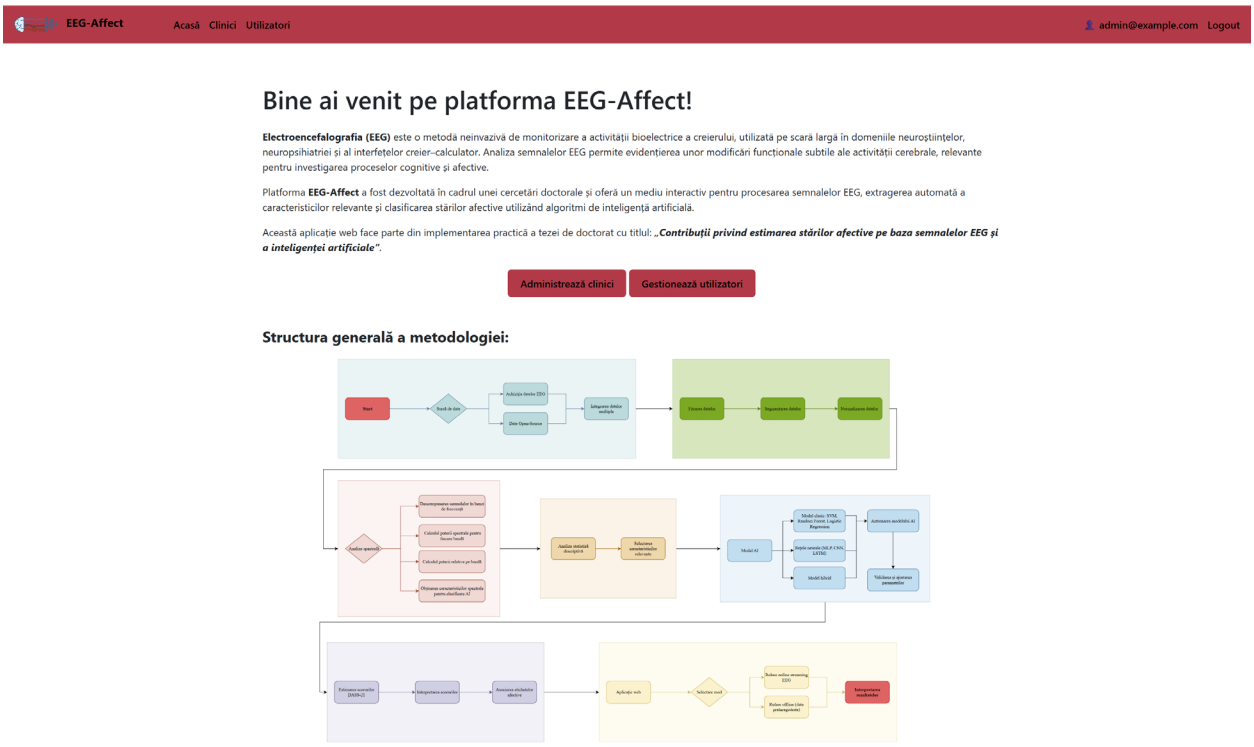


Figura 6.8 Panoul principal al administratorului din cadrul platformei EEG-Affect

Panoul principal al administratorului reprezintă fereastra de start afișată după autentificarea pentru un cont cu drepturi de **admin**. În partea superioară apare bara de navigare fixă, cu logo-ul **EEG-Affect**, secțiunile **Acasă**, **Clinici** și **Utilizatori**, precum și **identitatea utilizatorului (e-mail)** și **Logout**. Zona centrală conține titlul de bun-venit și un rezumat al scopului platformei, urmate de două acțiuni principale: **Administrează clinici** (deschide lista, de unde administratorul poate crea/edita/șterge clinici și gestiona apartenențele utilizatorilor) și **Gestionează utilizatori** (creează conturi noi, editează e-mail/rol, resetează parola, poate activa/dezactiva conturi). Sub aceste butoane este prezentată, în scop informativ, schema metodologică a fluxului de date.

Secțiunea **Clinici** (Figura 6.9) oferă o vedere globală asupra organizațiilor configurate în sistem. Pentru fiecare clinică se afișează numele și adresa, iar pentru administrator apar acțiuni explicite: **Editează**, **Membri** și **Șterge**. Crearea/actualizarea clinicilor se face prin formulare cu *validări server-side* (nume obligatoriu; adresă opțională). Ștergerea este protejată de o confirmare prealabilă și este permisă doar dacă în clinică nu există pacienți; în caz contrar, serverul refuză operația cu un **mesaj explicativ**.

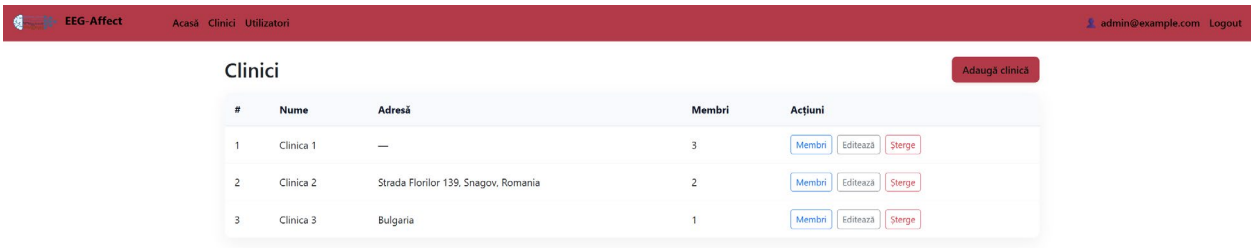


Figura 6.9 Fereastra de administrare a clinicilor

Formularul **Creare clinică** (Figura 6.10) este disponibil exclusiv administratorului și conține două câmpuri simple: **Nume clinică** (obligatoriu) și **Adresă** (opțional). La trimitere, cererea **POST** este validată și, dacă reușește, clinica este salvată, se afișează un mesaj de confirmare și utilizatorul este redirecționat la lista de clinici. Ruta este protejată prin verificarea rolului de admin și CSRF. De menționat este faptul că dacă numele clinicii introduse există deja (verificare case-insensitive), formularul este respins și se afișează mesajul de eroare **„Există deja o clinică cu acest nume.”** (Figura 6.11), iar înregistrarea nu este creată.



Figura 6.10 Fereastra de adăugare a unei noi clinici

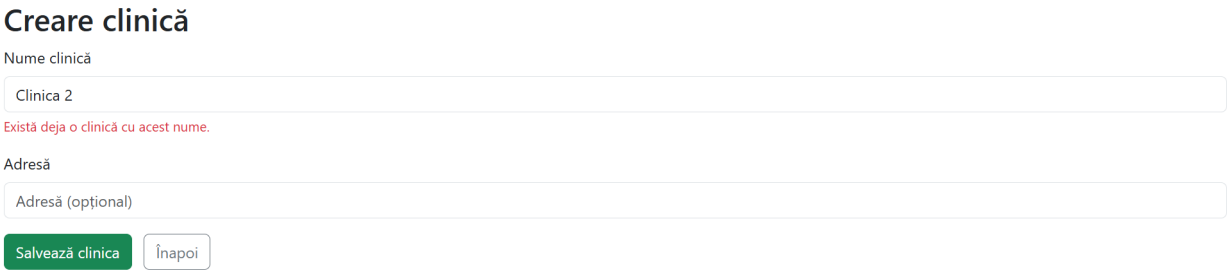


Figura 6.11 Mesajul care apare atunci când o clinică există deja

Formularul de editare a unei clinic – Figura 6.12 permite administratorului să modifice metadatele unei clinici: **Nume clinică** (obligatoriu) și **Adresă** (opțional). Acțiunile disponibile sunt **Salvează clinica** (persistă modificările) și **Înapoi** (revine la lista de clinici). Validările se fac atât în formular (obligatoriu), cât și pe server.



Figura 6.12 Fereastra de editare a unei clinici

Figura 6.13 prezintă membrii dintr-o clinică, unde **doar administratorul** gestionează apartenențele utilizatorilor la o clinică. În partea de sus există un **selector cu toate conturile** și butonul **„Adaugă membru”**; la trimitere se creează legătura în tabela *user_clinic* (sunt prevenite dublurile și se afișează un mesaj). Tabelul listează membrii existenți (email) și oferă acțiunea **„Elimină”**, care **dezactivează apartenența** (șterge rândul din *user_clinic*) fără a afecta contul de utilizator. Fluxul este protejat prin verificarea rolului de admin și CSRF; la reușită/eroare se afișează mesaje de feedback.

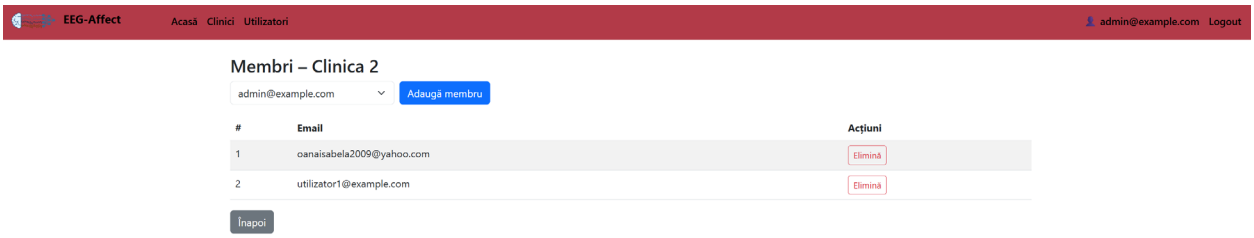


Figura 6.13 Fereastra cu membrii existenți într-o clinică

Figura 6.14 prezintă pagina de ștergere a unei clinici. Înaintea ștergerii, platforma afișează o pagină de **confirmare ireversibilă**, cu detalii despre clinică (nume, adresă) și **numărul de membri și pacienți**. Dacă există **cel puțin un pacient înregistrat**, operația este **blocată**: apare mesajul de avertizare *„Clinica nu poate fi ștearsă cât timp există pacienți înregistrați”*, iar la trimiterea formularului serverul respinge cererea (POST) și cere administratorului să vorbească cu un membru al clinicii să **transfere sau să șteargă pacienții** mai întâi. Doar când numărul de pacienți este zero, ștergerea reușește: se elimină automat legăturile din tabela de asociere *user_clinic*, se șterge clinica din clinic, iar utilizatorul primește un mesaj de confirmare. Acțiunea este disponibilă **exclusiv administratorului** și este protejată prin **CSRF și validări server-side**.

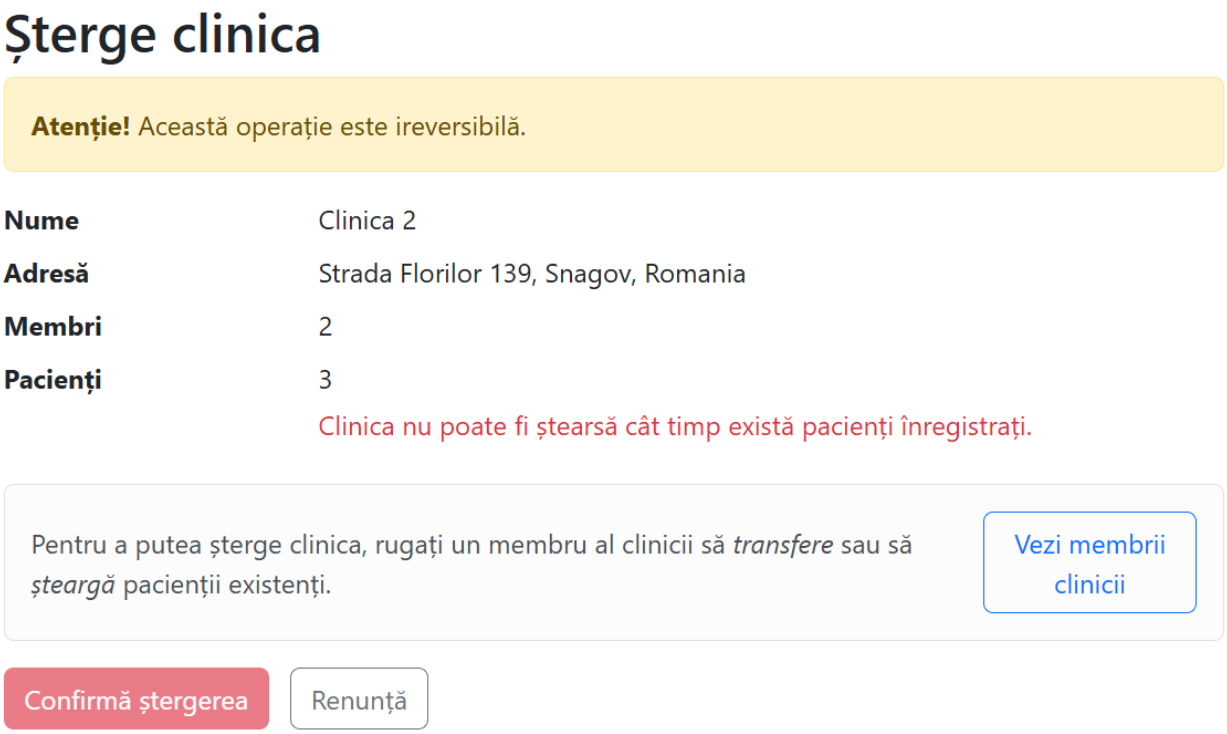


Figura 6.14 Fereastra de ștergere a unei clinici

În secțiunea **Utilizatori** (Figura 6.15), vizibilă doar administratorului, sunt listate toate conturile cu coloanele *Email*, *Admin* (DA/NU) și *Acțiuni*. Din butonul **„Editează”** se pot schimba e-mailul, parola (opțional la editare), promova/depromova la rol de admin și seta clinicile în care utilizatorul are acces – Figura 6.16. Butonul **„Șterge”** declanșează fluxul de eliminare care, dacă utilizatorul are pacienți, solicită mai întâi **realocarea** acestora către un alt proprietar, iar abia apoi curăță apartenențele N:M din *user_clinic* – Figura 6.18. În partea de jos, **„Adaugă utilizator nou”** deschide formularul de creare – Figura 6.17. Imaginea arată exact această listă cu acțiunile disponibile pe fiecare rând și butonul global de adăugare, ilustrând rolul de guvernanță al administratorului asupra conturilor și apartenențelor la clinici.

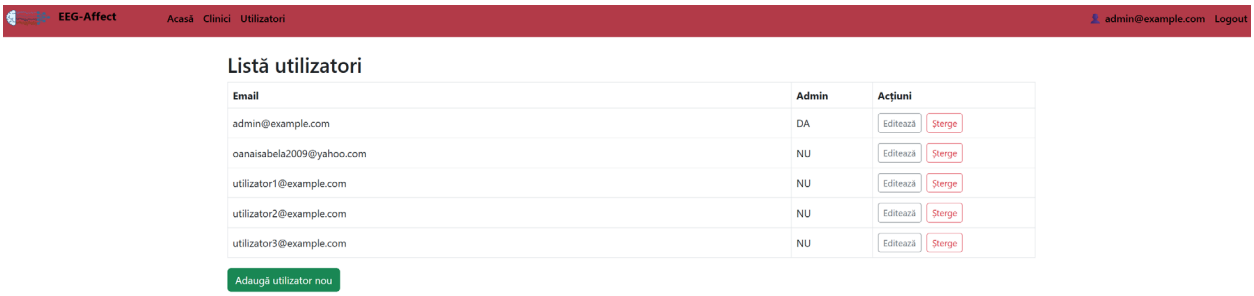


Figura 6.15 Secțiunea de administrare a utilizatorilor

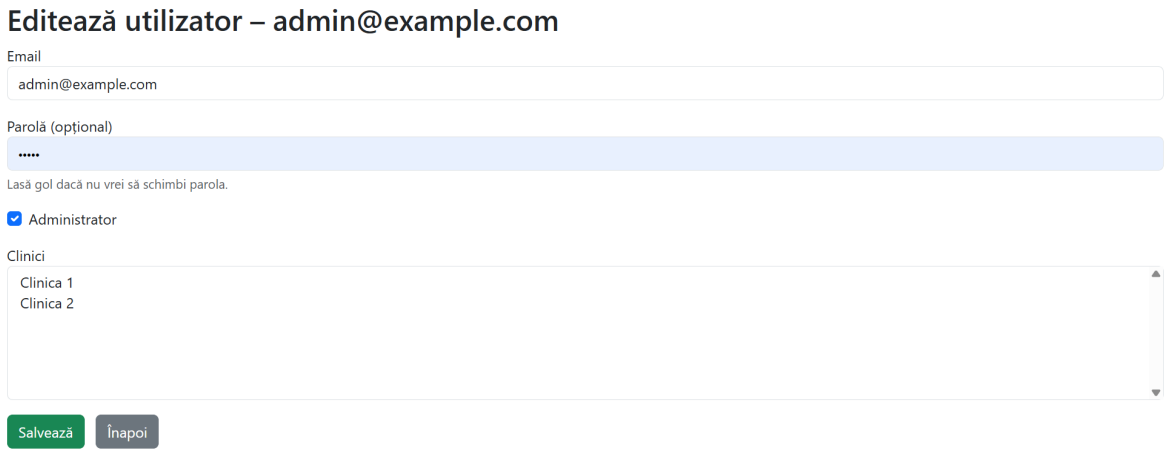


Figura 6.16 Fereastra de editare a utilizatorilor

Secțiunea de adăugarea a unui nou utilizator conține două câmpuri esențiale – **Email** și **Parolă** – urmate de butonul **Salvează**. La trimitere, serverul validează formatul adresei, unicitatea email-ului și o parolă minimă (≥ 6 caractere); dacă validările reușesc, contul este creat, iar alocarea la clinici și setarea rolului se fac ulterior din ecranul de editare. Formularul este protejat cu CSRF, iar erorile (de exemplu: email deja folosit) apar contextual sub câmpul relevant.

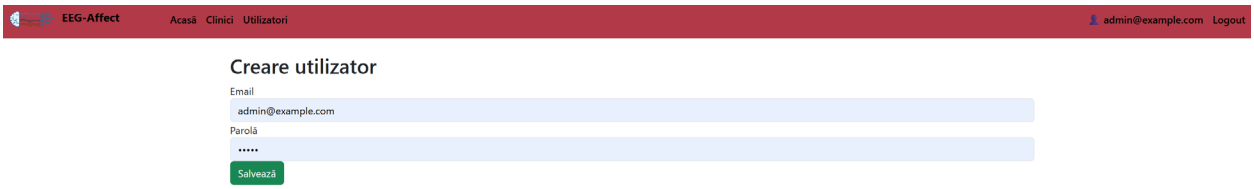


Figura 6.17 Fereastra de adăugare a unui nou utilizator

Ecranul **„Ștergere utilizator”** afișează un avertisment clar cu adresa contului ce urmează a fi eliminat și numărul de pacienți pe care îi deține, apoi cere în mod obligatoriu alegerea unui **„Nou proprietar”** dintr-o listă pentru **realocarea pacienților**. După ce se selectează noul proprietar, butonul **„Confirmă ștergerea și realocarea”** transferă toți pacienții către utilizatorul ales și abia apoi șterge contul, păstrând integritatea datelor; butonul **„Renunță”** revine fără modificări. Formularul este protejat cu CSRF, iar la confirmare se fac validări (existența noului proprietar și apartenențile la clinicile relevante), urmate de un mesaj de succes și curățarea apartenențelor N:M ale utilizatorului șters.

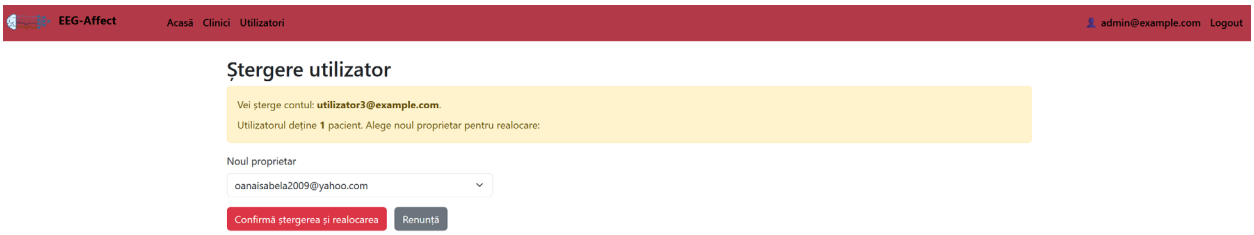


Figura 6.18 Ștergere utilizator cu realocarea pacienților către un nou proprietar

6.4. Contul de utilizator

Contul de **utilizator** deservește activității clinice propriu-zisă. După autentificare, interfața expune navigația **Acasă**, **Clinici** și **Pacienți** (ultimul item apare numai dacă utilizatorul este membru în cel puțin o clinică). În absența apartenențelor, aplicația afișează un mesaj de informare și ascunde funcțiile clinice până la asocierea contului cu o clinică (operație realizată de administrator). Secțiunea **Acasă** a utilizatorului afișează un mesaj de bun-venit și un rezumat al platformei, împreună cu o navigație adaptată rolului. În centru există un buton de acțiune „**Începe analiza EEG**” care conduce în fluxul clinic de încărcare și clasificare. Sub introducere este prezentată **structura generală a metodologiei** prin diagrame care sintetizează platforma EEG-Affect (prelucrare, extragere de caracteristici, modele și interpretare), oferind context rapid pentru utilizator.

Secțiunea **Clinici** afișează **doar** clinicile din care face parte utilizatorul, într-un tabel compact cu **Nume**, **Adresă** și un indicator „**Pacienți activi**” care reprezintă **numărul pacienților proprii** ai utilizatorului în fiecare clinică. Informațiile sunt strict **read-only** pentru utilizatorul clinic: **acțiunile administrative** (vizualizare membri, editare, ștergere) **nu apar** în interfață, ceea ce întărește separarea responsabilităților față de rolul de administrator.
La nivel de server, lista este obținută printr-un **JOIN pe tabela de asociere** *user_clinic*, filtrată după *session['user_id']*, iar **indicatorul de pacienți** este calculat printr-un **GROUP BY (clinic_id)** condiționat de *user_id* (numără doar subiecții deținuți de utilizator în clinicile sale). Astfel, chiar dacă un URL este manipulat manual, utilizatorul **nu poate vedea** alte clinici și **nu poate divulga** metadate despre ele.

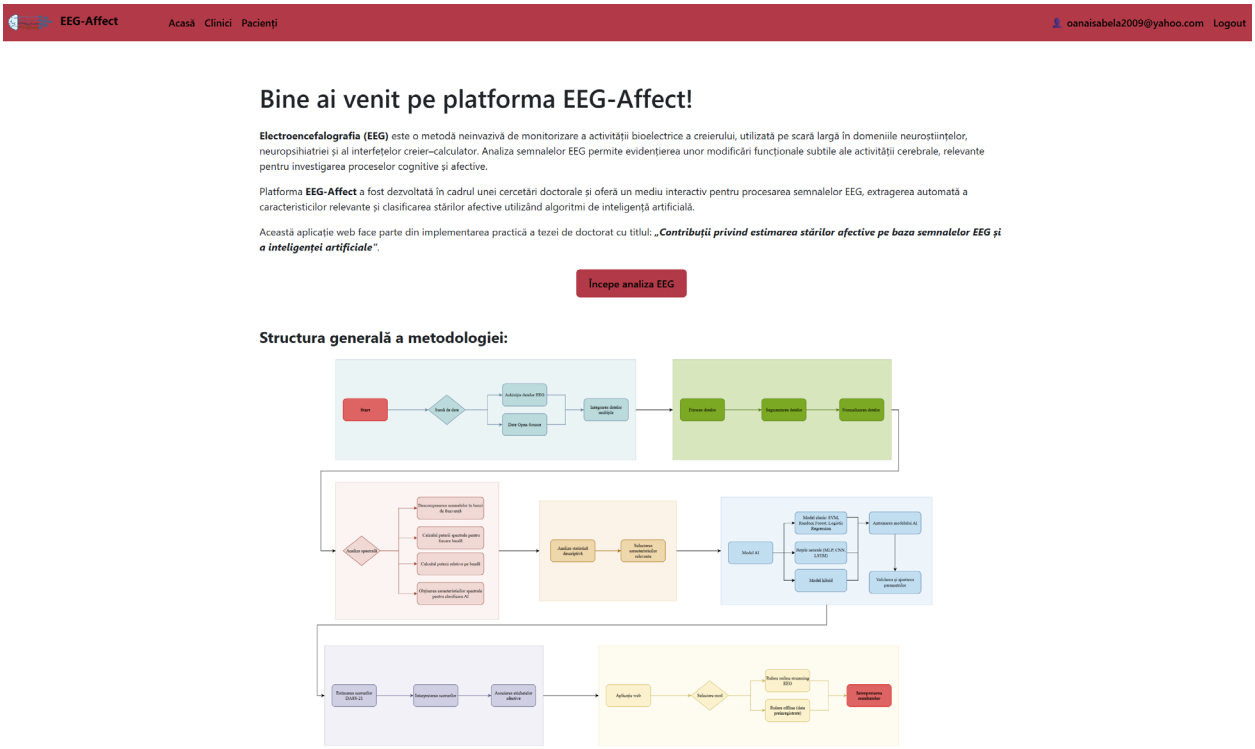


Figura 6.19 Panoul principal al utilizatorului din cadrul platformei EEG-Affect

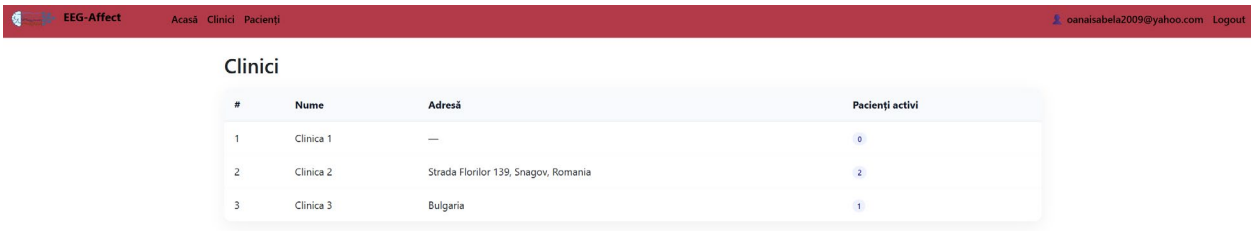


Figura 6.20 Clinicile de care aparține un utilizator

Secțiunea **Pacienți** deservește fluxurile clinice de zi cu zi ale utilizatorului – Figura 6.21. Lista afișată este întotdeauna filtrată de **clinica activă**, aleasă dintr-un selector de context; schimbarea clinicii reactivează filtrarea la nivel de interogare, astfel încât utilizatorul vede exclusiv **pacienții proprii** din acea clinică. Delimitarea vizibilității este strictă: toate acțiunile de tip POST revalidează pe server *clinic_id* și **proprietatea** asupra resursei, împiedicând forțări prin URL și accesul la date care nu aparțin utilizatorului.

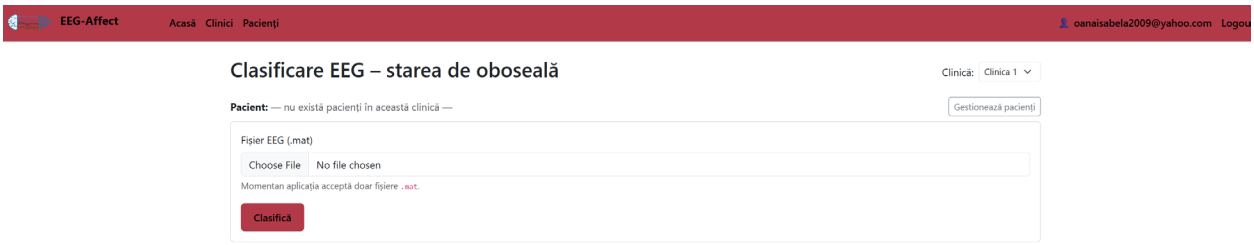


Figura 6.21 Secțiunea Pacienți din cadrul platformei EEG-Affect

Figura 6.22 prezintă fereastra „**Pacienții mei**”, unde sunt afișați doar pacienții deținuți de utilizator în **clinica activă**. Tabelul include coloanele *Nume*, *Data nașterii*, *Gen* (M/F/Nespecificat) și *Clinică* (denumirea clinicii), urmate de *Acțiuni*. În dreptul fiecărui pacient există butoanele **Editează** – Figura 6.23 și **Șterge**; ștergerea cere confirmare și este permisă numai proprietarului în cadrul clinicii selectate (regulă verificată din nou pe server). În partea de sus, butonul **Adaugă pacient** deschide formularul de creare – Figura 6.24, iar după salvare lista se actualizează filtrat pe clinica curentă. Interfața ascunde orice funcționalități care nu se aplică utilizatorului, iar rutele de pe server revalidează *clinic_id* și **proprietatea** la fiecare operație POST, prevenind accesul neautorizat prin URL.



Figura 6.22 Fereastra „Pacienții mei” din cadrul platformei EEG-Affect

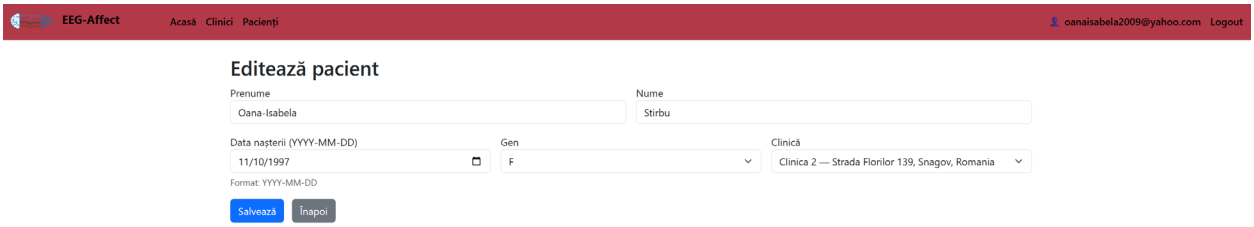


Figura 6.23 Formular de editare pacient cu selectorul de clinică și validări la salvare

Formularul **„Adaugă pacient”** permite înregistrarea rapidă a unui pacient nou, cu câmpuri pentru **Prenume**, **Nume**, **Data nașterii** (selector de dată), **Gen** (listă restrânsă de valori) și **Clinică** (doar din clinicile în care utilizatorul este membru). Butonul **Salvează** trimite un POST protejat CSRF; la nivel de server se verifică obligatoriu câmpurile esențiale, faptul că data nu este în viitor, precum și apartenența utilizatorului la clinica selectată. Butonul **Înapoi** revine la lista pacienților fără a face modificări.

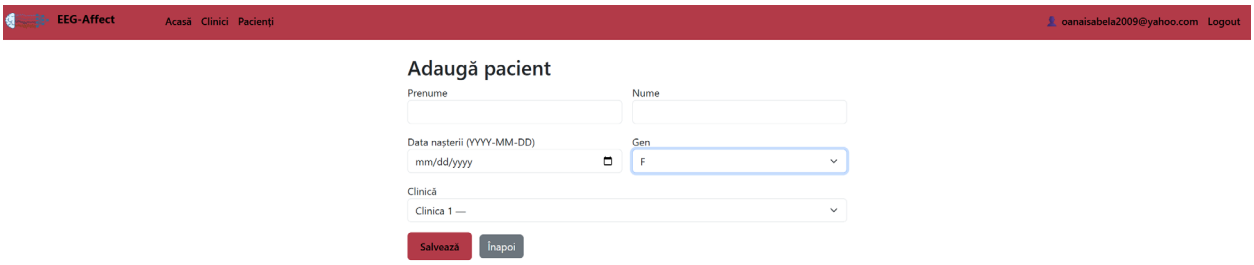


Figura 6.24 Formular de adăugare a unui nou pacient

Interfața de clasificare permite selectarea **clinicii active** și a **pacientului** (din lista proprie), încărcarea unui fișier EEG și lansarea procesării prin acțiunea **Clasifică**. După încărcare, aplicația declanșează automat pipeline-ul: **încărcarea semnalului**, **extragerea caracteristicilor**, **normalizarea** și apoi rulează **etapa de predicție** cu modelele încărcate la inițializarea serverului (un **MLP** și un **Random Forest**, pentru latență minimă). Rezultatele sunt afișate ca **bare de progres** cu scoruri normalizate în intervalul **[0, 1]**; depășirea pragului configurat (implicit **0,50**) activează o **evidențiere vizuală** și un **mesaj de atenționare**. Validările de fișier (format, dimensiune, integritate) și tratarea erorilor produc mesaje explicite, fără a întrerupe sesiunea curentă. Din perspectivă de securitate, pagina moștenește toate regulile RBAC descrise anterior: utilizatorul vede doar pacienții **proprii** din clinicile în care are **apartenență**, iar toate acțiunile *POST* revalidează pe server atât *clinic_id*, cât și **proprietatea** asupra resursei (principiile *least privilege* și *defense-in-depth*).

După cum se poate observa scorurile furnizate de **MLP** și **Random Forest** diferă pentru că cele două modele au arhitecturi distincte (vezi Capitolul 4). O rețea neuronală tip **MLP** tinde să producă scoruri mai „continue” și uneori mai extreme, fiind sensibilă la scalarea și corelațiile dintre trăsături. În schimb, **Random Forest** este de regulă mai robust la valori atipice și întoarce scoruri mai **moderate**, deoarece predicția finală rezultă din **agregarea** (vot majoritar sau mediere) răspunsurilor unui număr mare de arbori. Diferențele vizibile în figurile de mai jos (de exemplu: MLP = 0,95; RF = 0,67) reflectă tocmai aceste proprietăți complementare. Din perspectivă operațională, o politică prudentă este să semnalăm alertă dacă oricare dintre modele depășește pragul configurat; pragurile și modul de combinare (media, maximul sau o regulă de alertare) se pot calibra în funcție de obiectivele clinice și de raportul sensibilitate–specificitate dorit. Aspectele privind calibrarea probabilităților estimate, precum și selecția și interpretarea metricilor de evaluare sunt prezentate în detaliu în Capitolul 4.



Figura 6.25 Interfața de clasificare EEG – caz cu alertă (scoruri ridicate)

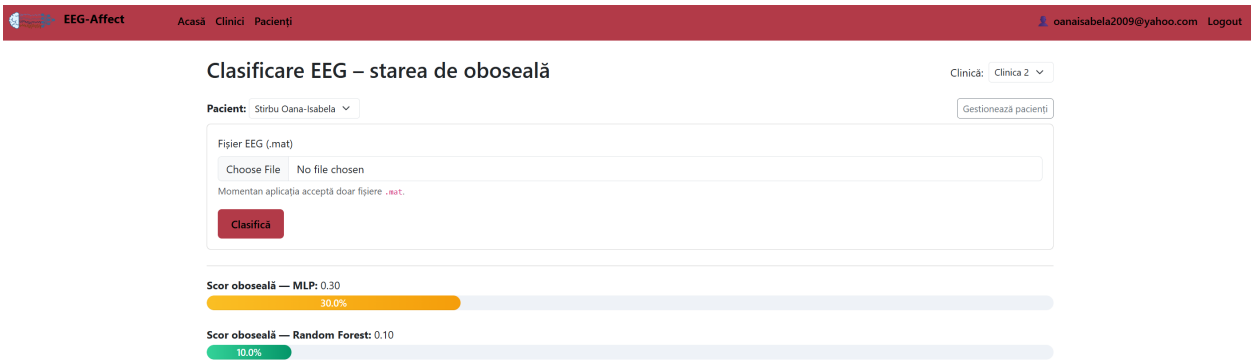


Figura 6.26 Interfața de clasificare EEG – scoruri intermediare (fără alertă)



Figura 6.27 Interfața de clasificare EEG – scoruri foarte mici (fără alertă)

Bibiliografie

[1] J. Singh, S. Rani, and V. Kumar, “Role-Based Access Control (RBAC) Enabled Secure and Efficient Data Processing Framework for IoT Networks,” *Int. J. Commun. Netw. Inf. Secur. IJCNIS*, Aug. 2024, doi: 10.17762/ijcnis.v16i2.6697.